

# 基于卷积神经网络的多导联心电图自动分类 方法研究



## 重庆大学硕士学位论文 (专业学位)

学生姓名：杜高飞

指导教师：米德伶 教授

专业学位类别：工程（光学工程）

研究方向：心电图自动分类

答辩委员会主席：毛本将 研究员

授位时间：2019 年 5 月 26 日

# **Research of Automatic Classification Method for Multi-lead ECG based on Convolution Neural Network**



A Dissertation Submitted to Chongqing University  
In Partial Fulfillment of the Requirement for the  
Professional Degree

**By**

**Du Gaofei**

**Supervised by Prof. Mi Deling**

**June, 2019**

## 摘 要

随着人们生活的节奏日益加快以及人们精神压力的陡增,诱发了心脏类疾病已成为对人体健康构成重大威胁的常见疾病。心电图是现代医院对心脏类疾病基本常规诊疗技术之一,可以为临床医生诊疗提供重要参考。

然而,传统心电图自动分类的研究,多聚焦于心拍类型的分类,虽然在测试集上精度很高,但实际临床效果很差,最终诊断仍需医生手工完成,说明心拍分类并不十分可行,误诊或误判时有发生,影响了对心脏类疾病的治疗。

近年来,以卷积神经网络为代表的深度学习方法在图像分类处理领域成果显著,为此,本文借鉴其在自动特征提取和分类准确率方面的优势,围绕基于卷积神经网络的多导联心电图自动分类方法展开了研究工作,研究内容主要包括:

①开展了多导联心电数据预处理方法研究。采用 ICBEB 心电数据库,包含了 6877 例心电数据,每个记录都来自临床不同患者的 12 导联心电数据。为了提高分类识别效果,针对心电数据采集中存在的基线漂移、肌电干扰、工频干扰等几类噪声,分别设计相应的滤波器加以滤除。

②开展了基于 Resnet50 网络的多导联心电图自动分类研究。与传统心电图自动分类中先设计特征提取算法再分类识别这一流程不同,研究中采用了卷积神经网络中的 Resnet50 网络对多导联心电图数据进行深度神经网络学习,自动提取心电图特征,并将其与分类过程融合在一起,最终拟合出决策函数对心电图进行自动分类,实现了对包括正常心律(Normal)在内、心房颤动(AF)、一级房室传导阻滞(I-AVB)、左束支传导阻滞(LBBB)、心室早发性收缩(PVC)、右束支传导阻滞(RBBB)、ST 段压低(STD)、房性期前收缩(PAC)、ST 段抬高(STE)等临床常见 9 种心律失常的分类,获得了所有指标平均  $F1=0.7$ ,部分异常指标  $F1=0.85$  的实验结果。

③开展了基于膨胀卷积的 Resnet 网络优化及心电图自动分类研究。在 Resnet 残差网络结构的基础上,针对 12 导联心电序列数据高维度的特点,研究了通过改进膨胀卷积模块以增加感受野,减少网络层数,优化损失函数,改进网络训练步骤等优化措施,并在 ICBEB 心电数据集上进行测试。实验结果表明,优化模型分类准确率可达 80%,9 种心律类别评价指标  $F1=0.74$ ,相比未优化网络性能有明显的提升。

**关键词:** 多导联心电图; ICBEB 心电数据库; 心律失常; 卷积神经网络; Resnet50

## Abstract

With the rapidly development of human society and economy, the rhythm of people's life is accelerating, causing people's mental stress to increase sharply, and the induction of heart disease has become a common disease that poses a major threat to human health. Electrocardiogram is one of the basic routine diagnosis and treatment techniques for heart diseases in modern hospitals, which can provide important reference for clinicians.

However, the research on the automatic classification of traditional electrocardiogram focuses on the classification of heart beat type. Although the accuracy of the test set is very high, the actual clinical effect is very poor. The final diagnosis still needs to be done manually by the doctor, indicating that the heart beat classification is not very feasible. Misdiagnosed and misjudgment occurs, which affects the treatment of heart disease.

In recent years, the deep learning method represented by convolutional neural network has achieved remarkable results in the field of image classification processing. For this reason, this paper draws on its advantages in automatic feature extraction and classification accuracy, and focuses on multi-lead based on convolutional neural network. The electrocardiogram automatic classification method has carried out research work, and the research content mainly includes:

① Research on preprocessing method of multi-lead ECG data. The ICBEBC ECG database was used to contain 6877 ECG data, each of which was derived from 12-lead ECG data from different clinical patients. In order to improve the classification and recognition effect, for the types of noise such as baseline drift, myoelectric interference and power frequency interference existing in ECG data acquisition, corresponding filters are designed to filter out.

② Research on Automatic Classification of Multi-lead ECG Based on Resnet50 Network. Different from the traditional ECG automatic classification, the design feature extraction algorithm is different from the classification process. In the research, the Resnet50 network in the convolutional neural network is used to perform deep neural network learning on the multi-lead ECG data, and the ECG features are automatically extracted. It is fused with the classification process, and finally the decision function is fitted to automatically classify the electrocardiogram, which includes normal heart

rhythm (Normal), atrial fibrillation (AF), and primary atrioventricular block (I-AVB). ), left bundle branch block (LBBB), ventricular early-onset contraction (PVC), right bundle branch block (RBBB), ST-segment depression (STD), atrial premature contraction (PAC), ST-segment elevation High (STE) and other clinical arrhythmia classification, obtained the average  $F1 = 0.7$ , and some abnormal indicators  $F1 = 0.86$ .

③ Resnet network optimization based on expanded convolution and automatic classification of electrocardiogram. Based on the Resnet residual network structure, the characteristics of the high-dimensionality of 12-lead ECG data are studied. By improving the expansion convolution module to increase the receptive field, reduce the number of network layers, optimize the loss function, and improve the network training steps. Optimize measures and test on the ICBEB ECG dataset. The experimental results show that the classification accuracy of the optimized model can reach 80%, and the evaluation index of 9 kinds of heart rhythm categories is  $F1=0.74$ , which is obviously improved compared with the unoptimized network performance.

**Key words:** Multi-lead ECG; ICBEB ECG database; Arrhythmia; Convolutional Neural Network; Resnet50

## 目 录

|                               |    |
|-------------------------------|----|
| 中文摘要.....                     | I  |
| 英文摘要.....                     | II |
| 1 绪 论.....                    | 1  |
| 1.1 课题研究背景及意义.....            | 1  |
| 1.2 国内外研究现状.....              | 1  |
| 1.2.1 心电图去噪预处理.....           | 2  |
| 1.2.2 心电图特征提取和分类.....         | 3  |
| 1.2.3 基于卷积神经网络的心电图自动分类.....   | 5  |
| 1.3 存在的问题.....                | 5  |
| 1.4 本文主要研究内容和章节安排.....        | 6  |
| 2 心电图与卷积神经网络.....             | 7  |
| 2.1 引言.....                   | 7  |
| 2.2 基本心电知识.....               | 7  |
| 2.2.1 心电图的产生.....             | 7  |
| 2.2.2 心电导联系统.....             | 8  |
| 2.2.3 正常心电图典型波形及特点.....       | 9  |
| 2.2.4 心律失常分类.....             | 10 |
| 2.3 心电图数据库.....               | 11 |
| 2.3.2 四大标准心电图数据库.....         | 11 |
| 2.3.3 ICBE 心电图数据库.....        | 12 |
| 2.4 卷积神经网络理论基础.....           | 13 |
| 2.4.1 人工神经网络.....             | 14 |
| 2.4.2 卷积神经网络特性.....           | 17 |
| 2.4.3 卷积神经网络操作.....           | 18 |
| 2.5 本章小结.....                 | 20 |
| 3 基于 Resnet 模型的心电图自动分类研究..... | 21 |
| 3.1 引言.....                   | 21 |
| 3.2 Resnet 网络模型.....          | 21 |
| 3.3 实验平台与评价指标.....            | 25 |
| 3.3.1 实验平台.....               | 25 |
| 3.3.2 评价指标.....               | 25 |

|                                 |    |
|---------------------------------|----|
| 3.4 ICBEb 心电图数据集预处理.....        | 26 |
| 3.4.1 心电图去噪.....                | 26 |
| 3.4.2 数据集划分与归一化.....            | 29 |
| 3.5 ICBEb 心电数据集实验.....          | 31 |
| 3.5.1 数据读取与转换.....              | 31 |
| 3.5.2 网络训练.....                 | 32 |
| 3.5.3 实验结果及分析.....              | 33 |
| 3.6 本章小结.....                   | 36 |
| 4 基于 Resnet 优化模型的心电图自动分类研究..... | 37 |
| 4.1 引言.....                     | 37 |
| 4.2 网络模型优化.....                 | 37 |
| 4.2.1 网络卷积模块优化.....             | 37 |
| 4.2.2 损失函数.....                 | 41 |
| 4.3 网络训练.....                   | 41 |
| 4.4 实验结果及分析.....                | 42 |
| 4.4.1 不同超参数值的模型分类.....          | 42 |
| 4.4.2 不同卷积核大小的模型分类.....         | 44 |
| 4.5 本章小结.....                   | 45 |
| 5 总结与展望.....                    | 46 |
| 参考文献.....                       | 48 |
| 附    录.....                     | 52 |
| A. 学位论文数据集.....                 | 52 |
| 致    谢.....                     | 53 |

## 1 绪 论

### 1.1 课题研究背景及意义

心脏类疾病是具有高患病率、高致残率和高死亡率特点的严重威胁人类生命健康的疾病，是致死人数最多的疾病。据统计，2008 年超过 1800 万人死于心脏类疾病，预计到 2030 年这一数字将会超过 2200 万人，占全世界总死亡人数的 35%<sup>[1]</sup>。在中国，心脏类疾病的发病率也在逐年增加，每天因患心脏类疾病而死亡的人数约为 9590，占总死亡原因致死人数的 41%。如果不对心脏疾病发病加以控制，全国因此类疾病而死亡的人数在 2030 年会增加 770 万<sup>[2]</sup>。由于心脏类疾病具有起病急、发展快的特点，及时有效的预防和诊断对降低死亡率、拯救患者生命有非常重要的意义。实际上，心律失常往往是心脏类疾病发生的重要征兆和表现。心电图可以实时反映心脏活动，因此可以通过心电图表现分析心律失常，进而预防和诊断心脏类疾病。

心电图（ECG-Electrocardiogram）是 1885 年荷兰生理学家 W.Einthoven 首次使用毛细静电计从人体体表记录得到。心电图具有方便易行、无创伤、随时随地可进行等优势，广泛应用于内、外、妇、儿等科室以及重症监护、危重病人抢救等。在临床实际操作中，传统的心电图分析由医生通过观察心电图波形并结合大量心脏领域现有的相关知识以及多年积攒的临床经验来对患者的病症做出诊断，而医生资源又是相当稀缺匮乏。因此，依靠传统的人工诊断心电图，效率相对较低，也容易因为医生水平参差不齐导致误判误诊而发生医疗事故。综合以上因素，研究心电图自动分类诊断的技术则可以很好的提高工作效率，缓解医疗资源短缺的压力。

然而，由于心电信号强度一般比较微弱，多为 mV 量级，频率低，抗干扰能力差，容易受到肌电，呼吸，工频等来自多方面的干扰。同时心脏疾病领域的知识理论抽象复杂，目前一些已经在临床上应用的心电图自动诊断技术，其诊断误差大，准确率低，只具有参考辅助作用，实际临床诊断仍需要专业医生。因此，心电图的自动诊断分类方法仍然是一个需要不断完善的研究工作。目前，心电图自动分类诊断方法的研究是医疗领域一个热点，而如何在现有基础上进一步提升其诊断精度，提高医生工作效率，对人类的生命健康具有相当重要的意义。

### 1.2 国内外研究现状

通过大量学者的研究，心电图的自动分类方法基本成熟。其研究过程主要可以总结为四个部分。图 1.1 为基本流程图，本节中将主要介绍心电图预处理、心电图



特征提取、心律失常分类的研究现状。




图 1.1 心电信号分类流程图

Fig.1.1 ECG signal classification flow chart

### 1.2.1 心电图去噪预处理

心电图作为重要的临床诊断依据，为了能够充分的利用它，必须对其进行有效的记录和处理，以便医师能够准确的分析患者的病情。而在心电图采集的过程中会受到噪声的干扰，有效的去除和抑制这些干扰是心电图后续处理的重要前提。

心电信号中，常见的噪声干扰有：基线漂移、肌电干扰、工频干扰等。由于病人的呼吸或移动会导致身体与电极间出现接触问题，引起电阻的变化进而导致心电信号的幅值和频率改变，这种干扰称为基线漂移<sup>[3]</sup>。心电图中表现为缓慢变化的曲线，频率范围为  $0.05\sim 2\text{Hz}$ 。如图 1.2 所示。




图 1.2 基线漂移

Fig.1.2 Baseline drift

肌电干扰是由于病人移动引起骨骼肌收缩导致的。在压力测试中常出现较大的干扰。例如在跑步机上就会出现剧烈的肌肉紧张而出现较大的肌电干扰。另外，环境温度的高低变化也会引起肌肉的收缩进而导致干扰的出现。这种现象通常不容易察觉，但会带来体表几微伏的电位变化。这些干扰带来的最大问题是干扰信号通常和心电信号交叠在一起，心电信号的频率变化范围为  $0.05\sim 150\text{Hz}$ ，而干扰信号的范围为  $20\sim 80\text{Hz}$ 。常见此类类肌电干扰，如图 1.3 所示。



图 1.3 肌电干扰

Fig.1.3 Myoelectric interference

工频干扰是在采集系统的供电过程中出现的电磁效应引起的,也可能由周围其他的电气装置引起。工频干扰的频率范围较小,通常取决于交流供电系统的频率,其变化范围为 50~60Hz。这类的干扰相对容易滤除。常用低频带阻滤波器来抑制此类噪声干扰。常见此类干扰,如图 1.4 所示。



图 1.4 工频干扰

Fig.1.4 Power frequency interference

心电信号的预处理方法的主要目的是为了去除叠加在心电信号上的噪声,从而便于对心电信号进行特征提取、特征分析和类型分类等<sup>[4]</sup>。预处理方法主要可以分成三类,即基于滤波器技术的预处理<sup>[5]</sup>、基于小波变换的预处理<sup>[6]</sup>和基于经验模态分解的预处理<sup>[7]</sup>。

基于滤波器技术的预处理方法主要是根据不同噪声对应的频率响应设计滤波器去除噪声。

基于小波变换的预处理根据频域内信号和噪声的不同分布,将信号进行多尺度小波变换,提取信号的小波系数,滤除噪声的小波系数,再根据小波逆变换将滤除噪声后的信号重构。

基于经验模态分解的预处理通过经验模态分解,高频噪声、基线漂移噪声和有效心电信号能够分别被分配到各自的本征模态函数。经验模态分解法可以减小高频噪声和基线漂移噪声的强度,而且能够减轻心电信号波形形态的扭曲程度。郑娱<sup>[8]</sup>利用不同噪声的频率特性,设计带阻滤波器滤除工频干扰,高通滤波器抑制基线漂移,再通过小波变换去除肌电干扰。Xin Yi<sup>[9]</sup>等人使用非线性中值滤波滤除基线漂移的低频部分,利用经验模态分解抑制其高频部分,实验表明,该方法可以提升信号信噪比,效果明显。李小燕<sup>[10]</sup>等人基于小波变换原理,使用 Coif 小波对信号进行尺度分解,滤除基线漂移,取得很好效果。

### 1.2.2 心电图特征提取和分类

特征提取是心电图分类的关键步骤。结合医学背景知识可知,在一个心拍中 QRS 波群和 P 波、T 波以及各波之间的时间间期等是医生对心律失常诊断的基本依据,因此这些波和间期特征的提取尤为重要。生物信号处理技术和模式识别技术方面的研究为波形检测提供了有力工具。早在上世纪六七十年代开始,一些对 QRS 波群的检测算法已经取得了很高的检测率。Pan<sup>[11]</sup>等提出了利用低、高通滤波

器级联的带通滤波器来进行 QRS 波的检测。该算法在 MIT-BIH 心律失常数据集上的测试准确率为 99.3%。近年来也提出了许多新的差分阈值算法<sup>[12]</sup>、小波变换法<sup>[13]</sup>和神经网络<sup>[14-15]</sup>等检测方法。差分阈值法主要利用 R 波幅度、斜率特征对 R 波进行检测, 优势在于方法简易、及时性好, 缺点在于稳健度较差。类似于希尔伯特变换、经验模态分解以及广泛使用的小波变换等方法是将原始信号转换为频域信号, 然后利用这些频域特性构建用于检测 QRS 波群的决策逻辑。Zahia<sup>[16]</sup>等的研究显示, 这类方法的查全率和查准率都可达 99.5%。在 QRS 波群检测的基础上还需要确定 P 波、T 波的定位以及各个波形起止点的定位、间期长度等。其中 P 波检测是对房室传导阻滞类疾病自动诊断的关键。T 波反映了心室在复极过程中的心电信号波形形态。这三者的正确检测直接影响对 P-R 间期、QRS 宽度、S-T 段检测等参数的计算<sup>[17]</sup>。

在滤波去噪和波形检测定位的基础上, 目前心电图自动分类方法可以总结为两大类: 一是基于时域波形特征的分类方法; 二是基于特征描述的特征提取分类方法。前者方法直观清晰, 易于理解; 后者通过提取心电图的内在属性特征, 更加抽象。

基于时域波形特征提取的方法是通过检测定位各个波形, 计算心电图包含的典型特征, 例如 QRS 波群及其幅值、P 波段及其幅值、T 波段及其幅值、RR 间期、PR 间期, ST 间期、QT 间期等等, 根据医学上病理规则进行诊断分类。Philip<sup>[18]</sup>通过提取波形特征以及各波形间的时间间期等 15 个特征, 实现了 5 种心拍类型分类准确率 81.9%; 李坤阳<sup>[19]</sup>根据小波变换和形态学相结合的方法得到 QRS 波群宽度和 RR 间期等特征, 取得对 4 种心拍类型分类准确率 94.2%。虽然该方法易于理解, 但容易受到噪声等干扰, 对心电图的质量要求较高, 需要对各波进行精确的检测定位, 如果提取的特征量不足够充足, 分类准确性较低。

目前应用最普遍是基于特征描述的特征提取方法, 包括特征空间变换的方法即将心电图信号由时间域转换到变换域内进行特征提取, 还包括基于统计的方法。Sung-Nien Yu<sup>[20]</sup>等人利用小波变换的方法对 QRS 波群采样并进行 2 尺度的离散小波分解得到三组小波系数, 再计算其在各自尺度上的自相关系数和最小最大值比值, 设计了包括原始 QRS 波群信号方差和 RR 间期在内的 11 个特征来表示一个心拍, 然后使用概率神经网络分类, 实现了对 6 种常见心拍类型分类 99.65% 的准确率。Ye<sup>[21]</sup>利用独立成分分析将其降低到 18 维。同时还提取了 RR 前向后向间期, RR 局部平均间期, 平均 RR 间期, 利用支持向量机对特征向量分类。在 MIT-BIH 数据库上实现对 15 种心拍的自动分类, 准确率达到 99.91%。

目前, 主流的分类器主要包括线性分类器、非线性分类器和决策分类器<sup>[22]</sup>。线性分类器主要包括支持向量机<sup>[23]</sup>、线性判别分析<sup>[24]</sup>和储备池计算<sup>[25]</sup>; 非线性分

类器主要包括人工神经网络<sup>[26]</sup>、聚类算法<sup>[27]</sup>和 K 最近邻方法<sup>[28]</sup>；决策分类器主要包括决策树方法<sup>[29]</sup>。其中，神经网络由于其具有自适应、抗噪声能力强、非线性、快速和准确等优点，已经成为很多研究人员采用的心电信号分类器。

### 1.2.3 基于卷积神经网络的心电图自动分类

近几年，诸多学者借鉴在图像处理领域应用广泛的卷积神经网络展开心电图自动分类研究。Kiranyaz<sup>[30]</sup>首次将一维卷积神经网络用于心律失常检测，该研究采用 6 层卷积神经网络结构，其中，卷积层、池化层和前向全相连层数目都分别为 2。网络输入包括原始心电信号和经过傅立叶变换得到的信号幅频特征。该检测方法虽然在整体准确率上达到 97%以上，但是室上性异位心跳的识别敏感度和阳性预测值都不高，分别为 60.3%和 63.5%。

此外，Acharya<sup>[31]</sup>采用 9 层一维卷积神经网络结构对心跳进行分类，网络输入为经过小波变换滤波和标准差归一化的心电信号。Acharya<sup>[32]</sup>都采用 11 层一维卷积神经网络结构，分别用于基于心电信号的冠心病、心律失常、心肌梗死和是否可通过电击治疗的室性心律失常检测，心电信号预处理方法都同样采用了小波变换滤波和标准差归一化。Pourbabaee<sup>[35]</sup>将卷积神经网络用于基于心电信号的心房颤动检测。除了疾病检测之外，Xia Y<sup>[37]</sup>根据不同个体以及相同个体不同部位采集得到的心电信号具有特异性的特点，将卷积神经网络分别用于确定个体身份和室性早搏起源点。

上述文献研究对于心电信号的特征提取和分类都采用卷积神经网络。但相对不足的是研究基本都是针对心拍类型分类，这就需要大量的带有标注的心拍，而实际临床一个多导联心电图记录往往只有整体的一个或多个心律失常标注，因此，基于多导联的心电图自动分类仍需要进一步研究。

## 1.3 存在的问题

首先，传统的心电图自动分类方法，基本都是将特征提取和分类分开进行。人工手动提取心电图特征费时费力，且能否准确的提取到好的特征很大程度上依赖研究者的个人经验和知识水平。传统算法中特征提取与分类识别相互独立带来这样的问题：即如果前期特征提取不能表现心电图本质属性，那么后期分类器将无法拟合出合适的决策函数，导致分类效果不理想。其次，实际临床上大量心电图都是多导联的，每个心电图记录一般只有整体心律失常类型标注，很少存在对每个心拍进行标注的记录。目前针对心拍的心电图自动分类研究，虽然达到了很高的准确率，但与实际临床应用相差甚远。

近些年，深度神经网络的兴起发展为心电图自动分类研究提供了新的思路。区别于传统手工设计方法提取心电图特征，深度学习神经网络可以自动的从大量

样本记录中逐层学习提取心电图内在抽象特征进行分类,避免了因对心电图内在属性认识不足导致特征提取不恰当和不充分造成的分类结果不理想。

为此,本文是利用卷积神经网络展开对实际临床上多导联心电图自动分类的研究。

## 1.4 本文主要研究内容和章节安排

针对上述研究现状和现存的主要问题,本文主要研究利用深度学习的卷积神经网络模型对 12 导联心电图进行自动分类,从而实现包括正常心律(Normal)、心房颤动(Atrial fibrillation)、一级房室传导阻滞(First-degree atrioventricular block)、左束支传导阻滞(Left bundle branch block beat)、右束支传导阻滞(Right bundle branch block beat)、房性期前收缩(Premature atrial contraction)、心室早发性收缩(Premature ventricular contraction)、ST 段压低(ST-segment depression)、ST 段抬高(ST-segment elevated)在内的 9 中常见心律类型的自动分析诊断。

研究工作主要有两大部分,一个是,对心电图进行预处理,包括了滤波去噪处理、数据集划分归一化、数据集读取三个部分;另一个是,搭建卷积神经网络,对心电图记录进行自动特征学习,最后一层通过 Softmax 分类器实现心电图的自动分类和诊断。

研究内容分为五章,即

第一章,主要阐述了本论文的研究背景与意义,简要叙述分析了国内外心电图分类的研究现状,包括心电图的预处理,心电图的特征提取和分类,卷积神经网络对心电图的分类以及研究中存在的问题。

第二章,首先,概述了心电图含义,包括心电图的产生机理,心律失常的分类与目前常用的四大心电图数据库。其次,简述了本文后面所使用的卷积神经网络的基本原理,网络特性和操作,这为后续工作奠定理论基础。

第三章,主要内容是在 ICBEB 心电数据集上基于 Resnet50 网络对心电图进行自动分类实验,包括 Resnet 网络结构,实验前的数据预处理,初步的实验结果及分析等。

第四章,研究了基于 Resnet 网络的优化模型,模型评估指标的改进以及网络训练技巧。针对不同超参数下进行网络训练,分析模型分类表现。

第五章,总结与展望。

## 2 心电图与卷积神经网络

### 2.1 引言

对心电图进行分类识别，就要先了解心电图基本知识。

本章，首先，阐述了心电图产生机理，12 导联系统，正常心电图波形的主要特点以及常见的心律失常类型。其次，分析了目前国际上公认的四大标准心电图数据库和本文研究所使用的 ICBEB 心电图数据库。最后，简述了卷积神经网络的理论基础，包括一些重要算法的推导，卷积神经网络的特性和基本操作等，这为后续研究奠定了理论基础。

### 2.2 基本心电知识

#### 2.2.1 心电图的产生

心电图指的是利用心电图机在身体四肢及胸部记录的心脏搏动时产生的电位变化图。它是反映心脏心电活动的发生、传输及恢复过程中的身体体表电位变化的客观指标。如图 2.1，心脏心电活动导体体系由窦房结、结间束、房室束、房室结、希氏束、束支（分为左、右束支，左束支又包含前后分支）和浦氏纤维组成。

心脏心电活动开始于窦房结，心房首先兴奋同时通过结间束传输到房室结，兴奋传输至此延迟时间约为 0.05~0.07s，然后依次经希氏束、左束支、右束支、浦氏纤维依次传输，到达终点心室<sup>[39]</sup>。这种按顺序进行的电激动的传输，会产生连续不断的电位变化，利用心电图机记录下这些变化便形成了心电图上的相应的波段。




图 2.1 心脏传导系统

Fig.2.1 Cardiac conduction system

### 2.2.2 心电导联系统

为了获取心电图需要在患者的不同部位安置不同的电极，并利用导联线连接心电图机记录仪的正负极，这样的导联连接电路系统称为心电图导联系统。目前，临床上广泛使用的心电导联系统是由 Einthoven 设计的常规 12 导联系统<sup>[40]</sup>，该导联系统包括放置在四肢的肢体导联和主要位于胸部的胸导联。

①肢体导联（Limb Leads）：肢体导联包括了标准 I 导联、II 导联、III 导联和 aVR、aVL、aVF 加压单极导联。其中标准导联为双极肢体导联，描记两个电极之间的电位差。电极连接方法如下：I 导联连接右上肢，左上肢；II 导联连接右上肢，左下肢；III 导联连接左上肢，左下肢。除这三个标准导联以外，还要在额面上还要加入三个加压肢体导联，这样就可以从各个方向上识别心电活动在冠状面、矢状面以及纵切面上的心电向量，进而判断心电活动是否正常。肢体导联示意图，如图 2.2 所示。




图 2.2 肢体导联及心电轴

Fig.2.2 Limb lead and electrocardiogram

为准确表示六个导联轴间的方向关系，将每一个标准导联的正负极间用一条直线连接起来，称为导联轴。将 I，II，III 导联的导联轴平移，将其与 aVR、aVL、aVF 的导联轴一同穿过坐标轴的中心点，这样就合成了额面六轴系统。在坐标系中左侧为 0 度，顺时针方向为正向，逆时针方向为负向。从图中可以看出每个导联轴由中心点位置分成正负两极，以 30 度为间隔均分整个额面。该系统在定位心脏额面心电轴时具有重要作用。

②胸导联（Precordial Leads）：胸导联属于单极导联，该导联系统是将用于检测的正电极放在胸部体表固定的部位，然后将 I 导联、II 导联、III 导联的三个电



极各串联一个  $5000\Omega$  的电阻后接到一起组成无干电极。这样可以在该点构建稳定的零电位点，用作导联的负极。V1~V6 导联的安装位置如图 2.3 所示。




图 2.3 导联安装位置图

Fig.2.3 Lead installation location

### 2.2.3 正常心电图典型波形及特点

正常心电图波形一般包括一个 P 波、一个 QRS 波群、一个 T 波<sup>[41]</sup>，如图 2.4 所示。医生通过观察并计算各个重要波形的起始点及其相关间期，幅值等特征参数，参考正常指标范围，从而做出诊断。下面介绍各个波、波段间期和各种指标的含义。




图 2.4 正常的心电节拍

Fig.2.4 Normal ECG beat

①P 波：心电图上第一个波形，其幅值不高呈圆钝形，在大部分导联中直立向上，但在 aVR 导联中的 P 波倒置。它描记的是窦房结兴奋后的右、左心房的去极过程中的电位和时间变化。在肢体导联中，P 波幅值一般不超过  $0.26\text{mV}$ ，在胸前



导联中一般不超过 0.18mV，其正常宽度在 0.06s~0.12s。

②PR 间期：P 波由起点位置到 QRS 波群起点位置间的时间间隔。它描记了电激动在心房通过房室结经希氏束-浦氏纤维的传输时间。正常的窦性心律的范围是在 0.10s~0.18s，一般幼儿时间相对较短，老年人间期相对较长。

③QRS 波群：QRS 波群是正常心拍中幅值最大的，由三个相邻波组成即 Q 波、R 波、S 波。它描记了左、右心室去极过程中的电位和时间变化，即兴奋从房室结发出经过房室束、左束支、右束支通过浦氏纤维后进入心室，引起心室的兴奋收缩。Q 波是波群中向下的波形，其宽度一般不超过 0.04s，振幅不超过 0.15mV，但 Q 波并不一直存在。R 波紧跟在 Q 波后，波形狭窄但幅值高，随后出现的负向的波形为 S 波。这三者根据振幅大小不同可以表示为大小写形式，振幅较大时表示为大写形式，振幅较小时表示为小写形式。因为振幅的大小不同也就有了多种不同的波形组合形式。如 QR 波、RS 波、QRS 波等。正常 QRS 波群的持续时间为 0.06~0.10s。当超过 0.12s 时可以认为存在病理学意义。

④ST 段：ST 段指的从 QRS 波群结束到 T 波起点的时间段。它描记了心室缓慢复极过程中的变化。对 ST 段的形态判断主要是观察其是否出现抬高或压低，正常 ST 段一般呈现为一条等电位线。ST 段的振幅变化如下：在肢体导联中的 ST 段其波形可高出 0.1mV 或略压低不大于 0.05mV。在胸前导联 ST 段压低都大于 0.05mV 或抬高大于 0.3mV，可认为存在病理学意义。

⑤T 波：T 波是 QRS 波群之后出现的第一个变化平缓的波形，描记了心室的复极变化。方向上，肢体导联中，I、II 导联中 T 波向上，aVR 导联中 T 波向下。胸前导联中 T 波通常向上。但 V1 和 V3 有时向下，当 V3 导联向下时，V1、V2 也应向下，否则视为非正常。T 波的振幅变化在不同的导联中变化不同，通常在肢体导联如果大于 0.5mV，在胸前导联中大于 1.0mV，可以判断存在病理学意义。

⑥QT 间期：包括心室除极和复极激动时间，代表心室去极化和复极化过程的总时程，时间长度为 Q 波起点到 T 波的终点。QT 间期与心率快慢有密切关系，正常人心率加速则 QT 间期缩短，反之则延长。QT 间期改变对诊断恶性心室律失常和心脏性猝死具有重要参考价值。

根据以上所列的心电图常规特征，医师可以对病人的病情做基本的病理学分析。对于更深一步的病情分析还需要结合具体的形态特征来判读。心电图的主要形态特征体现在 QRS 波群、P 波、T 波等波形中，其中 QRS 波群的特征变化最为多样，也是做出诊断的主要依据。

#### 2.2.4 心律失常分类

心脏电信号稳定性的一个重要指标是心律失常的类型和发生频率，心律失常的不同类型能反映患者机理存在的不同问题。目前心律失常的分类方法尚未完全

统一，较为常用的是心律失常的速率分类方法，如表 2.1 所示。

表 2.1 心律失常的速率分类

Table 2.1 Rate classification of arrhythmia

|         |   |
|---------|---|
| 快速性心律失常 | (1) 过早搏动：房性、房室交接性、室性；(2) 心动过速：窦性、室上性（阵发性室上性心动过速、非阵发性房性心动过速）；(3) 扑动和颤动：心房扑动、心房颤动、心室扑动、心室颤动             |
| 缓慢性心律失常 | (1) 窦性缓慢性心律失常：窦性心动过缓、停搏、阻滞；(2) 房室交接性心律；(3) 房室传导阻滞：I 度、II 度、III 度；(4) 心室内传导阻滞：完全性左、右束支传导阻滞、左前、左后分支传导阻滞 |

## 2.3 心电图数据库

### 2.3.2 四大标准心电图数据库

目前，国际上常用的心电数据库有四个，即 MIT-BIH 数据库、QT 数据库、CSE 数据库、AHA 数据库。

MIT-BIH 数据库<sup>[42]</sup>是美国波士顿的贝斯以色列医院在 1975 到 1979 年间采集的 4000 条 Holter 记录中选择的其中的 48 条记录，每条记录包括两个导联数据。每条记录的时长略大于 30 分钟，采样频率为 360Hz。每条记录标注内容包括 R 波波峰位置及心拍类型等包括左束支传导阻滞、右束支传导阻滞、室性心动过速、室性期前收缩等 15 种心律失常类型。由于该数据库标注详细，可以免费获取，是目前使用最多的数据库。

AHA 数据库<sup>[43]</sup>由美国国家心肺及血液研究院资助的美国心脏协会为评价室性心律不齐探测器性能而开发的数据库。数据库总有 155 条记录，每个记录包含两导联心电数据，采样率 250Hz，采样时长 3 小时，标注范围是最后 30 分钟。该数据库标注的心律失常总共有 8 个大类，每类又分别有 10 个心电图记录。

QT 数据库<sup>[44]</sup>共有 105 个心电图记录，每个记录都包含 2 导联，记录时长 15 分钟，采样频率 250Hz，但没有标注心拍类型。

CSE 数据库<sup>[45]</sup>是欧盟为测试心电图自动分析仪的性能开发而来。数据库包含 1000 条长度为 10 秒的 12 或 15 导联的心电记录。数据采样频率 500Hz，每个记录都是全覆盖标注，同样也没有心拍类型。表 2.2 即四大数据库详细信息。

表 2.2 四大数据库一览表

| Table2.2 Comparison of the four databases |         |          |            |       |
|---|---------|----------|------------|-------|
|   | MIT-BIH | AHA      | QT         | CSE   |
| 导联数量                                      | 2       | 2        | 2          | 12    |
| 采样率                                       | 360Hz   | 250Hz    | 250Hz      | 500Hz |
| 记录数量                                      | 48      | 155      | 105        | 1000  |
| 记录长度                                      | 30 分钟   | 3 小时     | 15 分钟      | 10 秒  |
| 标注范围                                      | 所有      | 最后 30 分钟 | 部分节拍       | 所有    |
| 峰值特征                                      | QRS 主波  | QRS 主波   | P-QRS-T 主波 | 无     |
| 心拍类型                                      | 有       | 有        | 无          | 无     |
| 价格  | 免费      | 昂贵       | 免费         | 昂贵    |

### 2.3.3 ICBEB 心电图数据库

ICBEB 心电图数据库<sup>[46]</sup>是由东南大学刘飞飞教授团队为第一届中国信号挑战赛提供，旨在为生理信号分析的开源数据和算法提供平台，从而推动心血管疾病检测与预测的研究。数据集由 11 家医院收集得到，总共有 9831 例记录。每个记录都是 12 导联心电图，同时包括每个被采集者的性别，年龄。心电图数据采样频率为 500Hz，持续长度 6s~60s。其中 2954 例记录用于测试评价指标而未公开。已公开 6877 例心电图记录详细信息如表 2.3 所示。

表 2.3 ICBEB 数据库

| Table2.3 ICBEB database                |           |       |       |       |        |       |  |
|--|-----------|-------|-------|-------|--------|-------|--|
| Type                                   | recording | Mean  | SD    | Min   | Median | Max   |  |
| Normal                                 | 918       | 15.43 | 7.61  | 10.00 | 13.00  | 60.00 |  |
| Atrial fibrillation(AF)                | 1098      | 15.01 | 8.39  | 9.00  | 11.00  | 60.00 |  |
| Left bundle branch block beat(LBBB)    | 207       | 14.92 | 8.09  | 9.00  | 12.00  | 60.00 |  |
| Right bundle branch block beat(RBBB)   | 1695      | 14.42 | 7.60  | 10.00 | 11.19  | 60.00 |  |
| Premature atrial contraction(PAC)      | 556       | 19.46 | 12.36 | 9.00  | 14.00  | 60.00 |  |
| Premature ventricular contraction(PVC) | 672       | 20.21 | 12.85 | 6.00  | 15.00  | 60.00 |  |
| ST-segment depression(STD)             | 825       | 15.13 | 6.82  | 8.00  | 12.78  | 60.00 |  |

| Type  | recording | Mean  | SD    | Min   | Median | Max   |
|---|-----------|-------|-------|-------|--------|-------|
| First-degree atrioventricular<br>block(I-AVB) | 704       | 14.32 | 7.21  | 10.00 | 11.27  | 60.00 |
| ST-segment elevated(STE)                      | 202       | 17.15 | 10.72 | 10.00 | 11.89  | 60.00 |
| Total   | 6877      | 15.79 | 9.04  | 6.00  | 12.00  | 60.00 |

该数据库中每个记录即一个 12 导联心电图只有一个心律失常标注，总共有 9 个类别分别是正常心律 (Normal)、心房颤动 (AF)、一级房室传导阻滞 (I-AVB)、左束支传导阻滞 (LBBB)、心室早发性收缩 (PVC)、右束支传导阻滞 (RBBB)、ST 段压低 (STD)、房性期前收缩 (PAC)、ST 段抬高 (STE)。如下图 2.5 所示，A0011 心电图记录临床表现为左束支传导阻滞，即 LBBB。




图 2.5 A0011 记录 12 导联心电图

Fig.2.5 Example of 12-lead ECG waveforms (LBBB, from A0011)

## 2.4 卷积神经网络理论基础

卷积神经网络最早由动物视觉神经机理的启发而提出的，是目前应用最为广泛的一种深度学习网络，并在图像识别分类，语音识别，人脸检测等领域成果显著，是深度学习的热门方向。该网络的基础是人工神经网络，本节首先介绍神经网络的基础概念神经元及前向传播和后向传播算法，然后介绍网络的特点和基本

操作。

### 2.4.1 人工神经网络

生理上，神经元是构成人体神经系统的基本组成单元，神经系统里有数以亿计的神经元相互连接，并对外界信息进行处理反馈。人工神经网络就是参考人的神经系统，其基本工作原理是通过前期向网络中输入大量样本数据，经网络前向传播得到输出，再和样本数据标签做比较，根据输出结果和标签之间的残差经反向传播调整网络参数，努力使输出和标签相一致，最后通过训练后的模型对未知样本进行识别。

如图 2.6 所示的单个神经元，训练样本  $(x^{(i)}, y^{(i)})$ ,  $x^{(i)}$  为第  $i$  个输入参数向量， $y^{(i)}$  是样本标签， $W$ ,  $b$  为网络参数。




图 2.6 单个神经元工作原理

Fig.2.6 A single neuron

该神经元输入参数为某一样本的特征向量  $x_1, x_2, x_3$  以及截距  $+1$ ,  $h_{w,b}(x) = f(W^T x) = f(\sum_{i=1}^3 W_i x_i + b)$  表示经过神经元后的输出， $f$  为激励函数。网络中常用的四种激励函数，分别是 sigmoid 函数、tanh 函数、relu 函数、softplus 函数，公式如下，四种函数曲线如图 2.7 所示。

$$f(z) = \frac{1}{1 + \exp(-z)} \quad (2.1)$$

$$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (2.2)$$

$$f(z) = \max(0, 1) \quad (2.3)$$

$$f(z) = \text{Softplus}(z) = \log(1 + e^z) \quad (2.4)$$




图 2.7 四种激活函数的曲线

Fig.2.7 Curves of four activation functions

神经网络是由许多这样的神经元构成，下图 2.8 即是一个简单的神经网络。这里，通过这个网络来介绍深度学习中重要的算法原理部分即前向传播和反向传播算法。




图 2.8 神经网络模型

Fig.2.8 Neural network model

网络中圆代表神经元，箭头连线代表神经元之间的连接，圈中+1 表示截距。该网络包含 3 个神经元的输入层，隐藏层以及 1 个神经元的输出层。参数 $W_{ij}^{(l)}$ 为第 $l$ 层第 $j$ 个神经元与第 $l+1$ 层第 $i$ 个神经元之间的权重， $b_i^{(l)}$ 为第层第 $l+1$ 个神经元的截距， $a_i^{(l)}$ 为第 $l$ 层第 $i$ 个神经元的激活值。网络各层计算如下：

$$a_1^{(2)} = f(W_{11}^{(1)}x_1 + W_{12}^{(1)}x_2 + W_{13}^{(1)}x_3 + b_1^{(1)}) \quad (2.5)$$

$$a_2^{(2)} = f(W_{21}^{(1)}x_1 + W_{22}^{(1)}x_2 + W_{23}^{(1)}x_3 + b_2^{(1)}) \quad (2.6)$$

$$a_3^{(2)} = f(W_{31}^{(1)}x_1 + W_{32}^{(1)}x_2 + W_{33}^{(1)}x_3 + b_3^{(1)}) \quad (2.7)$$

$$h_{W,b}(x) = a_1^{(3)} = f(W_{11}^{(2)}a_1^{(2)} + W_{12}^{(2)}a_2^{(2)} + W_{13}^{(2)}a_3^{(2)} + b_1^{(2)}) \quad (2.8)$$

$z_i^{(l)}$  表示第  $l$  层第  $i$  个神经元的输入。

$$z_i^{(2)} = \sum_{j=1}^n W_{ij}^{(1)}x_j + b_i^{(1)} \quad (2.9)$$

推导可得：

$$a_i^{(l)} = f(z_i^{(l)}) \quad (2.10)$$

用向量方式表示激活函数  $f(\cdot)$ ，即  $f([z_1, z_2, z_3]) = [f(z_1), f(z_2), f(z_3)]$ ，则有：

$$z^{(2)} = W^{(1)}x + b^{(1)} \quad (2.11)$$

$$a^{(2)} = f(z^{(2)}) \quad (2.12)$$

$$z^{(3)} = W^{(2)}a^{(2)} + b^{(2)} \quad (2.13)$$

$$h_{W,b}(x) = a^{(3)} = f(z^{(3)}) \quad (2.16)$$

若  $a^{(l)}$  表示第  $l$  层的激活值，则第  $l+1$  层：

$$z^{(l+1)} = W^{(l)}a^{(l)} + b^{(l)} \quad (2.14)$$

$$a^{(l+1)} = f(z^{(l+1)}) \quad (2.15)$$

以上即是前向传播算法推导过程。而反向传播算法是人工神经网络最常用的网络调参方法，一般用于梯度下降法中求取偏导数。

对样本数据  $(x, y)$ ，代价函数计算公式：

$$J(W, b; x, y) = \frac{1}{2} \|h_{W,b}(x) - y\|^2 \quad (2.16)$$

对  $m$  个样本数据  $\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$  的数据集，整体的代价函数：

$$\begin{aligned} J(W, b) &= \left[ \frac{1}{m} \sum_{i=1}^m J(W, b; x^{(i)}, y^{(i)}) \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} (W_{ji}^{(l)})^2 \\ &= \left[ \frac{1}{m} \sum_{i=1}^m \left( \frac{1}{2} \|h_{W,b}(x^{(i)}) - y^{(i)}\|^2 \right) \right] + \frac{\lambda}{2} \sum_{l=1}^{n_l-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} (W_{ji}^{(l)})^2 \end{aligned} \quad (2.17)$$

式中， $W$ 、 $b$  是网络的参数，也是问题的求解关键，求解方法为改变参数  $W$ 、 $b$  使  $J(W, b)$  最小，而对于损失函数  $J(W, b)$ ，因其为非凸函数，求解过程可能会遇到局部最优解。

梯度下降法按式 2.23 与 2.24 更新参数  $W$ 、 $b$ 。

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b) \quad (2.18)$$

$$b_i^{(l)} = b_i^{(l)} - \alpha \frac{\partial}{\partial b_i^{(l)}} J(W, b) \quad (2.19)$$

$\alpha$  表示学习率。由上式可知，参数通过  $W$ 、 $b$  的偏导数进行迭代更新。对于某个样本  $(x, y)$  的代价函数  $J(W, b; x, y)$ ，其偏导数为  $\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y)$  与  $\frac{\partial}{\partial b_i^{(l)}} J(W, b; x, y)$ ，

则整体代价函数的偏导数：

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b) = \left[ \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x^{(i)}, y^{(i)}) \right] + \lambda W_{ij}^{(l)} \quad (2.20)$$

$$\frac{\partial}{\partial b_i^{(l)}} J(W, b) = \frac{1}{m} \sum_{i=1}^m \frac{\partial}{\partial b_i^{(l)}} J(W, b; x^{(i)}, y^{(i)}) \quad (2.21)$$

以下是反向传播算法的详细步骤:

①前向传播运算, 得出 $L_1, L_2 \cdots L_{n_l}$ 等各层神经元的激活值;

②利用下式(2.22), 计算第 $n_l$ 层每个神经元的残差:

$$\delta_i^{(n_l)} = -(y_i - a_i^{(n_l)}) \cdot f'(z_i^{(l)}) \quad (2.22)$$

③对 $l = n_l - 1, n_l - 1, \dots, 2$ 的各层, 第 $l$ 层第 $i$ 个神经元的残差计算:

$$\delta_i^{(n_l)} = \left( \sum_{j=1}^{s_{l+1}} W_{ij}^{(l)} \delta_j^{(l+1)} \right) \cdot f'(z_i^{(l)}) \quad (2.23)$$

④最后, 利用所求残差计算偏导:

$$\frac{\partial}{\partial W_{ij}^{(l)}} J(W, b; x, y) = a_j^{(l)} \delta_j^{(l+1)} \quad (2.24)$$

$$\frac{\partial}{\partial b_i^{(l)}} J(W, b; x, y) = \delta_j^{(l+1)} \quad (2.25)$$

对于神经网络, 向量的使用可以提高编写程序的速度和加快网络运算速度, 上述运算改写为向量运算形式。“ $\cdot$ ”表示阿达马积, 即 $a = b \cdot c$ , 同时对 $f'(\cdot)$ 作如下处理:

$$f'([z_1, z_2, z_3]) = [f'(z_1), f'(z_2), f'(z_3)] \quad (2.26)$$

则, 前述步骤有如下简写方式:

①前向传播运算, 得出 $L_1, L_2 \cdots L_{n_l}$ 等各层神经元的激活值。

②对于第 $n_l$ 层, 计算其残差:

$$\delta^{(n_l)} = -(y - a^{(n_l)}) \cdot f'(z^{(n_l)}) \quad (2.27)$$

③对于 $l = n_l - 1, n_l - 1, \dots, 2$ , 残差为:

$$\delta^{(l)} = \left( (W^{(l)})^T \delta^{(l+1)} \right) \cdot f'(z^{(l)}) \quad (2.28)$$

④最终偏导数为:

$$\nabla_{W^{(l)}} J(W, b; x, y) = \delta^{(l+1)} (a^{(l)})^T \quad (2.29)$$

$$\nabla_{b^{(l)}} J(W, b; x, y) = \delta^{(l+1)} \quad (2.30)$$

利用上述方法重复迭代, 可逐渐减小代价函数值, 当达到设定的迭代次数或代价函数小于某值时, 结束迭代,  $W$ 和 $b$ 的值已被解出, 至此, 网络训练阶段完成。

## 2.4.2 卷积神经网络特性

卷积神经网络<sup>[47]</sup>是一种经典的前馈神经网络, 主要受生物学中的感受野的概念提出的<sup>[48]</sup>。卷积神经网络中常见的有卷积层、下采样层和全连接层, 每层包含若干特征图。每个特征图都有一些神经元, 每个特征图都是经过卷积核与前一层



输入卷积得到，并对应一种特征。

①局部连接<sup>[49]</sup>是卷积神经网络中比较重要的一个特性。人在生理上对外部世界的认识是由局部开始，再到全局整体。同样图像的像素关系也是如此，即相邻局部相关性较强，而距离相对较远则联系微弱。所以，神经网络中每个神经元通过对局部感知，由局部整合到全局。所谓局部连接，即是每个神经元不再和上一层的所有神经元相连，而只和一小部分神经元相连。与全连接相比，局部连接对减少相邻层的连接数有很大作用，降低运算量。图 2.9 所示，左图是全连接，右图是局部连接，明显的局部连接所需要训练参数远远要比全连接要少。

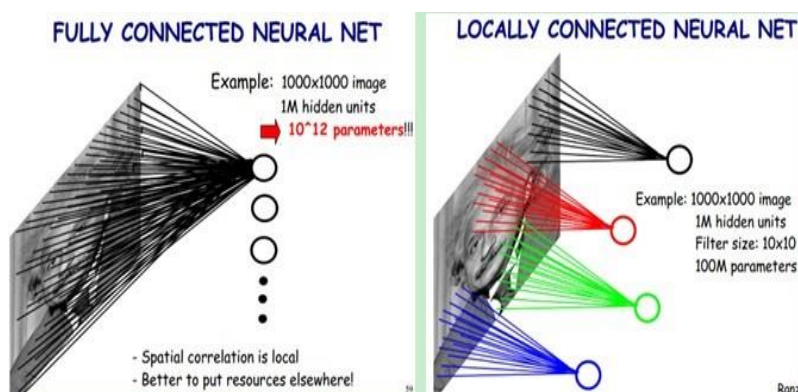


图 2.9 全连接与局部连接

Fig.2.9 Full connection and local connection

②权值共享同样可以减少网络中的参数数量。对不同特征图使用同一个过滤器进行卷积运算可以得到一个对应的特征图，即学习到一个特征。因此，通过使用更多的过滤器就可以得到图像更多的特征。例如图像尺寸为  $400 \times 400$  像素，过滤器尺寸为  $10 \times 10$  像素，网络中有  $10^6$  个隐藏单元，全连接网络需要  $400 \times 400 \times 10^6 = 1.6 \times 10^{11}$  个参数，而局部连接网络只需要  $10 \times 10 = 100$  个参数，从而看出权值共享机制减少训练参数，提高网络模型训练速度。

③基于图像空间局部相关性原理，卷积神经网络加入了下采样机制<sup>[51]</sup>，下采样可以降低图像分辨率即，保留图像有效信息，减少运算数据量，增强网络对图像变化的适应性。同时网络训练速度能快，一定程度上防止出现过拟合现象。

### 2.4.3 卷积神经网络操作

很多深度学习框架中已经有开发成接口的各个层。卷积层主要是对输入图像进行卷积操作，即特征的提取学习。卷积层是卷积神经网络中核心的网络层，主要进行卷积操作，基于图像的空间局部相关性分别抽取图像局部特征，通过连接形成整体特征。最初卷积神经网络应用于图像处理领域，二维卷积最为常见，如图 2.10 所示。




图 2.10 二维卷积实例

Fig.2.10 Example of two-dimensional convolution

为便于理解卷积，将图像的像素进行编号， $x_{i,j}$ 表示图像的第*i*行第*j*列元素，对滤波器的每个权值编号， $w_{d,m,n}$ 表示滤波器第*d*层第*m*行第*n*列权重， $w_b$ 表示滤波器的偏置项，对特征图的每个元素进行编号， $a_{d,i,j}$ 表示特征图的第*d*层第*i*行第*j*列元素， $f$ 表示激活函数。卷积计算公式：

$$a_{d,i,j} = f \left( \sum_{d=0}^{D-1} \sum_{m=0}^{F-1} \sum_{n=0}^{F-1} w_{d,m,n} x_{d,i+m,j+n} + w_b \right) \quad (2.31)$$

式中，D是深度，F是滤波器的大小。

相比于二维卷积，一维卷积常用于序列模型，自然语言处理领域。针对本文的研究对象心电图，每个样本记录都是 12 个导联的一维数组，因此本文在卷积神经网络中使用一维卷积。数学角度上一维卷积计算公式如下：

$$s(n) = f(n) * g(n) = \sum_{m=0}^N f(m)g(n-m) \quad (2.32)$$

式中， $N$ 为信号 $f(n)$ 的长度， $g(n)$ 为滤波器， $s(n)$ 为卷积结果序列。

下采样层一般通过池化操作得到，因此也称为池化。池化的策略有最大值池化、平均值池化、求和区域池化和随机区域池化等。这里，主要介绍网络中使用最多的最大值池化和平均值池化，如图 2.11 所示。在平均值池化操作中，卷积核中每个单元值都是 0.25，步长设置 2，经过均值池化后，图片大小变成原图的 1/4。同样最大值池化中，卷积核中只有一个卷积单元不为 0，经过池化后的特征图即只留下每个区域的最大值。




图 2.11 最大值池化与均值池化

Fig.2.11 Maximum pooling and averaging pooling

## 2.5 本章小结

本章，首先，概述了本文研究对象——心电图的基本知识，包括心电图的产生机理，心电图多导联系统，正常心电图波形特点，心律失常的分类，以及国际上四大心电图数据库和本文中使用的 ICBE 心电图数据库。其次，研究分析了人工神经网络组成的基本结构神经元以及神经网络前向传播和后向传播算法推导。最后，重点阐述了卷积神经网络及其三大特性和主要操作。这些都是开展心电图分类识别研究工作前期所需要了解和掌握的基础，为后续工作提供理论支撑。

### 3 基于 Resnet 模型的心电图自动分类研究

#### 3.1 引言

在心脏类疾病的诊断中，心电图是辅助医生做出正确诊断的一种常用手段。相比人工分析心电图诊断疾病，基于心电图的自动分类研究是目前医学信号领域的热点之一。

在绪论中，已经分析了部分前人的研究成果，这些研究更多是采用传统机器学习方法，其是针对每一个标注心拍，人工提取心电图中的特征后再进行分类识别。该类方法虽然识别率高，但临床使用效果很差。

本章采用卷积神经网络自动提取心电特征，并将特征提取与分类过程融合，达到心电图自动分类的目的。实验采用 ICBEB 数据库，数据来自不同患者使得网络具有很好的泛化能力，更加接近实际应用临床，为医疗领域心电图诊断心律失常提供更好的帮助。

#### 3.2 Resnet 网络模型

Resnet 即深度残差网络<sup>[52]</sup>（Deep residual network）的英文简称。Resnet 网络由微软亚洲研究院何凯明团队提出，并在 2015 年 ImageNet 比赛上取得冠军，Resnet 的提出是在深度卷积神经网络处理图像领域一件里程碑事件。

网络的深度对模型的性能至关重要，当增加网络层数后，网络可以进行更加复杂的特征模式的提取，所以当模型更深时理论上可以取得更好的结果。但事实上，实验发现深度网络出现了退化问题：增大网络深度后带来的第一个问题就是梯度消失、爆炸。这个问题在 Szegedy<sup>[53]</sup>提出 BN(Batch Normalization)结构后被顺利解决，BN 层能对各层的输出做归一化，这样梯度在反向层层传递后仍能保持大小稳定，不会出现过小或过大的情况。第二个问题是准确率下降问题即层级大到一定程度时准确率就会饱和，然后迅速下降，这种下降既非梯度消失引起也与过拟合无关，而是由于网络过于复杂，仅仅依靠无约束、放养式的训练很难达到理想的错误率。

深度网络的退化问题说明深度网络难以训练。考虑这样一种情况：假设有一个浅层网络，想通过向上堆积新层来建立深层网络，一个极端情况是：这些增加的层什么也不学习，仅仅复制浅层网络的特征，即这个新层是恒等映射（Identity mapping）。何凯明提出了残差结构来实现恒等映射，如图 3.1 所示。整个模块除了正常的卷积层输出外，还有一个分支把输入直接连到输出上，该输出和卷积的输出做算术相加得到最终的输出，用公式表达就是  $H(x) = F(x) + x$ 。可以转换为

学习一个残差函数  $F(x) = H(x) - x$ ，只要  $F(x) = 0$ ，就构成了一个恒等映射  $H(x) = x$ ，而且拟合残差更加容易。




图 3.1 快捷连接示意图

Fig.3.1 Shortcut connection

理论上，对于“随着网络加深，准确率下降”的问题，Resnet 提供了两种映射方式，一种是恒等映射，指的就是图 3.1 中“弯弯的曲线”即公式中的  $x$ ，所以最后的输出是  $H(x) = F(x) + x$ 。另一种残差映射是除了“弯弯的曲线”那部分，指的是“差”，即  $H(x) - x$ ，所以残差指的就是  $F(x)$  部分。如果网络已经到达最优，继续加深网络，残差映射将被推为零，只剩下恒等映射，这样理论上网络一直处于最优状态了，网络的性能也就不会随着深度增加而降低了。这种残差学习结构可以通过前向神经网络与快捷连接实现，如结构图所示。快捷连接相当于简单执行了同等映射，不会产生额外的参数，也不会增加计算复杂度，网络依然是端到端的反向传播训练。残差结构可写成如下公式：

$$x_{l+1} = x_l + F(x_l, W_l) \quad (3.1)$$

递归后得到任意深层单元  $L$  特征表达：

$$x_L = x_l + \sum_{i=l}^{L-1} F(x_i, W_i) \quad (3.2)$$

这表明对于任意单元  $L$  和  $l$  之间都具有残差特性。同样的，对于任意深的单元  $L$ ，它的特征表达式：

$$x_L = x_0 + \sum_{i=0}^{L-1} F(x_i, W_i) \quad (3.3)$$

即之前所有残差函数输出的总和再加上  $x_0$ 。对于反向传播，假设损失函数为  $loss$ ，根据反向传播的链式法则得到：

$$\frac{\partial loss}{\partial x_l} = \frac{\partial loss}{\partial x_L} \frac{\partial x_L}{\partial x_l} = \frac{\partial loss}{\partial x_L} (1 + \frac{\partial}{\partial x_l} \sum_{i=l}^{L-1} F(x_i, W_i)) \quad (3.4)$$

可以发现, 这个导数可以被分为两部分: 不通过权重层的传递 $\frac{\partial loss}{\partial x_L}$ 以及权重层的传递 $\frac{\partial loss}{\partial x_L} \frac{\partial}{\partial x_l} \sum_{i=l}^{L-1} F(x_i, W_i)$ , 前者保证了信号能够直接传回任意的浅层 $x_l$ , 因为 $\frac{\partial}{\partial x_l} \sum_{i=l}^{L-1} F(x_i, W_i)$ 不可能为-1, 因此也保证了不会出现梯度消失现象。

Resnet 网络使用的快捷连接有两种方式:

①同等维度映射,  $F(x)$ 与 $x$ 相加就是逐元素相加:

$$y = F(x_i, W_i) + x \quad (3.5)$$

$$F = W_2 \sigma(W_1 x) \quad (3.6)$$

②如果两者维度不同, 需要给 $x$ 执行一个线性映射来匹配维度

$$y = F(x_i, W_i) + W_s x \quad (3.7)$$

$$F = W_2 \sigma(W_1 x) \quad (3.8)$$

以上的公式表示为了简化, 都是基于全连接层的, 实际上当然可以用于卷积层, 加法随之变为对应通道间的两个特征图逐元素相加。

网络设计规则:

1) 对于输出特征图大小相同的层, 有相同数量的滤波器, 即通道数一致。

2) 当特征图尺寸通过池化变成原来的一半, 滤波器数量翻倍。对于残差网络, 快捷连接为实线, 反之为虚线。维度不相同, 有两种解决方案: 使用零填充来改变维度或通过 $1 \times 1$ 卷积实现, 即改变 $1 \times 1$ 卷积层的滤波器数量。

本章中, 使用 Resnet50 网络进行模型训练。顾名思义, Resnet50 指共 50 层的残差网络, 包括卷积层和全连接层, 其中没有需要训练的参数的层, 例如池化层不参与计数, Resnet50 结构如下表。

表 3.1 Resnet50 结构一览表

| Table3.1 Construction of Resnet50 |                      |
|-----------------------------------|----------------------|
| Layer name                        | 50-layer             |
| conv1                             | 7,64, stride 2       |
|                                   | 3 max pool, stride 2 |
|                                   | 1,64                 |
| conv2_x                           | ( 3,64 ) * 3         |
|                                   | 1,256                |
|                                   | 1,64                 |
| conv3_x                           | ( 3,64 ) * 4         |
|                                   | 1,256                |
|                                   | 1,64                 |
| Conv4_x                           | ( 3,64 ) * 6         |
|                                   | 1,256                |
|                                   | 1,256                |

|                                 |              |
|---------------------------------|--------------|
|                                 | 1,64         |
| Conv5_x                         | ( 3,64 ) * 3 |
|                                 | 1,256        |
| average pool , 9-d fc , softmax |              |

Resnet50 包含了恒等块(Identity block)和卷积块(Convolutional block)两种结构, 如图 3.2 所示。恒等块因为输入和输出维度保持不变, 所以可以串联多个; 后者卷积块如图 3.3 所示, 其输入和输出维度不一致, 不能连续串联, 其作用是为了改变特征向量的维度。




图 3.2 恒等块

Fig.3.2 Identity block




图 3.3 卷积块

Fig.3.3 Convolutional block

图 3.4 是以 Identity block 和 Convolutional block 模块为基础搭建的 Resnet50 结构图, 大致包括了 5 个阶段, 最后一层为全连接, 与表 3.2 相对应。




图 3.4 Resnet50 结构图

Fig.3.4 Construction of Rsenet50

### 3.3 实验平台与评价指标

#### 3.3.1 实验平台

本文实验平台，主要有：

硬件环境，采用英特尔 Core i7-3.70GHz CPU 处理器，16G 内存的 64 位 ubuntu 16.04LTS 操作系统，配置显卡型号 NVIDIA TITAN Xp。NVIDIA TITAN Xp 图形处理单元加速卡拥有 3840 个 CUDA 核心，板载 12GB GDDR5X 384bit 显存，核心频率高达 1582MHz，显存速度 547.7GB/s，热设计功耗 250W。由于网络模型的训练需要大量的运算，GPU 可以大幅加快运算速度，提高网络训练效率。

软件环境平台，使用 64 位 ubuntu 16.04LTS 操作系统，Keras 深度学习框架。Keras 是基于 Theano 的一个深度学习框架，用 python 语言编写，是一个高度模块化的神经网络，支持 GPU 和 CPU 无缝运行。

#### 3.3.2 评价指标

针对 ICBEB 心电数据集，根据表 3.2 来评价分类模型的性能。

表 3.2 分类计算规则一览表

Table3.2 Counting rules for the numbers of the variables

|           |        | Predicted |          |           |          |          |          |          |          |          |          |
|-----------|--------|-----------|----------|-----------|----------|----------|----------|----------|----------|----------|----------|
|           |        | Normal    | AF       | I-AV<br>B | LB<br>BB | RB<br>BB | PAC      | PVC      | STD      | STE      | Total    |
| Reference | Normal | $N_{11}$  | $N_{12}$ | $N_{13}$  | $N_{14}$ | $N_{15}$ | $N_{16}$ | $N_{17}$ | $N_{18}$ | $N_{19}$ | $N_{1x}$ |
|           | AF     | $N_{21}$  | $N_{22}$ | $N_{23}$  | $N_{24}$ | $N_{25}$ | $N_{26}$ | $N_{27}$ | $N_{28}$ | $N_{29}$ | $N_{2x}$ |
|           | I-AVB  | $N_{31}$  | $N_{32}$ | $N_{33}$  | $N_{34}$ | $N_{35}$ | $N_{36}$ | $N_{37}$ | $N_{38}$ | $N_{39}$ | $N_{3x}$ |
|           | LBBB   | $N_{41}$  | $N_{42}$ | $N_{43}$  | $N_{44}$ | $N_{45}$ | $N_{46}$ | $N_{47}$ | $N_{48}$ | $N_{49}$ | $N_{4x}$ |
|           | RBBB   | $N_{51}$  | $N_{52}$ | $N_{53}$  | $N_{54}$ | $N_{55}$ | $N_{56}$ | $N_{57}$ | $N_{58}$ | $N_{59}$ | $N_{5x}$ |
|           | PAC    | $N_{61}$  | $N_{62}$ | $N_{63}$  | $N_{64}$ | $N_{65}$ | $N_{66}$ | $N_{67}$ | $N_{68}$ | $N_{69}$ | $N_{6x}$ |
|           | PVC    | $N_{71}$  | $N_{72}$ | $N_{73}$  | $N_{74}$ | $N_{75}$ | $N_{76}$ | $N_{77}$ | $N_{78}$ | $N_{79}$ | $N_{7x}$ |
|           | STD    | $N_{81}$  | $N_{82}$ | $N_{83}$  | $N_{84}$ | $N_{85}$ | $N_{86}$ | $N_{87}$ | $N_{88}$ | $N_{89}$ | $N_{8x}$ |
|           | STE    | $N_{91}$  | $N_{92}$ | $N_{93}$  | $N_{94}$ | $N_{95}$ | $N_{96}$ | $N_{97}$ | $N_{98}$ | $N_{99}$ | $N_{9x}$ |
| Total     |        | $N_{x1}$  | $N_{x2}$ | $N_{x3}$  | $N_{x4}$ | $N_{x5}$ | $N_{x6}$ | $N_{x7}$ | $N_{x8}$ | $N_{x9}$ |          |

对每个心律类别评价指标F1有如下定义：

$$\text{Normal: } F_{11} = \frac{2*N_{11}}{(N_{1x}+N_{x1})} \quad \text{AF: } F_{12} = \frac{2*N_{22}}{(N_{2x}+N_{x2})} \quad \text{I-AVB: } F_{13} = \frac{2*N_{33}}{(N_{3x}+N_{x3})}$$



$$\begin{aligned}
\text{LBBB: } F_{14} &= \frac{2*N_{44}}{(N_{4x}+N_{x4})} & \text{RBBB: } F_{15} &= \frac{2*N_{55}}{(N_{5x}+N_{x5})} & \text{PAC: } F_{16} &= \frac{2*N_{66}}{(N_{6x}+N_{x6})} \\
\text{PVC: } F_{17} &= \frac{2*N_{77}}{(N_{7x}+N_{x7})} & \text{STD: } F_{18} &= \frac{2*N_{88}}{(N_{8x}+N_{x8})} & \text{STE: } F_{19} &= \frac{2*N_{99}}{(N_{9x}+N_{x9})} \\
\text{总体平均 } F1 &= \frac{F_{11}+F_{12}+F_{13}+F_{14}+F_{15}+F_{16}+F_{17}+F_{18}+F_{19}}{9}
\end{aligned}$$

根据心律失常分类，我们还关注模型对亚异常类型分类的表现，评价指标：

$$\begin{aligned}
\text{AF: } F_{12} &= \frac{2*N_{22}}{(N_{2x}+N_{x2})} & \text{Block: } F_{Block} &= \frac{2*(N_{33}+N_{44}+N_{55})}{(N_{3x}+N_{x3}+N_{4x}+N_{x4}+N_{5x}+N_{x5})} \\
\text{Premature contraction: } F_{PC} &= \frac{2*(N_{66}+N_{77})}{(N_{6x}+N_{x6}+N_{7x}+N_{x7})} \\
\text{ST-segment change: } F_{ST} &= \frac{2*(N_{88}+N_{99})}{(N_{8x}+N_{x8}+N_{9x}+N_{x9})}
\end{aligned}$$

### 3.4 ICBEB 心电图数据集预处理

#### 3.4.1 心电图去噪

心电图去噪预处理主要是针对基线漂移、工频干扰和肌电干扰的抑制或消除。经典滤波器法是目前比较成熟的去噪方法之一，针对单一滤波器对高低频噪声滤除效果不明显的缺点，本文设计一种级联滤波器，利用不同的滤波器实现不同频率的去噪功能。

数字滤波器可用系统函数表示如下：

$$H(z) = \frac{\sum_{k=0}^M b_k z^{-k}}{1 - \sum_{k=1}^N a_k z^{-k}} = \frac{Y(z)}{X(z)} \quad (3.9)$$

本节构建的级联滤波器，如图 3.5 所示。

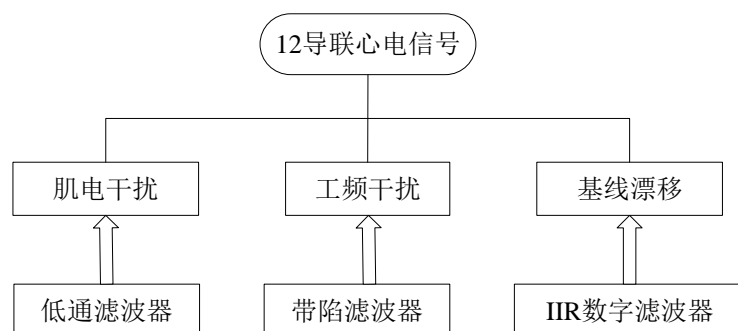


图 3.5 级联滤波器流程

Fig.3.5 Cascade filter

#### ①低通滤波器滤除肌电干扰

由于巴特沃斯滤波器特点是其通频带的频率响应曲线平滑度最大、随频率升

高逐渐减小,所以可以利用低通滤波器滤除肌电干扰。图 3.6 是该低通滤波器幅频响应,记录 A0003.mat 文件中 I 导联原始信号经低通滤波器后的滤波效果,如图 3.7 所示。




图 3.6 巴特沃斯低通滤波器幅频曲线

Fig.3.6 Butterworth low pass filter amplitude frequency curve




图 3.7 低通滤波器滤除肌电干扰

Fig.3.7 Low-pass filter filters out myoelectric interference

## ②带陷滤波器抑制工频干扰

带陷滤波器是一种可以使输入信号在某一特定频率点迅速衰减的滤波器。心电图信号需要滤除 50Hz 的工频干扰,本文中设计一个低通滤波器叠加一个高通滤波器来构成 50Hz 带陷滤波器。设计低通滤波器截止频率  $wc1=49\text{Hz}$ , 高通滤波器

截止频率  $\omega_c=51\text{Hz}$ ，幅频曲线如图 3.8 所示。原始心电信号经低通滤波器滤除肌电干扰后再经带陷滤波器抑制工频干扰，如图 3.9 所示。




图 3.8 50Hz 带陷滤波器幅频曲线

Fig.3.8 50Hz banded filter amplitude frequency curve

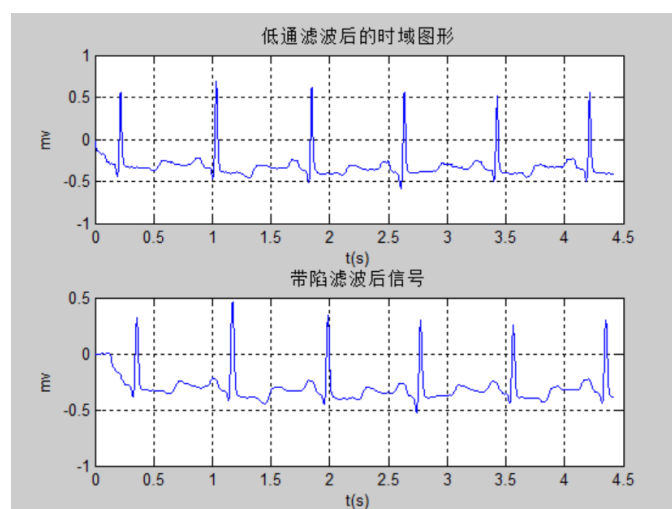


图 3.9 50Hz 带陷滤波器滤除工频干扰

Fig.3.9 50Hz trap filter to filter power frequency interference

### ③IIR零相移数字滤波器纠正基线漂移

零相移滤波器特点是输入信号在通过该滤波器后相位不会改变，即零相移滤波器的相位响应等于零。对于因果系统，在事先无法知道信号相位谱的情况下，实现零相移是不可能的，非因果系统才有可能存在零相移。如图3.10和3.11所示，分别是幅频曲线和原始信号经低通滤波器以及带陷滤波器后再通过IIR零相移数字滤波器纠正基线漂移，可以看到滤波后基线漂移得到很大改善。




图3.10 IIR零相移滤波器幅频曲线

Fig.3.10 IIR zero phase shift filter amplitude frequency curve




图 3.11 IIR 零相移数字滤波器纠正基线漂移

Fig.3.11 IIR zero phase shift digital filter corrects baseline drift

### 3.4.2 数据集划分与归一化

ICBEB 心电图数据库已公开 6877 例带标签心电图记录, 本文实验中, 按照 8:2 的比例对心电图的每一类划分训练集和测试集, 如表 3.3 所示。

表 3.3 训练集与测试集一览表

Table3.3 Training set and Test set

|     | Normal | AF   | I-AVB | LBBB | RBBB | PAC | PVC | STD | STE | 合计   |
|-----|--------|------|-------|------|------|-----|-----|-----|-----|------|
| 训练集 | 735    | 879  | 564   | 166  | 1357 | 442 | 542 | 660 | 162 | 5507 |
| 测试集 | 183    | 219  | 140   | 41   | 338  | 114 | 130 | 165 | 40  | 1370 |
| 合计  | 918    | 1098 | 704   | 207  | 1695 | 556 | 672 | 825 | 202 | 6877 |

数据归一化的目的，就是将数据的所有特征都映射到同一尺度上，这样可以避免由于量纲的不同使数据的某些特征形成主导作用。归一化后可以加快梯度下降求最优解的速度。如图 3.12 所示，红色曲线表示损失函数的等高线，左图未归一化，右图是归一化之后，箭头表示最优解寻解过程。




图 3.12 数据归一化最优解寻解

Fig.3.12 Data normalized optimal solution

同时，数据归一化可能提高精度。一些分类器算法需要计算样本之间的距离例如 KNN、K-means 等。如果一个特征值域范围非常大，那么距离计算就主要取决于这个特征，从而与实际情况相悖。

目前，常用数据归一化类型主要有三种：

#### ①线性归一化

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (3.10)$$

这种归一化方法比较适用在数值比较集中的情况。这种方法有个缺陷，如果  $\max$  和  $\min$  不稳定，很容易使得归一化结果不稳定，使得后续使用效果也不稳定。实际使用中可以用经验常量值来替代  $\max$  和  $\min$ 。

#### ②均值方差归一化

$$x^* = \frac{x - \mu}{\sigma} \quad (3.11)$$

其中,  $u$  为样本数据的均值,  $\sigma$  为样本数据的标准差。

均值方差归一化的特点是, 经过处理的数据符合标准正态分布, 即均值为 0, 标准差为 1, 不容易受到异常值影响。

### ③非线性归一化

非线性归一化经常用在数据分化比较大的场景, 有些数值很大, 有些很小。通过一些数学函数, 将原始值进行映射。该方法包括 取对数、指数, 正切等。需要根据数据分布的情况, 决定非线性函数的曲线。

针对心电导联的数据分布, 拟采用均值方差归一化方法对每个样本进行归一化预处理。

## 3.5 ICBEb 心电数据集实验

### 3.5.1 数据读取与转换

ICBEb 心电数据集中, 每个记录以 .mat 格式保存, 表 3.4 记录了 A0003.mat 内容。

表 3.4 A0003.mat 记录一览表

| Table 3.4 A0003.mat recording |                 |         |        |
|-------------------------------|-----------------|---------|--------|
| 字段                            | 值               | 最小值     | 最大值    |
| sex                           | Female          |         |        |
| age                           | 71              | 71      | 71     |
| data                          | 12*18488 double | -2.3932 | 3.3974 |

其中, data 是二维数组, 即 12 导联心电图数据, 数组的每一维代表一个心电导联。因此, 需要对数据的组织方式进行转换, 如图 3.13 所示。即, 将 data 中的二维数组转换成 12 通道一维数组以便在网络训练中进行一维卷积, 池化等操作。




图 3.13 数据维度转换

Fig.3.13 Data dimension conversion

### 3.5.2 网络训练

ICBEB 心电数据集的数据都来自临床的不同患者,根据上一小节中数据划分,训练集共有 5507 例记录,测试集共有 1370 例记录。本节中,将使用前文介绍的卷积神经网络 Resnet50 网络对心电图进行总共 9 种心律失常分类。实验流程图 3.14 所示。

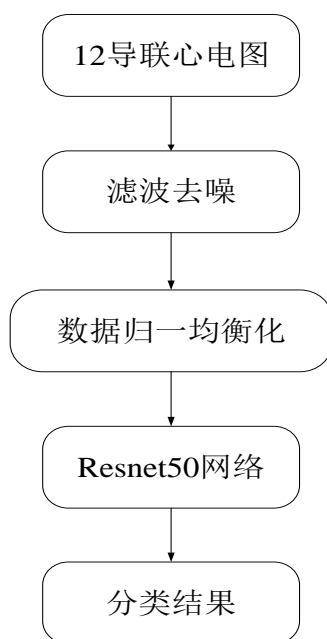


图 3.14 实验流程

Fig.3.14 Experiment process

由于 ICBEB 心电数据集每个类别数量分布不均,例如心律失常 RBBB 样本有 1695 例记录,而 LBBB 和 STE 却分别只有 207 例和 202 例记录。因此,样本需要均衡化,即以相同数量比例组成一个批次送入网络训练。代码的 dataGenerator.py 文件中定义了 BalanceGenerator()函数实现这一目的。

至此,数据准备阶段全部完成,开始网络模型训练。Resnet50 网络的优化器采用 Adam 算法,损失函数采用交叉熵损失函数 Cross Entropy Loss,网络评价指标设置为测试集准确率 val\_acc。为了达到评价指标最优,可以通过设置回调函数来提高网络的训练速度和精度。摘取 train.py 文件中回调函数解释网络训练步骤:

```
callbacks.ModelCheckpoint((os.path.join(args.weights_dir,'resnet50_weights.h5'),monitor='val_acc')
```

```
callbacks.ReduceLROnPlateau(monitor='val_acc', factor=0.2, patience=5)
```

```
callbacks.EarlyStopping(monitor='val_acc',patience=15,verbose=0,mode='max')
```

首先,网络调节器设置为训练模型在测试集上的准确率 val\_acc。训练中当准

准确率  $\text{val\_acc}$  连续 5 个周期没有提升, 网络学习率  $\text{lr}$  将以 0.2 的衰减因子进行衰减, 当准确率连续 15 个周期没有提高, 网络训练自动结束, 并保存最优模型。

### 3.5.3 实验结果及分析

Resnet50 网络模型默认超参数设置, 如表 3.5 所示。

表 3.5 超参数默认值一览表

Table3.5 Hyperparameter default

| learning rate(lr) | dropout | weight_decay | batch_size | optimizer | epoch |
|-------------------|---------|--------------|------------|-----------|-------|
| 0.01              | 0.0     | 0.0          | 64         | Adam      | 100   |

网络对于这些超参数的选择有一定的原则和经验。学习率  $\text{lr}$  对于深度学习是一个重要的超参数, 它控制着基于损失梯度调整神经网络权值的速度。学习率越小, 网络训练损失  $\text{loss}$  下降的速度越慢, 收敛的时间越长; 学习率太大, 参数更新的幅度就非常大, 就会导致网络收敛不到局部最优点或者网络损失直接开始增加。如图 3.15 所示, 不同学习率下, 网络损失  $\text{loss}$  的表现趋势。




图 3.15 不同学习率下训练网络  $\text{loss}$  表现

Fig.3.15 Training network loss performance under different learning rates

在本网络训练中, 学习率会根据模型在测试集上的分类准确率进行衰减。网络训练初期, 学习率较大, 这样损失梯度下降迅速即  $\text{loss}$  下降更快, 当训练一段时间后, 准确率连续 5 个周期没有提升, 将乘以衰减因子 0.2 来降低学习率继续训练, 这样可以使目标函数在合适的时间内收敛到局部最优点。表 3.6 即是初始学习率  $\text{lr}=0.1$ ,  $0.01$ ,  $0.0001$  时模型训练所需要周期。直观的, 当  $\text{lr}=0.1$  时模型  $\text{loss}$  值很大表明网络不能收敛,  $\text{lr}=0.0001$  偏小时, 训练需要更多周期即耗时更多, 模型训练收敛太慢, 相对的  $\text{lr}=0.01$  则是对网络训练合适的初始学习率。



表 3.6 不同学习率下网络训练一览表

| lr     | epoch | loss  |
|--------|-------|-------|
| 0.1    | 27    | 14.32 |
| 0.01   | 52    | 0.39  |
| 0.0001 | 70    | 0.68  |

在训练神经网络的时候经常会遇到过拟合的问题，即模型在训练集上表现为损失函数较小，分类准确率较高；但是在测试数据上损失函数变大，预测准确率较低。**dropout**（随机失活）是指在网络的训练过程中，网络按照一定的概率将某些神经元暂时从网络中丢弃，该操作可以比较有效的缓解过拟合的发生，在一定程度上达到正则化的效果。为选择合适的 **dropout**，这里设置 **dropout**=0.0, 0.3, 0.5, 0.7, 0.9 分别训练模型对心电图分类，结果如图 3.16 所示。根据 ICBEb 心电数据集心律失常分类的评价指标，总体来看，在其他参数一定时，当 **dropout**=0.3，模型分类结果较好。

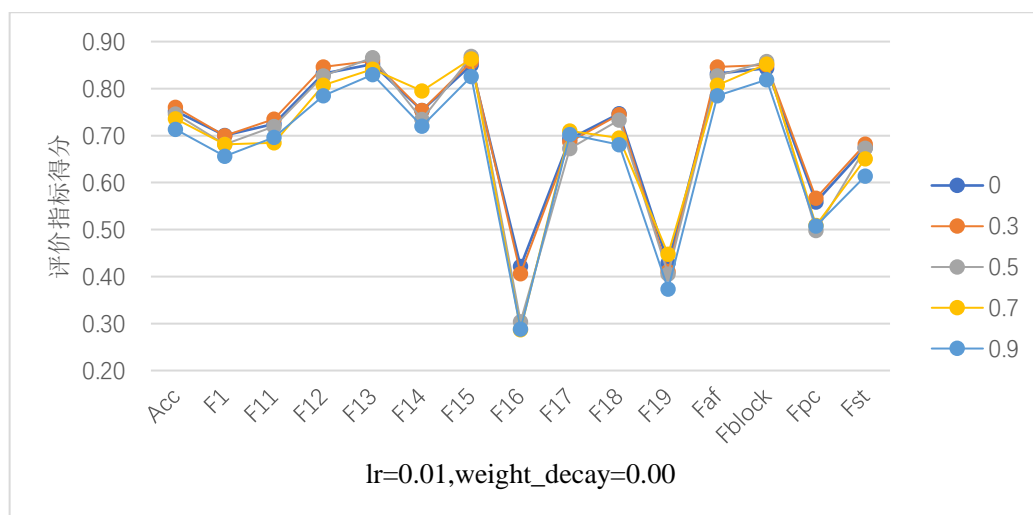


图 3.16 dropout 取不同值模型分类结果

Fig.3.16 Model classification results for different dropout

**weight\_decay**（权值衰减）又叫 **L2 正则化**，目的就是为了让权重衰减到更小的值，在一定程度上减少模型过拟合的问题。从模型的复杂度来看，更小的权值，表示网络的复杂度更低，对数据的拟合更好，而在实际应用中，也验证了这一点，**L2 正则化**的效果往往好于未经正则化的效果。图 3.17 所示，不同权值 **weight\_decay**

对模型分类的影响，当  $\text{weight\_decay}=0.001$  时，模型分类结果最优。



图 3.17 不同  $\text{weight\_decay}$  的模型分类结果

Fig.3.17 Model classification results for different  $\text{weight\_decay}$

通过以上对  $\text{lr}$ ,  $\text{dropout}$ ,  $\text{weight\_decay}$  取不同值发现，每个超参数对网络模型分类结果的影响趋势一致，各超参数的选择过大或过小将影响网络训练的速度和分类结果的精度。综合各个超参数取不同值时模型的分类表现，当网络的三个超参数分别取值 0.01, 0.3, 0.0 时，Resnet50 网络模型分类相对最优。具体各类评价指标，如图 3.18 所示。

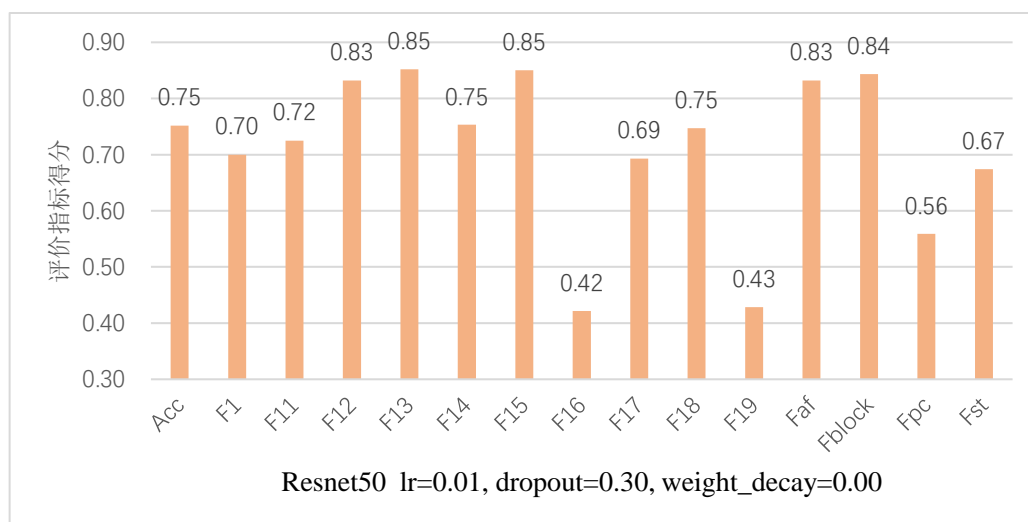


图 3.18 基于 Resnet50 模型的分类结果

Fig.3.18 Classification results based on Resnet50 model

基于 Resnet50 网络对心电图 9 种心律失常自动分类, 实现  $F1 = 0.70$ 。其中, 由于数据集中 AF, I-AVB, RBBB 这三类心律失常数量分布最多, 分类效果也最好, F1 得分分别为 0.83, 0.85, 0.85。而 STE 心律失常共有 202 例样本记录, 分配到训练集的就更少, 模型训练效果 F1 得分只有 0.43。

### 3.6 本章小结

本章, 首先, 简述了 Resnet 网络结构和其典型代表 Resnet50 网络, 明确了网络模型分类的实验平台和评价指标, 并针对 ICBEB 心电数据集 9 种心律失常进行了分类。根据心电数据集实际情况, 对其进行网络训练前的预处理, 包括去噪预处理即滤除肌电干扰, 工频干扰, 基线漂移三种主要噪声, 把数据集按比例划分成训练集和测试集, 以及对数据归一化处理。其次, 使用 Resnet50 网络对标注好的数据进行训练, 主要分析超参数取值不同对模型分类结果的影响, 分析了造成个别类评价结果不理想的可能原因, 并确定了最终合适的超参数, 这为下一章网络优化奠定基础。

## 4 基于 Resnet 优化模型的心电图自动分类研究

### 4.1 引言

在前一章节中，通过训练一维卷积的 Resnet50 网络模型对心电图进行了初步的自动分类，并取得较好的结果。所使用的 Resnet 网络，其残差结构的引入在深度学习领域具有划时代的意义，它允许网络尽可能的加深，解决了传统网络堆叠深度造成的准确率下降，梯度消失问题，这是当前应用最为广泛的 CNN 特征提取网络，并且在图像处理领域取得了很好的效果。

然而，针对 12 导联的一维心电数据，直接使用 Resnet50 网络进行训练模型分类效果并不理想，尤其是，部分训练集数据集较少的类型。

本章，以上述 Resnet 残差结构为基础，对网络中的卷积模块进行改进和优化，应用于 ICBEB 心电数据集，分类效果获得了一定提升。

### 4.2 网络模型优化

#### 4.2.1 网络卷积模块优化

针对 ICBEB 心电数据集，在上一章实验中，直接使用一维卷积的 Resnet50 网络，残差结构包括两个即 Identity block 和 Convolutional block，如图 3.3 和 3.4 所示。考虑到心电数据每个导联序列都长达 3000 维，因此，可以在卷积层使用膨胀卷积的技巧。

膨胀卷积就是在标准的卷积核里注入空洞，以此来增加感受野。相比原来的标准卷积，空洞卷积多了一个参数即膨胀系数（dilation\_rate）。膨胀后的卷积核尺寸计算公式：

$$\begin{aligned} \text{kernel\_size\_after\_dilate} - 1 \\ = \text{dilated\_rate} * (\text{kernel\_size\_before\_dilate} - 1) \end{aligned} \quad (4.1)$$

此时，如果 pad 参数设置为‘SAME’，其大小为：

$$\text{pad} = \text{int}((\text{kernel\_size} + (\text{dilated\_rate} - 1) * ((\text{kernel\_size} - 1)) - 1) / 2) \quad (4.2)$$

更为直观的形象解释如图 4.1 所示：

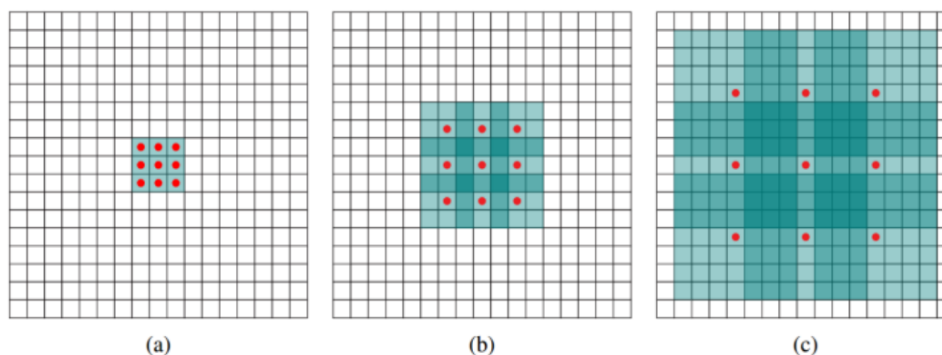


图 4.1 膨胀卷积

Fig.4.1 Dilated Convolution

(a) 图对应  $3 \times 3$  的  $\text{dilated\_rate}=1$  卷积核，实际就是普通的卷积。(b) 图对应  $3 \times 3$  的  $\text{dilated\_rate}=2$  卷积核，本质上卷积核大小  $3 \times 3$ ，增加 1 个空洞。在  $7 \times 7$  图像块内，实际上是  $3 \times 3$  的卷积核与 9 个红色点进行卷积，可以看到卷积核大小虽然只有  $3 \times 3$ ，但是卷积的感受野已经增大到了  $7 \times 7$ 。(c) 图是 4-dilated conv 操作，同理跟在两个  $\text{dilated\_rate}$  分别为 1 和 2 的卷积层后面，能达到  $15 \times 15$  的感受野。对比传统的卷积操作，3 层  $3 \times 3$  的卷积加起来，步长为 1，只能达到  $7 \times 7$  的感受野，也就是和层数成线性关系，而膨胀卷积的感受野是指数级的增长。其好处是在不做池化损失信息的情况下，加大了感受野，让每个卷积输出都包含较大范围的信息。

基于 Resnet 网络的残差结构，以及结合参考苏剑林光谱分类网络<sup>[54]</sup>和 GoogLeNet<sup>[55]</sup>中 Inception 基本结构，搭建了新的卷积模块，实现信息的多路径流通。当输入序列与输出维度保持一致，输入可以直接相加，模块如图 4.2 所示。

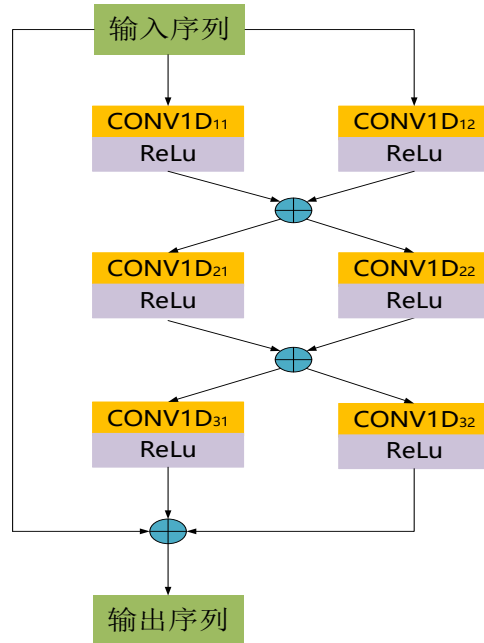


图 4.2 输入与输出维度一致

Fig.4.2 Input and output dimensions are consistent

当输入与输出维度不相等时，类似于 Resnet 网络结构，通过使用卷积核为 1 的卷积层改变通道数，模块如图 4.3 所示。

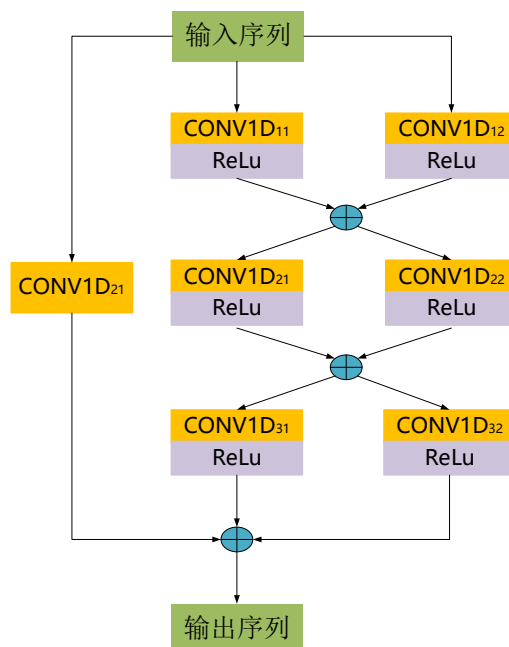


图 4.3 输入与输出维度不相等

Fig.4.3 Input and output dimensions are not equal

Block 结构中，输入序列先进行膨胀卷积，经过 Batch Norm 层和 ReLU 层后，

再通过 Lambad 层，实现通道融合。每个 Block 包含三个卷积层，膨胀卷积  $dilated\_rate$  依次设置为 1, 2, 4。Block 模块代码如下：

```
def block(inputs, filters, name)
    bn_axis = 1 if K.image_data_format()=='channels_first' else -1
    x = Conv1D(filters*2, 3, padding='SAME',dilation_rate=1)(inputs)
    x = BatchNormalization(axis=bn_axis, name=name+'_conv_1')(inptus)
    x = Activation('relu')(x)
    x = Lambda(lambda x: x[:,::filters] + x[:,::filters])(x)
    .....
    if int(inputs.shape[-1])!= filters:
        inptus = Conv1D(filters, 1, padding='SAME',name=name+'_skip_')(inputs)
        inptus= BatchNormalization(axis=bn_axis, name=name+'_bn_skip')(inptus)
        x = add([inptus, x])
        x = Activation('relu')(x)
    return x
```

每个 Block 后都增加一个最大池化用以降维，最后 Dense 层全连接。整个网络结构如图 4.4 所示。




图 4.4 基于 Resnet 优化的网络结构图

Fig.4.4 Resnet-based optimized network structure diagram

### 4.2.2 损失函数

在 Resnet50 网络中，损失函数直接采用常见的交叉熵损失函数对网络进行训练。交叉熵损失是基于 softmax 计算来的，softmax 将网络最后输出  $z$  通过指数转变成概率形式，softmax 计算公式：

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}} \quad (4.3)$$

其中，分子  $e^{z_i}$  是要计算的类别  $i$  的网络输出的指数；分母是所有类别网络输出的指数和，共  $k$  个类别。这样就得到类别  $i$  的输出概率  $p_i$ 。交叉熵损失公式：

$$J = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^k y_{ij} \cdot \log(p_{ij}) \quad (4.4)$$

其中， $y_i$  是类别  $i$  的真实标签； $p_i$  是上面 softmax 计算出来的类别  $i$  的概率； $k$  是类别数， $N$  是样本总数。

针对心电图自动分类评价指标 marco f1\_score，一般来说，F1 值都是不可导的，所以 marco f1\_score 也是不可导，无法直接用来做损失函数。但是可以写出 marco f1\_score 相反数的近似公式，并将其作为损失函数，在接下来的网络训练中将使用该损失函数。f1\_score\_loss 定义代码如下：

```
def f1_score_loss(y_true, y_pred):
    loss = 0
    for i in np.eye(9):
        y_true_ = K.constant([list(i)]) * y_true
        y_pred_ = K.constant([list(i)]) * y_pred
        loss += (2 * K.sum(y_true_ * y_pred_) / K.sum(y_true_ * y_pred_ +
            K.epsilon())) / 9
    return -K.log(loss + K.epsilon()) / 9
```

## 4.3 网络训练

上一章，基于 Resnet50 网络模型对心电图自动分类实验中，网络优化器选择 Adam 算法，损失函数采用 Cross Entropy Loss，测试集准确率 Accuracy 作为模型评价指标。网络训练步骤通过在回调函数进行设置。学习率 lr 根据模型在测试集上的分类准确率进行衰减，即当训练模型在测试集上分类准确率连续 5 个周期没有提升，学习率以 0.2 的倍数衰减，当准确率连续 15 个周期没有增加，网络训练结束，同时在训练中保存最高 F1 得分的模型文件。

基于 Resnet50 优化的网络，直接定义 marco f1\_score 计算函数，并将其作为模型训练的评估指标。函数代码如下：



```
def f1_score_loss(y_true, y_pred):
    y_true = K.argmax(y_true)
    y_pred = K.argmax(y_pred)
    score = 0
    for i in range(9)
        y_true = K.cast(K.equal(y_true, i), 'float32')
        y_pred = K.cast(K.equal(y_pred, i), 'float32')
        score += (2 * K.sum(y_true * y_pred) / K.sum(y_true + y_pred + K.epsilon())) / 9
    return score
```

为使数据集分类评价指标最优，整个网络训练分为两个过程。首先设置初始学习率  $lr$ ，优化器 Adam 和损失函数 Cross Entropy Loss 将模型训练到最优，这一过程类似于之前 Resnet50 网络训练，不同之处在于模型评估指标由测试集准确率  $val\_acc$  换成  $f1\_score$ 。当  $f1\_score$  连续 15 个周期没有提高，本阶段训练结束。然后，网络使用  $f1\_score\_loss$  替换 Cross Entropy Loss 损失函数，同时学习率乘以 0.1 衰减因子继续训练模型到最优。

## 4.4 实验结果及分析

### 4.4.1 不同超参数值的模型分类

本小节中，同样通过对超参数学习率  $lr$ ，dropout，weight\_decay 设置不同值进行模型训练，选择在该网络模型下最优的超参数，使模型分类效果达到最佳。

首先，其他参数不改变，学习率  $lr$  分别为 0.1，0.01，0.001，0.0001，模型分类各评价指标得分，如图 4.5 所示。当  $lr=0.1$  时，模型分类基本没有效果，说明学习率的值选择过大，直接导致网络训练没有收敛。




图 4.5 不同学习率下模型分类结果

Fig.4.5 Model classification results for different learning rate

超参数 dropout 分别取值 0.00, 0.30, 0.50, 0.80, 模型分类表现各评价指标得分, 如图 4.6 所示。




图 4.6 不同 dropout 下模型分类结果

Fig.4.6 Model classification results for different dropout

可以发现, 当其他参数不变, dropout 为 0.0 和 0.8 时, 分类结果相对最差。分析原因, 当 dropout=0.0 时, 网络可能出现了轻度过拟合, 而当 dropout=0.8 时, 网络训练时神经单元大量的暂时丢弃, 直接影响了模型训练, 导致最终在测试集上分类效果不佳。

同样地, 在 weight\_decay 分别取值 0.0, 0.01, 0.0001, 0.0005 时, 模型分类结果, 如图 4.7 所示。该参数目的也是防止网络训练过拟合, 因此 weight\_decay 选值过大或过小都不合适, 当其他参数一定, weight\_decay=0.0001 时, 模型分类表现较好。




图 4.7 不同 weight\_decay 下模型分类结果

Fig.4.7 Model classification results for different weight\_decay

#### 4.4.2 不同卷积核大小的模型分类

深度神经网络中，不同尺寸的卷积核感受野大小不同，需要训练的参数也不同，在 GoogLeNet inceptionV2 网络提出，使用两个连续的  $3 \times 3$  的卷积层组成的小网络代替单个  $5 \times 5$  卷积层，既在保持感受野范围的同时又减少了参数量。在基于 Resnet 残差网络改进的模型中每个 Block 包含三个膨胀卷积，卷积核大小  $\text{kernel\_size}=3$ 。根据一般经验，这里  $\text{kernel\_size}$  分布设置为 3, 5, 7 进行网络训练，如图 4.8 所示。对比模型分类结果，确定大小合适的卷积核。从实验结果来看，卷积核大小等于 5 或 7 时，只是对个别导联特征提取效果较好，而卷积核大小为 3 时可以对每个导联特征总体上有相对好的提取。




图 4.8 不同卷积核大小的模型分类

Fig.4.8 Model classification results for different kernel size

综合各超参数值及卷积核大小下模型分类表现, 基于 Resnet 改进的模型在 ICBEB 心电图数据集上对 9 种心律失常分类结果, 如图 4.9 所示。相比于第三章一维卷积的 Resnet50 网络对心电图自动分类, 改进的模型具有更少的网络层数和待训练参数, 但分类效果却更好。特别是对心律失常 PVC 和 STD, F1 得分分别提升 0.14 和 0.07, 对其他心律失常分别提升 0.01~0.07, 最终实现基于 ICBEB 心电图数据集对心电图 9 种心律失常自动分类评价指标 F1 平均得分 0.74。




图 4.9 优化模型的分类结果

Fig.4.9 classification results for Optimized model

## 4.5 本章小结

本章, 针对一维心电导联数据特点, 基于 Resnet 网络结构, 采用膨胀卷积方式来构建新的卷积模块。考虑到模型分类的评价指标, 网络中用 `f1_score` 替换测试集分类准确率作为模型训练期间的评估标准, 又定义了 `f1_score` 损失函数, 将其应用于网络训练的后期过程。同时, 对超参数以及卷积核大小设置不同值进行训练分类, 选择模型最优分类表现参数。最终取得模型对心电图 9 种心律失常 F1 平均得分 0.74。

## 5 总结与展望

心脏类疾病已经是对人体健康构成重大威胁的常见疾病之一。心电图是可以反映心脏心电活动的重要指标,对心电图的自动分析与分类一直是计算机辅助诊断的热点。尽管在该领域内,各种算法不断提出和改进,但是目前这些研究大多均是针对心拍分类,其虽在数据集上实验精度高,但在临床上效果很差,达不到实际应用,尚还不能为医生提供正确精准的辅助诊断信息。

可见,针对心电图自动分类的研究仍还需要不断深入开展。本文研究了目前深度学习领域普遍应用的卷积神经网络,将其应用到心电图自动分类,并基于 Resnet 提出了优化的网络结构进行心电图分类且取得了一定的研究成果,可以为心脏相关疾病的临床诊断准确率的改善提供支持或帮助。

本论文主要研究工作,总结如下:

①噪声干扰是心电信号自动分析技术首先要考虑的问题。对心电信号影响最严重的三类干扰分别是工频干扰、基线漂移和肌电干扰。针对这三种干扰类型,文中采用了级联滤波器算法来去除不同的干扰类型。实验证明,本文采用的经典数字滤波方法能够很好的实现滤波效果而且对心电信号有较高的保真度。

②针对已有的心电图自动分类研究大多局限于对心拍类型进行分类以及传统的心电图分类方法,通常需要人工设计方法进行特征提取,而能否准确的提取到心电图内在本质特征以及特征提取是否充分,都将直接决定后期分类效果。本文研究了直接利用 Resnet50 网络对 12 导联心电图进行网络自动提取心电图特征,并将特征提取和分类过程相结合,拟合出了决策函数对心电图进行自动分类。

③针对基于 Resnet 网络残差结构,优化卷积模块,改进网络训练过程,构建了新的模型对心电图进行自动分类,最终在 ICBEB 心电数据集上实现了对 12 导联心电图包括正常心律在内的 9 种心律分类,且模型分类准确率 80%,模型分类评价指标 F1 得分 0.74。相比之前在标准心电图数据库上针对心拍的分类,该方法具有更好的泛化能力,更加实际的临床应用。

本文基于卷积神经网络 Resnet50 及优化的网络模型对 12 导联的心电图进行 9 种心律的自动分类方法的研究工作,仅是初步的,实验虽取得一定效果,但仍需要继续研究或改进,主要是:

①本文在 ICBEB 心电数据集上进行研究,包含正常心律在内的 9 种常见心律类型。数据集总体样本依然偏少,特别是一些心律失常类别样本更加稀少,导致样本分布严重不均衡。由于数据集只对一整个 12 导联心电图记录做标注,而导联中的心拍没有标注,这种类型数据样本使得分类难度增大。后续研究中,应获取

更多标注详细的临床数据，以便进一步优化分类算法，提高分类效果。

②论文中，使用卷积神经网络中的 Resnet50 网络进行初步实验探索，并基于 Resnet 结构进行了改进。模型最终分类准确率 80%，评价指标 F1 得分 0.74。虽然这种心电图自动分类的方法具有更好的泛化能力和实际临床意义，但距离真正的临床应用还有很大距离和提升空间，仍需要尝试使用更多深度神经网络，并针对心电图这一特殊数据形式，对网络模型结构及参数进行设计和优化，达到更好的分类效果。

## 参考文献

- [1] Executive Summary: Heart Disease and Stroke Statistics: 2015 Update: A Report From the American Heart Association [R]. American: AHA, 2015
- [2] 蒋玉明. 心脑血管疾病患者急诊救治的研究进展[J]. 吉林医学, 2014(12):2642-2643
- [3] 陈学琴. 基于心电图分析的心律失常分类[D]; 北京交通大学, 2011.
- [4] Rai H M, Trivedi A, Shukla S. ECG signal processing for abnormalities detection using multi-resolution wavelet transform and artificial neural network classifier[J]. Measurement, 2013, 46(9): 3238-3246.
- [5] Addison P S. Wavelet transforms and the ECG: a review[J]. Physiological Measurement, 2005, 26(5): R155-R199.
- [6] Elhanine M, Abdelmounim E Haddadi R, et al. Electrocardiogram signal denoising using discrete wavelet transform[C]// 2014 International Conference on Multimedia Computing and Systems(ICMCS). IEEE.
- [7] Pal S, Mitra M. Empirical mode decomposition based ECG enhancement and QRS detection[J]. Computing in Biology and Medicine, 2012, 42(I): 83-92.
- [8] 郑娉. 基于信号质量评估的动态心电分析系统研究[D]. 东北大学, 2014.
- [9] Xin Yi, Chen Yu1, Hao Wei Tuo. ECG baseline wander correction based on mean-median filter and empirical mode decomposition[J]. Bio-medical materials and engineering, 2014, 24 (1): 365-371.
- [10] 李小燕, 王涛, 冯焕清, 等. 基于小波变换的自适应滤波消除 ECG 中基线漂移[J]. 中国科学技术大学, 2000, 30(4): 450-454.
- [11] J. Pan and W. J. Tompkins. A real-time QRS detection algorithm [J]. IEEE Transactions on Biomedical Engineering . 1985, BME-32(3):230-236.
- [12] Chen HC, Chen SW. A Moving Average based Filtering System with its Application to Real-time QRS Detection [C]. IEEE Computers in Cardiology, 2003, 30: 585-588
- [13] Cuiwei Li, Chongxun Zheng, Changfang Tai. Detection of ECG Characteristic Points Using Wavelet Transforms [J]. IEEE Trans on BME, 1995:42(1):21-28
- [14] Ceylan R, Ozbay Y, Karlik B. A novel approach for classification of ECG arrhythmias: Type- 2 fuzzy clustering neural network [J]. Expert Systems with Applications, 2009, 36 (3,Part 2) :6721 -6726.
- [15] Ceylan R, Ozbay Y. Comparison of FCM, PCA and WT techniques for classification ECG arrhythmias using artificial neural network[J]. Expert Systems with Applications,

- 2007,33(2):286-295.
- [16] Madeiro J P V, Cortez P C, Marques J A L, et al. An innovative approach of QRS segmentation based on first-derivative, Hilbert and Wavelet Transforms.[J]. Medical Engineering & Physics, 2012, 34(9):1236–1246.
- [17] 胡广书, 朱泽煌. 心电图的计算机辅助分析[J]. 生物医学工程学进展, 1995(4):59-60.
- [18] Philip de Chazal, O Dwyer M, Reilly R.B. Automatic classification of heartbeats using ECG morphology and heartbeat interval features[J]. IEEE Transactions on Biomedical Engineering, 2004,51(7):1196-1206
- [19] 李坤阳, 胡广书. 基于心电图分析的心律失常分类[J]. 清华大学学报, 2009, 49(3): 416-423
- [20] S. N. Yu, Y. H. Chen. Electrocardiogram beat classification based on wavelet transformation and probabilistic neural network[J]. Pattern Recognition Letters, 2007, 28(10): 1142-1150.
- [21] C. Ye, M. T. Coimbra, B. V. K. V. Kumar. Arrhythmia detection and classification using morphological and dynamic features of ECG signals[C]. IEEE International Conference on Engineering in Medicine and Biology Society, 2010: 1918-1921.
- [22] Llamado M, Martinez J P. An automatic patient-adapted ECG heartbeat classifier allowing expert assistance[J]. IEEE Transactions on Biomedical Engineering, 2012, 59(8): 2312-2320.
- [23] Liao K Y-K, Chiu C-C, The S-J. A novel approach for classification of congestive heart failure using relatively short-term ECG waveforms and SVM classifier[C]//2015 International Multi Conference of Engineers and Computer Scientists (IMECS 2015).
- [24] Zhang Z, Dong J, Lou X, et al. Heartbeat classification using disease-specific feature selection[J]. Computers in Biology and Medicine, 2014, 46:79-89.
- [25] Escalona-Moran M A, Soriano M C, Fischer I, et al. Electrocardiogram classification using reservoir computing with logistic regression[J]. IEEE Journal of Biomedical and Health Informatics, 2015, 19(3): 892-898.
- [26] Kiranyaz S, Ince T, Gabbouj M. Real-time patient-specific ECG classification by 1-D convolutional neural networks[J]. IEEE Transactions on Biomedical engineering, 2016. 63(3): 664-675.
- [27] Yeh Y-C, Chiou C W, Lin H-J. Analyzing ECG for cardiac arrhythmia using cluster analysis[J]. Expert Systems and Applications, 2012, 39(1): 1000-1010.
- [28] Mishra A K, Raghav S. Local fractal based ECG arrhythmia classification[J]. Biomedical Signal Processing and Control, 2010, 5(2):114-123.
- [29] Sadiq A T, Shukr N H, Classification of cardiac arrhythmia using ID3 classifier based on wavelet transform[J]. Iraqi Journal of Science, 2013, 54(Supplement 4) 1167-1175.
- [30] Kiranyaz S, Ince T, Gabbouj M. Real-time patient-specific ECG classification by 1-D



- convolutional neural networks[J]. IEEE Transactions on Biomedical engineering, 2016, 63(3): 664-675.
- [31] Acharya U R, Oh S L, Hagiwara Y, et al. A deep convolution neural network model to classify heartbeats[J]. Computers in Biology and Medicine, 2017, 89: 389-396.
- [32] Acharya U R, Fujita H, Lih O S, et al. Automated detection of arrhythmias using different intervals of tachycardia ECG segments with convolutional neural network[J]. Information Sciences, 2017, 405: 81-90.
- [33] Acharya U R, Fujita H, Oh S L, et al. Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals[J]. Information Sciences, 2017, 415-416: 190-198.
- [34] Acharya U R, Fujita H, Oh S L, et al. Automated identification of shockable and non-shockable life-threatening ventricular arrhythmias using convolutional neural network[J]. Future Generation Computer Systems, 2018, 79(3): 952-959.
- [35] Liu W, Zhang M, Zhang Y, et al. Real-time multilead convolutional neural network for myocardial infarction detection[J]. IEEE Journal of Biomedical and Health Informatics, 2017, pp(99): 1-1.
- [36] Pourbabaee B, Roshtkhari M J, Khorasani K. Deep convolutional neural networks and learning ECG features for screening paroxysmal atrial fibrillation patients[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, PP(99): 1-10.
- [37] Xia Y, Wulan N, Wang K, et al. Detecting atrial fibrillation by deep convolutional neural networks[J]. Computer in Biology and Medicine, 2018, 93(1): 84-92.
- [38] Yang T, Yu L, Jin Q, et al. Location of origins of premature ventricular by means of convolutional neural network from 12-lead ECG[J]. IEEE Transactions on Biomedical Engineering, 2017, PP(99): 1-1.
- [39] 孙凯, 韩瑞娟, 李坤城. 心脏电-机械耦联与双源 CT 冠脉动脉成像最佳成像时间窗[J]. 中华临床医师杂志. 2013,(23): 254-256.
- [40] 卢喜烈. 12 导联心电图同步诊断学[M]. 人民军医出版社, 1997.
- [41] 刘士杰. 心电图诊断学[M]. 人民卫生出版社, 2003.
- [42] Goldberger A L, Amaral L A, Glass L, et al. Physio Bank Physio Toolkit. PhysioNet: Components of a New Research Resource for Complex Physiologic Signals[J]. Circulation, 2000, 101(23): E215-E220.
- [43] AHA 心电图数据库[EB/OL]. <http://www.physionet.org/physiobank/database/ahadb/>.
- [44] PhysioNet. QT database[EB/OL]. <http://www.physionet.org/physiobank/database/qtddb/>.
- [45] Willems J, Amaud P, van Bommel J, et al. A reference data base for multilead

- electrocardiographic computer measurement programs[J]. Journal of American College of Cardiology, 1987, 10: 1313-1321.
- [46] F. F. Liu, C. Y. Liu\*, L. N. Zhao, X. Y. Zhang, X. L. Wu, X. Y. Xu, Y. L. Liu, C. Y. Ma, S. S. Wei, Z. Q. He, J. Q. Li and N. Y. Kwee. An open access database for evaluating the algorithms of ECG rhythm and morphology abnormal detection. Journal of Medical Imaging and Health Informatics, 2018, 8(7): 1368–1373.
- [47] Y. LeCun, L. Bottou, Y. Bengio, et al. Gradient-based learning applied to document recognition[J]. Proc. IEEE, 1998, 86(11): 2278-2324.
- [48] D. H. Hubel, T. Wiesel. Receptive fields, binocular interaction, and function architecture in the cat's visual cortex[J]. Jour. of Phys., 1962, 160: 106-154.
- [49] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Computer Science, 2017.
- [50] Qayyum A, Anwar S M, Awais M, et al. Medical image retrieval using deep convolutional neural network[J]. Neurocomputing, 2017.
- [51] Miki Y, Hayashi T, Hayashi T, et al. Classification of teeth in cone-beam CT using deep convolutional neural network[J]. Computers in Biology & Medicine, 2017, 80(C): 24-29.
- [52] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, Microsoft Research Deep Residual Learning for Image Recognition. In CVPR 2016.
- [53] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, Zbigniew Wojna. Rethinking the Inception Architecture for Computer Vision. In CVPR 2016.
- [54] 苏剑林.《基于 Conv1D 的光谱分类模型（一维序列分类）》, 2018.
- [55] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[J]. arXiv preprint arXiv:1409.4842, 2014.

## 附 录

## A. 学位论文数据集

|  |            |        |  |             |  |
|--|------------|--------|--|-------------|--|
| 关键词  |            | 密级     |  | 中图分类号       |  |
| 多导联心电图；ICBEB 心电数据库；心律失常；卷积神经网络                 |            | 公 开    |  | TN          |  |
| 学位授予单位名称                                       | 学位授予单位代码   | 学位类别   |  | 学位级别        |  |
| 重庆大学   | 10611      | 专业学位   |  | 硕士          |  |
| 论文题名   |            | 并列题名   |  | 论文语种        |  |
| 基于卷积神经网络的多导联心电图自动分类方法研究                        |            |        |  | 中文          |  |
| 作者姓名   | 杜高飞        | 学号     |  | 20160813067 |  |
| 培养单位名称   |            | 培养单位代码 |  |             |  |
| 重庆大学   |            | 10611  |  |             |  |
| 学科专业   | 研究方向       | 学制     |  | 学位授予年       |  |
| 工程   | 心电图自动分类    | 3 年    |  | 2019        |  |
| 论文提交日期   | 2019 年 6 月 | 论文总页数  |  | 60          |  |
| 导师姓名   | 米德伶        | 职称     |  | 教授          |  |
| 答辩委员会主席  |            | 毛本将    |  |             |  |
| 电子版论文提交格式                                      |            |        |  |             |  |
| 文本（√）    图像（）    视频（）    音频（）    多媒体（）    其他（） |            |        |  |             |  |

## 致 谢

时光荏苒，弹指一挥间，三年的研究生生涯即将结束。在这三年的时间中，实验室的各位老师和同学都给予了我很大的关怀和帮助。在此论文完成之际，我想向所有关心和帮助过的人说声谢谢。

首先，感谢魏彪教授和米德伶教授，不论是在课业学习还是在科研工作中，都给予了我宝贵的建议和支持。在他们的悉心指导下，我的科研能力不断提升。在此，向他们表示最衷心的感谢。

其次，深深感谢冯鹏老师和何鹏老师在研究生期间给予我的帮助，冯老师的悉心指导为我的课题研究提供了不少解决方法，在我遇到困难的时候帮助我鼓励我，使得课题研究得以顺利开展推进。在此，我表示由衷的感谢。

在这三年的学习以及科研工作中，我还要感谢实验室同学在生活和学习中给予我的帮助，特别感谢龙邹荣博士对我课题研究的指导和帮助，还有师兄师姐师弟师妹在研究生期间给予我的照顾和帮助。

最后，感谢父母的悉心养育、谆谆教诲。没有父母的支持与鼓励，就不会成就现在的我，在这里我想对他们说声：谢谢！我将会继续努力，给他们带来更多的惊喜、快乐。

衷心感谢各位专家、教授在百忙之中评阅论文、参加答辩。

杜高飞

二〇一九年五月 于重庆