



河北工业大学
HEBEI UNIVERSITY OF TECHNOLOGY

硕士学位论文

PROFESSIONAL MASTER THESIS

学 院： 电气工程学院

学位类别： 工程硕士

领 域： 电气工程

论文作者： 赵宁

指导教师： 耿读艳

河北工业大学研究生院

二〇二二年 五 月

编号： 201931403057

河北工业大学硕士学位论文

基于深度学习的心律失常分类识别研究

论文作者： 赵 宁

学 生 类 别： 全日制

专业学位类别： 工程硕士

专业学位领域： 电气工程

指导教师： 耿读艳

职 称： 教 授

2022 年 5 月

Thesis Submitted to
Hebei University of Technology
for
The Master Degree in
Electrical Engineering

**Research on classification and recognition of
arrhythmia based on deep learning**

By

Zhao Ning

Supervisor: Prof. Geng Duyan

May, 2022

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文不包含任何他人或集体已经发表的作品内容，也不包含本人为获得其他学位而使用过的材料。对本论文所涉及的研究工作做出贡献的其他个人或集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：

赵宇

日期：2022. 5. 22

关于学位论文版权使用授权的说明

本人完全了解河北工业大学关于收集、保存、使用学位论文的以下规定：学校有权采用影印、缩印、扫描、数字化或其它手段保存论文；学校有权提供本学位论文全文或者部分内容的阅览服务；学校有权将学位论文的全部或部分内容编入有关数据库进行检索、交流；学校有权向国家有关部门或者机构送交论文的复印件和电子版。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

赵宇



日期：2022. 5. 22

导 师 签 名：

耿俊艳

日期：2022. 5. 22

硕士学位论文答辩委员会决议书

论文题目	基于深度学习的心律失常分类识别研究		
<p>决议书内容（就基础知识、创新性、论文价值、科研能力、写作规范性及答辩情况等做出评价）（600字以内）</p> <p>赵宁同学的硕士学位论文“基于深度学习的心律失常分类识别研究”设计了一种心律失常自动识别方法。论文选题具有重要理论意义和应用价值。论文作者查阅了该领域相关文献资料，熟悉该领域国内外研究状况。作者研究了基于 EWT 的 ECG 信号降噪方法，并基于深度学习构建心律失常自动识别模型，实现了 ECG 信号的心律失常自动识别。由实验结果可知，该方法能够满足心血管疾病的心电监测需要。作者掌握了本学科坚实的理论基础和系统的专门知识，具有一定的独立从事科研工作的能力。论文写作层次分明，条理清晰，结构合理，重点突出，符合学位论文写作的规范要求。作者答辩过程措辞准确，能够正确地回答问题。</p> <p style="text-align: center;">综上，答辩委员会认为这是一篇 <u>较高</u>（高、较高、合格、不合格）水平的硕士学位论文。</p> <p>按照“河北工业大学学位授予实施细则”的规定，本答辩委员会于 <u>2022</u> 年 <u>5</u> 月 <u>22</u> 日审议了 <u>赵宁</u> 申请硕士学位的有关材料，组织了答辩会，并采取了无记名投票表决，最后建议 <u>授予</u>（授予、不授予）该生 <u>电气工程</u>（领域）<u>工程</u> 硕士专业学位。</p> <div style="text-align: right; margin-top: 20px;"> <p>答辩委员会主席（签章）： </p> <p>答辩委员会委员（签章）： </p> <p style="text-align: right;">2022 年 5 月 22 日</p> </div>			
投票统计	建议授予硕士学位	建议不授予硕士学位	弃权
	5 票	0 票	0 票

摘要

在心血管疾病的发病初期常会出现心律失常现象，并且会表现在心电信号波形的异变上，通过识别心电信号可以监测心律失常现象。在医疗资源日益紧张的今天，实现心电信号的自动准确识别对防治心血管疾病具有重要意义。目前，心律失常自动识别算法主要作为辅助诊断方法，其识别准确率并不足够满足临床上的需要，如何进一步提高心电信号识别的准确率一直是研究的热点。传统的心电信号自动识别方法依赖于对信号特征的提取，而深度学习提供了一种无需进行特征工程的自动学习方法。利用深度学习在自主学习样本特征上的能力，本文提出了一种基于深度学习的心电信号自动识别方法。本文有如下研究内容：

1、基于经验小波变换（EWT）的心电信号降噪研究。为了滤除心电信号的噪声，本文提出了一种基于 EWT 的心电信号降噪方法，将心电信号通过 EWT 分解得到多个经验模态函数，通过计算过零率和相关系数确认噪声成分，并使用小波阈值法进一步去除噪声。使用公开数据集和实际采集得到的心电信号对提出的去噪方法进行实验，并与基于其他常用的信号时域分解算法的去噪方法进行对比。本文提出的方法满足心电信号实时识别情况下的去噪要求，能够有效去除心电信号的噪声。

2、心律失常识别模型的构建与分析。使用 MIT-BIH 心律失常数据库基于 Intra-Patient 和 Inter-Patient 两种情况设计数据集并划分心拍，基于深度学习构建了 ResNet、ResNet-LSTM 和 MSCResNet-LSTM 三种心律失常识别模型，实现了心律失常的自动分类识别。通过计算模型分类结果的准确度、灵敏度、特异性、查准率和 F1 分数，对模型进行对比分析。MSCResNet-LSTM 综合了多尺度卷积结构（MSC）和长短时记忆网络（LSTM）在提取多层次特征和处理时序信号上的优点，在对心律失常的分类识别上达到了先进水平。

本文研究了基于深度学习的心律失常识别方法，实现了对心电信号的较准确识别，对减轻医疗负担、预防和治疗心血管疾病具有积极意义。

关键词：心律失常；心电信号；深度学习；经验小波变换；残差网络

ABSTRACT

Arrhythmia often occurs in the early stage of cardiovascular disease, and it will be manifested in the abnormality of the ECG signal waveform. By identifying the ECG signal, arrhythmia can be monitored. In today's increasingly tight medical resources, it is of great significance to realize the automatic and accurate identification of ECG signals for the prevention and treatment of cardiovascular diseases. At present, the automatic arrhythmia identification algorithm is mainly used as an auxiliary diagnosis method, and its identification accuracy is not enough to meet the clinical needs. How to further improve the accuracy of ECG signal identification has always been a research hotspot. The traditional automatic identification method of ECG signal relies on the extraction of signal features, and deep learning provides an automatic learning method without feature engineering. Taking advantage of the ability of deep learning in autonomously learning sample features, this thesis proposes an automatic recognition method for ECG signals based on deep learning. This thesis has the following research contents:

1. Research on ECG signal noise reduction based on empirical wavelet transform (EWT). In order to filter out the noise of the ECG signal, this thesis proposes a noise reduction method for the ECG signal based on EWT. The ECG signal is decomposed by EWT to obtain multiple empirical mode functions, and the noise components are confirmed by calculating the zero-crossing rate and the correlation coefficient, the noise is further removed by the wavelet threshold method. The proposed denoising method is tested using the public data set and the actual collected ECG signals, and compared with other denoising methods based on commonly used signal time domain decomposition algorithms. The method proposed in this thesis satisfies the denoising requirements in the case of real-time recognition of ECG signals, and can effectively remove the noise of ECG signals.

2. Construction and analysis of arrhythmia recognition model. Using the MIT-BIH arrhythmia database to design data sets based on Intra-Patient and Inter-Patient, and divide the heartbeat. Three arrhythmia recognition models, ResNet, ResNet-LSTM and MSCResNet-LSTM are constructed based on deep learning to realize arrhythmia automatic classification recognition. The models are compared and analyzed by calculating the accuracy, sensitivity, specificity, precision and F1score of the model classification results.

MSCResNet-LSTM combines the advantages of multi-scale convolution (MSC) and long short term memory (LSTM) in extracting multi-level features and processing time series signals, and has reached an advanced level in the classification and recognition of arrhythmia.

In this thesis, the arrhythmia identification method based on deep learning is studied, which achieves a more accurate identification of ECG signals, has positive significance for reducing medical burden and preventing and treating cardiovascular diseases.

Key words: Arrhythmia; ECG signal; Deep learning; Empirical wavelet transform; Residual network

目 录

第一章 绪论	- 1 -
1.1 研究背景及意义	- 1 -
1.2 国内外研究现状	- 1 -
1.3 主要研究内容	- 3 -
第二章 心电信号的生理意义和深度学习理论	- 5 -
2.1 心电信号的生理意义	- 5 -
2.1.1 心电信号的波形特征及其生理意义	- 5 -
2.1.2 心律失常的病理特异性	- 6 -
2.1.3 心律失常的分类标准	- 8 -
2.2 深度学习相关理论	- 9 -
2.2.1 深度神经网络	- 9 -
2.2.2 卷积神经网络	- 9 -
2.2.3 批归一化算法	- 11 -
2.2.4 激活函数	- 12 -
2.2.5 Dropout 算法	- 14 -
2.2.6 损失函数	- 15 -
2.2.7 优化方法	- 15 -
2.3 本章小结	- 16 -
第三章 基于经验小波分解的心电信号降噪研究	- 17 -
3.1 心电信号噪声分析	- 17 -
3.2 心电信号降噪问题的提出	- 18 -
3.3 相关算法原理	- 19 -
3.3.1 小波变换	- 19 -
3.3.2 经验模态分解	- 20 -
3.3.3 集合经验模态分解	- 21 -
3.3.4 经验小波变换	- 22 -
3.4 经验小波变换去噪算法	- 25 -
3.4.1 经验小波变换存在的问题	- 25 -
3.4.2 改进的经验小波变换方法	- 27 -

3.4.3	心电信号降噪方法	28 -
3.4.4	实验结果与比较	31 -
3.5	本章小结	35 -
第四章	心律失常识别模型构建与分析	37 -
4.1	样本数据集	37 -
4.1.1	数据集划分方法	37 -
4.1.2	心拍划分	37 -
4.1.3	数据集构建	38 -
4.2	评价方法	40 -
4.3	基于 ResNet 的心律失常分类识别	40 -
4.3.1	ResNet	40 -
4.3.2	分类结果	43 -
4.4	基于 ResNet-LSTM 的心律失常分类识别	46 -
4.4.1	长短时记忆网络	46 -
4.4.2	ResNet-LSTM	48 -
4.4.3	分类结果	49 -
4.5	基于 MSCResNet-LSTM 的心律失常分类识别	52 -
4.5.1	MSCResNet-LSTM	52 -
4.5.2	分类结果	54 -
4.6	实验结果分析	57 -
4.7	本章小结	59 -
结论	61 -
总结	61 -
展望	61 -
参考文献	63 -
攻读学位期间所取得的相关科研成果	69 -
致谢	71 -

第一章 绪论

1.1 研究背景及意义

现如今,心血管疾病患者人数正在增加,这在一定程度上是伴随人口老龄化而来的^[1]。根据《中国心血管病报告 2018》显示^[2],约有 2.9 亿人患有心血管疾病。心血管疾病的死亡大多出现在没有明确症状的情况下,对心血管疾病的发生进行警示是十分必要的。多数心血管疾病在发病初期,常发生心律失常现象。在这种情况下,心脏节律出现变化,可能太快也可能太慢,即使是心脏运动的微小变化,也可能导致严重的心律失常发作。它可能会导致呼吸短促,降低心脏的血液泵送能力,引起胸部疼痛,并造成意识缺乏和疲劳。采取适当措施监测心律失常,能够有效防止心血管疾病的发生^[3]。心律失常会引起心电信号时频域特征的改变,这些变化可以通过心电图(electrocardiograph, ECG)识别。

ECG 是一种非侵入式诊断工具,它通过安置在人体皮肤上的电极采集心脏随时间变化的生理电活动,能够以不同导联从不同角度和位置捕捉心脏的电势。心电信号包含人体心跳运动的丰富信息,能够通过波形和节律的异常来指示疾病的状态^[4]。不同类型的心律失常对应了心脏电传导的不同模式,能够被不同波形的心电信号所表示^[5]。由于心电信号描述了心肌活动和心脏状况的大量相关信息,心电信号的监测与分析识别在心律失常疾病的预防和诊断中十分重要。

在过去,心律失常的识别和诊断是通过医生目视观察和解释来完成的,非常依赖医生本身的知识 and 经验,人工分析心电信号也消耗了医生大量的时间和精力。当需要对病人进行持续性得心电监测时,这样的方法不仅成本高昂而且占用了大量的医疗资源。在过去十几年,可穿戴式心电监测设备的种类和数量大大增加^[6],需要医生分析的心电信号数量更多、时间更长,智能医疗的兴起对心电信号检测分析的实时性也有了更高要求,这势必需要更加智能化的手段。如果使用心律失常自动识别算法,将为医生在诊断和治疗心血管疾病中起到重要作用。

1.2 国内外研究现状

传统的心电信号分类算法一般包括两部分,首先是对心电信号进行特征提取,之

后将提取到的特征输入到分类器中而不是直接将原信号作为输入。这类分类算法更集中于提高对信号特征提取的能力而不是网络的结构,如 Yoon 等人^[7]通过离散小波变换和离散余弦变换组合方式提取心电特征,并使用人工神经网络对心电信号进行分类;Minami 等人^[8]通过傅里叶变换观测心电信号中 QRS 波群因节律变动而产生的变化,并利用神经网络识别三种心律失常;Martis 等人^[9]利用小波包分解和高阶谱累积量对正常心拍和异常心拍进行分类;Khadra 等人^[10]通过双谱分析提取信号特征,通过自回归模型对心电信号的种类进行估计;Tuncer 等人^[11]使用离散小波变换和一维十六进制局部模型相结合的算法提取心电特征,并使用最近邻算法进行心律失常的识别;Plawiak 等人^[12]使用 welch 算法和离散傅里叶变换计算信号的功率谱密度,增强信号的特征。张浪飞等人^[13]结合心电信号的频谱分析,使用正弦辅助经验模态分解(Empirical Mode Decomposition, EMD)的方法分解信号,并计算信号分量的色散熵以提取心电信号的多尺度特征;徐晨华等人^[14]将心电信号的 RR 间期、高阶统计量、局部二值模式和小波分量作为特征,使用 XGBoost 算法集成的支持向量机(Support Vector Machine, SVM)实现了心律失常信号的准确分类;刘姝等人^[15]将心电信号双谱矩阵的谱特征作为输入特征,结合采用径向基核函数的 SVM 有效区分异常心电信号。

在很多时候,提取到的信号特征有更高的维度,研究者也会采用如主成分分析、独立成分分析等降维方法对特征向量的大小进行控制。如 Martis 等人^[16]对经离散小波分解提取到的特征使用主成分分析、线性判别分析等方法进行降维,并将降维后的特征向量作为输入添加到分类器中。传统方法使用的分类器主要有神经网络^[17-21]、基于核函数的分类器如 K 最近邻算法(K-Nearest Neighbor, KNN)^[22]、SVM^[23,24]等方法。

深度学习是近年来在机器学习方面非常流行的一种技术,它提供了一种不需要特征工程的知识学习手段^[25]。近年来,深度学习在图像识别^[26]、语言识别^[27]、对象检测^[28]等多个领域带来了突破,深度学习也越来越多应用于临床医疗中^[29]。基于深度学习的心电信号分类算法与传统算法不同点是深度学习网络不需要对原始信号进行特征的提取,直接将原始信号作为输入,深度学习网络即可自主得学习信号的特征,实现心律失常的识别分类。如果为深度学习网络提供足够的数据集,深度学习有潜力学习所有的人工提取特征以及以前未知的特征,并且随着优化问题的不断解决和图形处理单元硬件水平的进步,深层网络的高效使用已经能够实现。有研究显示,在心电信号中,相比于医学专家明确提取的特征,深度学习自动提取的特征更具信息量^[30,31]。基于深度学习的心律失常自动识别已经逐渐成为一个热门的研究领域。Hannun 等^[32]使用 53549 名患者的 91232 条心电记录训练 34 层卷积神经网络(convolutional neural network, CNN)对 12 种心律失常节律的识别能力超过了心脏病学专家。但对大多数

研究者而言,主要的问题是如何使用较少的数据集实现准确的心电信号分类。Li 等^[33]建立了 CNN 模型,并使用特定病人的少量信号微调训练好的 CNN,实现了模型对个体特征的良好识别。Yildirim 等^[34]提出了一种基于小波变换的心电信号识别方法,模型使用双向长短时记忆神经网络,将小波变换嵌入到神经网络的第一层分解输入信号,提高了网络提取特征的能力。Jiang 等^[35]使用 CNN 结合双向特征训练,改善了模型在不平衡数据集下的分类性能。有些研究者通过结合不同类型的神经网络以改善模型的分类性能。张异凡等^[36]提出了一种 CNN 和长短时记忆网络(Long and Short-Term Memory, LSTM)并行网络实现了对心电信号的 5 种分类。Oh 等^[37]提出了一种 CNN-LSTM 网络,能够对可变长度的心电信号进行有效的分类识别。柯丽等^[38]提出了一种 CNN-LSTM 网络,结合 CNN 网络提取特征的优势,提高了心电信号分类的能力。Guo 等^[6]提出了一种密集连接网络(DenseNet)和门控循环单元(Gated Recurrent Neural, GRU)的融合模型,成功实现了未进行预处理的心电信号的分类。依据心电信号的特点,针对性改进神经网络的结构也是研究的重点。杨淑莹等^[39]提出了结构优化的 1D-GoogLeNet 的心电信号分类模型,提高了模型的准确率和运算效率。刘亚楠等人^[40]设计了一种包含空洞卷积的深度残差网络并使用评价指标的相反数的近似函数代替损失函数以获得更高的异常心电信号识别率。蒋明峰等人^[41]改进了 CNN,将金字塔型卷积结构作为神经网络的第一层以实现模型对心电信号多维度特征的学习,使不同的心电信号得到了有效识别。在目前的心律失常识别研究中,很多算法对心电信号的识别取得了不错的结果,但总体上心电信号自动识别算法仍是作为一种辅助诊断方法,如何设计一种准确的心电信号分类算法仍需要不断的深入研究。

1.3 主要研究内容

随着生活水平的提高,人们对拥有高品质的身体状况有了更高的要求,而随着老龄化程度的加深,如心血管疾病等更容易发生在老年人群的相关疾病患病人数不断增加,这导致如今对医疗资源的需求与日俱增。这样的需求和科技的进步共同促进了智能医疗的兴起和发展,心律失常的自动识别是其中研究的热点问题。在足够的数据集下,已经有研究者使用深度学习的方法设计了媲美专业医生的心律失常自动识别系统,但是这样的数据集是宝贵而不易获取的。在现有数据集下,进一步提高心律失常自动识别的准确性一直是研究者们努力的目标。因此,本文提出了一种基于深度学习的心律失常识别方法,旨在为准确识别心律失常这一目标提供一种新的解决方案。本文共有五个章节,每个章节的内容安排如下:

第一章 绪论。绪论主要介绍了本课题的研究背景和意义,并详细介绍了传统的心电信号分类方法和基于深度学习的心电信号分类方法的研究现状。

第二章 心电信号的生理意义和深度学习理论。在这一章中,分别对心电信号和深度学习这两部分进行了介绍。主要介绍了心电信号的生理基础、组成部分和心律失常的特征及心电信号的波形表现,并且介绍了本课题使用的 MIT-BIH 心律失常数据库和心律失常的分类标准。深度学习是本文进行研究的主要方法,卷积神经网络是网络设计的主干部分得到了主要介绍,同时还介绍了批归一化层、激活函数、Dropout 层、损失函数和相关优化方法等深度学习相关知识作为课题研究的理论依据。

第三章 基于经验小波分解的心电信号降噪研究。在这一章节,主要讨论和研究了影响心律失常准确识别的信号噪声。分析了心电信号噪声的主要来源和形式特征,基于经验小波分解在信号分解的优良能力提出了一种基于经验小波分解的降噪方法,并与基于小波变换、经验模态分解、集合经验模态分解这三种常用的信号时域分解手段的降噪方法进行了对比研究。

第四章 心律失常识别模型构建与分析。在本章中,首先对 MIT-BIH 心律失常数据库基于 Intra-Patient 和 Inter-Patient 两种数据集构建方式建立了两个数据集,设计了 ResNet、ResNet-LSTM、MSCResNet-LSTM 三种深度学习模型对心电信号进行自动识别研究,并根据三种模型在两个数据集上的分类结果进行分析研究。

第五章 总结和展望。在这一章中,回顾了本文的主要研究内容,对课题进行了总结,指出了研究中的优势和不足,并展望了未来的进一步研究。

第二章 心电信号的生理意义和深度学习理论

2.1 心电信号的生理意义

2.1.1 心电信号的波形特征及其生理意义

人的心脏被称作向全身输送血液的泵，它被分为四个腔室，由上到下分别为左右心房和左右心室。左心房接受来自肺部富含氧气的血液，这些血液由左心房传递到左心室并由左心室泵到身体的其他器官，血液在被消耗掉氧气后最终返回到右心房并传递到右心室，经由右心室，血液被泵到肺部重新接受氧气。这种运动是由右心房顶部的一些被称作窦房结的细胞有规律得产生电脉冲而触发的心肌收缩的结果。电脉冲经由心肌细胞传播，并使左右心房和左右心室相继收缩和放松，从而将血液输送到全身。这种电脉冲可以由放置在人体表面的电极片采集得到，采集到的信号就是心电信号。

心电信号可以被表示为一组波的组成，这些波随心动周期而周期性的在心电信号上出现，分别是 P 波、Q 波、R 波、S 波、T 波和 U 波，其中 U 波并不常见。一个心动周期的正常心电信号如图 2.1 所示。在心电信号中，每一个波都反应了电脉冲在心肌细胞中传递情况，波的形状和持续时间的异常都可以反映到心律失常疾病上，下面将进一步介绍心电信号中的各种波形。




图 2.1 心电信号波形示意图

Figure 2.1 Schematic diagram of ecg signal waveform

P 波：心电信号第一个明显的波形是 P 波，表示了左右心房因窦房结触发去极化而收缩的现象，这种现象被称作心房收缩。P 波的正常持续时间为 0.06 秒到 0.12 秒之

间，幅值在 0.02-0.03mV 之间。

Q 波：在 P 波之后是 Q 波，代表了电脉冲穿过心房壁后向下移动，到达位于房室隔膜的房室结，房室结触发去极化的现象。Q 波的持续时间小于 0.04 秒，幅值通常小于 0.02mV。

R 波：R 波反映了通过心室壁的电脉冲，它是整个心电周期中幅值最显著的波，R 波通常被用作分析心电信号的基点，如用 R-R 间隔反应心率（HR），用 R-R 间隔的变化表示心率变异性（HRV）。

S 波：S 波反应了浦肯野（purkinje）纤维的去极化现象，这是最后一个去极化的区域。S 波相比于其他波形，在反应心脏疾病现象上并不具有重要意义。

T 波：T 波反应了在下一个心跳周期发生之前，心室的复极化现象，T 波相较于其他波段，持续时间较长，波形较明显。

U 波：心跳周期的最后一个波段是 U 波，U 波是一种特殊的波形并不常见，U 波可能会在摄入酒精和服用与心脏活动相关药物的群体中因电解质失衡或药物影响出现，U 波被认为反应了浦肯野纤维的复极化。

QRS 波群：Q 波、R 波和 S 波组成的波群被称作 QRS 波群，它反应了左右心室的去极化，它的正常持续时间为 0.06 到 0.12 秒之间。QRS 波群含有心电信号的重要信息，对心律失常检测有重要意义。

2.1.2 心律失常的病理特异性

心律失常是由于心电脉冲在起源和传导部位任何地方出现紊乱导致电脉冲在速率和规律上出现变异的现象。心律失常可表现为缓慢、快速或不规则的心跳，严重的心律失常现象可能会危及生命。常见的心律失常有房性早搏、室性早搏、室性融合心跳、左右束支传导阻滞等。简单介绍几种常见的心律失常如下：

房性早搏：情绪紧张，精神波动，过量饮酒，以及心脏器质性病变如甲亢、洋地黄中毒等情况可能会使心房受到兴奋刺激导致提前收缩，P 波提前发生，P 波波形发生异变，在某些情况下可能与上一心跳周期的 T 波重合，PR 间期时间延长。房性早搏会导致心悸、胸闷、乏力，经常是快速室上性心律失常的前兆，房性早搏波形如图 2.2 所示。

室性早搏：室性早搏是最常见的心律失常之一，在窦房结电脉冲抵达心室之前，心室中提前发生电冲动引起心室的提前除极，表现在心电波形上使 QRS 波陡度变小，T 波方向倒置。在临床上，室性早搏产生的症状有很大的变异性，从无症状或轻微心悸到引发严重室性心律不齐导致人体昏厥都有发生。室性早搏波形如图 2.3 所示。




图 2.2 房性早搏

Figure 2.2 Atrial premature beats




图 2.3 室性早搏

Figure 2.3 Ventricular premature beat

室性融合心跳：由窦房结和心房、房室交界、心室等其他部位的异位节律点产生的冲动同时刺激心室产生的室性融合波，视融合程度不同，室性融合心跳的 QRS 波群波形变化不同，室性融合心跳如图 2.4 所示。




图 2.4 室性融合心跳

Figure 2.4 Fusion of ventricular and normal beat

2.1.3 心律失常的分类标准

本实验使用 MIT-BIH 心律失常数据库，这是一个被广泛使用的数据库。数据库的来源是贝斯以色列医院采集的长期动态心电图记录，数据库包含来自 25 名男性和 22 名女性共 47 人，年龄分布为 23 到 89 岁的 48 条心电数据（其中两条记录来自同一名女性），每条记录约 30 分钟，以 360hz 进行采样，由医学专家对每个记录进行了标注。每组记录包含两个导联的信号，一种是肢体导联 II，由放置在胸部的电极记录，另一种则包含了导联 V1，V2，V4 和 V5，在本实验中为保证导联的相同性仅使用了 II 导联的信号。

MIT-BIH 心律失常数据库中的心跳种类有 15 种，并且各种类数量极不平衡，有些类别数量很少而且仅分布在少数记录中，为了能够更好得对数据库中的信号进行分类识别，在本实验中根据美国医疗器械促进协会（Association for the Advancement of Medical Instrumentation, AAMI）标准^[42]，该标准被用于评估检测心律失常的算法性能，将心律失常分为正常搏动（N）、室上性异位搏动（S）、心室异位搏动（V）、融合搏动（F）、未分类的搏动（Q）五大类，如表 2.1 所示。

表 2.1 AAMI 标准心律失常分类

Table 2.1 AAMI standard classification of arrhythmias

心拍类型	子集	标注
正常搏动(N)	正常节律心拍	N
	左束支传导阻滞	L
	右束支传导阻滞	R
	房性逸搏心拍	e
	节性逸搏	j
室上性异位搏动(S)	房性早搏	A
	异常房性早搏	a
	节性早搏	J
	室上性早搏或异常	S

表 2.1 (续)

Table 2.1 (Continuation)

心拍类型	子集	标注
心室异位搏动(V)	室性早搏	B
	室性搏逸	E
融合搏动(F)	室性融合心跳	F
未分类的搏动(Q)	起搏心跳	/
	起搏融合心拍	f
	未分类心跳	Q

2.2 深度学习相关理论

2.2.1 深度神经网络

深度神经网络(Deep Neural Networks, DNN)是深度学习领域中最广义的神经网络。作为一种计算机自动学习模型, DNN 的设计灵感来源是现实自然中生物大脑的神经元结构。DNN 由一组组相互连接的节点组成, 这些节点模拟了生物大脑里相互连接的神经元, 因此这些节点可以被称作人工神经元。就像生物大脑中神经元之间由突触连接并传递信号, 人工神经元之间也存在连接, 这些连接被用来在多层人工神经元之间传递信息。人工神经元在接收到信号后, 对其进行初始计算, 并将输出信号传递给与之相连的其他神经元。神经元与其他神经元之间的连接可以用权重来表示, 连接的重要性反应在权重的大小上, 权重随着网络的学习而不断迭代和更新。在大多数神经网络的实现中, 人工神经元的输出是输入信号进行权重相乘和偏置相加后引入非线性函数(激活函数)的结果。

2.2.2 卷积神经网络

CNN 是一种使用卷积运算的 DNN, 最早由 Lecun^[43]提出以用于识别手写数字。CNN 具有局部连接和权值共享的特点, 不同于直接考虑全部特征的矩阵相乘的计算方法, CNN 通过卷积核只对特征矩阵的局部特征进行卷积计算, 这样的局部计算又被称作感受野。权值共享是指卷积核的权重在遍历特征图时保持不变, 由于局部连接和

权值共享, CNN 极大减少了运算的参数量。卷积运算的计算公式为如式(2.1)所示。

$$(f * g)(x) = \int_{-\infty}^{\infty} f(\tau)g(x-\tau)d\tau \quad (2.1)$$

在实际计算中, 我们更常使用的是离散信号, 离散卷积的计算公式如式(2.2)所示。

$$(f * g)(x) = \sum_{\tau=-\infty}^{\infty} f(\tau)g(x-\tau) \quad (2.2)$$

CNN 通常由卷积层、池化层、全连接层等组成。

(1) 卷积层

卷积层通过卷积核同输入层连接, 卷积核的权重同经过的局部特征相乘, 并在滑动的过程中保持不变, 每个卷积层通常使用多个卷积核以同时学习不同特征。由于卷积核的权重共享和层间的稀疏连接使卷积神经网络的参数量有效减少。卷积层的计算公式为:

$$X_j^l = \sigma(\sum_{i \in M_j} w_{ij}^l * X_i^{l-1} + b_j^l) \quad (2.3)$$

式中, X_j^l 为第 l 层与第 j 个卷积核对应的特征向量, σ 为激活函数, M_j 表示第 l 层的输入特征的集合, w_{ij}^l 表示第 l 层第 j 个卷积核中的第 i 个权重, b_j^l 为偏置权重, $*$ 为卷积运算。




图 2.5 卷积层

Figure 2.5 Convolutional layer

(2) 池化层

池化层与卷积层类似, 以特定步长移动池化区域, 将输入特征的空间维度分割为几个区域, 取每个区域中特征的最大值或平均值, 得到有较小维度的新特征图。池化运算在特征的每个通道维度上独立运算, 因此在池化层之后特征图的通道维度保持不变。池化层实现了数据降维的同时也使有效特征得以保留, 提高了神经网络的鲁棒性, 有效防止网络在训练过程中的过拟合问题。平均池化层如图 2.6 所示, 池化核大小为 $2*2$, 步长为 2, 池化层输出的是每个池化区域的平均值。平均池化层能够在实现降维的同时, 最大程度保留特征信息。




图 2.6 平均池化

Figure 2.6 Average pooling

最大池化层如图 2.7 所示，池化核大小为 2*2，步长为 2，池化层输出的是每个池化区域的最大值，最大池化可以突出特征中响应强烈的部分，避免平均池化的模糊效果。




图 2.7 最大池化

Figure 2.7 Max pooling

(3) 全连接层和 softmax 函数

全连接层中的每一个神经元都可以看作一个特征提取器，对输入特征进行线性融合，输出特征的维度取决于全连接层神经元的个数，全连接层能够实现输出维度的升高与减少。在 CNN 中，全连接层通常作为最后一层神经网络，将特征维度降维以与 softmax 函数相匹配。

Softmax 函数是 logistic 回归在多分类情况的变体，函数的输入维度和输出维度相同，输出的幅值范围为[0, 1]且和为 1。Softmax 的函数表达式如式(2.4)所示。

$$S_i = \frac{e^{x_i}}{\sum_{i=1}^n e^{x_i}} \quad (2.4)$$

其中， x_i 是 softmax 的第 i 个输入，n 是 softmax 的维度， S_i 是 softmax 第 i 个类别的输出，也可以表示为分类模型认为是该类别的概率。

2.2.3 批归一化算法

批量归一化算法在 2015 年由 Ioffe^[44]提出，应用于每层神经网络的非线性激活函数之前。在对神经网络进行训练时，由于特征向量在不同层网络的数据分布不同，同

一层的不同维度的数据分布也不相同,为使模型学习时损失函数能够有效下降,只能以最小的学习率进行迭代。批量归一化算法使不同层、不同维度的数据分布保持一致,可以使模型以较高的学习率进行训练,提高模型迭代优化的速度。

批归一化的计算公式如下:

$$\mu = \frac{1}{m} \sum_{i=1}^m X(i) \quad (2.5)$$

$$\sigma = \frac{1}{m} \sum_{i=1}^m (X(i) - \mu)^2 \quad (2.6)$$

$$\hat{X}(i) = \frac{X(i) - \mu}{\sqrt{\sigma^2 + \epsilon}} \quad (2.7)$$

$$Y(i) = \gamma \hat{X}(i) + \beta \quad (2.8)$$

其中 μ 和 σ 分别为输入特征图的均值和方差, m 为批的数量, $X(i)$ 为输入特征 ($i=1, 2, \dots, m$), $\hat{X}(i)$ 为归一化后的特征。由于 $\hat{X}(i)$ 被限制在正态分布下,通过 γ 和 β 对其进行尺度变换和偏移,增加网络的表达能力,得到输出特征 $Y(i)$ 。 γ 和 β 由网络经训练学习得到。

2.2.4 激活函数

线性计算方法不能解决所有的现实问题,为了使神经网络能够处理非线性问题,激活函数被引入神经网络,激活函数应用于神经元之后,对神经元的输出结果进行非线性计算以适应非线性问题。虽然理论上来说,所有可以进行非线性运算的函数都可以作为激活函数,但实际应用中,研究者更倾向于使用以下几种激活函数。

(1) Sigmoid 函数

Sigmoid 函数也被称作 Logistic 函数,它是最经典的激活函数之一,它将输入值限制在 $[0, 1]$ 范围内,计算公式如式(2.9)所示。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.9)$$

Sigmoid 函数连续可导,函数导数等于函数本身,求导计算非常方便, Sigmoid 函数导数在原点附近数值很大,但在其他区间内导数近似为零,这使得神经网络在反向传播时经过多个 Sigmoid 函数后梯度信息变得极小,不利于神经网络权重参数的优化。

Sigmoid 函数的另一个缺点是函数是非原点对称的，这会导致该神经元的输出结果的均值不为 0，影响神经网络权重更新的效率。Sigmoid 函数波形如图 2.8 所示。




图 2.8 Sigmoid 函数

Figure 2.8 Sigmoid function

(2) Tanh 函数

Tanh 函数与 Sigmoid 函数相似，但函数的输出值取 $[-1, 1]$ 。Tanh 函数的计算公式如式(2.10)所示。

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.10)$$

与 Sigmoid 函数相比，Tanh 的输出均值为 0，一定程度改善了神经网络训练的效率，Tanh 的梯度更大，更有利于神经网络的反向传播。但与 Sigmoid 函数类似，只有在靠近原点的时候，Tanh 函数才有高的梯度值，越趋于两端，梯度越接近为 0，这不利于神经网络权重的优化。Tanh 函数波形如图 2.9 所示。




图 2.9 Tanh 函数

Figure 2.9 Tanh function

(3) ReLU 函数

ReLU 函数能够在输入特征中寻找正值，当函数的输入为正时，函数的输出为函数的输入本身，当函数的输入为负值时，函数的输出为 0。ReLU 函数的表达式如式 (2.11)所示。

$$\text{ReLU}(x) = \max(0, x) \quad (2.11)$$

ReLU 函数实际上就是一个对输入特征取正的函数，所以计算更为简单快速，虽然由于函数的性质，使之在原点不可导，但对于输入的正值，相比于 Sigmoid 和 Tanh 函数，ReLU 函数的梯度始终可求，避免了梯度因多个极小数相乘而趋于零的现象。在卷积神经网络中，ReLU 函数已经被证明是有更好性能的激活函数并得到了广泛应用。ReLU 函数波形如图 2.10 所示。




图 2.10 ReLU 函数

Figure 2.10 ReLU function

2.2.5 Dropout 算法

当使用的数据集数据较少或神经网络相对于数据集较复杂时，可能会出现神经网络对训练数据集过度适应，因而在未参加训练的数据集上准确率较低，出现过拟合现象。这表明神经网络是在记忆数据集而不是学习数据集的特征，这导致网络在训练集上的准确率很高，而在验证集上却不理想。Hinton^[45]在 2012 年提出了 Dropout 算法来防止网络出现过拟合，Dropout 可以视为一种特殊的全连接层，它通常被应用在神经网络的其他连接层之后。Dropout 层断开一定比例的神经元之间的连接，使其他神经元能够独立得学习输入信号的特征，从而避免因为多个神经元之间相互依赖得学习了输入信号的特征权重而出现过拟合现象。

2.2.6 损失函数

损失函数是每一个深度学习模型都不可缺少的重要部分，它表示了模型预测结果值与真实值之间的差异，而深度学习模型训练的目的就是使损失函数减小。损失函数有多种计算方法，交叉熵损失函数是被经常使用的一种损失函数，计算公式如式(2.12)所示。

$$L = -\frac{1}{n} \sum_{i=1}^n y_i \log(x_i) \quad (2.12)$$

其中 x_i 是模型的预测值，通常以 Softmax 函数的输出作为此输入， y_i 是数据的真实标签值，通常以热编码的形式嵌入到模型的训练过程中。

2.2.7 优化方法

优化方法是指为了使损失函数最小，更新深度学习模型中的可学习参数使用的迭代方法。为了有效训练深度学习模型，需要选择合适的优化方法，优化方法有很多种，下面列举出几种常用的优化方法。

(1) 梯度下降法

梯度下降法是深度学习中最流行的优化方法之一。梯度下降法在前向传播时起作用，利用计算损失函数的微分得到梯度值，并利用梯度值寻找更新神经元权重和偏置的最优方向，通过更新神经元权重和偏置使模型的预测值与真实值的差异更小。目前流行的梯度下降法有随机梯度下降法和小批量随机梯度下降法。

随机梯度下降法是对标准梯度下降法的一种改进，标准的梯度下降法每次迭代都要遍历整个数据集，花费时间大大增加，而随机梯度下降法每次迭代只随机使用一个样本，很大程度提高了每次迭代的速度。但引入随机梯度可能会导致模型朝着局部最优的方向优化而偏离正确的方向，为了解决这样的问题，引入了小批量梯度下降法。小批量梯度下降法是相对前两种方法的折中办法，用一个如 128、256 之类的小批量代替全部样本或随机一个样本从而兼顾效率和准确性。

使用梯度下降法时会面临一些问题。首先，学习率的设置是梯度下降法面临的第一个问题，学习率代表了权重更新幅度的大小，如果设置的学习率太小，模型将陷入长时间在向全局最小值更新的过程中，这使得模型的训练难以完成；如果学习率设置的太大，模型在迭代时会越过目标点而使损失函数不可能到达最小点。此外，当使用的数据是稀疏数据时，数据特征出现的频率是不同的，而对所有参数使用相同的学习率会导致罕见的特征和频繁出现的特征以相同程度影响模型权重的更新，而在理想情

况中，罕见的特征应得到更大的学习率以更大程度更新权重。梯度下降法面临的另一个问题是当损失函数是非凸函数时，函数存在局部极小值点和鞍点，在这些点周围所有方向上的梯度都是负数或为零，所以导致梯度下降法很难摆脱这些点，导致优化难以完成。

（2）Adagrad

Adagrad 算法的特点是学习率 η 能够适应低层参数，在每次迭代中，学习率被逐参数得除以历史梯度值的平方和，根据参数出现的频率，学习率 η 能够被设置为不同数据以进行匹配。当参数出现的频率很高时，学习率就会被设置得很低；而参数出现频率很低时，学习率会被设置得很大。因为学习率能够自适应调节，Adagrad 算法被应用于稀疏数据中。使用 Adagrad 算法的好处是不需要人为设置学习率，而只需把学习率设置为一个初始值，但是由于在训练过程中学习率会因为分母梯度值的不断增大而衰减导致训练时间增加，降低了模型更快学习的能力。

（3）Adam

Adam (Adaptive Moment Estimation) 即自适应矩估计算法，这是计算每个参数自适应学习率的另一种算法，除了在计算中储存所有过去梯度值平方和的指数衰减平均值，Adam 算法同样保留了指数衰减的过去梯度值之和。与其他的优化算法相比，Adam 算法收敛更快，模型的学习能力更强，更适合在大数据集和大规模的参数优化问题应用，同时 Adam 算法也解决了学习率消失、方差过大、损失函数波动等问题。

2.3 本章小结

本章主要介绍了心电信号的生理意义和深度学习的相关理论。首先介绍了心电信号的生理基础和各组成波形的特征以及相关心律失常疾病如何影响心电信号的波形，同时介绍了本文使用的心电信号数据库和心律失常的分类标准。接着介绍了深度学习相关理论，包括 DNN、CNN、批归一化算法、激活函数、Dropout 算法、损失函数和相关优化方法，为接下来的心律失常识别研究提供了理论基础。

第三章 基于经验小波分解的心电信号降噪研究

心电信号是一种微弱的电信号，噪声会改变心电信号的波形，掩盖心脏电活动的重要信息，影响对心律失常的诊断。为了消除噪声，提高心电信号的波形质量，获取心电信号的真实信息，本章结合经验小波变换（Empirical Wavelet Transform, EWT）在信号分解上的优势，提出了一种心电信号降噪方法。

3.1 心电信号噪声分析

心电信号是一种生物电信号，在采集过程中容易收到噪声的干扰^[46]。常见的心电信号噪声有如下几种。

（1）基线漂移

基线漂移噪声通常是因人体的呼吸运动产生的，表现为 0.5-1Hz 的低频信号。基线漂移噪声对心电信号中的 PQ 波段和 ST 波段有较大影响，基线漂移会使信号波形失真，影响心电信号的心律失常检测。

（2）工频干扰

工频干扰是因为心电信号采集装置电子元件中电容和电感耦合产生的固有噪声，通常为 50Hz 或 60Hz，这部分噪声频率相对固定，比较容易去除。

（3）肌电干扰

心脏附近的肌肉收缩能够被心电图捕捉到，反应到波形上为小幅度震荡的波。人体其他肌肉的活动也能够被心电图读取成为信号中的噪声。这些噪声被称作肌电干扰。肌电干扰频率通常位于 10-300Hz 内，频率分布范围广且与心电信号的主要成分在频率上重叠，导致其对心电信号有较大干扰。

（4）运动伪影

运动伪影通常表现为一些具有较大峰值的振幅，严重影响了对心电信号 R 波的观测，使心率计算失真。这些运动伪影通常是由于在心电采集时人体较大幅度的运动或电极片位移产生的，提高采集质量可以较大程度消除这些噪声。

（5）环境噪声

荧光灯和电子产品有时会影响到心电信号的采集，使之产生伪影，这些噪声被称作环境噪声，通过一些适当的措施如减少使用电子设备等能够较大程度得消除这些噪声。

3.2 心电信号降噪问题的提出

如何消除心电信号的噪声一直是一个热门的问题,研究者在对心电信号进行去噪研究时使用的方法有很多种,如自适应滤波器^[47-49]、FIR 滤波器^[50,51]、卡尔曼滤波器^[52]、主成分分析^[53]等,一些研究也采用了非线性的滤波方法如贝叶斯滤波^[54]、非线性投影滤波^[55],基于非局部均值(Non Local Mean, NLM)^[56]的降噪方法也有很好的效果。近些年,神经网络^[57-60]也被应用于心电信号的降噪中。但最常用的是基于时域信号分解算法的降噪方法^[61-69],如小波变换、EMD、集合经验模态分解(Ensemble Empirical Mode Decomposition, EEMD)等。很多方法都表现出了良好的心电信号去噪能力,但它们也会存在各自的问题和缺点。

自适应滤波器常用于去除运动伪影和肌电干扰噪声,它的主要缺点是需要一个参考信号,但在一些情况下,这样的参考信号并不容易得到。卡尔曼滤波在保持信号的边缘部分上有较好的能力,但是在实验中需要手动初始化一个完整心电信号周期的幅值、宽度、相位等相关参数^[54]。在多导联心电信号的去噪中,主成分分析法可以利用不同导联信号的相关性获得更好的去噪性能,但在单导联心电信号的去噪中,主成分分析法的效果不太理想^[53]。基于 NLM 的去噪方法容易受到特殊斑块的影响,在对心电信号的高频成分如 QRS 波群的去噪时不够有效^[56]。基于神经网络的降噪方法通常需要大量数据集,并且在模型的训练上耗费较多时间。在基于时域信号分解算法中,基于小波变换的硬阈值或软阈值去噪方法是常用的算法,然而这种方法不能很好得保持信号边缘,并且去噪能力与小波基的选择有很大关系,应用小波变换去噪有很大的局限性。而 EMD 由于本身存在的模态混叠问题,导致分解得到的本征模态函数并不准确,重构后信号仍会存在噪声。EEMD 通过向信号多次添加白噪声解决了模态混叠问题,但由于本身的迭代计算使算法计算复杂,并且添加的白噪声也增加了重构误差。

结合 EMD 的自适应能力和小波变换的严谨性, Gilles^[70]提出了 EWT 的方法,通过计算边界使小波滤波器组提取经验模态函数(Empirical Mode Function, EMF)以实现信号的分解。EWT 旨在通过信号自身特性构建小波基函数,并通过一组适当的小波滤波器组来提取信号的不同成分, Gilles 在实验中证明了相比于 EMD, EWT 在信号的时域分解上有更好的能力。在本文中,通过结合 EWT 在信号分解中的优良能力,提出了一种基于 EWT 的心电信号降噪方法,并通过与其他常用方法的对比实验验证了该方法在心电降噪上的能力。

3.3 相关算法原理

3.3.1 小波变换

小波变换是一种具有多分辨率的信号分析算法,能够从时域和频域上同时对信号进行分析,对非平稳信号有良好的适应能力。

小波是一种有限长度、均值为零的特殊波形,之所以被称作“小波”,是因为其有几个特点:(1)小波函数在时域上具有紧支撑集或近似紧支撑集,即小波是一种快速衰减的有限波形。(2)小波函数幅值呈现正负交替的震荡形式,且均值为零。(3)小波在时域上的能量是有限的且集中在某一点。

小波分析的讨论是建立在 $L^2(R)$ 上,若有函数 $\psi(t) \in L^2(R)$, 函数 $\psi(t)$ 的傅里叶变换 $\hat{\psi}(\omega)$ 满足:

$$\int_{-\infty}^{+\infty} |\hat{\psi}(\omega)|^2 |\omega|^{-1} d\omega < +\infty \quad (3.1)$$

则 $\psi(t)$ 可被作为一个母小波函数。

在得到母小波函数后,对其进行伸缩和平移变换,如式(3.2)所示。

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \quad (3.2)$$

其中 $\psi_{a,b}(t)$ 是小波基函数。 a 为尺度因子,用以控制小波基的宽窄, b 为平移因子,用于控制小波基的中心位置且 $a, b \in R, a \neq 0$ 。

设有信号 $x(t)$, 则信号 $x(t)$ 的小波变换为:

$$W_x(a,b) = \langle x, \psi_{a,b} \rangle = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{+\infty} x(t) \bar{\psi}\left(\frac{t-b}{a}\right) dt \quad (3.3)$$

其中, $W_x(a,b)$ 表示对 $x(t)$ 的连续小波变换, $\bar{\psi}$ 表示取 ψ 的共轭运算。

由式 3.3 可以看出, $W_x(a,b)$ 是一个二维函数,即连续小波变换实现了信号从一维到二维的转换,为对信号进行时频域分析提供了理论基础。在实际应用中,常使用小波变换的离散形式,当 $a = a_0^j, b = a_0^j k$ 时,小波变换离散化过程如式(3.4)、(3.5)所示。

$$\psi_{j,k}(t) = a_0^{-j/2} \psi(a_0^{-j}t - k), \quad j, k \in Z \quad (3.4)$$

$$W_x(j, k) = \langle x(t), \psi_{j,k}(t) \rangle = a_0^{-j/2} \int_{-\infty}^{+\infty} x(t) \bar{\psi}(a_0^{-j}t - k) dt \quad (3.5)$$

小波变换可以理解为将待分析信号表示为不同尺度因子和平移因子的小波基的投影叠加，通过调整尺度因子和平移因子 a 和 b ，小波变换在不同时域和频域尺度上与信号相匹配，实现了信号在时频域上的局部化分析。由此可见，小波变换可以视为一组滤波器组，其中每种滤波器对应一种震荡模式。

3.3.2 经验模态分解

EMD 是一种基于时域信号的自适应分解方法，并能够应用于非线性非平稳信号。相对于小波变换，EMD 最显著的特点是不需要选定基函数，信号按特定的规则自适应分解为多个本征模态函数。在 EMD 的思想中，任何信号都可以被分解为若干个本征模态函数。

本征模态函数受两个条件的约束：

- (1) 在整个信号的时间历程中，信号不能在横轴的一侧反复波动，即信号的极值点和过零点最大相差为 1。
- (2) 在任意时刻，由局部极大值组成的上包络线和局部极小值组成的下包络线的平均值为零，即上包络线与下包络线以横轴局部对称。

EMD 算法的具体流程如下：

寻找信号 $x(t)$ 的所有局部极大值点和极小值点，并以三次样条插值法分别拟合局部极大值点之间的线条和局部极小值点之间的线条，被称作上包络线和下包络线。求取上包络线和下包络线的平均值曲线 $m(t)$ ，对信号 $x(t)$ 与 $m(t)$ 做差得到差值 $h_1(t)$ 如式 (3.6) 所示。

$$x(t) - m_1(t) = h_1(t) \quad (3.6)$$

判断 $h_1(t)$ 是否满足本征模态函数的两个约束条件，如果约束条件成立， $h_1(t)$ 即为第一个本征模态函数，如果条件不满足，则以该信号为基础，重复上述过程：

$$h_1(t) - m_{11}(t) = h_{11}(t) \quad (3.7)$$

其中 $m_{11}(t)$ 为信号 $h_1(t)$ 上下包络线的均值曲线。

假设经过 k 次重复后，第 k 次的差值结果 $h_{1k}(t)$ 满足本征模态函数的两个约束条

件,以 $h_k(t)$ 为第一个本征模态函数设为 $c_1(t)$, 计算信号 $x(t)$ 与 $c_1(t)$ 的差值 $r_1(t)$, 以 $r_1(t)$ 为剩余分量:

$$x(t) - c_1(t) = r_1(t) \quad (3.8)$$

以 $r_1(t)$ 为新的输入信号, 重复上述过程, 直到剩余分量 $r_n(t)$ 为单调函数为止, 得到 n 个本征模态函数, 以 $c_n(t)$ 表示:

$$r_{n-1}(t) - c_n(t) = r_n(t) \quad (3.9)$$

此时, EMD 的分解过程结束, 待分解信号 $x(t)$ 可以表示为:

$$x(t) = \sum_{i=1}^n c_i(t) + r_n(t) \quad (3.10)$$

3.3.3 集合经验模态分解

在应用于实际信号时, EMD 容易产生模态混叠问题, 这是因为 EMD 的分解与信号的局部极值点分布相关, 而噪声的存在会使局部极值点发生偏移从而导致由 EMD 分解产生的本征模态函数存在误差。

Wu 等人^[71]提出的 EEMD 算法是 EMD 算法的优化, 目的是解决 EMD 算法存在的模态混叠问题。在对信号进行分解时, EEMD 多次向信号添加白噪声, 将信号不同时间尺度的趋势分解开, 形成多个不同尺度的时间序列, 同时补充信号缺失的尺度信息, 在多次实验后求取均值, 在这个过程中, 只有真实信号是维持不变的, 而白噪声相互抵消, 从而更加接近真实信号的分解结果。

EEMD 算法的具体过程如下:

- (1) 对原始信号 $x(t)$ 添加白噪声信号 $\sigma_i(t)$, 得到新的信号 $s_i(t)$:

$$s_i(t) = x(t) + \sigma_i(t) \quad (3.11)$$

- (2) 对信号 $s_i(t)$ 进行 EMD 分解, 得到多个本征模态函数:

$$s_i(t) = \sum_{j=1}^n c_{i,j}(t) + r_{i,n}(t) \quad (3.12)$$

- (3) 继续对 $x(t)$ 添加新的白噪声 $\sigma_i(t)$, 重复步骤 (1)、(2)。

- (4) 将重复 N 次得到的各本征模态函数按顺序分组, 并求取均值, 作为最终求得的本征模态函数:

$$c_n(t) = \frac{1}{N} \sum_{i=1}^N c_{i,n}(t) \quad (3.13)$$

(5) 最终原始信号 $x(t)$ 可以表示为:

$$x(t) = \sum_{i=1}^n c_i(t) + r_n(t) \quad (3.14)$$

3.3.4 经验小波变换

通过构建与待处理信号相适应的小波族, Gilles 提出了 EWT 的方法, 首先对信号的傅里叶频谱自适应分割计算边界, 基于计算边界构建小波滤波器组提取 EMF 以实现信号不同成分的提取。依据香农准则将信号的傅里叶频谱规范化在 $[0, \pi]$ 区间, 将频谱分割为 N 个片段, 用 ω_n 表示分割点的位置 (分割点 ω_0 为 0, 分割点 ω_N 为 π), 当 n 取 $[0, N]$ 时, 第 n 个频谱片段为 $[\omega_{n-1}, \omega_n]$ 。如图 3.1 所示, 以每个 ω_n 为中心, 定义 T_n 为过渡相宽, 长度为 $2\tau_n$, 以图中的阴影部分表示。




图 3.1 EWT 频谱划分示意图

Figure 3.1 Schematic diagram of EWT spectrum division

经验小波被定义为每个分割段上的带通滤波器, 并在全频域构成带通滤波器组。基于构造 littlewood-paley 和 meyer 小波的思想, 并用一定比例的 ω_n 表示 τ_n , 即以 $\gamma\omega_n$ 表示 τ_n , 定义经验尺度函数 $\hat{\phi}_n(\omega)$ 和经验小波 $\hat{\psi}_n(\omega)$:

$$\hat{\phi}_n(\omega) = \begin{cases} 1 & |\omega| \leq (1-\gamma)\omega_n \\ \cos\left[\frac{\pi}{2}\beta\left(\frac{1}{2\gamma\omega_n}(|\omega| - (1-\gamma)\omega_n)\right)\right] & (1-\gamma)\omega_n \leq |\omega| \leq (1+\gamma)\omega_n \\ 0 & \text{其他} \end{cases} \quad (3.15)$$

$$\hat{\psi}_n(\omega) = \begin{cases} 1 & (1+\gamma)\omega_n \leq |\omega| \leq (1-\gamma)\omega_{n+1} \\ \cos \left[\frac{\pi}{2} \beta \left(\frac{1}{2\gamma\omega_{n+1}} (|\omega| - (1-\gamma)\omega_{n+1}) \right) \right] & (1-\gamma)\omega_{n+1} \leq |\omega| \leq (1+\gamma)\omega_{n+1} \\ \sin \left[\frac{\pi}{2} \beta \left(\frac{1}{2\gamma\omega_n} (|\omega| - (1-\gamma)\omega_n) \right) \right] & (1-\gamma)\omega_n \leq |\omega| \leq (1+\gamma)\omega_n \\ 0 & \text{其他} \end{cases} \quad (3.16)$$

式中： $2\gamma\omega_n$ 是过渡相宽的长度($0 < \gamma < 1$)， $\beta(x)$ 是满足式(3.17)的任意函数，如式(3.18)。

$$\beta(x) = \begin{cases} 1 & x \geq 1 \\ 0 & x \leq 0 \end{cases}, \beta(x) + \beta(1-x) = 1, \forall x \in [0, 1] \quad (3.17)$$

$$\beta(x) = x^4(35 - 84x + 70x^2 - 20x^3) \quad (3.18)$$

傅里叶频谱的分割方法关系到经验小波分解分析信号时的适应能力，如果设定将信号的傅里叶频谱分割为 N 个片段，除去 $0, \pi$ 两个分割点外还需要 $N-1$ 个分割点。分割点的确定方法有两种情况：

(1) 当信号的傅里叶频谱中的极大值点个数大于等于 N 时，取前 N 个极大值，并将两个相邻极大值点中间的极小值点作为分割点；

(2) 当傅里叶频谱的极大值点个数小于 N 时，更改频谱分段数 N 为现在的极大值数，仍取两个相邻极大值点中的极小值点作为分割点。

依据 meyer 小波的思想，当 $\sum_{k=-\infty}^{+\infty} \left(\left| \hat{\phi}_1(\omega + 2k\pi) \right|^2 + \sum_{n=1}^N \left| \hat{\psi}_n(\omega + 2k\pi) \right|^2 \right) = 1$ 时，

$\{\phi_1(t), \{\psi_n(t)\}_{n=1}^N\}$ 是一组紧支撑。由于频谱 2π 的周期性（如图 3.2 所示），只关注区间

$[0, 2\pi]$ 就够了，可以写出 $[0, 2\pi] = \bigcup_{n=1}^N \Lambda_n \cup \bigcup_{n=1}^N \Lambda_{\sigma(n)}$ 。 $\Lambda_{\sigma(n)}$ 与 Λ_n 幅值相同，但以 $2\pi - \nu_n$

代替 ν_n 为中心。




图 3.2 滤波器组周期性示意图

Figure 3.2 Diagram of filter bank periodicity

当 $\omega \in (\bigcup_{n=1}^N \Lambda_n / \bigcup_{n=1}^N T_n) \cup (\bigcup_{n=1}^N \Lambda_{\sigma(n)} / \bigcup_{n=1}^N T_{\sigma(n)})$ 时:

$$\left| \hat{\phi}_1(\omega) \right|^2 + \left| \hat{\phi}_1(\omega - 2\pi) \right|^2 + \sum_{n=1}^N \left(\left| \hat{\psi}_n(\omega) \right|^2 + \left| \hat{\psi}_n(\omega - 2\pi) \right|^2 \right) = 1. \quad (3.19)$$

根据 β 的性质, 如果 T_n 连续不重叠, T_n 也满足:

$$\tau_n + \tau_{n+1} < \omega_{n+1} - \omega_n \Leftrightarrow \gamma \omega_n + \gamma \omega_{n+1} < \omega_{n+1} - \omega_n \Leftrightarrow \gamma < \frac{\omega_{n+1} - \omega_n}{\omega_{n+1} + \omega_n} \quad (3.20)$$

这个条件必须对所有的 n 都成立, 即对最小的 T_n 也成立, 通过适当得选取参数,

当 $\gamma < \min_n \left(\frac{\omega_{n+1} - \omega_n}{\omega_{n+1} + \omega_n} \right)$ 时, $\{\phi_1(t), \{\psi_n(t)\}_{n=1}^N\}$ 是一组在 $L^2(R)$ 上的紧支撑。

以传统的小波变换相同的方法定义经验小波函数 $W_f^\varepsilon(n, t)$:

$$W_f^\varepsilon(n, t) = \langle f, \psi_n \rangle = \int f(\tau) \overline{\psi_n(\tau - t)} d\tau = (\hat{f}(\omega) \overline{\hat{\psi}_n(\omega)})^\vee \quad (3.21)$$

通过与尺度函数的内积定义近似系数 $W_f^\varepsilon(0, t)$:

$$W_f^\varepsilon(0, t) = \langle f, \phi_1 \rangle = \int f(\tau) \overline{\phi_1(\tau - t)} d\tau = (\hat{f}(\omega) \overline{\hat{\phi}_1(\omega)})^\vee \quad (3.22)$$

其中, 上标 \wedge 和 \vee 代表傅里叶变换和逆变换。

经验模态函数 f_k 可以写作:

$$f_0(t) = W_f^\varepsilon(0, t) * \phi_1(t) \quad (3.23)$$

$$f_k(t) = W_f^\varepsilon(k, t) * \psi_n(t) \quad (3.24)$$

其中, $*$ 代表卷积运算。

信号 $f(t)$ 的重构公式如下:

$$f(t) = W_f^e(0, t) * \phi_1(t) + \sum_{n=1}^N W_f^e(n, t) * \psi_n(t) = f_0(t) + \sum_{n=1}^N f_k(t) \quad (3.25)$$

由此实现了信号基于 EWT 的分解与重构。

3.4 经验小波变换去噪算法

3.4.1 经验小波变换存在的问题

EWT 提取信号不同成分的能力很大程度上取决于信号频谱的划分, 心电信号频谱频带范围广, 幅值变化大, 使用传统的 EWT 频谱分割方法并不能够良好适应心电信号的频谱特点。为了探究在心电信号去噪问题上 EWT 存在的问题, 使用 MIT-BIH 心律失常数据库中 106 号心电信号的一条噪声较少的片段作为测试的信号, 信号如图 3.3 (a) 所示。该信号采样点数为 1800 个点, 时长为 5 秒, 由图看出该信号波形较为清晰, 噪声较少。为了能够更清晰得展示 EWT 的去噪能力, 为信号添加 20dB 的白噪声以模拟肌电噪声, 添加频率为 0.3Hz 幅值为 0.2mV 的正弦信号以模拟基线漂移噪声, 添加完噪声后的信号如图 3.3 (b) 所示。




图 3.3 (a) 106 号记录; (b) 添加噪声的 106 号记录

Figure 3.3 (a) The record of no.106; (b) Add noise to record no.106

使用传统的 EWT 的频谱分割方法对 106 号心电信号进行频谱划分, 考虑信号去噪的时间成本和去噪效果, 将频谱的分段数设置为 12。信号的傅里叶频谱和分段情况

如图 3.4 所示，图中红色虚线为分割线，可以看出由于频谱幅值震荡变化的特点，前 N 个极大值点都处于信号频谱的低频部分。由此，频谱分割线密集得位于频谱低频部分而忽略了其他部分，削弱了经验小波变换对心电信号不同成分的提取能力。




图 3.4 频谱分段情况

Figure 3.4 Spectrum segmentation

106 号心电信号片段的 EMF 分解情况如图 3.5 所示，可以看出 EMF12 包含了信号的大部分信息，该模态函数的幅值明显高于其他成分，而其他的 EMF 只反应了信号信息的一小部分。由此发现，传统的 EWT 的频谱划分方式并不能使算法有效提取心电信号中的不同成分。

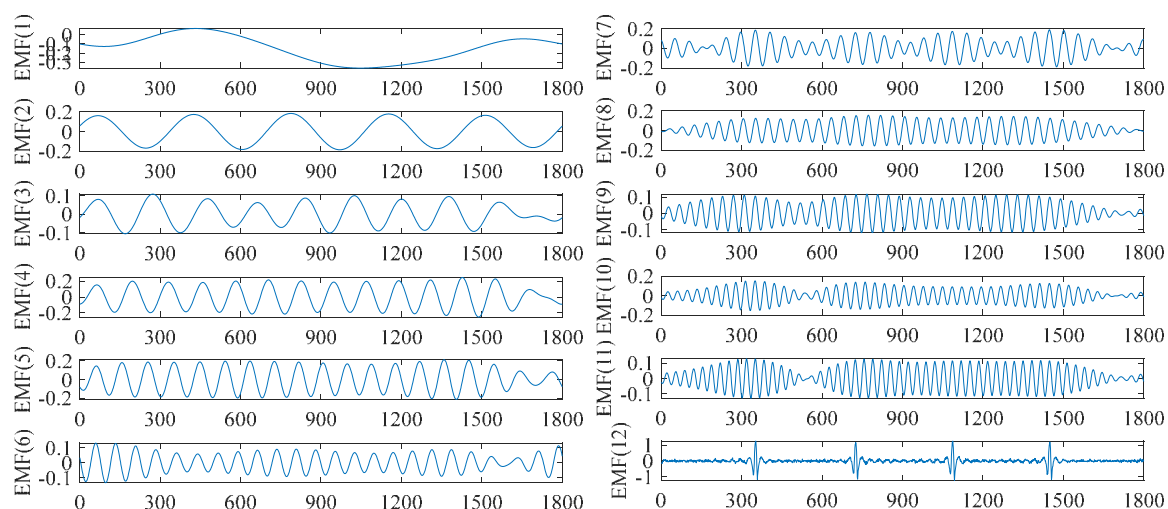


图 3.5 EMF 分量

Figure 3.5 EMFs

3.4.2 改进的经验小波变换方法

在进行频谱分割时，我们希望分割的频带能够体现心电信号全频域的信息，基于心电信号的傅里叶频谱特点，本文提出了一种改进的频谱分割方法。原方法在分割时过度注重低频而忽视了信号的中高频部分，改进后的方法通过阈值选择对信号频谱进行了全频域的划分。假定将频谱划分为 N 段，首先计算目标信号的傅里叶频谱，找出所有的极大值点，将相邻极大值点间的极小值点设为分割点 ω_n ，以阈值 Th_n 来限制分割点 ω_n 的选取，最终得到 $N-1$ 个分割点。 Th_n 的计算公式为：

$$Th_n = a \times k^{n-1} \quad (3.26)$$

$$\omega_{n+1} - \omega_n \geq Th_n \quad (3.27)$$

式中，阈值系数 a ， k 由经验确定，经过实验，在这里取 0.978 和 1.2； n 表示第 n 个分割点，取值范围为 $[1, N-2]$ 。

将测试用的 106 号心电信号片段使用改进的频谱分割方法进行傅里叶频谱的划分，结果如图 3.6 所示。可以看出，相比于传统的分割方法，改进后的方法划分的频带更均匀，兼顾了低频、中频和高频，同时心电信号的绝大部分成分都处于低中频，所以以渐增的阈值使低频段频带密集，高频段频带稀疏。




图 3.6 修改后的频谱分段情况

Figure 3.6 Modified spectrum segmentation

使用改进的方法划分频带后，信号经由 EWT 的分解结果如图 3.7 所示。中低频 EMF 的信号波形有明显的周期性，而高频 EMF 很大程度上被噪声淹没。不同的 EMF

基本上体现了心电信号在不同频段的有效成分。结果表明，经过改进的 EWT 频谱划分方式能够有效实现对心电信号不同成分的提取，为接下来心电信号的降噪提供了基础条件。

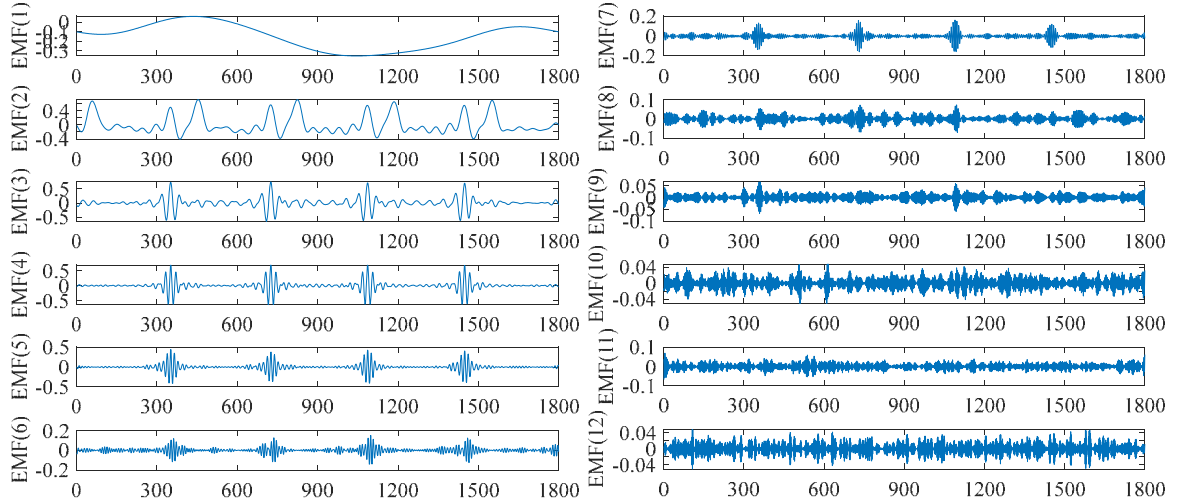


图 3.7 修改后的 EMF 分量

Figure 3.7 Modified EMFs

3.4.3 心电信号降噪方法

基线漂移噪声频率低于 1Hz，通常处于信号的第一个 EMF，如果信号含有基线漂移分量，那么第一个 EMF 的主要成分也将会有极低的频率，在计算机上可以通过计算过零率来识别该 EMF 是否为基线漂移噪声分量，计算公式为：

$$Z_n = \frac{1}{2} \sum_{m=2}^M |Sgn[emf_n(m)] - Sgn[emf_n(m-1)]| \quad (3.28)$$

$$Sgn(x) = \begin{cases} 1 & x \geq 0 \\ -1 & x < 0 \end{cases} \quad (3.29)$$

其中， emf_n 代表第 n 个 EMF， M 代表了 EMF 的采样点数。

心电信号主要成分的频率通常低于 100Hz，而其主要能量更是集中在 45Hz 以下，在更高频带上的信号可以被视为高频噪声，可以通过计算高次模态函数与原信号的相关系数，并将相关系数过低的模态函数视为噪声分量以去除高频噪声的影响，相关系数计算公式为：

$$R(f, emf_n) = \frac{\sum_{t=1}^M [f(t) - \bar{f}][emf_n(t) - \overline{emf_n}]}{\sqrt{\sum_{t=1}^M [f(t) - \bar{f}]^2} \sqrt{\sum_{t=1}^M [emf_n(t) - \overline{emf_n}]^2}} \quad (3.30)$$

式中, f 为原信号, M 代表了信号的采样点数量。

仍以 106 号心电信号片段为例, 各模态函数的相关系数计算结果如图 3.8 所示, 模态函数 2、3、4 与原信号的相关系数最高, 这也再次印证了心电信号有效成分的频带主要位于中低频。为了将高频噪声干扰去除, 通过多次实验选择以 0.05 为阈值筛除高频噪声分量, 在该心电信号片段中即模态函数 9-12, 在这些模态函数中, 心电信号的真实信息较少, 大部分成分为高频噪声, 在重构计算中将它们去除有助于实现信号的良好去噪。




图 3.8 相关系数曲线

Figure 3.8 Correlation coefficient curve

肌电干扰噪声的频带范围通常位于 10-300Hz, 与心电信号的真实信息成分有很大程度上的重叠, 所以将排除了基线漂移和高频噪声分量之后的 EMF 通过小波阈值法进一步去噪, 小波基选择常见的 sym8, 该小波基在心电信号去噪上有良好的效果^[64], 分解层数选择为 6 层, 并将处理过的 EMF 通过 EWT 的规则进行重构, 以实现信号噪声的有效去除。将前述的添加了噪声后的 106 号心电信号通过本文提出的降噪算法进行去噪, 结果如图 3.9 所示。可以看出去噪后信号波形平滑, 去除了肌电噪声和基线漂移影响, 同时原心电信号的波形得到了极大程度的保留。结果表明, 基于 EWT 的心电信号降噪方法能够有效滤除信号的噪声干扰, 还原信号的真实信息。




图 3.9 (a) 降噪前信号; (b) 降噪后信号

Figure 3.9 (a) Signal before noise reduction; (b) Signal after noise reduction

基于 EWT 的心电信号降噪算法流程如图 3.10 所示, 首先将待降噪信号通过 EWT 分解得到不同的 EMF, 之后通过计算过零率和相关系数将基线漂移分量和高频噪声分量筛除, 通过小波变换的去噪方法对 EMF 剩余噪声实现有效的去除, 最后对处理后的 EMF 进行重构实现心电信号的降噪。

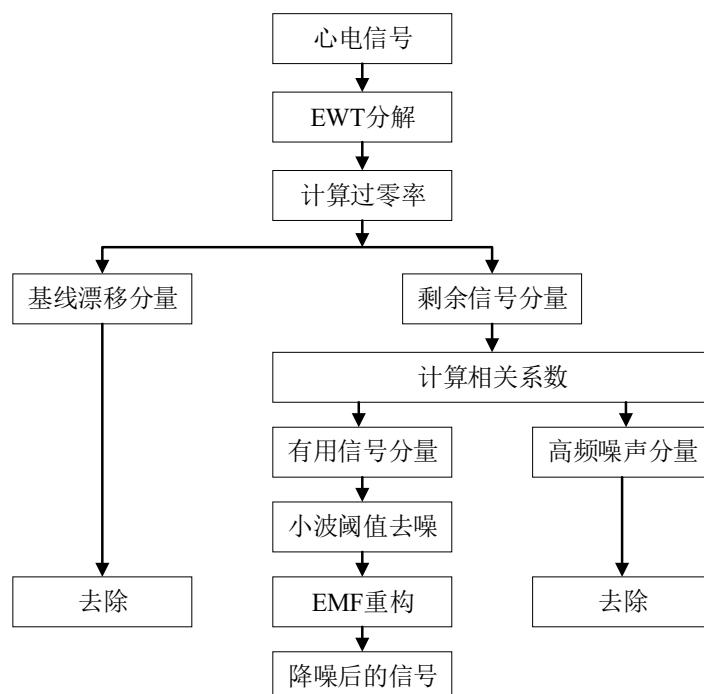


图 3.10 降噪方法结构图

Figure 3.10 Structure diagram of noise reduction method

3.4.4 实验结果与比较

(1) 模拟信号实验结果

为了进一步验证本文提出的心电信号去噪方法的能力,从 MITBIH 心律失常数据库中 100 号记录同样截取一段 5s 的信号,并在添加模拟噪声之前先行使用上述降噪方法进行去噪,将去噪后信号视为纯净信号,为该纯净信号添加 0.2mV 幅值、0.3Hz 频谱的正弦信号模拟基线漂移,添加 20dB 的高斯白噪声模拟肌电干扰,信号的波形如图 3.11 所示。




图 3.11 (a) 100 号记录; (b) 降噪后的 100 号记录; (c) 重新添加噪声的 100 号记录

Figure 3.11 (a) Record no.100; (b) No.100 record after noise reduction; (c) Add the no.100 record of noise again

分别使用小波阈值法、EMD、EEMD 和 EWT 四种方法对重新添加噪声后的 100 号心电信号片段进行去噪以比较不同方法的能力,其中 EMD 和 EEMD 两种算法的去噪过程与本文提出算法类似,通过计算相关系数筛除噪声分量,并将剩余分量通过小波阈值法去噪后重构。去噪结果如图 3.12 所示。相比于小波阈值法和 EMD, EWT 和 EEMD 都能够有效去除基线漂移分量;小波阈值法去噪后信号波形平滑但损失了部分原信号信息,心电信号的 P 波、T 波显示不清晰,不利于之后进行的心电信号分类研究;EMD 很大程度上还原了真实信号的波形,但由于自身的模态混叠问题导致在 QRS

波群处去噪能力较为粗糙，去噪后波形仍有明显噪声干扰；EEMD 和 EWT 去噪后信号波形平滑，并且能够最大程度保留 QRS 波群和 P 波、T 波的形态学特征。




图 3.12 (a) 使用小波阈值法去噪后信号；(b) 使用 EMD 去噪后信号；(c) 使用 EEMD 去噪后信号；(d) 使用 EWT 去噪后信号

Figure 3.12 (a) Denoising signals using wavelet threshold method; (b) Denoised signal using EMD; (c) Denoised signal using EEMD; (d) Denoised signal using EWT

为了进一步评价不同方法去噪能力的好坏，计算信号在降噪后与无噪声信号之间的信噪比（SNR）和均方根误差（RMSE），计算公式如式(3.31)、(3.32)所示，并记录算法在相同硬件水平计算机上的运行时间，结果如表 3.1 所示。从表中可以看出，小波阈值法去噪效果最为粗糙，而 EEMD 和 EWT 两种算法都有很好的去噪能力，但基于 EEMD 的方法，由于在算法中需要添加噪声并进行迭代求解，所以用时较长。基于 EWT 的心电信号去噪方法不单有良好的去噪能力，同时运算时间不到 1 秒，可以满

足在心电信号实时识别情况下的去噪条件，综合考虑，基于 EWT 的心电信号去噪方法有最好的去噪能力。

$$SNR = 10 \lg \sum_{n=1}^M \frac{[f(n)]^2}{[f(n) - f'(n)]^2} \quad (3.31)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{n=1}^M [f(n) - f'(n)]^2} \quad (3.32)$$

式中， $f(n)$ 为原信号， $f'(n)$ 为降噪后信号， M 为信号的采样点个数。

表 3.1 信噪比、均方根误差和运行时间比较

Table 3.1 Comparison of SNR, RMSE and running time

算法	SNR/dB	RMSE/mV	时间/s
小波阈值法	6.4554	0.0746	0.096
EMD	14.5788	0.0293	1.288
EEMD	16.4529	0.0237	21.896
EWT	17.7382	0.0203	0.724

(2) 实际采集信号实验结果

为验证 EWT 的心电信号降噪方法的泛用性，通过对实际测得的心电信号进行去噪研究。对 8 位年龄在 23-27 岁健康男性使用 ECG-300A 数字式三道心电图机采集心电信号，在每组测试信号中随机选取一段时长 8s 的信号，设为 M1-M8。心电图机采样频率为 1000Hz，待处理信号长度为 8000 采样点。使用本文提出的降噪方法对 M1 号信号进行去噪运算，结果如图 3.13 所示，可以看出原信号噪声较少，但仍因为随机噪声信号波形产生畸变，去噪后信号平滑，QRS 波群和 T 波、P 波波形能够有效还原，毛刺噪声基本去除。

使用小波阈值法、EMD、EEMD 和 EWT 四种方法对待处理信号 M1-M8 进行去噪，并计算信号的信噪比和均方根误差，计算结果如表 3.2 和表 3.3 所示。由表中可以看出，小波阈值法降噪后信号的信噪比较低而均方根误差较高，说明小波阈值法去噪能力较差，信号波形还原程度较低，但小波阈值法算法简单，运算时间快，适合作为信号的粗处理算法；EMD 相较于小波阈值法，去噪能力有较大提升，但相较于其他两种方法仍有一些差距。计算去噪信号的信噪比和均方根误差的总体均值如图 3.14 所示，结果表明 EEMD 和 EWT 都有出色的去噪能力和信号还原能力，但 EEMD 运行时间较长，不适合作为心电信号实时监测时的去噪算法，EWT 兼顾去噪能力和运算效率，适合作为心电信号自动分类系统中的信号预处理方法。




图 3.13 (a) 原心电信号; (b) 去噪后心电信号;

Figure 3.13 (a) Original ecg signal; (b) Ecg signal after denoising;

表 3.2 信噪比比较

Table 3.2 Comparison of SNR

算法	SNR/db							
	M1	M2	M3	M4	M5	M6	M7	M8
小波阈值法	7.025	7.0129	6.8085	6.4570	6.3913	7.0335	6.9839	6.6939
EMD	14.922	15.015	14.347	13.543	13.389	15.043	14.797	14.157
EEMD	19.288	19.353	18.661	17.445	17.207	19.436	19.081	18.056
EWT	19.956	20.046	19.413	18.742	18.686	20.015	19.921	19.206

表 3.3 均方根误差比较

Table 3.3 Comparison of RMSE

算法	RMSE/mV							
	M1	M2	M3	M4	M5	M6	M7	M8
小波阈值法	0.2162	0.2165	0.2216	0.2308	0.2325	0.2159	0.2172	0.2246
EMD	0.0871	0.0862	0.0930	0.1021	0.1039	0.0859	0.0883	0.0951
EEMD	0.0527	0.0523	0.0566	0.0651	0.0669	0.0518	0.0539	0.0607
EWT	0.0488	0.0483	0.0520	0.0561	0.0565	0.0485	0.0490	0.0532

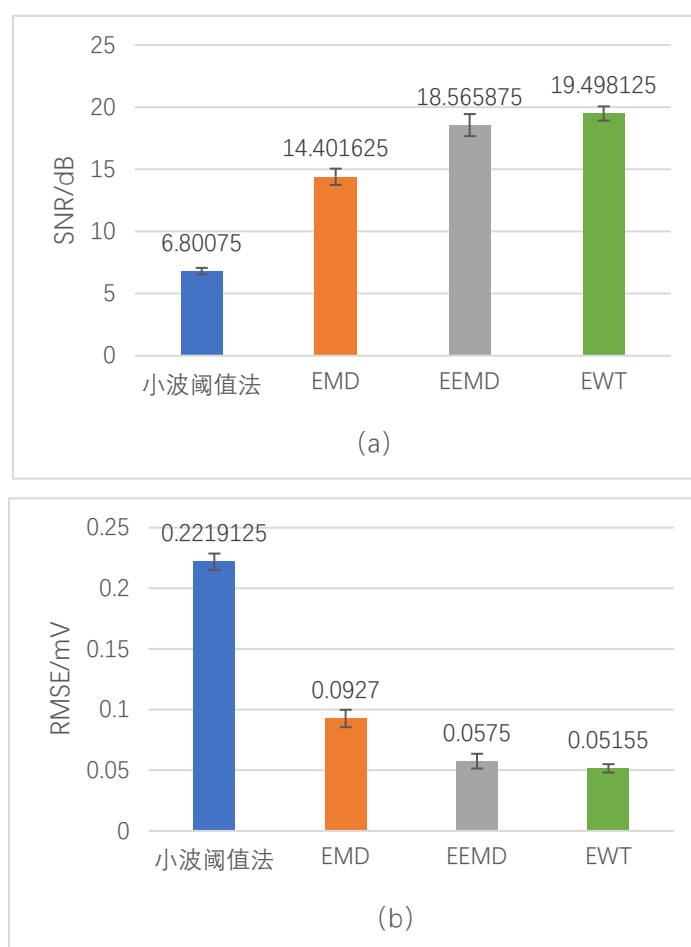


图 3.14 (a) 信噪比较; (b) 均方根误差比较;

Figure 3.14 (a) Comparison of SNR; (b) Comparison of RMSE;

3.5 本章小结

本章主要完成了基于 EWT 的去噪方法对心电信号的去噪工作。在该算法中, 通过对心电信号的傅里叶频谱进行分析, 改进了 EWT 的计算边界选取方法, 依据改进后的计算边界对心电信号进行了经验小波分解, 得到了多个 EMF 分量, 通过计算相关系数和过零率筛除基线漂移和高频噪声, 对其余分量通过基于小波变换的去噪方法进一步去除剩余噪声。通过计算 SNR、RMSE 并与其他常用方法对比分析, 基于 EWT 的降噪方法能够有效去除噪声, 为接下来的心律失常自动识别奠定了基础。

第四章 心律失常识别模型构建与分析

深度学习技术使许多领域迎来了新的发展，在临床医学领域也不例外。本章基于深度学习方法构建 ResNet、ResNet-LSTM、MSCResNet-LSTM 三种深度学习模型对心电信号进行分类，并根据实验结果，探究具有最好能力的神经网络，实现心律失常的准确自动识别。

4.1 样本数据集

4.1.1 数据集划分方法

大多数的心电信号分类研究在神经网络训练阶段并不考虑心电信号被测者的个体差异，这些被测者的一部分心电数据被用在训练集以训练网络的识别能力，他们的另一部分心电数据则被用于验证集以验证模型的性能，这样的数据集划分方式被称作 Intra-Patient。在这种情况下，神经网络能够区分不同心律失常信号的原因很难说是因为网络能够学习到的特征是心律失常信号本身的共有差异性还是不同被测者心电信号的个体差异性。

在实际情况中，心律失常自动识别系统只会有部分被测者的信号记录，对多数被测者来说，识别系统是不应有先验信息的。为了模拟这种情况，有学者在构建心律失常自动识别系统的数据集时，将 MIT-BIH 数据库的心电记录分为两组，并保证两组数据中不会出现同一被测者的心电记录，以此体现神经网络对个体差异性的考虑。这样的数据集划分方式被称作 Inter-Patient。为了从多方面验证心律失常分类模型的性能，使用 Intra-Patient、Inter-Patient 两种划分方式构建数据集。

4.1.2 心拍划分

在本实验中，不采用常用的以单个心拍作为输入样本的方法，而是取四个心拍作为一个样本，取第一个心拍 r 点的前 119 点到第四个心拍 r 点后 160 点，并将样本统一为 1440 个点，即 4s 时间，不足的用 0 补足，少数超过 1440 个点的则截取前 1440 个点。实验使用的心电信号经本文提出的基于 EWT 的去噪方法进行去噪，并按照 AAMI 规则，划分心律失常类型。由于每个样本有四个心拍，为了确定样本的标签，由以下规则对样本进行标签的赋予：

如果全部心拍为正常，则为正常；如果有异常心拍，则标签为数量最多的异常类型；如果多种异常心拍数量一致，标签则为其中最先出现的类型。正常标签和异常标签样本如图 4.1 所示。

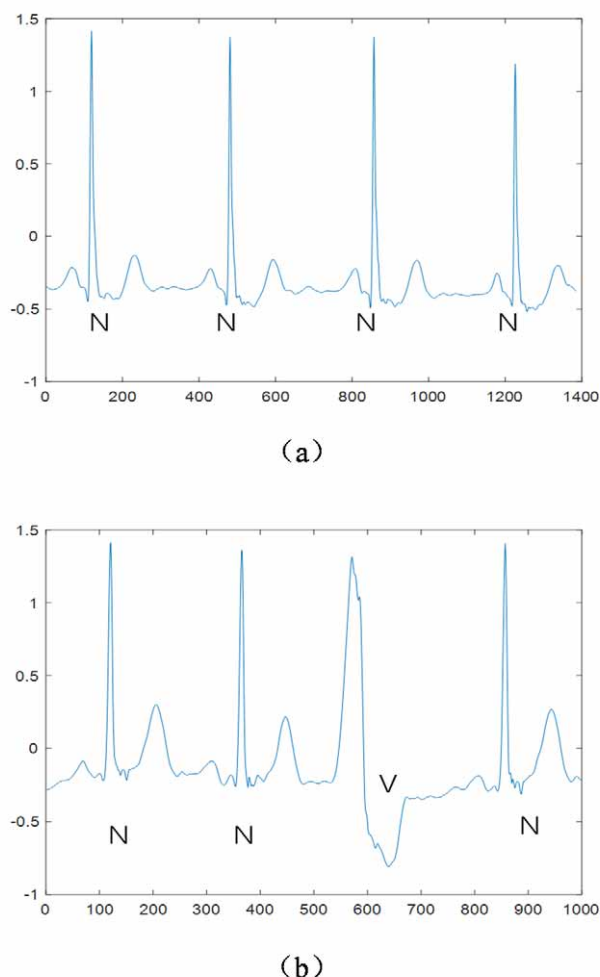


图 4.1 (a) 正常样本; (b) 异常样本

Figure 4.1 (a) Normal samples; (b) Abnormal samples

4.1.3 数据集构建

按照 AAMI 的建议，首先将包含起搏心跳（P）的四组记录（102、104、107 和 217）排除，因为这些记录信号质量较差。然后对剩下的 44 组记录进行 Intra-Patient 和 Inter-Patient 两种方案的划分。

在 Intra-Patient 中，随机将 60%数据划分为训练集，20%数据划分为验证集，20%数据划分为测试集，验证集和测试集不参与模型的训练。其中 N 类样本有 18012 组，随机取其中 7000 组参与训练和测试，以均衡数据集中各类别样本的数量，避免 N 类

样本与其他类别样本的数量之比过于悬殊以使神经网络在训练时只专注于 N 类别即可获得较高准确率，同时舍去过少的 Q 类样本，这是由于 Q 类样本极少使模型对 Q 类样本的分类变得没有意义。训练集、验证集和测试集数据如表 4.1 所示。

表 4.1 Intra-Patient 方案心电类别

Table 4.1 ECG category distribution in Intra-Patient scheme

	N	S	V	F	总计
训练集	4200	763	2686	292	7941
验证集	1400	255	895	98	2648
测试集	1400	255	895	98	2648
总计	7000	1273	4476	488	13237

在 Inter-Patient 中，与上述数据集的区别是将心电记录分为两个独立的数据集 DS1 和 DS2，两个数据集中的样本来自两组不同的病人，如表 4.2 所示，这样划分的原因是保证两个数据集中有相同的人数和数量相似的各类别样本，划分方式参考了 Chazal^[72]的研究成果。

表 4.2 Inter-Patient 方案心电记录分布

Table 4.2 ECG record distribution in Inter-Patient scheme

数据集	MIT-BIH 数据集中的记录
DS1	101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223, 230
DS2	100, 103, 105, 111, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233, 234

Inter-Patient 中的各类别样本数量如表 4.3 所示。DS1 用于训练模型，DS2 用于验证模型。与前述的数据集划分方法类似，在 N 类样本中，DS1 有 9356 组，DS2 有 8656 组，各随机选出 3500 组，同时舍去过少的 Q 类样本。

表 4.3 Inter-Patient 方案心电类别

Table 4.3 ECG category distribution in Inter-Patient scheme

	N	S	V	F	总计
DS1	3500	538	2192	244	6474
DS2	3500	735	2284	244	6763
总计	7000	1273	4476	488	13237

4.2 评价方法

本文使用准确度 (accuracy, Acc)、灵敏度 (sensitivity, Sen)、特异性 (specificity, Spe)、查准率 (Precision, Pre) 和 F1 分数 (F1score) 评估模型分类效果。公式定义如下:

$$\text{Acc} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{TN} + \text{FN}) \quad (4.1)$$

$$\text{Sen} = \text{TP} / (\text{TP} + \text{FN}) \quad (4.2)$$

$$\text{Spe} = \text{TN} / (\text{FP} + \text{TN}) \quad (4.3)$$

$$\text{Pre} = \text{TP} / (\text{FP} + \text{TP}) \quad (4.4)$$

$$\text{F1score} = 2(\text{Sen} \cdot \text{Pre}) / (\text{Sen} + \text{Pre}) \quad (4.5)$$

其中 TP (True Positive) 为真阳性, 表示正确分类为当前类别的个数; FP (False Positive) 为假阳性, 表示其他类别的样本被错误分为当前类别的个数; TN (True Negative) 为真阴性, 表示正确分类非当前类别的个数; FN (False Negative) 为假阴性, 表示当前类别样本被错误划分为其他类别的个数。Acc 是最直观的参数, 代表了模型识别能力的准确性。Sen 也被称作召回率 (recall), 表示模型检索到的项目占有所有应检索的项目的比例。Spe 也被称作真阴性率 (True Negative Rate), 表明了模型对负类的识别能力。Pre 表示正确识别的项目占有所有被识别到的项目中的比例, 体现的是模型分类的精确性。在信息检索中, Sen 和 Pre 是相互影响的, 虽然我们的期望是两者都达到高水平, 但实际情况可能是 Sen 提高, Pre 就会降低, 或者相反。在疾病的检测识别中, 一般是在保证 Pre 后, 尽可能提高 Sen。F1 分数是 Sen 和 Pre 的调和平均, 反应了模型兼顾 Sen 和 Pre 的表现, 体现了模型的综合分类能力。

4.3 基于 ResNet 的心律失常分类识别

4.3.1 ResNet

在卷积神经网络中, 随着层数加深, 网络因卷积层堆叠产生的权重不断卷积使梯度信息在反向传播中趋于 0, 导致网络精度退化, 使得模型难以继续训练。He 等^[73]提出 ResNet 网络, 通过引入残差映射, 使得梯度信息在回传到前几层时仍有较大的值, 克服深层网络产生的梯度消失问题。在网络的构建中, 我们可以使用更深层的网络提

升模型的分类精度。

残差块是残差网络的重要部分，深度神经网络的残差块通常有两到三层卷积层组成，并通过直接映射，将残差块的输入同输出相连接。一个包含两层卷积层的残差块计算公式如式(4.6)所示。

$$Y = \sigma(W_2(\sigma(W_1(x)))) + x \quad (4.6)$$

其中， W_1 ， W_2 分别卷积层 1 和卷积层 2 的权重参数， σ 为激活函数， Y 为残差块的输出， x 为残差块的输入特征。

残差块的示意图如图 4.2 所示。




图 4.2 两层残差块示意图

Figure 4.2 The diagram of two-layer residual blocks

构建 ResNet 网络如图 4.3 所示。输入信号首先经由卷积层拓展通道维数，卷积核大小为 3×1 ，数量为 64 个，步长为 2，输出特征的大小为 720×64 。在这之后是池化层，采用最大池化的池化方法降低特征尺寸，减少运算的参数量，池化核大小为 3×1 ，步长为 3，输出特征的大小为 240×64 。之后经由四个残差块进行特征的深度提取，每个残差块由四层卷积层组成，在每两层之间通过残差映射直接相连，残差块的具体结构如图 4.4 所示。在神经网络的最后，使用全局平均池化将特征的空间维度池化，保留通道维度，输出特征大小为 256，并通过有四个神经元的全连接层以匹配 softmax 函数，输出分类结果。




图 4.3 ResNet 网络结构示意图

Figure 4.3 The structure diagram of ResNet

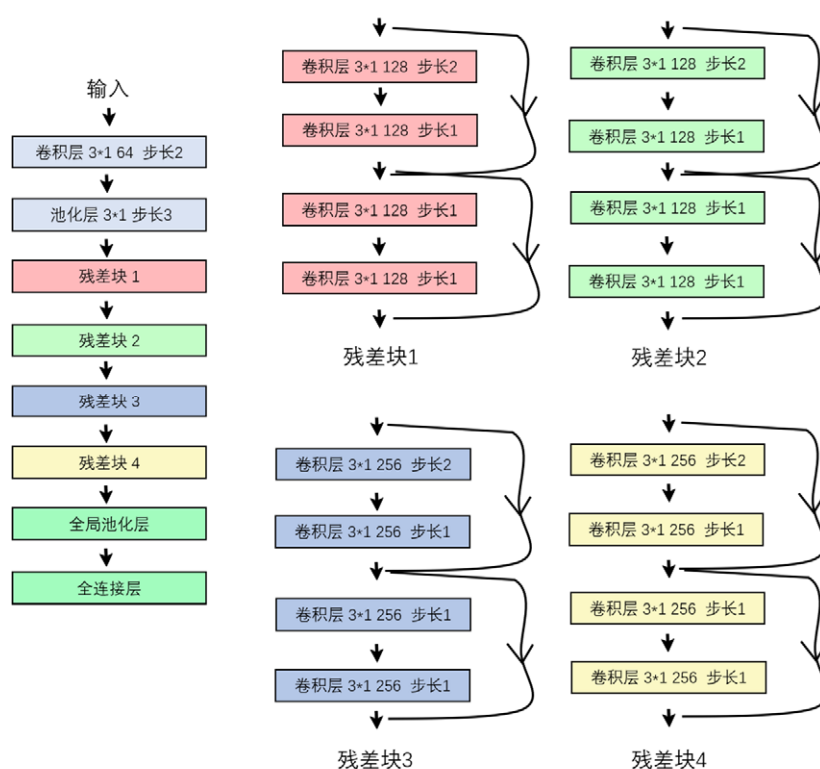


图 4.4 ResNet 详细信息

Figure 4.4 The detailed information of ResNet

输入样本的尺寸大小为 1440×1 ，经由卷积层和池化层使空间维度不断减小，通道维度增加，之后经四个残差块进一步压缩样本空间尺寸，拓展通道特征，第四个残差块输出的特征尺寸为 15×256 ，这时样本的绝大部分信息已经由空间维度转移到通道维度中去，代表神经网络学习到的信号的高级特征，ResNet 的参数如表 4.4 所示。

表 4.4 ResNet 网络结构的详细信息

Table 4.4 The details of ResNet structure

层类型	输出维度	核大小	步长
卷积层 1	720×64	3	2
池化层 1	240×64	3	3
残差块 1	120×128	-	-
残差块 2	60×128	-	-
残差块 3	30×256	-	-
残差块 4	15×256	-	-
池化层 2	256	15	15
全连接层	4	-	-

在实验中, 卷积层使用 ReLu 函数作为激活函数。模型在训练中使用交叉熵损失函数, Adam 优化算法, 并采用学习率衰减算法对学习率进行设置, 在刚开始训练时, 学习率较高以使损失函数能够快速降低, 减少模型的训练时间, 之后学习率逐渐衰减, 以防止过大的学习率使模型在迭代优化时难以抵达极小值点而使训练难以完成, 从而总体上提高模型的收敛速度。为确定残差块中卷积层卷积核的参数, 使用大小为 1×1 , 3×1 和 5×1 的卷积核进行实验, 结果如表 4.5 所示。选择参数量较小且准确率较高的 3×1 作为残差块中卷积层卷积核的尺寸参数。实验环境是 Inter(R) Core(TM) i5-9300H CPU@2.40GHz、Nvidia Geforce GTX 1650 GPU、8GB RAM 和 Microsoft Windows 10 操作系统和 Tensorflow2.0 框架, 迭代次数为 50 次。

表 4.5 不同卷积核大小的准确率

Table 4.5 The accuracy of different convolution kernel sizes

数据集	准确率		
	1×1	3×1	5×1
Intra-Patient	82.39%	95.37%	95.16%
Inter-Patient	69.18%	84.58%	83.23%

4.3.2 分类结果

使用提出的 ResNet 心律失常分类模型分别对数据集使用 Intra-Patient 和 Inter-Patient 两种划分方案的情况下进行分类实验以评估模型的性能。

(1) Intra-Patient 方案

使用 Intra-Patient 的数据集进行模型的训练和测试, 模型在训练集和验证集的分类准确率曲线如图 4.5 所示。可以看到在经过五次迭代后, 训练集和验证集准确率都达到了 90%以上, 在第十一次迭代后模型的训练集已经达到或接近 100%, 验证集准确率也几乎保持不变, 说明模型的训练在 11 次迭代后已基本完成。在 5 次迭代之后, ResNet 的验证集准确率始终比训练集要低, 这说明 ResNet 在训练中出现了过拟合现象, 原因可能是由于数据集各类别样本数量的不均衡导致的。经过 50 次迭代后, ResNet 在验证集上的准确率为 95.37%, 训练时间为 890 秒。

使用测试集对模型进行测试, 测试集的分类准确率为 95.61%, 模型在测试集的混淆矩阵和性能参数如表 4.6、4.7 所示。在混淆矩阵中行代表了该类别被 ResNet 模型识别分类的个数, 如第一行 N 类即正常样本, 在总的测试集中, N 类总共有 1400 例, 其中被模型识别为 N 类的有 1380 例、识别为 S 类的有 8 例、识别为 V 类的有 10 例、识别为 F 类的有 2 例; 在混淆矩阵中, 列代表了由模型所识别为某类的样本其实际标签的各类别个数, 如第二列 S 类即室上性异位搏动, 由 ResNet 模型识别为 S 类的样

本总共有 225 例，其中有 8 例实际为 N 类、213 例被正确分类、2 例实际为 V 类、2 例实际为 F 类。可以看出，大部分的样本都能够被 ResNet 模型正确分类，模型识别能力较差的部分是有较多 S 类被错误分类为 N 类，和较多的 F 类被错误识别为 N 类和 V 类，这点也可以由 S 类的 Sen 为 0.8352 和 F 类的 Sen 和 Pre 分别为 0.6530 和 0.8767 反映出来。




图 4.5 ResNet 在 Intra-Patient 的准确率曲线

Figure 4.5 The accuracy of ResNet in Intra-Patient scheme

表 4.6 ResNet 在 Intra-Patient 方案的混淆矩阵

Table 4.6 The confusion matrix of ResNet in Intra-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
ResNet	N	1380	8	10	2
	S	34	213	7	1
	V	12	2	875	6
	F	21	2	11	64

表 4.7 ResNet 在 Intra-Patient 方案的性能参数

Table 4.7 The parameters of ResNet in Intra-Patient scheme

网络模型	性能指标	N	S	V	F
ResNet	Acc	0.9671	0.9796	0.9818	0.9837
	Sen	0.9857	0.8352	0.9776	0.6530
	Spe	0.9463	0.9949	0.9840	0.9964
	Pre	0.9536	0.9466	0.9689	0.8767
	F1score	0.9694	0.8874	0.9732	0.7485

(2) Inter-Patient 方案

使用 Inter-Patient 的数据集对模型进行训练和测试，模型在训练集和验证集的分类准确率曲线如图 4.6 所示。可以看到在经过 8 次迭代后，训练集的准确率都达到了 95% 以上，在第十次迭代后模型的训练集已经达到或接近 100%，验证集准确率也几乎保持不变，模型的训练基本完成。相比于 Intra-Patient 的数据集，在使用 Inter-Patient 的情况下 ResNet 的验证集准确率比训练集要更低，这说明 ResNet 在训练中出现了过拟合现象更为严重，过拟合现象的出现主要是由于数据集样本数量的不足，这也是大多数深度学习分类模型所面临的问题，在大部分情况下，有足够的样本数据是最宝贵的也是最难实现的。而在 Inter-Patient 的情况下，由于在训练集中模型并没有学习到验证集和测试集中被测者的个体特征，导致分类准确率较低，但这更符合实际情况，大多数需要心电信号监测的病人在分类系统中是没有先验信息的。经过 50 次迭代后，ResNet 在验证集上的准确率为 84.58%，训练时间为 760 秒。

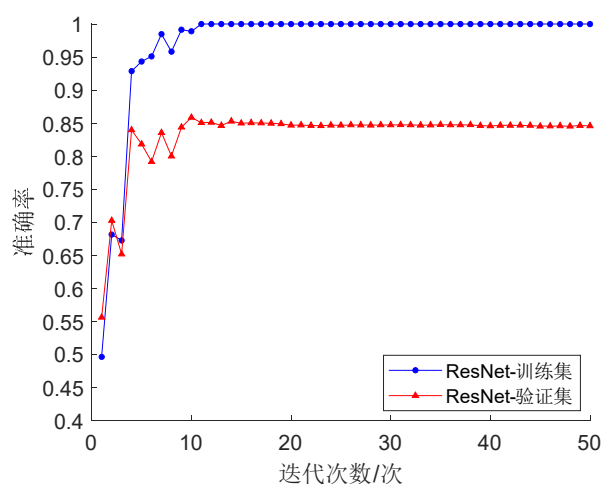


图 4.6 ResNet 在 Inter-Patient 的准确率曲线

Figure 4.6 The accuracy of ResNet in Inter-Patient scheme

模型第 50 次迭代的验证集混淆矩阵和性能参数如表 4.8、4.9 所示，可以看出，大部分的样本都能够被 ResNet 模型正确分类，模型识别能力较差的部分是有较多 S 类被错误分类为 N 类和 V 类，和较多的 F 类被错误识别为 N 类和 V 类，S 类的 Sen 相比其他参数较低为 0.6367，F 类的 Sen 和 Pre 分别为 0.6434 和 0.7040，没有取得较高的分数，但模型对 N 类和 V 类的识别能力较好，这点可以由混淆矩阵和各项参数证明。

表 4.8 ResNet 在 Inter-Patient 方案的混淆矩阵

Table 4.8 The confusion matrix of ResNet in Inter-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
ResNet	N	3130	67	286	17
	S	208	468	57	2
	V	263	9	1965	47
	F	17	6	64	157

表 4.9 ResNet 在 Inter-Patient 方案的性能参数

Table 4.9 The parameters of ResNet in Inter-Patient scheme

网络模型	性能指标	N	S	V	F
ResNet	Acc	0.8731	0.9494	0.8927	0.9773
	Sen	0.8942	0.6367	0.8603	0.6434
	Spe	0.8504	0.9863	0.9091	0.9901
	Pre	0.8651	0.8509	0.8284	0.7040
	F1score	0.8794	0.7284	0.8440	0.6723

4.4 基于 ResNet-LSTM 的心律失常分类识别

4.4.1 长短时记忆网络

正如 CNN 模仿视觉感受设计感受野以进行图像识别一样, 循环神经网络 (Recurrent Neural Network, RNN) 被设计为模仿思维的持续性。RNN 存在连接到过去输出的反馈回路, 这种独特的结构给了 RNN 记忆的能力, 这种记忆能力被用来实现前馈网络所不能做到的功能。在 RNN 中, 过去的顺序信息被保存在网络的隐藏状态中, 它能够跨越多个时间步骤向前级联以影响新输入的结果。因此, RNN 能够寻找相隔许多时刻的输出之间的相关性, 因为当前时刻的输出可能是先前一个或多个输出的函数。然而, RNN 面临的挑战是在处理长时序列信息时, 在反向传播中会出现梯度消失或梯度爆炸, 从而使 RNN 面临长期依赖问题, 即网络难以关联相隔时刻较远的记忆。因此, 需要找到一种方法来确定过去的输入有多少是重要的, 从而将不需要的信息删除, 减轻网络在反向传播时面临的梯度极化问题。LSTM 就是为了解决这个问题而开发的。

LSTM 是一种特殊的 RNN, 相比于 RNN, LSTM 在处理长时序列数据时有更好

的能力，能够有效解决 RNN 面临的长期依赖问题。LSTM 的特殊之处在于“门”结构，在 LSTM 中，过去时刻的信息存储在一个门控单元中，这个门控单元在循环网络的正常流转之外，门控单元能够决定什么信息将被存储和写入，什么信息要从单元的存储器中删除。通过这样的门控单元，LSTM 能够根据信息的重要程度来允许或阻断信息的传播，在反向传播和调整权重的迭代过程中，了解什么信息是有效的，什么信息是无效的。每个 LSTM 细胞都有遗忘门、输入门、输出门三个门控单元，LSTM 通过遗忘门、输入门、输出门和记忆单元实现了对输入特征的读、写和对历史信息的更新，克服了 RNN 在处理长时信息时产生的梯度消失和梯度爆炸问题。

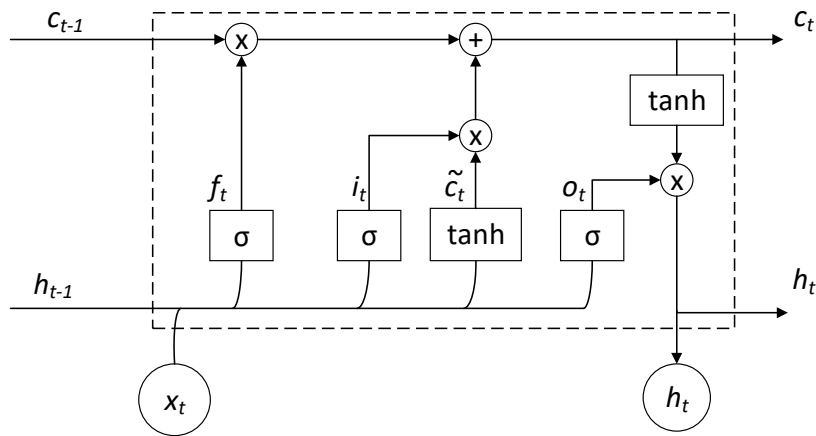


图 4.7 LSTM 示意图

Figure 4.7 The diagram of LSTM

LSTM 的细胞结构如图 4.7 所示，一个 LSTM 细胞的输入包括上一时刻的状态 c_{t-1} ，上一时刻的输出 h_{t-1} 和本时刻的输入 x_t ；输出本时刻的状态 c_t 和本时刻的输出 h_t 。

h_{t-1} 和 x_t 通过遗忘门中 sigmoid 函数得到 f_t 决定了上一时刻的状态 c_{t-1} 有多少信息被保留：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (4.7)$$

其中 W_f 为遗忘门的权值， b_f 为相对应的偏置， σ 为 sigmoid 函数。

输入特征通过输入门中的 tanh 函数产生了本时刻的细胞状态 \tilde{c}_t ，通过输入门中的 sigmoid 函数得到 i_t 决定 \tilde{c}_t 有多少信息被传递到细胞状态 c_t 中：

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (4.8)$$

$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (4.9)$$

$$c_t = f_t c_{t-1} + i_t \tilde{c}_t \quad (4.10)$$

其中 W_i , W_c 为输入门与 i_t 和 \tilde{c}_t 相关的权重, b_i 和 b_c 为相对应的偏置, σ 为 sigmoid 函数。

在输出门中, 细胞状态 c_t 通过 \tanh 函数并被 o_t 筛选得到输出 h_t :

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (4.11)$$

$$h_t = o_t \tanh(c_t) \quad (4.12)$$

其中 W_o 为输出门权值, b_o 为相对应的偏置, σ 为 sigmoid 函数。

4.4.2 ResNet-LSTM

ResNet-LSTM 的主要结构与上节提出的 ResNet 相同, 在全局池化层处替换使用 LSTM 层。输入信号首先经卷积层拓展特征通道, 之后通过池化层减少空间尺寸。输入大小为 240×64 的特征样本通过四个残差块进一步提取特征, 输出维度大小为 15×256 的特征向量经 LSTM 层提取特征的时序信息, LSTM 层输出 64 个特征点, 经全连接层降维到 4 个特征点, 通过 Softmax 函数输出网络的分类结果。ResNet-LSTM 网络结构如图 4.8 所示。




图 4.8 ResNet-LSTM 网络结构示意图

Figure 4.8 The structure diagram of ResNet-LSTM

ResNet-LSTM 的参数如表 4.10 所示。在实验中, 卷积层使用 ReLu 函数作为激活函数。模型在训练中使用交叉熵损失函数, Adam 优化算法, 并采用学习率衰减算法对学习率进行设置, 实验环境是 Inter(R) Core(TM) i5-9300H CPU@2.40GHz、Nvidia Geforce GTX 1650 GPU、8GB RAM 和 Microsoft Windows 10 操作系统和 Tensorflow2.0 框架, 迭代次数为 50 次。

表 4.10 ResNet-LSTM 网络结构的详细信息

Table 4.10 The details of ResNet-LSTM structure

层类型	输出维度	核大小	步长
卷积层 1	720×64	3	2
池化层 1	240×64	3	3
残差块 1	120×128	-	-
残差块 2	60×128	-	-
残差块 3	30×256	-	-
残差块 4	15×256	-	-
LSTM 层	64	-	-
全连接层	4	-	-

4.4.3 分类结果

使用提出的 ResNet-LSTM 心律失常分类模型分别对数据集使用 Intra-Patient 和 Inter-Patient 两种划分方案的情况下进行分类实验并评估模型的性能。

(1) Intra-Patient 方案

使用 Intra-Patient 的数据集进行模型的训练和测试，模型在训练集和验证集的分类准确率曲线如图 4.9 所示。可以看到在经过三次迭代后，训练集和验证集准确率都达到了 85%以上，在第十三次迭代后模型的训练集已经达到或接近 100%，验证集准确率也几乎保持不变，说明模型的训练在十三次迭代后已基本完成。在经过前几轮迭代之后，ResNet-LSTM 的验证集准确率始终比训练集要低，但相较于没有添加 LSTM 层的 ResNet 网络，训练集和验证集准确率的差值更小，这说明，添加了 LSTM 层之后降低了模型的过拟合程度。经过 50 次迭代后，ResNet-LSTM 在验证集上的准确率为 96.95%，训练时间为 1050 秒。

使用测试集对模型进行测试，测试集的分类准确率为 97.05%，略高于第 50 次迭代的验证集分类准确率，模型在测试集的混淆矩阵和性能参数如表 4.11、4.12 所示。ResNet-LSTM 能够对大部分样本进行准确的分类，模型对 S 类别的识别能力相较于 ResNet 模型有所提高，该类别被错误识别的更少了。S 类的 Sen 和 Pre 分别为 0.9019 和 0.9623 高于 ResNet 的 0.8352 和 0.9466。但模型对样本数量最少的 F 类识别能力较差，有 21 例 F 类样本被错误分为了其他类别，约占 F 类样本总量的 22%，F 类的 Sen 和 Pre 分别为 0.7857 和 0.8750，相较于 ResNet 有所提高。模型在对心电信号的识别中，对 S 类和 F 类的识别能力较差，不均衡的数据集对模型泛化能力有了更高的要求。




图 4.9 ResNet-LSTM 在 Intra-Patient 的准确率曲线

Figure 4.9 The accuracy of ResNet-LSTM in Intra-Patient scheme

表 4.11 ResNet-LSTM 在 Intra-Patient 方案的混淆矩阵

Table 4.11 The confusion matrix of ResNet-LSTM in Intra-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
ResNet-LSTM	N	1382	6	7	5
	S	16	230	7	2
	V	7	3	881	4
	F	9	0	12	77

表 4.12 ResNet-LSTM 在 Intra-Patient 方案的性能参数

Table 4.12 The parameters of ResNet-LSTM in Intra-Patient scheme

网络模型	性能指标	N	S	V	F
ResNet-LSTM	Acc	0.9811	0.9871	0.9848	0.9879
	Sen	0.9871	0.9019	0.9843	0.7857
	Spe	0.9743	0.9962	0.9851	0.9956
	Pre	0.9773	0.9623	0.9713	0.8750
	F1score	0.9822	0.9311	0.9778	0.8279

(2) Inter-Patient 方案

使用 Inter-Patient 的数据集对模型进行训练和测试，模型在训练集和验证集的分类准确率曲线如图 4.10 所示。可以看到在经过 12 次迭代后，训练集的准确率达到 99% 以上，但验证集的准确率仍有所变化，在 18 次迭代后，验证集准确率才几乎保持

不变。相比于 Intra-Patient 的数据集, 在使用 Inter-Patient 的情况下 ResNet-LSTM 的验证集准确率比训练集要更低, 受到更大的过拟合现象影响, 这点与 ResNet 的结果相似。经过 50 次迭代后, ResNet-LSTM 在验证集上的准确率为 87.36%, 高于 ResNet 的 84.58%, 训练时间为 820 秒。

模型第 50 次迭代的验证集混淆矩阵和性能参数如表 4.13、4.14 所示, 可以看出, 大部分的样本都能够被正确分类, 模型对 S 类和 F 类相较于 ResNet 网络识别能力更强。N 类的 Sen 较低, 为 0.9100, 表明模型将较多的 N 类错误识别为其他的类别。S 类的 Sen 和 Pre 分别为 0.6884 和 0.7198, 相比与 ResNet 的 0.6367 和 0.8509, ResNet-LSTM 在分类策略上将较多其他类别分为 S 类以期减少对 S 类漏检的可能性。F 类的 Pre 相比其他参数较低为 0.4316, 这是由于 F 类样本的总体数量较少, 模型在学习 F 类心律失常的深层特征时较为困难。ResNet-LSTM 对 V 类的识别参数 Sen 和 Pre 分别为 0.8892 和 0.9244, F1score 为 0.9065 远高于 ResNet 的 0.8440, 模型对 V 类能够实现较准确得识别。

心电信号作为一种反应心脏电活动的时序信号, 信号在时间顺序上的前后不同波段含有内在联系, 而 LSTM 是一种专门处理长时时序信号的神经网络模型, 将 LSTM 层嵌入到残差网络中, 能够有效提高分类模型的鲁棒性和泛化能力。实验结果也表明, 总体上, ResNet-LSTM 相较于 ResNet 表现更出色。




图 4.10 ResNet-LSTM 在 Inter-Patient 的准确率曲线

Figure 4.10 The accuracy of ResNet-LSTM in Inter-Patient scheme

表 4.13 ResNet-LSTM 在 Inter-Patient 方案的混淆矩阵

Table 4.13 The confusion matrix of ResNet-LSTM in Inter-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
ResNet-LSTM	N	3185	148	92	75
	S	156	506	45	28
	V	74	37	2031	142
	F	17	12	29	186

表 4.14 ResNet-LSTM 在 Inter-Patient 方案的性能参数

Table 4.14 The parameters of ResNet-LSTM in Inter-Patient scheme

网络模型	性能指标	N	S	V	F
ResNet-LSTM	Acc	0.9169	0.9370	0.9380	0.9552
	Sen	0.9100	0.6884	0.8892	0.7623
	Spe	0.9243	0.9673	0.9629	0.9624
	Pre	0.9280	0.7198	0.9244	0.4316
	F1score	0.9189	0.7037	0.9065	0.5511

4.5 基于 MSCResNet-LSTM 的心律失常分类识别

4.5.1 MSCResNet-LSTM

在卷积神经网络中, 输入信号的感受野被卷积核遍历产生特征图, 但是单一特征图包含的信息有限, 本文提出了一种多尺度卷积结构(Multi-Scale Convolution, MSC)对输入信号在不同尺度上进行卷积并融合特征以增加表征的信息, 实现模型对多层次特征的有效学习。

本文提出的 MSCResNet-LSTM 网络模型, 如图 4.11 所示。在第一、第二、第三残差块之后分别加入卷积层, 并使用不同核大小的最大池化层对特征图进行池化, 不同尺度的卷积分块使模型呈现金字塔形结构。融合特征包含不同尺度、不同层级的特征, 既有初级的波形、幅值特征, 也有高级的语义特征, 保留了模型从浅层到高层的不同细节, 能够提高模型的精度和鲁棒性。

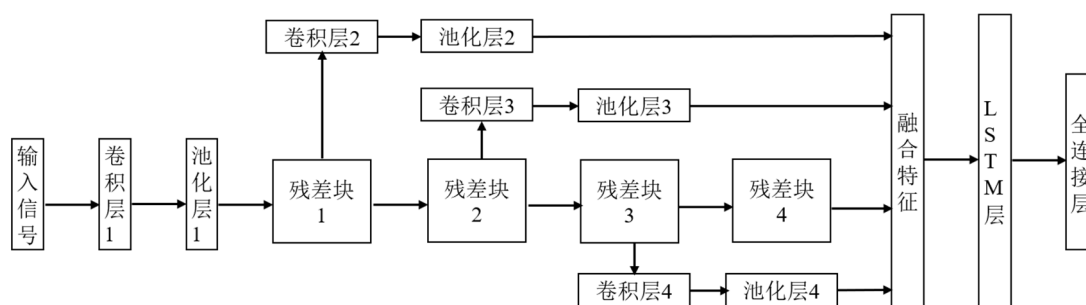


图 4.11 MSCResNet-LSTM 网络结构示意图

Figure 4.11 The structure diagram of MSCResNet-LSTM

输入样本先经由一维卷积层扩展通道维度，经过最大池化层缩减空间尺寸，减少运算参数，在卷积层之后是四个残差块，在残差块 1，残差块 2，残差块 3 之后分别加入卷积层以实现在通道维度上的匹配，之后通过池化层输出维度大小为 15×256 的浅层特征。残差块 4 和三个池化层的输出组成融合特征，融合特征既包含在模型的底层网络中既被提取出的浅层特征也包含经过四个残差块后模型学习到的深层特征，融合特征先经过 LSTM 层，之后经由全连接层进行信号的分类，MSCResNet-LSTM 参数如表 4.15 所示。

模型在训练中使用交叉熵损失函数，Adam 优化算法，并采用学习率衰减算法对学习率进行设置，以提高模型的收敛速度。卷积层使用 ReLu 函数作为激活函数。计算机实验环境是 Inter(R) Core(TM) i5-9300H CPU@2.40GHz、Nvidia Geforce GTX 1650 GPU、8GB RAM 和 Microsoft Windows 10 操作系统和 Tensorflow2.0 框架，迭代次数为 50 次。

表 4.15 MSCResNet-LSTM 网络结构的详细信息

Table 4.15 The details of MSCResNet-LSTM structure

层类型	输出维度	核大小	步长
卷积层 1	720×64	3	2
池化层 1	240×64	3	3
残差块 1	120×128	-	-
残差块 2	60×128	-	-
残差块 3	30×256	-	-
残差块 4	15×256	-	-
卷积层 2	120×256	3	1
池化层 2	15×256	8	8
卷积层 3	60×256	3	1

表 4.15 (续)

Table 4.15 (Continuation)

层类型	输出维度	核大小	步长
池化层 3	15×256	4	4
卷积层 4	30×256	3	1
池化层 4	15×256	2	2
LSTM 层	64	-	-
全连接层	4	-	-

4.5.2 分类结果

使用提出的 MSCResNet-LSTM 心律失常分类模型分别对数据集使用 Intra-Patient 和 Inter-Patient 两种划分方案的情况下进行分类实验，计算相关参数，评价模型的能力。

(1) Intra-Patient 方案

使用 Intra-Patient 的数据集进行模型的训练和测试，模型在训练集和验证集的分类准确率曲线如图 4.12 所示。可以看到在经过三次迭代之后，训练集和验证集准确率都达到了 90%以上，在第十一次迭代后模型的训练集已经接近 100%，验证集准确率也几乎保持不变，说明模型的训练在十一次迭代后已基本完成。相较于前述的 ResNet 和 ResNet-LSTM 网络，模型的验证集准确率处于更高的水平，MSCResNet-LSTM 在学习数据的深层特征上更有优势，模型更不容易出现过拟合。经过 50 次迭代后，MSCResNet-LSTM 在验证集上的准确率为 97.52%，训练时间为 1180 秒。

使用测试集对模型进行测试，测试集的分类准确率为 97.65%，高于 ResNet-LSTM 的 97.05%，模型在测试集的混淆矩阵和性能参数如表 4.16、4.17 所示。MSCResNet-LSTM 在对所有类别样本的识别中都表现出了更好的能力，只有很少的样本被模型错误分类。在更难识别的 F 类中，模型在各项参数的表现也很好，分数最低的 Sen 也达到了 0.7959。在对 S 类的识别中，仅有少量的 S 类样本被错误分为其他类别，主要是被识别为数量最多的 N 类，S 类的 Sen 和 Pre 分别达到了 0.9333 和 0.9675，明显高于前述 ResNet 和 ResNet-LSTM 网络的表现。




图 4.12 MSCResNet-LSTM 在 Intra-Patient 的准确率曲线

Figure 4.12 The accuracy of MSCResNet-LSTM in Intra-Patient scheme

表 4.16 MSCResNet-LSTM 在 Intra-Patient 方案的混淆矩阵

Table 4.16 The confusion matrix of MSCResNet-LSTM in Intra-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
MSCResNet-LSTM	N	1385	5	8	2
	S	9	238	6	2
	V	4	3	885	3
	F	7	0	13	78

表 4.17 MSCResNet-LSTM 在 Intra-Patient 方案的性能参数

Table 4.17 The parameters of MSCResNet-LSTM in Intra-Patient scheme

网络模型	性能指标	N	S	V	F
MSCResNet-LSTM	Acc	0.9868	0.9906	0.9860	0.9898
	Sen	0.9893	0.9333	0.9887	0.7959
	Spe	0.9840	0.9967	0.9846	0.9973
	Pre	0.9858	0.9675	0.9704	0.9176
	F1score	0.9875	0.9501	0.9795	0.8524

(2) Inter-Patient 方案

使用 Inter-Patient 的数据集对模型进行训练和测试，模型在训练集和验证集的分类准确率曲线如图 4.13 所示。可以看到在经过 17 次迭代后，训练集的准确率达到 99% 以上，验证集的准确率曲线也基本平稳。由于添加了多尺度卷积结构，相比于

ResNet-LSTM 网络, 模型在学习样本多层次特征, 提高模型泛化能力上更有优势。经过 50 次迭代后, MSCResNet-LSTM 在验证集上的准确率为 89.46%, 训练时间为 1070 秒。




图 4.13 MSCResNet-LSTM 在 Inter-Patient 的准确率曲线

Figure 4.13 The accuracy of MSCResNet-LSTM in Inter-Patient scheme

模型第 50 次迭代的验证集混淆矩阵和性能参数如表 4.18、4.19 所示, 可以看出, 模型对 S 类和 F 类两类别较少数量的样本类别相较于 ResNet-LSTM 网络的识别能力更强。模型的错误识别主要是将 S 类和 V 类误分类为 N 类, 和将 N 类误分类为 V 类, 由于数据集中 N 类和 V 类样本数量更多, 模型的训练策略使之更倾向于将未分类样本识别为这两类。总体上, MSCResNet-LSTM 能够在 Inter-Patient 情况下较好地完成对不同心律失常信号的识别分类。

表 4.18 MSCResNet-LSTM 在 Inter-Patient 方案的混淆矩阵

Table 4.18 The confusion matrix of MSCResNet-LSTM in Inter-Patient scheme

网络模型	真实类别	预测类别			
		N	S	V	F
MSCResNet-LSTM	N	3243	69	162	26
	S	179	522	25	9
	V	125	36	2089	34
	F	20	0	28	196

表 4.19 MSCResNet-LSTM 在 Inter-Patient 方案的性能参数

Table 4.19 The parameters of MSCResNet-LSTM in Inter-Patient scheme

网络模型	性能指标	N	S	V	F
MSCResNet-LSTM	Acc	0.9141	0.9530	0.9394	0.9827
	Sen	0.9266	0.7102	0.9146	0.8033
	Spe	0.9007	0.9826	0.9520	0.9894
	Pre	0.9092	0.8325	0.9067	0.7396
	F1score	0.9178	0.7665	0.9106	0.7701

4.6 实验结果分析

在心律失常的自动识别研究中,相比于其他心跳类别的分类,研究者们更关注室上性异位搏动和心室异位搏动即 S 和 V 的分类^[74]。室上性异位搏动起源于心房或房室结,包括四种心跳类型,其中,心房早搏最为常见。心房早搏是心房受到兴奋刺激导致提前收缩引起的。频繁的心房早搏会引起心衰和房颤以及其他危险情况,经常是快速室上性心律失常的前兆。心室异位搏动包括两种心跳类型,主要是室性早搏。室性早搏是在窦房结电脉冲抵达心室之前,心室中提前发生电冲动引起心室的提前除极所引发的。室性早搏可导致心悸,严重的情况下可能会出现昏厥,在有心脏病病史的病人中,室性早搏会使室性心动过速和心室颤动的风险增高并可导致猝死^[75]。因此,能够准确检测室上性异位搏动和心室异位搏动对心律失常自动识别模型来说是非常重要的。

为了更接近临床应用的实际情况,评估本文提出的心律失常自动识别模型的有效性,在使用不含先验信息的 Inter-Patient 数据集情况下,比较本文提出的模型与其他研究者在对 S 类和 V 类心律失常的分类情况。表 4.20 和表 4.21 为 ResNet、ResNet-LSTM、MSCResNet-LSTM 和其他研究者在 Inter-Patient 分类情况下对 MIT-BIH 心律失常数据库心电信号 S 和 V 两类心律失常分类的研究进展。可以看出, MSCResNet-LSTM 模型在 S 类和 V 类的检测中都有较高的 Sen 和 Pre,表明模型较大程度将应识别为 S 类和 V 类的样本识别准确,同时一旦识别到有 S 类和 V 类发生,检测的置信程度很高,这同临床应用相适应。在 Acc 和 Spe 上,本文提出的模型并没有取得很好的优势,原因是因为这项研究中并没有使用全部的 N 类样本,因为 N 类样本的数量最高,高于其他类别几倍到十几倍,所以经过训练后的模型对 N 类的识别能力最出色,测试集中更多的 N 类样本最终提高了 S 和 V 两类的 Acc 和 Spe。在对 S 类的分类中,部分研究者在 Sen 上取得了较好分数,但在 Pre 上分数较低,原因是由于这些深度学

习模型在训练阶段更倾向于将待分类样本分为 S 类, 使大多数真实类别为 S 类的样本能够被识别出来从而提高 Sen, 但由于将更多的非 S 类识别为 S 类, 导致 Pre 较低。F1score 兼顾了 Sen 和 Pre, 能够反应模型的综合识别能力, 在 F1score 上, MSCResNet-LSTM 在 S、V 两类识别中分别为 0.7665 和 0.9106, 有最好的表现。总得来说, 本文使用的 MSCResNet-LSTM 模型对 S 和 V 两种类别的分类能力在各项指标上都达到了较高的水平, 并且在 F1score 上取得了最高的分数, 优于目前其他类似的研究。MSCResNet-LSTM 中的多尺度卷积结构通过对输入样本多层次特征的学习, 帮助提升了模型的泛化能力和鲁棒性, 最终提高了模型对不同心律失常信号的准确分类能力。

表 4.20 本文和其他研究者对 S 类的分类效果

Table 4.20 Classification effect of S class by this paper and other researchers

研究	S				
	Acc	Sen	Spe	Pre	F1
线性判别分类器 ^[76]	0.946	0.759	None	0.385	0.5108
BbNN ^[77]	0.966	0.506	0.988	0.679	0.5799
DWT+ANN ^[78]	0.961	0.621	0.985	0.567	0.5928
DNN ^[79]	0.949	0.378	0.975	0.405	0.391
DBN ^[80]	0.9378	0.8839	None	0.3363	0.4872
DenseNet-GRU ^[6]	0.9361	0.627	0.964	0.6121	0.6194
CNN ^[35]	0.973	0.644	0.986	0.637	0.6404
ResNet	0.9494	0.6367	0.9863	0.8509	0.7284
ResNet-LSTM	0.9370	0.6884	0.9673	0.7198	0.7037
MSCResNet-LSTM	0.9530	0.7102	0.9826	0.8325	0.7665

表 4.21 本文和其他研究者对 V 类的分类效果

Table 4.21 Classification effect of V class by this paper and other researchers

研究	V				
	Acc	Sen	Spe	Pre	F1
线性判别分类器 ^[76]	0.974	0.777	None	0.819	0.7974
BbNN ^[77]	0.981	0.866	0.993	0.933	0.8982
DWT+ANN ^[78]	0.976	0.834	0.981	0.874	0.8521
DNN ^[79]	0.978	0.901	0.986	0.871	0.8857
DBN ^[80]	0.9663	0.7774	None	0.692	0.8053
DenseNet-GRU ^[6]	0.9371	0.9125	0.9477	0.883	0.8975

表 4.21 (续)

Table 4.21 (Continuation)

研究	V				
	Acc	Sen	Spe	Pre	F1
CNN ^[35]	0.988	0.91	0.993	0.90	0.9049
ResNet	0.8927	0.8603	0.9091	0.8284	0.8440
ResNet-LSTM	0.9380	0.8892	0.9629	0.9244	0.9065
MSCResNet-LSTM	0.9394	0.9146	0.9520	0.9067	0.9106

4.7 本章小结

在本章中，基于 MIT-BIH 心律失常数据库建立了 Intra-Patient 和 Inter-Patient 两种数据集，设计并构建了 ResNet、ResNet-LSTM、MSCResNet-LSTM 三种心律失常自动识别模型。通过对三种模型的 Acc、Sen、Spe、Pre 和 F1score 进行分析，MSCResNet-LSTM 在 Intra-Patient 和 Inter-Patient 两种数据集下都有最好的能力，分类准确率分别达到了 97.65%和 89.46%。在 Inter-Patient 数据集下，MSCResNet-LSTM 识别 S 类和 V 类心律失常的 F1 分数分别为 0.7665 和 0.9106，优于目前其他研究，较好实现了心律失常的分类识别。

结论

总结

现如今，心血管疾病患者人数正在增加，这在一定程度上是伴随人口老龄化而来的，心血管疾病已成为中国的重要卫生问题。大多数心血管疾病发病初期，常出现心律失常现象，采取措施检测心律失常，可以有效预防心血管疾病的发生。心律失常会引起心电信号时频域特征的改变，这些变化可以通过心电图识别。心律失常的传统识别方法不仅需要医生掌握熟练的心脏病学知识，而且目视识别的方法需要大量的精力和时间，且受一定主观因素的影响。在这样的情况下，心电信号的自动识别研究对减轻医疗负担、预防和治疗心血管疾病是十分有意义的。基于此，本文提出了一种基于深度学习的心律失常识别方法。本文的主要工作和成果如下：

1、从传统的心律失常识别和基于深度学习的心律失常识别两方面总结了国内外研究现状，阐述了本课题的主要研究内容，表明了课题的研究意义。

2、对心电信号的生理基础和波形特点以及心律失常的病理特异性和分类标准进行了概括，总结了深度学习的相关理论。

3、考虑到 EWT 在信号分解上的优越性，提出了一种基于 EWT 的心电信号降噪方法。通过分析心电信号的傅里叶频谱，改进了 EWT 基于傅里叶频谱选择计算边界的算法，使 EWT 更加适应对心电信号的分解。通过计算过零率和相关系数对包含基线漂移和低频噪声的 EMF 进行筛选，并通过小波阈值法对残余噪声进一步去噪。根据本文提出的算法与其他常用降噪方法的对比，基于 EWT 的心电信号降噪方法能够做到心电信号噪声的有效去除，同时算法的计算时间较短，能够满足心电信号实时监测条件下信号去噪的实时性，为心电信号的自动分类识别提供了良好的基础。

4、本文基于深度学习构建了 ResNet、ResNet-LSTM、MSCResNet-LSTM 三种心律失常自动识别模型，基于 Intra-Patient 和 Inter-Patient 两种数据集划分方式构建数据集。对比三种模型的分类结果，MSCResNet-LSTM 在两种数据集下都有最好的分类能力。在 Inter-Patient 数据集上的 S 类识别上，MSCResNet-LSTM 的准确度、灵敏度、特异性、查准率和 F1 分数分别为 0.9530, 0.7102, 0.9826, 0.8325, 0.7665；在 V 类的识别上，分别为 0.9394, 0.9146, 0.9520, 0.9067, 0.9106。本文提出的识别模型在心律失常分类识别上达到了先进水平，能够实现对心律失常的准确划分。

展望

本课题设计了基于深度学习的心律失常识别模型，一定程度实现了对心律失常的准确分类，但还有一些缺陷和不足需要进一步完善和研究。

1、在对心电信号的去噪研究中，主要讨论了几种常见的噪声类型：基线漂移、肌电干扰和高频噪声，但心电信号因采集条件等因素产生的噪声是多种多样的，本文提出的降噪算法在面对含有其他噪声成分的心电信号时降噪的有效能力和鲁棒性仍需进一步研究。

2、在使用 Inter-Patient 数据集情况下，MSCResNet-LSTM 模型对 S 类心律失常分类的 Sen 和 Pre 相比其他参数较低，这一方面是由于 S 类与 N 类在心电波形上较为相似，同时在数据集中 S 类样本的数量较少，这对深度学习模型提取深层特征的能力和面对不平衡样本时的泛化能力有了更高要求，如何提高模型的泛化能力是接下来的工作。

参考文献

- [1] Laksman Z, Wauchop M, Lin E, et al. Modeling atrial fibrillation using human embryonic stem cell-derived atrial tissue[J]. Scientific Reports, 2017, 7(1): 1-11.
- [2] 胡盛寿, 高润霖, 刘力生, 等. 《中国心血管病报告 2018》概要[J]. 中国循环杂志, 2019, 34(03): 209-220.
- [3] 骆方正, 蒋明峰, 张鹏, 等. 基于 BMD101 可穿戴式心电监测系统设计[J]. 电子测量技术, 2021, 44(21): 113-119.
- [4] Yao Q, Wang R, Fan X, et al. Multi-class Arrhythmia detection from 12-lead varied-length ECG using Attention-based Time-Incremental Convolutional Neural Network[J]. Information Fusion, 2020, 53: 174-182.
- [5] Boda S, Mahadevappa M, Dutta P K. A hybrid method for removal of power line interference and baseline wander in ECG signals using EMD and EWT[J]. Biomedical Signal Processing and Control, 2021, 67: 102466.
- [6] Guo L, Sim G, Matuszewski B. Inter-patient ECG classification with convolutional and recurrent neural networks[J]. Biocybernetics and Biomedical Engineering, 2019, 39(3): 868-879.
- [7] Yoon S J, Jang C-S. Classification of ECG arrhythmia using Discrete Cosine Transform, Discrete Wavelet Transform and Neural Network[J]. The Journal of The Korea Institute of Electronic Communication Sciences, 2012, 7(4): 727-732.
- [8] Minami K, Nakajima H, Toyoshima T. Real-time discrimination of ventricular tachyarrhythmia with Fourier-transform neural network[J]. IEEE Transactions on Biomedical Engineering, 1999, 46(2): 179-85.
- [9] Martis R J, Acharya U R, Lim C M, et al. Application of higher order cumulant features for cardiac health diagnosis using ECG signals[J]. International journal of neural systems, 2013, 23(04): 1350014.
- [10] Khadra L, Al-Fahoum A S, Binajjaj S. A quantitative analysis approach for cardiac arrhythmia classification using higher order spectral techniques[J]. IEEE Transactions on Biomedical Engineering, 2005, 52(11): 1840-1845.
- [11] Tuncer T, Dogan S, Pławiak P, et al. Automated arrhythmia detection using novel hexadecimal local pattern and multilevel wavelet transform with ECG signals[J]. Knowledge-Based Systems, 2019, 186: 104923.

- [12] Plawiak P, Acharya U R. Novel deep genetic ensemble of classifiers for arrhythmia detection using ECG signals[J]. *Neural Computing & Applications*, 2020, 32(15): 11137-11161.
- [13] 张浪飞, 李诗楠, 梁竹关, 等. 基于自适应多元多尺度熵的心电信号分类研究[J/OL]. *计算机应用研究*: 1-6. DOI: 10.19734/j.issn.1001-3695.2021.10.0450.
- [14] 徐晨华, 叶思超, 丰云杰, 等. 基于 SVM+XGBoost 集成分类器的 inter-patient 心律失常心电信号分类[J]. *国际生物医学工程杂志*, 2020, 43(05): 366-371,375.
- [15] 刘姝, 邵杰, 张颐婷, 等. 基于双谱和谱特征的心电信号分类方法[J]. *电子科技*, 2021, 34(05): 42-46+71.
- [16] Martis R J, Acharya U R, Min L C. ECG beat classification using PCA, LDA, ICA and Discrete Wavelet Transform[J]. *Biomedical Signal Processing and Control*, 2013, 8(5): 437-448.
- [17] Hu Y H, Tompkins W J, Urrusti J L, et al. Applications of artificial neural networks for ECG signal detection and classification[J]. *Journal of Electrocardiology*, 1993, 26: 66-73.
- [18] Izeboudjen N, Farah A. A New Neural Network System for Arrhythmia's Classification[J]. *NC*, 1998, 98: 23-25.
- [19] Acir N. Classification of ECG beats by using a fast least square support vector machines with a dynamic programming feature selection algorithm[J]. *Neural Computing & Applications*, 2005, 14(4): 299-309.
- [20] Wang J-S, Chiang W-C, Hsu Y-L, et al. ECG arrhythmia classification using a probabilistic neural network with a feature reduction method[J]. *Neurocomputing*, 2013, 116: 38-45.
- [21] Banupriya C V, Karpagavalli S. Electrocardiogram beat classification using probabilistic neural network[J]. *Int. J. Comput. Appl.(IJCA)*, 2014, 1(7): 31-37.
- [22] Zuo W M, Lu W G, Wang K Q, et al. Diagnosis of cardiac arrhythmia using kernel difference weighted KNN classifier[C]. *2008 Computers in Cardiology*. Bologna, Italy: IEEE, 2008: 253-256.
- [23] Song M H, Lee J, Cho S P, et al. Support vector machine based arrhythmia classification using reduced features[J]. *International Journal of Control Automation and Systems*, 2005, 3(4): 571-579.
- [24] Uyar A, Gurgen F. Arrhythmia classification using serial fusion of support vector machines and logistic regression[C]. *4th IEEE International Workshop on Intelligent Data Acquisition and Advanced Computing Systems*. Dortmund, Germany: IEEE, 2007: 560-565.
- [25] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. *Nature*, 2015, 521(7553): 436-444.
- [26] He X Y, Zhang W. Emotion recognition by assisted learning with convolutional neural networks[J]. *Neurocomputing*, 2018, 291: 187-194.
- [27] Marra G, Zugarini A, Melacci S, et al. An Unsupervised Character-Aware Neural Approach to Word and Context Representation Learning[C]. *27th International Conference on Artificial Neural*

- Networks (ICANN). Rhodes, Greece: ENNS, 2018: 126-136.
- [28] Liu S P, Tian G H, Zhang Y, et al. Active Object Detection Based on a Novel Deep Q-Learning Network and Long-Term Learning Strategy for the Service Robot[J]. IEEE Transactions on Industrial Electronics, 2022, 69(6): 5984-5993.
- [29] Feder A, Vainstein D, Rosenfeld R, et al. Active deep learning to detect demographic traits in free-form clinical notes[J]. Journal of Biomedical Informatics, 2020, 107: 103436.
- [30] Hong S, Wu M, Zhou Y, et al. ENCASE: An ENsemble CLASSifier for ECG classification using expert features and deep neural networks[C]. 2017 Computing in Cardiology. Rennes, France: IEEE, 2017: 1-4.
- [31] Hong S, Zhou Y, Wu M, et al. Combining deep neural networks and engineered features for cardiac arrhythmia detection from ECG recordings[J]. Physiological measurement, 2019, 40(5): 054009.
- [32] Hannun A Y, Rajpurkar P, Haghpanahi M, et al. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network[J]. Nature Medicine, 2019, 25(1): 65-69.
- [33] Li Y Z, Pang Y W, Wang J, et al. Patient-specific ECG classification by deeper CNN from generic to dedicated[J]. Neurocomputing, 2018, 314: 336-346.
- [34] Yildirim O. A novel wavelet sequence based on deep bidirectional LSTM network model for ECG signal classification[J]. Computers in Biology and Medicine, 2018, 96: 189-202.
- [35] Jiang J, Zhang H, Pi D, et al. A novel multi-module neural network system for imbalanced heartbeats classification[J]. Expert Systems with Applications: X, 2019, 1: 100003.
- [36] 张异凡, 黄亦翔, 汪开正, 等. 用于心律失常识别的 LSTM 和 CNN 并行组合模型[J]. 哈尔滨工业大学学报, 2019, 51(10): 76-82.
- [37] Oh S L, Ng E Y K, Tan R S, et al. Automated diagnosis of arrhythmia using combination of CNN and LSTM techniques with variable length heart beats[J]. Computers in Biology and Medicine, 2018, 102: 278-287.
- [38] 柯丽, 王丹妮, 杜强, 等. 基于卷积长短时记忆网络的心律失常分类方法[J]. 电子与信息学报, 2020, 42(08): 1990-1998.
- [39] 杨淑莹, 桂彬彬, 陈胜勇. 基于小波分解和 1D-GoogLeNet 的心律失常检测[J]. 电子与信息学报, 2021, 43(10): 3018-3027.
- [40] 刘亚楠, 于婷婷, 漆伟, 等. 基于优化残差网络的动态心电信号分类算法研究[J]. 光电子·激光, 2021, 32(08): 894-901.
- [41] 蒋明峰, 鲁慧, 李杨, 等. 基于金字塔卷积结构的深度残差网络心电信号分类方法研究[J]. 生物医学工程学杂志, 2020, 37(04): 692-698.

- [42] ANSI. Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms: ANSI/EC57-2012[S]. US: AAMI, 2012.
- [43] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [44] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]. 32nd International Conference on Machine Learning. Lille, France: IMLS, 2015: 448-456.
- [45] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. Computer Science, 2012, 3(4): 212-223.
- [46] 张海斌. 心电图信号质量评估方法研究[D]. 武汉: 武汉大学, 2019.
- [47] Thakor N V, Zhu Y S. Applications of adaptive filtering to ECG analysis: noise cancellation and arrhythmia detection[J]. IEEE Transactions on Biomedical Engineering, 1991, 38(8): 785-94.
- [48] Marque C, Bisch C, Dantas R, et al. Adaptive filtering for ECG rejection from surface EMG recordings[J]. Journal of Electromyography and Kinesiology, 2005, 15(3): 310-315.
- [49] Lu G, Brittain J-S, Holland P, et al. Removing ECG noise from surface EMG signals using adaptive filtering[J]. Neuroscience Letters, 2009, 462(1): 14-19.
- [50] Afonso V X, Tompkins W J. Comparing stress ECG enhancement algorithms[J]. IEEE Engineering in Medicine & Biology Magazine, 1996, 15(3): 37-44.
- [51] Christov I I, Daskalov I K. Filtering of electromyogram artifacts from the electrocardiogram[J]. Medical Engineering & Physics, 1999, 21(10): 731-6.
- [52] Sayadi O, Shamsollahi M B. ECG denoising and compression using a modified extended Kalman filter structure[J]. IEEE Transactions on Biomedical Engineering, 2008, 55(9): 2240-2248.
- [53] Gokgoz E, Subasi A. Effect of multiscale PCA de-noising on EMG signal classification for diagnosis of neuromuscular disorders[J]. Journal of Medical Systems, 2014, 38(4): 1-10.
- [54] Sameni R, Shamsollahi M B, Jutten C, et al. A nonlinear Bayesian filtering framework for ECG denoising[J]. IEEE Transactions on Biomedical Engineering, 2007, 54(12): 2172-2185.
- [55] Schreiber T, Kaplan D T. Nonlinear noise reduction for electrocardiograms[J]. Chaos (Woodbury, N.Y.), 1996, 6(1): 87-92.
- [56] Tracey B H, Miller E L. Nonlocal Means Denoising of ECG Signals[J]. IEEE Transactions on Biomedical Engineering, 2012, 59(9): 2383-2386.
- [57] Chiang H T, Hsieh Y Y, Fu S W, et al. Noise Reduction in ECG Signals Using Fully Convolutional Denoising Autoencoders[J]. IEEE Access, 2019, 7: 60806-60813.
- [58] 崔焘, 周亚同, 张若男, 等. 应用目标检测网络自动检测 ECG 信号所含噪声[J]. 中国医学物

- 理学杂志, 2020, 37(08): 1053-1061.
- [59] 李鑫, 熊鹏, 张兵, 等. 基于无损约束降噪自动编码器的心电信号降噪[J]. 计算机工程与设计, 2020, 41(09): 2401-2407.
- [60] 钱炜, 郑威, 徐伟, 等. 多层降噪自动编码器的心电信号去噪算法[J]. 计算机与数字工程, 2021, 49(10): 1957-1962.
- [61] 刘华, 楼光海, 黄微. 结合双树复小波变换和滑动平均滤波的心电信号去噪方法[J]. 电子测量技术, 2018, 41(19): 112-117.
- [62] 徐利, 徐久强, 冯家乐. 结合 CEEMDAN 与改进区间阈值的 ECG 降噪研究[J]. 小型微型计算机系统, 2020, 41(08): 1576-1579.
- [63] 张淼, 魏国. 心电信号平滑分解阈值去噪方法[J]. 哈尔滨工程大学学报, 2020, 41(09): 1329-1339.
- [64] 张培玲, 李小真, 崔帅华. 基于改进小波阈值-CEEMDAN 算法的 ECG 信号去噪研究[J]. 计算机工程与科学, 2020, 42(11): 2067-2072.
- [65] 王芳, 季忠, 彭承琳. 基于双树复小波变换的心电信号去噪研究[J]. 仪器仪表学报, 2013, 34(05): 1160-1166.
- [66] 杨园格. 基于提升方案的双小波心电信号去噪研究[J]. 机电信息, 2020(29): 120-121.
- [67] Hu M, Zhang S, Dong W, et al. Adaptive denoising algorithm using peak statistics-based thresholding and novel adaptive complementary ensemble empirical mode decomposition[J]. Information Sciences, 2021, 563: 269-289.
- [68] Xie X, Liu H, Shu M, et al. A multi-stage denoising framework for ambulatory ECG signal based on domain knowledge and motion artifact detection[J]. Future Generation Computer Systems-the International Journal of Escience, 2021, 116: 103-116.
- [69] 李国权, 李必禄, 林金朝, 等. 基于改进 EWT 的心电信号基线校正算法[J]. 仪器仪表学报, 2020, 41(04): 156-166.
- [70] Gilles J. Empirical Wavelet Transform[J]. IEEE Transactions on Signal Processing, 2013, 61(16): 3999-4010.
- [71] Wu Z, Huang N E. Ensemble empirical mode decomposition: a noise-assisted data analysis method[J]. Advances in Adaptive Data Analysis, 2009, 1(01): 1-41.
- [72] De Chazal P, O'dwyer M, Reilly R B. Automatic classification of heartbeats using ECG morphology and heartbeat interval features[J]. IEEE Transactions on Biomedical Engineering, 2004, 51(7): 1196-1206.
- [73] He K M, Zhang X Y, Ren S Q, et al. Deep Residual Learning for Image Recognition[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, USA: IEEE, 2016:

770-778.

- [74] Huang H, Liu J, Zhu Q, et al. A new hierarchical method for inter-patient heartbeat classification using random projections and RR intervals[J]. Biomedical Engineering Online, 2014, 13(1): 1-26.
- [75] Rodríguez-Sotelo J L, Castellanos-Domínguez G, Acosta-Medina C D, et al. Recognition of Cardiac Arrhythmia by Means of Beat Clustering on ECG-Holter Recordings[J]. Advances in Electrocardiograms-Methods and Analysis, 2011, 221: 225-250.
- [76] De Chazal P, Reilly R B. A patient-adapting heartbeat classifier using ECG morphology and heartbeat interval features[J]. IEEE Transactions on Biomedical Engineering, 2006, 53(12): 2535-2543.
- [77] Jiang W, Kong S G. Block-based neural networks for personalized ECG signal classification[J]. IEEE Transactions on Neural Networks, 2007, 18(6): 1750-1761.
- [78] Ince T, Kiranyaz S, Gabbouj M. A Generic and Robust System for Automated Patient-Specific Classification of ECG Signals[J]. IEEE Transactions on Biomedical Engineering, 2009, 56(5): 1415-1426.
- [79] Al Rahhal M M, Bazi Y, Alhichri H, et al. Deep learning approach for active classification of electrocardiogram signals[J]. Information Sciences, 2016, 345: 340-354.
- [80] Mathews S M, Kambhamettu C, Barner K E. A novel application of deep learning for single-lead ECG classification[J]. Computers in Biology and Medicine, 2018, 99: 53-62.

攻读学位期间所取得的相关科研成果

- [1] 耿读艳,赵宁,庞耕,秦兆旭,高泽宇.改进 EWT 算法的心电信号去噪研究[J].电子测量技术,2021,44(23):30-35.

致谢

时间转瞬即逝，研一刚入学的日子似乎在昨天，回首我的研究生生活，它有阳光也有风雨，可不管怎样，这些日子都成为了经验和回忆，光阴带走的是岁月，带来的是成长。在这三年的时光里，我遇到了许多可敬、可爱的人们，我要向他们表达我衷心的感谢。

首先要感谢我的导师耿读艳教授，耿老师对待科研严谨认真，学识渊博，本文是在耿老师的悉心指导下完成的，从课题的选择到关键问题的解决都离不开耿老师的谆谆教导。

感谢我的师兄师姐在学习上的指导和生活中的关照。感谢我的课题组同届同学和师弟师妹们，同他们的交流使我受益良多。感谢我的室友们在学习和生活上的陪伴和帮助。

感谢河北工业大学为我提供了完善的学习环境和平台资源，感谢电气工程学院所有老师和同学的帮助。

最后，我要感谢我的父母和家人，是他们让我能够以勇敢的心态面对所有的挑战。各位朋友，彼此珍重，我们一同迈向更精彩的未来。