

分类号: TP391

学校代码: 10410

密 级: 公开

学 号: 0202019091

江西農業大學
全日制学术型硕士学位论文



**基于深度学习的心电信号心律失常
分类方法研究**

**Research on ECG arrhythmia classification
method based on deep learning**

申 请 人: 李兴秀

指 导 教 师: 唐建军 副教授、华晶 副教授

学 科 专 业: 计算机科学与技术

所在培养单位: 计算机与信息工程学院

论文提交日期: 二〇二二年 六月

独创性声明

本人声明,所呈交的学位论文,是在指导教师指导下,通过我的努力取得的成果,并且是自己撰写的。尽我所知,除了文中作了标注和致谢中已经作了答谢的地方外,论文中不包含其他人发表或撰写过的研究成果,也不包含在江西农业大学或其它教育机构获得学位或证书而使用过的材料。与我一同对本研究做出贡献的同志,都在论文中作了明确的说明并表示了谢意。如被查有严重侵犯他人知识产权的行为,由本人承担应有的责任。

学位论文作者亲笔签名: 李兴秀 日期: 2022.6.2

论文使用授权的说明

本人完全了解江西农业大学有关保留、使用学位论文的规定,即学校有权送交论文的复印件和电子版,允许论文被查阅和借阅;学校可以公布论文的全部或部分内容,可以采用影印、缩印或其他复制手段保存论文。

保密,在____年后解密可适用本授权书。 ☐

不保密,本学位论文属于不保密。 ☒

(请在方框内打“√”)

学位论文作者亲笔签名: 李兴秀 日期: 2022.6.2

指导教师亲笔签名: 张华 日期: 2022.6.2

目 录

摘 要	I
Abstract	II
1 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 心电信号预处理研究现状	2
1.2.2 心电信号波形检测研究现状	3
1.2.3 心电信号特征提取和分类研究现状	4
1.3 本文研究内容	6
1.4 论文结构安排	7
2 心电信号分类相关基础理论	8
2.1 心电图信号的基础知识	8
2.2 心电信号预处理	9
2.2.1 基于小波变换的降噪	10
2.2.2 心电信号节拍分割和归一化	11
2.3 心律失常类型	12
2.4 心电数据库介绍	13
2.5 深度学习方法	14
2.5.1 卷积神经网络	14
2.5.2 长短期记忆网络	18
2.6 本章小结	19
3 基于 CNN 与 BLSTM 的心律失常分类	20
3.1 数据预处理及表示	20
3.2 基于 CNN 与 BLSTM 的心律失常分类模型	20
3.2.1 模型整体架构	20
3.2.2 卷积神经网络模块	22
3.2.3 双向长短期记忆网络模块	22

3.2.4 网络参数设置	23
3.3 实验与结果分析	23
3.3.1 实验数据	23
3.3.2 交叉验证	24
3.3.3 评估指标	24
3.3.4 实验结果及分析	25
3.3.5 与其他方法对比	26
3.3.6 消融实验	27
3.3.7 有无去噪对比分析	27
3.4 本章小结	28
4 基于改进的 HRNet-ECA 的心电信号 R 峰检测与心律失常分类	29
4.1 HRNet 介绍	29
4.1.1 HRNet 整体架构	29
4.1.2 特征融合	30
4.2 数据预处理	31
4.3 基于改进的 HRNet-ECA 的心电信号 R 峰检测与心律失常分类	32
4.3.1 模型整体架构	32
4.3.2 改进的 HRNet 架构	32
4.3.3 ECA-Res 单元	33
4.3.4 训练目标与参数设置	34
4.4 实验和结果分析	35
4.4.1 实验数据	35
4.4.2 交叉验证及评估指标	36
4.4.3 实验结果与分析	36
4.4.4 卷积核大小的选取	37
4.4.5 有无 ECA 模块的对比分析	37
4.4.6 比较 U-Net 和 HRNet 的性能	38
4.4.7 与其他方法比较	39
4.4.8 可视化分析	39

4.5 本章小结	40
5 总结与展望	41
5.1 总结	41
5.2 展望	41
参考文献	43
致谢	47
作者简介	48

摘 要

心律失常是心血管疾病中常见的病症之一,诊断心律失常往往需要通过心电图检查。然而对心电图的目视检查不仅耗时,而且可能导致误诊,影响疾病的预防及治疗。因此,需要通过自动分析技术来辅助医生进行心律失常的诊断,从而提高诊断效率和准确性。目前,实现心律失常自动分类的方法主要有基于传统机器学习方法和基于深度学习方法。传统机器学习方法分类器的性能很大程度上取决于手工提取特征的质量,模型泛化能力弱。基于深度学习的分类算法可以自动学习特征,能实现比传统机器学习算法更好的分类性能。因此,根据心电信号的特征,本文进行了基于深度学习的心电信号 R 峰检测和心律失常分类方法研究:

(1) 针对现有方法预处理时间成本高、对噪声敏感问题,提出了一种基于原始一维心电信号的心律失常自动分类的方法。该方法首先利用卷积神经网络(CNN)学习和提取心电信号的形态特征,之后通过双向长短期记忆网络(BLSTM)获取特征中的时间依赖关系,最后借助 softmax 函数完成心律失常的自动分类任务。方法采用 Mish 函数作为激活函数,使得模型在训练中更为稳定。在公开数据库 MIT-BIH 心律失常数据库上进行五折交叉验证,评估指标达到了 99.11%的平均准确率,表明该模型可以有效地提取原始心电信号的重要特征。

(2) 针对现有的方法大多数是对单个节拍的分类,提出了一种基于改进的高分辨率网络(HRNet)和有效通道注意力机制(ECA)的心电信号 R 峰检测与心律失常分类方法,该方法能够对包含多个心电节拍的心电信号片段进行识别分类。方法首先将原始心电信号分割成 5 秒时间长的心电信号片段,共 1800 个采样点,然后将这些片段输入到改进的 HRNet 模型中进行自动学习和分类。通过引入有效通道注意力机制模块,进一步加强了模型的特征提取和特征选择能力。在 MIT-BIH 心律失常数据库上进行了相关实验,所提方法在心律失常分类任务上获得了 99.86%的平均准确率,验证了方法的有效性。

关键词: 心电信号;深度学习;心律失常分类;R 峰检测

Abstract

Arrhythmia is one of the common diseases in cardiovascular diseases. The diagnosis of arrhythmia often needs ECG examination. However, the visual examination of ECG is not only time-consuming, but also may lead to misdiagnosis and affect the prevention and treatment of diseases. Therefore, automatic analysis technology is needed to assist doctors in the diagnosis of arrhythmia, so as to improve the accuracy and efficiency of diagnosis. At present, the automatic classification methods of arrhythmias mainly include traditional machine learning methods and deep learning methods. The performance of traditional machine learning classifier largely depends on the quality of manual feature extraction, and the generalization ability of model is weak. The classification algorithm based on deep learning can automatically learn features and achieve better classification performance than the traditional machine learning algorithm. Therefore, according to the characteristics of ECG signal, this paper studies the R-peak detection and arrhythmia classification method of ECG signal based on deep learning:

(1) Aiming at the problems of high preprocessing time cost and noise sensitivity of existing methods, an automatic classification method of arrhythmia based on original one-dimensional ECG signal is proposed. This method first uses the convolutional neural network (CNN) to learn and extract the morphological features of ECG signals, then obtains the time-dependent relationship in the features through bidirectional long short-term memory network (BLSTM), and finally completes the automatic classification of arrhythmias with the help of softmax function. The mish function is used as the activation function to make the model more stable in training. The five-fold cross validation is carried out on the open database MIT-BIH arrhythmia database, and the evaluation index reaches an average accuracy of 99.11%, which shows that the model can effectively extract the important features of the original ECG signal.

(2) Aiming at the classification of single beat in most of the existing methods, an ECG R-peak detection and arrhythmia classification method based on modified high-resolution network (HRNet) and effective channel attention mechanism (ECA) is proposed. This method can recognize and classify ECG segments containing multiple ECG beats. Methods first divides the original ECG signal into 5-second ECG segments with a total of 1800 sampling points, and then input these segments into the improved HRNet model for automatic learning and classification. By introducing the effective channel attention mechanism module, the ability of feature extraction and selection of the model is further strengthened. Relevant experiments are carried out on the MIT-BIH arrhythmia database. The average accuracy of the proposed method in arrhythmia classification task is 99.86%, which verifies the effectiveness of the proposed model.

Key words: ECG; Deep learning; Arrhythmia classification; R-peak detection

1 绪论

1.1 研究背景及意义

根据世界卫生组织提供的数据表明,心血管疾病(Cardiovascular disease, CVD)的死亡率占世界死亡率的 1/3。据资料[1]显示,我国现有心血管病患者人数为 3.3 亿且患病率持续上升,心血管病死亡率占城乡居民疾病死亡构成的 40%以上,具体的,城市为 43.81%,农村为 46.66%。心律失常是最常见的一种心血管疾病,由心脏电活动产生兴奋的异常、传导的异常或者两种异常的相互作用导致,可分为房性早搏、心室颤动和房室传导阻滞等。部分心律失常类型(如心室颤动和心室扑动)会导致心脏骤停和猝死,而其他不会危及生命的心律失常类型也需观察和治疗,以免恶化。因此,准确诊断和早期预防心律失常对降低心脏病发病率非常重要,及时检测出心律失常对救治该类心血管疾病患者具有重要意义。

心电图(Electrocardiogram, ECG)是一种简单无创、低成本测量心脏节律和电活动的技术,利用体表电极记录心脏每个心动周期所产生的电信号,提供了心脏状况和功能的重要信息,因此心电图被广泛用于诊断和治疗心律失常过程中^[2]。近年来,由于单导联测量 ECG 信号的智能可穿戴设备的可用性,能够实现对 ECG 信号的采集以用于预防和风险管理中,越来越多人开始关注自己的心脏健康状况。目前,诊断心律失常的主要方法是对心电图的目视检查。医生根据相关领域知识与积累经验对心电信号进行观察与分析,进而判断患者的心律失常类型。但是,异常的心电信号不仅种类繁多,而且部分异常的心电信号波形与正常信号波形存在的差异非常小,对复杂多样的心电图波形进行目视诊断容易造成误判。此外,部分患者需要对心电活动进行 24 小时长期的监测。于医生而言,对大量的长时间的心电信号的目视检查不仅费时费力,很难在短时间内观察到心电记录中的异常信息,还会因为人工精力的不足影响诊断的准确性和效率,因此一种能实现心律失常高效、准确的心电信号自动分类技术是迫切需要的^[3]。

随着科学技术的发展,计算机作为医学辅助诊断工具被不断应用于诸多医学领域,如生物医学信号的检测与分析、医学影像处理等,能够在很大程度上帮助医生减轻工作量,提高诊断效率,节约时间和人力成本。早期的心律失常自动检测技术,是利用以特征为中心的传统机器学习算法实现的,例如决策树、随机森林和支持向量机等。这些算法能帮助医生更及时和更准确的对患者的心电活动做出判断,提高疾病检测的效率,降低因人工误诊而导致的死亡风险。但是基于特征为中心的自动分类技术,往往需要深入的领域知识和预处理工作,这种方法一方面会因为提取关键的或重要的特征而增加额外的计算与时间成本,另一方面是传统分类器的性能高度依赖于预处理模块的性能和提取特征的质量,这使得研究者们将工作重心放在提取独特特征方面而非增强分类器的能力^[4],难以提升模型泛化性能。

自深度学习提出以来,众多工作者们对其进行了大量的研究工作,从全连接神经网络到卷积神经网络,网络性能越来越强。基于深度学习的自动分类方法因此受到了广泛的关注,例如使用卷积神经网络来实现图像的自动分类任务。与之类似的基于深

深度学习的心律失常分类方法可以减少预处理和特征提取工作，不需要额外的人工选择特征，可以自发学习输入数据的低层和高层特征，以端到端的形式将输入的心电信号自动映射到各个类别，克服了传统分类器的困难。基于此，本文研究了深度学习算法，并根据心电信号的特征进行了基于深度学习的心电信号心律失常自动分类方法研究。

1.2 国内外研究现状

长期以来，国内外研究人员为实现心电信号的自动分类开展了众多的研究工作。心电信号自动分类算法的流程如图 1-1 所示，首先在采集到心电信号之后，根据需要对心电数据预处理，预处理主要包括去除噪声、波形检测以及根据波形特征进行心电信号分割，之后对分割得到的心电节拍（单个心跳）进行特征提取，最后依据特征完成分类。目前，国内外研究者主要围绕心电信号的预处理、波形检测、特征提取以及分类四个方面进行了大量的研究。因此本文按照这四个方面介绍国内外的研究现状。

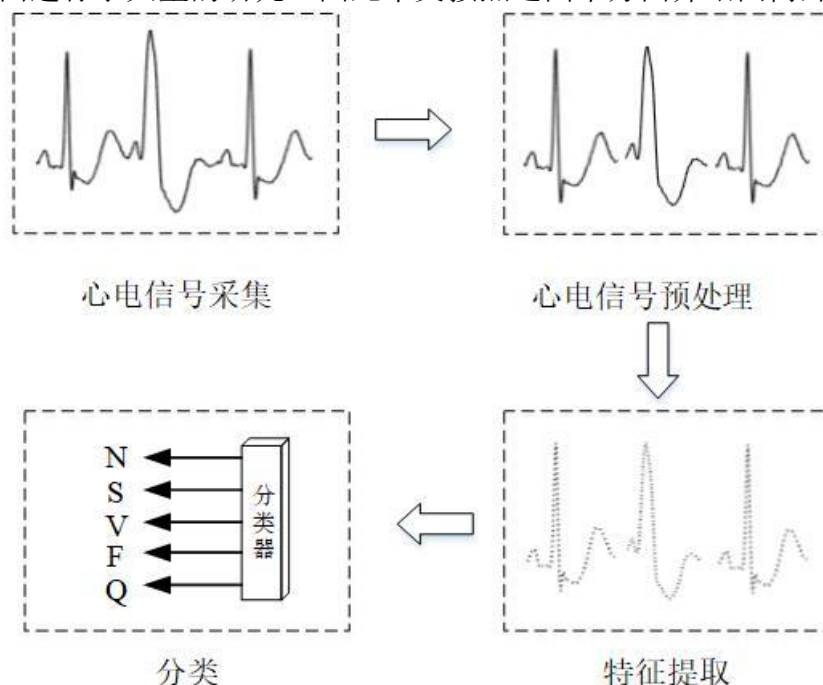


图 1-1 心电信号自动分类算法的流程

Fig 1-1 Process of ECG automatic classification algorithm

1.2.1 心电信号预处理研究现状

传统的心电信号自动分类方法往往需要高质量的心电信号，因为噪声等干扰信息会严重影响心律失常疾病的诊断，因此需要对原始信号进行预处理，大多采用滤波操作。心电信号预处理过程的滤波操作主要是消除信号中的噪声与基线漂移。降低心电信号噪声的方法中，最早被广泛使用的是有限脉冲响应(Finite impulse response, FIR)数字滤波器^[5]。但是这类方法无法实现对未知频带噪声的有效处理，若任意使用高通、低通滤波器则会改变原来心电信号的形态，失真严重的信号将无法用于心律失常的诊断。为解决此问题，自适应滤波器被提出并用于心电信号的预处理中，用来去除心电信号中的噪声^{[6],[7]}，如 Xue 等人提出了一种基于人工神经网络的自适应滤波算法，能

够有效消除噪声^[8]。

近年来,用于预处理的降噪算法主要有中值滤波、卡尔曼滤波、统计分析(如主成分分析、独立成分分析)、小波变换(Wavelet transform, WT),经验模态分解(Empirical mode decomposition, EMD)和神经网络等。由于小波变换能够保留原始数据的重要特征,许多研究工作采用了该方法进行心电信号的去噪,例如 Zhang 等人提出了基于离散小波变换(Discrete wavelet transform, DWT)的心电信号预处理方法,可以有效去除低频基线漂移和高频噪声^[9]。Chen 等人使用小波变换中的 Daubechies 6 小波来去除心电信号中的基线干扰^[10]。Sayadi 等人提出了一种改进的小波变换,称之为多自适应仿生小波变换(Multiadaptive bionic wavelet transform, MABWT),可以显著消除心电信号的噪声和基线漂移^[11]。李肃义等人提出了小波变换与模极大值法相结合的降噪算法,通过仿真实验结果表明该方法可以有效地去除心电信号中的各种噪声并且能使信号具有较小的失真度^[12]。EMD 算法可以将给定的数据根据本征模态函数(Intrinsic mode function, IMF)进行分解,是医学信号处理的新热点。例如 Ji 等人使用 EMD 算法将心电信号分解成多个经验模态,通过小波变换算法和中值滤波算法消除高频和低频的噪声与基线漂移,之后对处理过的经验模态和剩余的未处理的模态进行重新构建,获得了平滑且无噪声的心电信号^[13]。

除了以上提到的几种去除噪声的方法外,深度学习方法也被用于心电信号预处理中,例如 Xiong 等人开发了一个堆叠压缩去噪自动编码器用于心电信号的降噪^[14]。Arsene 等人提出了两种深度学习模型,分别为卷积神经网络模型和长短期记忆模型,通过实验表明两种方法均能处理高水平噪声,在均方根误差方面,卷积神经网络模型的表现显著优于长短期记忆模型,此外,作者还进行了基于小波标准的心电信号降噪实验,结果表明小波技术仅适用于去除随机噪声^[15]。

1.2.2 心电信号波形检测研究现状

正常的心电图信号是一种周期性的生物学信号,分为 P 波、QRS 波和 T 波等基本波形。采集的心电记录在经过降噪预处理后,通常需要根据波形来分割成心电信号片段,之后再进行下一步的特征提取和分类。由于心电信号的波形中 QRS 波群最为显著且提供了波形检测所需的重要信息,而 R 波在 QRS 波群中峰值较高,因此可以根据 R 波波峰计算其他波的位置,找到 R 波波峰的过程即为 R 峰检测。

在 R 峰检测的研究工作中,最具开创性的工作是 1985 年 Pan 等人提出的 Pan-Tompkins (PT) 算法,该算法首先利用数字带通滤波器对心电信号降噪,之后结合微分、平方、积分和自适应阈值等方法来检测心电信号中的 R 峰,在 MIT-BIH 心律失常数据库上可检测出 99.3% 的 QRS 波群^[16]。此外,遗传算法、香农信息熵算法、基于数学形态学方法、小波变换和深度学习算法等也被用于 R 波的检测。例如 Li 等人利用小波变换的多尺度特性,结合模极大值法来检测心电信号特征点,实验结果表明该方法即使在有严重噪声干扰的心电信号中,也能准确识别出 QRS 波群、P 波和 T 波^[17]。Benitez 等人使用希尔伯特变换来检测 QRS 波群,该方法具有较好的鲁棒性,即在有高噪声的心电信号中也能获得较高的灵敏度和阳性预测值^[18]。苏嘉豪等人利

用香农信息熵对经过滤波处理的心电信号进行 R 波的提取, 并根据 R 波的特征使用逻辑判断来检测 R 峰^[19]。Tarassenko 等人开发了一个多元感知器来学习识别特定患者的正常节拍, 当检测到形态异常的 QRS 波群时则将此心跳标记为异常, 通过训练该算法可以用来检测室性异位搏动^[20]。

深度学习方法中, Oh 等人通过改进的 U-Net 模型来实现 R 峰检测和心律失常分类, 在 R 峰检测任务上达到了 98.76% 的阳性预测值, 但灵敏度较低^[21]。Sarlija 等人使用了一维卷积神经网络分类器来检测心电信号中的 QRS 波形^[22], 该方法在预处理过程中对信号进行了归一化, 获得了 99.81% 的灵敏度和 99.93% 的阳性预测值。Wang 等人提出了基于一维残差卷积神经网络的心电图 QRS 波形检测方法^[23], 该方法相比方法^[22]减少了预处理步骤, 对噪声具有更强的鲁棒性。受方法^[23]的启发, Bitrafan 等人提出了一种基于残差扩展卷积神经网络的方法来检测 R 峰, 之后再根据检测到的 R 峰来分割心电信号^[24]。

由于深度学习算法需要大量的数据用于训练模型, 因此目前将其用于 QRS 波群检测的研究工作还较少。但是深度学习方法不需要任何先验知识就可对不同波形进行识别, 将会有更多改善的深度学习模型用于 QRS 波群的检测。

1.2.3 心电信号特征提取和分类研究现状

实现心律失常的自动分类最常用的方法有基于传统机器学习算法和基于深度学习算法。

(1) 基于传统机器学习算法

在早期的心电信号自动分类算法中, 为实现高性能的分类, 研究工作主要集中在特征提取和特征约简方面, 通常利用小波变换、频率分析、主成分分析、独立成分分析和高阶谱等方法获取心电信号中的形态特征、时域特征、频率特征和高阶统计等非线性特征^[25]。在得到需要的重要特征后, 使用支持向量机、决策树、K 最近邻、线性判别分析等分类器进行心律失常的分类。

基于传统机器学习算法中, Minami 等人先利用傅里叶变换观察由心律起源和传导路径引起的 QRS 波群的变化, 然后使用神经网络分类器进行分类, 在室性心律和室上性心律上实现了高于 98% 的灵敏度和特异性^[26]。Turker 等人结合离散小波变换 (DWT) 和一维十六进制局部模式技术对 10 秒的心电信号进行分解和特征提取, 使用 1 个最近邻 (1-NN) 分类器实现了 95% 的准确率^[27]。Martis 等人首先利用高阶谱方法捕捉心电信号的高阶累积量特征, 然后使用主成分分析对累积量特征进行数据缩减, 最后使用三层前馈神经网络分类器对 5 种心电信号进行分类^[28]。Sabut 等人提出了一种改进的基于多分辨率小波变换的 QRS 复合特征检测算法, 在支持向量机分类器上实现了 98.39% 的分类准确率^[29]。王金海等人利用经验模态分解算法和近似熵方法得到心电信号的特征向量, 然后利用具有粒子群优化算法的支持向量机分类器进行识别分类, 分类准确率达到 98.57%^[30]。

然而, 以上方法为获取关键的或重要的特征往往需要更多的推理计算和时间成本, 且模型分类的性能在很大程度上取决于提取特征的质量, 难以得到更好的泛化能力。

(2) 基于深度学习方法

随着深度学习技术的发展以及数据量的大幅增加,基于深度学习的机器学习算法能够有效地提高分类、检测等效率,并成功应用于心电图处理^[31]。与传统的机器学习方法不同的是,基于深度学习模型的方法可以自动学习输入数据的特征并实现分类,即无需进行人工提取特征,深度学习模型可以自发从输入信号中学习到重要特征并实现自动分类,实现端到端训练。

深度学习方法中,由于卷积神经网络(Convolution neural network, CNN)可以提取输入数据的深层次特征而被广泛应用^[32],例如, Kiranyaz 等人提出了一种针对特定患者心电图训练一维卷积神经网络的方法,即为特定的患者训练专门的卷积神经网络模型,以实现实时监测和快速准确地分类,该算法在室性异位搏动和室上异位搏动上实现了较好的分类性能^[33]。Rajpurkar 等人搭建了一个 34 层残差卷积神经网络模型,可以从一个可穿戴的单导联装置记录的心电图信号中检测出心律失常信息^[34]。Oh 等人提出的 U-Net 模型在心律失常分类任务上实现了 97.32%的准确率^[21]。Ullah 等人提出了一种基于二维卷积神经网络的方法,该方法首先通过短时傅里叶变换将一维时序心电信号转换成二维谱图,然后将谱图输入到由四个卷积层和四个池化层组成的二维卷积神经网络模型中进行特征学习和分类,得到了 99.11%的准确率^[35]。Golrizkhatami 等人利用卷积神经网络、小波变换和统计方法来提取心电信号中的形态学特征、统计特征和时间特征等不同层次的特征信息,然后使用决策层融合这些特征信息以输出心电信号的类别^[36]。Bouny 等人将卷积神经网络与平稳小波变换相结合,同时提取心电信号和其小波频带中的可判别特征,该方法达到了 99.11%的总体准确率^[37]。

心电信号是一维时间序列数据,而长短期记忆网络(Long short-term memory network, LSTM)能够捕获输入与目标之间复杂的时间上下文依赖关系^[38],因此部分研究者们使用 LSTM 来学习提取心电信号的时域特征。例如 Saadatnejad 等人提出了一种利用小波变换和多个 LSTM 自动提取特征的轻量级分类算法,该算法能够满足在处理能力有限的可穿戴设备上连续执行的时间要求^[39]。Pandey 等人通过高阶统计量、小波、形态描述符和 R-R 间隔将心电信号分解为 45 个特征,然后将这些特征进行组合归一化后输入到 LSTM 模型中分类,得到了 99.37%的准确率^[40]。Yildirim Ö 将心电信号分解为小波序列,然后将其输入到深度双向长短期记忆模型中进行分类,实现了 99.39%的准确率^[41]。循环神经网络(Recurrent neural network, RNN)也被用于心律失常的分类中,如 Pengfei 等人实现了一个并行的通用循环神经网络(GRNN)来对心跳进行分类,该方法达到了 95%的准确率^[42]。

由卷积神经网络和长短期记忆网络组成的混合网络架构,能实现比单个网络更好的分类效果。柯丽等人首先使用卷积神经网络对心电信号进行深度编码,提取心电信号的形态特征,然后根据心电信号的特征,采用长短期记忆网络实现心律失常的自动分类,该混合模型比单独使用长短期记忆模型获得了更好的性能^[43]。Wang 等人建立了与长短期记忆网络并联的叠层残差网络分类模型^[44]。在方法[24]中,作者设计了一个扩展的卷积层和一个长短期记忆网络层用于实现心电信号的分类,该算法在测试集上实现了 98.93%的整体准确率。Zeng 等人提出了一种基于可调 Q 因子小波变换

(TQWT)、变分模式分解 (VMD)、相空间重构 (PSR) 的心电信号特征提取方法, 之后将特征信息输入到深度学习模型中分类^[45]。Essa 等人提出了一种多模型集成深度学习的分类方法, 该方法使用了两种不同的深度学习模型 (CNN-LSTM 模型和 RR 特征-HOS 特征-LSTM 模型) 训练, 最后通过分类器输出最终决策^[46]。Huang 等人利用时不变最大重叠小波变换算法对 10 秒的心电信号进行分解, 对不同尺度的信号样本进行重构, 然后将其输入到快速压缩残差卷积神经网络中, 该网络由三个残差卷积模块和一个分类模块组成, 得到了 98.79% 的诊断准确率^[47]。Mousavi 等人提出了一种序列间深度学习方法, 该方法利用卷积神经网络和双向循环神经网络单元 (BiRNN) 来执行心跳检测任务^[48]。

1.3 本文研究内容

本文针对现有心电信号的 R 峰检测和心律失常分类方法的研究现状和存在问题, 进行了以下研究:

(1) 卷积神经网络 (CNN) 具有处理原始输入数据的能力, 对噪声具有鲁棒性。长短期记忆网络 (LSTM) 能够获得输入数据的长期依赖关系, 其中双向长短期记忆网络 (Bi-directional long Short-term memory, BLSTM) 能更好的对特征进行提取和表示, 适用于一维心电信号的处理。由上述两种网络组合起来得到一种混合网络架构 (CNN-BLSTM), 可以在信号特征提取过程中发挥它们各自的优势。基于这一想法, 针对现有方法对噪声敏感以及预处理时间成本高等问题, 提出了一种基于原始一维心电信号的心律失常自动分类方法。该方法首先利用卷积神经网络具有良好的噪声鲁棒性和计算速度比长短期记忆网络快等特点, 搭建了卷积神经网络模型来学习原始心电信号的深层次形态特征, 减少了长短期记忆网络中计算的数据点数量, 之后通过双向长短期记忆网络获取特征之间的时间依赖联系, 最后借助 softmax 函数完成分类任务。方法采用 Mish 函数作为激活函数, 使得模型在训练中更为稳定。最后通过在 MIT-BIH 心律失常数据库上进行相关仿真实验, 验证了本文提出模型的性能。

(2) 现有的心律失常心电图 (ECG) 自动识别算法是针对单个心电节拍或少数 QRS 波群的形态学特征的评估, 但通过对长时间 ECG 信号片段的分析, 实现对连续的 ECG 节拍信号准确分类更有利于心律失常的诊断。为实现对含有多个心电节拍的 ECG 片段的 R 峰检测和心律失常准确分类, 本文提出一种基于改进的高分辨率网络 (High-resolution network, HRNet) 和有效通道注意力机制 (Efficient channel attention, ECA) 的分类方法。该方法能够对正常窦性心律 (正常心跳)、房性早搏、室性早搏、左束支传导阻滞和右束支传导阻滞五种典型的心电信号类型进行 R 峰检测和心律失常分类两项任务。本文首先将原始心电信号分割成 5 秒时间长的 ECG 片段 (每个 ECG 片段包含 1800 个采样点), 然后输入到改进的 HRNet 模型中进行训练, 实现逐个采样点的 R 峰检测与逐个心电节拍的心律失常分类。为了获得合适的跨通道交互信息, 在模型中嵌入 ECA 模块。在 MIT-BIH 心律失常数据库上进行五折交叉验证实验, 该方法在 R 峰检测任务上实现了 99.95% 的准确率, 在心律失常分类任务上实现了 99.86% 的准确率, 验证了模型的有效性。最后, 与 UNet 模型进行对比, 结果表明无论是在

心电信号的 R 峰检测任务上还是在心律失常分类任务上, HRNet 模型均具有更好的性能。

1.4 论文结构安排

本文通过五个章节展开说明, 各章节内容安排如下

第 1 章: 绪论。首先介绍了心律失常分类的研究背景及意义, 其次介绍了心电图心律失常自动分类的国内外研究现状, 围绕现有研究主要进行的四个方面: 心电信号预处理、波形检测、特征提取和分类展开说明。

第 2 章: 心电信号心律失常分类相关基础理论说明。主要包括心电信号的基础知识、心电信号的预处理、心律失常的分类、心电数据库和涉及到的深度学习方法的扼要介绍。

第 3 章: 介绍提出的基于卷积神经网络和双向长短期记忆模型的心律失常分类方法, 该方法采用了 Mish 函数作为激活函数, 通过公开的 MIT-BIH 心律失常数据库验证了该算法的分类性能。此外, 在同一数据库上进行了原始心电数据和经过滤波处理数据的对比实验, 结果表明提出方法在噪声方面具有较好的鲁棒性。

第 4 章: 提出了基于改进的高分辨率网络和有效通道注意力机制的心电信号 R 峰检测与心律失常分类方法, 能够对 5 秒时间长的包含多个心电节拍的心电信号进行分类。在 MIT-BIH 心律失常数据库上进行有关实验, 实验结果验证了模型的有效性。

第 5 章: 总结与展望。总结了本文提出的方法, 展望了未来的研究工作。

2 心电信号分类相关基础理论

2.1 心电图信号的基础知识

心脏是一个特殊的电传导系统,通过控制有节奏的收缩和舒张将血液输送到全身,完成一次收缩和舒张的活动周期称之为一个心跳。心脏跳动正常的起搏点位于右心房的窦房结 (Sinoatrial node), 该处存有能够产生电信号的起搏细胞。信号通过结间束传到房室结 (Atrioventricular node), 之后沿着希氏束 (His bundle) 传递到心尖和浦肯野纤维 (Purkinje fibers), 最后到达心室^[49]。心脏的电传导系统和正常电活动反映的心电信号波形如图 2-1, 图 2-2 所示。




图 2-1 心脏的电传导系统^[50]

Fig 2-1 Electrical conduction system of heart^[50]




图 2-2 一个标准的心电节拍

Fig 2-2 A standard ECG beat

心电信号波形反映了心肌细胞在受到电信号刺激下发生的除极和复极过程,具体表现如下:静息电位时,心肌细胞处于外正内负的极化状态,当细胞受到电信号刺激时,细胞膜对钠离子通透性增加,对钾离子通透性降低,带正电荷的钠离子大量内流,

细胞外负电荷离子浓度相对升高,导致细胞膜两侧变成外负内正的动作电位,此过程称为除极;当电信号刺激消失时,心肌细胞膜电位又恢复到原来的极化状态,称之为复极。除极过程和复极过程会引起皮肤表面电势变化,将这种电势变化通过心电图机记录下来就是心电图(ECG)。

一个标准的心电节拍波形如图 2-2 所示,包含四种基本波形:P 波、QRS 波、T 波和 U 波。医生可以根据波形中的一些特征参数,如 ST 段、QRS 波群持续时间以及 QRS 波群的形态特征等来正确诊断心脏病,各波形介绍如下:

P 波: 在心电图上,P 波最早出现且振幅较小,代表的是心房除极的电位变化,持续时间通常为 0.08 秒,一般不超过 0.12 秒。

PR 间期: 自 P 波起始至 QRS 波群起始的间距,代表心房除极到心室除极所需时间,正常持续时间为 0.12 秒至 0.20 秒。

PR 段: 是 P 波终点到 Q 波起点的时段,反映了心房复极过程的电活动。

QRS 波群: QRS 波群的波形和振幅变化较大,反映左、右心室除极全过程的电位变化,正常时长为 0.06 秒至 0.10 秒。QRS 波群由 Q 波、R 波以及 S 波三个波组成,首先是向下的 Q 波,之后是向上的高而尖的 R 波,最后向下的是 S 波。

ST 段: ST 段表示 S 波结束点到 T 波开始点的间距,反映了心室完成除极到开始复极前的一段时间,时长在 0.08 秒至 0.12 秒。

T 波: 反映了心室复极过程的电位变化,持续时间在 0.05 秒至 0.25 秒。

QT 间期: 自 Q 波起点至 T 波终点的间距,表示心室开始除极至复极完毕的时间,正常值为 0.32 秒至 0.44 秒。

心电图能够反映心脏电活动从产生、传导至恢复全过程的电位变化。通过分析心电图可以了解心脏功能的基本信息,因此心电图被广泛用于检测心血管疾病中。

2.2 心电信号预处理

心电信号具有低频、低振幅等特点,一般需经过采集设备放大后再进行处理,在此过程中受设备、人体呼吸等因素,采集到的心电信号会夹杂干扰噪声。心电信号的噪声按其产生原因主要分为三类,第一类是采集设备在采集信号过程中产生的工频干扰,此类噪声频率一般固定在 50Hz,较容易去除;第二类是人体在采集中由于呼吸、肢体运动等产生的基线漂移,主要表现为心电信号的基线(等电位线)明显偏离正常位置,干扰严重时会使心电信号发生明显的畸变,造成信号严重失真,极不利于心电图的诊断;第三类是人体皮肤表面电流因肢体拉伸或人体肌肉颤动产生的肌电干扰,该类噪声的频谱接近白噪声,往往较难去除。

目前,消除心电信号中存在的噪声的方法有很多,如数字滤波、傅里叶变换、经验模态分解和小波变换等。其中小波变换是在傅里叶变换和短时傅里叶变换基础上发展起来的新的变换分析方法,能够提供一个随频率改变的时间-频率窗口,具备较好的时频分析特性,广泛应用于图像处理与信号处理等领域。由于心电信号是非平稳、非线性的时间序列信号,小波变换能够将信号进行多尺度分解,使用可变长窗口分析高频和低频信息,具有时频多分辨率分析的功能,非常适合处理时变的非平稳心电信

号，因而本文将小波变换用于相关的降噪实验中。

2.2.1 基于小波变换的降噪

小波变换实质上是使用多尺度分析对输入信号进行分解，得到不同尺度上的两个分量：细节系数（捕获原始信号中的高频、低尺度信息）和近似系数（原始信号中的低频、高尺度信息），通过不同尺度上的细节系数和近似系数将信号分解到不同的频带，提供时域和频域的代表性信息，实现对信号不同空间局部特征和不同时间尺度特征的自适应分析，对不同尺度上的小波系数进行取舍处理，最后通过逆变换重建信号。图 2-3 显示了输入信号进行多尺度小波分解到第四级的小波分解树及其细节系数(D)和近似系数(A)。输入信号由其相应的小波系数表示为(A4+D4+D3+D2+D1)。

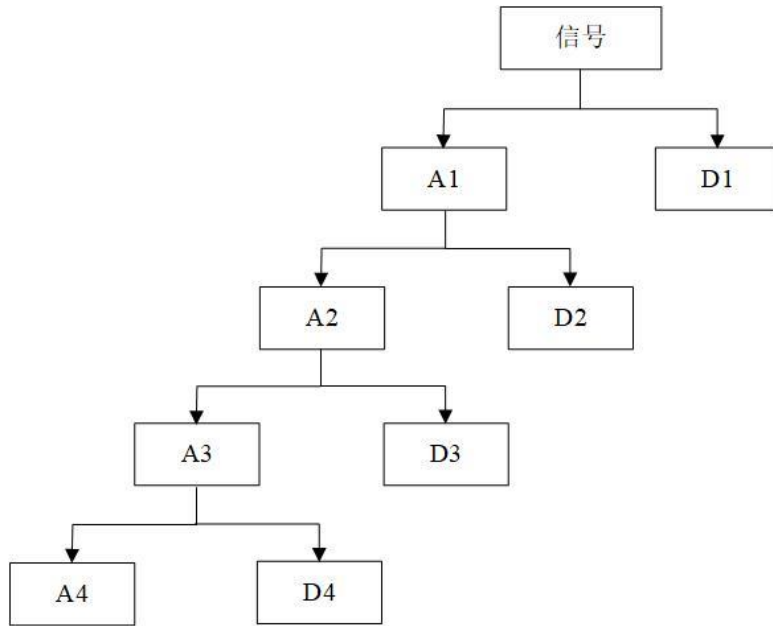


图 2-3 小波分解树^[51]

Fig 2-3 Wavelet decomposition tree^[51]

为计算信号的时频分量，定义了小波基函数 $\Psi_{a,b}(t)$ 。在小波变换中，小波基函数由基本小波进行伸缩与平移变换得到。基本小波也称为小波母函数，具体地，小波基函数 $\Psi_{a,b}(t)$ 由小波母函数 $\Psi(t)$ 通过伸缩尺度因子 a 和位移尺度因子 b 变换得到，如公式 (2-1) 所示：

$$\Psi_{a,b}(t) = \frac{1}{\sqrt{a}} \Psi\left(\frac{t-b}{a}\right) \quad (2-1)$$

其中伸缩尺度因子 a 控制小波母函数的伸缩，位移尺度因子 b 控制小波母函数的平移。小波母函数需满足重建（容许性）条件 C_Ψ ，条件公式如 (2-2) 所示：

$$C_\Psi = \int_{-\infty}^{\infty} \frac{|\Psi(s)|^2}{|s|} ds < \infty \quad (2-2)$$

令给定的心电信号为 $x(t)$ ，则其进行连续小波变换的本质是不同尺度下基本小波 $\Psi(t)$ 和信号 $x(t)$ 作内积，连续小波变换公式如 (2-3) 所示：

$$W_x(a,b) = \langle x, \Psi_{a,b} \rangle = \int_{-\infty}^{\infty} x(t) \Psi_{a,b}(t) dt = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} \Psi\left(\frac{t-b}{a}\right) x(t) dt \quad (2-3)$$

为从小波系数中重构输入信号 $x(t)$ ，相应的逆变换如公式 (2-4) 所示：

$$x(t) = \frac{1}{C_\Psi} \int_0^\infty \int_{-\infty}^\infty W_x(a,b) \Psi_{a,b}(t) db \frac{da}{a^2} \quad (2-4)$$

基于小波变换的心电信号去噪流程是：首先将信号进行多尺度分解，得到不同尺度下的细节系数分量和近似系数分量，之后结合阈值法或模极大值法等方法对每个尺度的小波系数进行分析处理，去除系数中被认为是噪声的部分，对剩余系数进行小波逆变换重新构建信号，以得到干净的数据。

在进行小波变换时，需根据小波的相似性、正则性、支撑长度、消失距阶数和对称性等指标来选择合适的波基函数。由于 Daubechies 小波的波形与心电信号相似，且具有良好的正则性（信号的光滑程度），因此本文选择 Daubechies 6 (db6) 小波结合阈值法将心电信号进行分解与重构。使用 Daubechies 6 滤波能够去除基线和噪声，去噪前、后心电信号波形如图 2-4 所示。

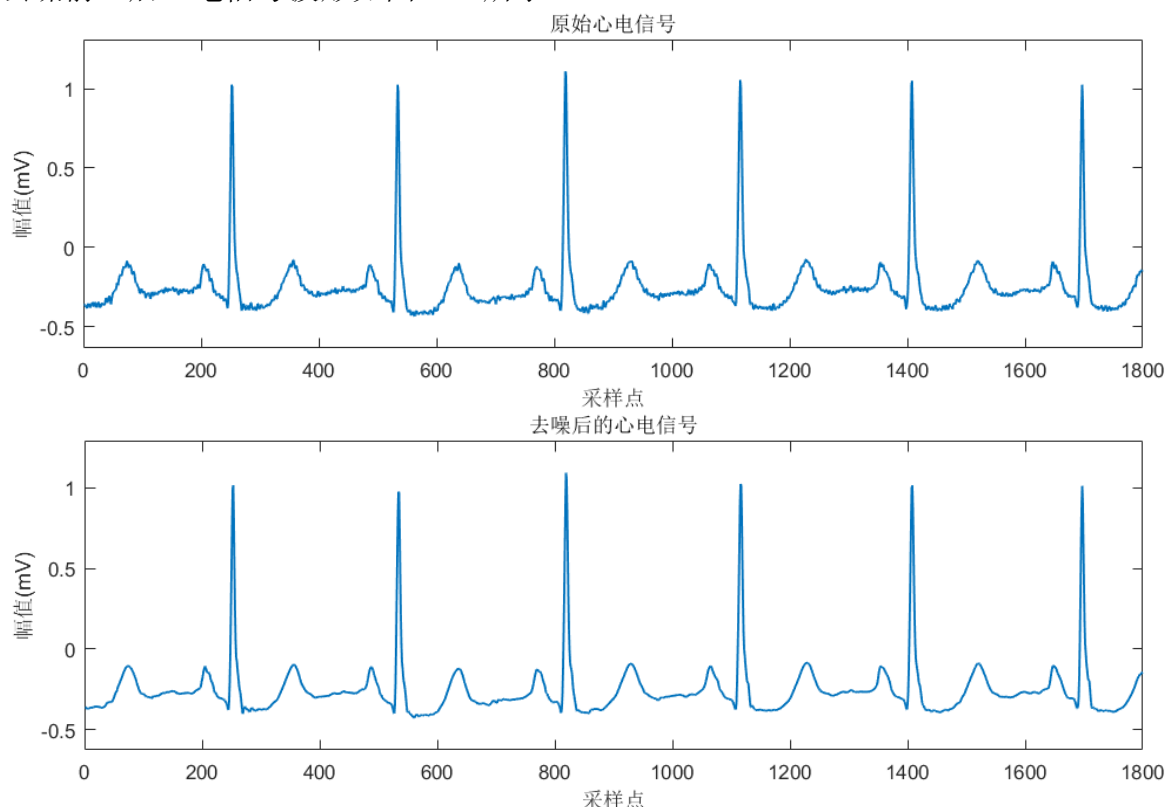


图 2-4 去噪前、后心电信号波形图

Fig 2-4 ECG signal waveform before and after denoising

2.2.2 心电信号节拍分割和归一化

为减少模型的计算量，滤波后的心电信号需要分割成合适的片段后再用于后续的特征提取和分类步骤。本节参考分割方法如下：采用 MIT-BIH 心律失常数据库^[52]，根据方法[48]在数据库的注释文件中找到 R 波集（所有 R 波波峰的位置信息），然后从检测到的 R 波集找到 T 波集，最后根据 T 波集将心电信号分割成单个的节拍（一

个心跳周期)。ECG 信号分割示意图如图 2-5 所示。




图 2-5 心电信号分割图

Fig 2-5 Schematic diagram of ECG signal segmentation

为统一数据长度，将每个分段心跳的采样长度固定为 256 个采样点。最后，对这些采样点进行归一化处理，将原始值映射到[0, 1]的范围。采用 mapminmax 函数进行归一化，该函数表达式如公式 (2-5) 所示：

$$x_{new} = (y_{max} - y_{min}) * \frac{x - x_{min}}{x_{max} - x_{min}} + y_{min} \quad (2-5)$$

其中 x 是输入的原始心电数据， y_{min} 与 y_{max} 是调用该归一化函数时设置的参数，默认的归一化区间为[-1, 1]， x_{min} 与 x_{max} 是数据中的最小值与最大值， x_{new} 是归一化后的心电数据。归一化后得到的心电节拍如图 2-6 所示。




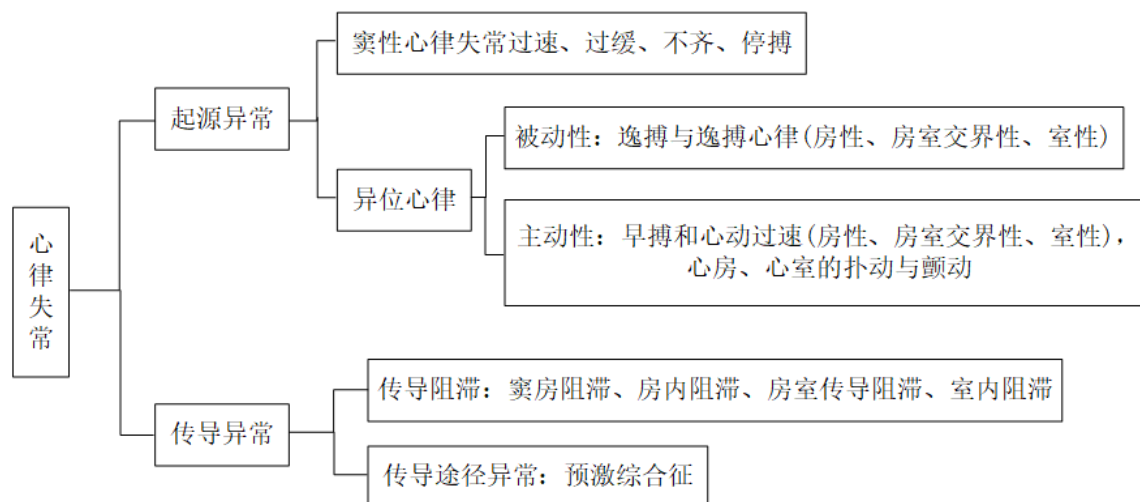
图 2-6 心电信号归一化结果图

Fig 2-6 ECG normalization result diagram

2.3 心律失常类型

心律失常是心血管疾病中的典型代表，可单独发作也可与其他心血管病共同发作。当发生心律失常时，会导致血液循环失常，引起心悸、胸闷和无力等症状。轻微的心律失常如因运动或兴奋造成的心动过速不会对普通成年人的生活造成严重影响，但也需尽早发现并监测，以免恶化成更危险的疾病。少数心律失常类型如心室颤动、室性心动过速等严重时会引起猝死，需要及时通过药物或手术治疗。心律失常按其产生原

因可分为两大类，分别是心脏电活动的起源异常和在传导过程中发生的传导异常。常见心律失常类型如图 2-7 所示。



2.4 心电数据库介绍

目前国际上具有权威性的心电数据库有四个，分别是美国麻省理工学院提供的 MIT-BIH 数据库、欧盟 CSE 数据库、美国心脏学会提供的 AHA 数据库和欧盟 ST-T 心电数据库。MIT-BIH 心律失常数据库包含 48 个双导联的心电记录，每条记录包含从 47 个患者的 24 小时记录中选择的 30 分钟段，47 名患者中 25 名男性年龄在 32 岁至 89 岁之间，22 名女性年龄在 23 岁至 89 岁之间，心电记录以 0.1 至 100Hz 的频率通过带通滤波器，采样频率是 360Hz。CSE 多导联数据库大约含有 1000 个 12 导联或 15 导联 ECG 记录，每个记录均以 500 个采样点/秒的速度采样，持续时间为 10 秒。AHA 数据库由 155 个双导联模拟动态心电图记录组成，包含八种心律失常类别，每段记录的采样频率是 250Hz，长度为 3 小时，但仅对最后 30 分钟内的节拍进行了注释。ST-T 数据库包含 90 个数据记录，每个心电记录的采样频率是 250Hz，每个心电节拍的 ST 段和 T 波改变均由医生人工标注，该数据库主要用于评估算法对 ST 段和 T 波的检测性能。四个心电数据库的基本信息如表 2-1 所示。

表 2-1 四个权威的心电信号数据库
Table 2-1 Four authoritative ECG databases

信息	MIT-BIH	CSE	AHA	ST-T
导联数量	2	12 或 15	2	2
采样频率	360Hz	500 Hz	250 Hz	250 Hz
记录总数	48	大约 1000	155	90
每条记录长度	30 分钟	10 秒	3 小时	2 小时
记录注释范围	所有	所有	最后 30 分钟	所有
价格	免费	收费	收费	免费

由于目前大多数研究都采用 MIT-BIH 心律失常数据库进行心律失常的检测与分类，因此本文采用该数据库进行实验以便对比。MIT-BIH 心律失常数据库的 48 条心

电记录大约包含 109500 个心电节拍，其中异常的心电节拍占比约为 30%，主要包括 16 种心电类型标签，具体类别如表 2-2 所示。

MIT-BIH 心律失常数据库的每个心电记录包含三个文件类型，分别是记录数据相关属性信息（如采样频率、数据格式、导联号、分辨率等）的头文件、有两个导联信号数据的数据文件以及注释文件，注释文件记录了权威专家标注的心电节拍类型和 QRS 波群 R 波的位置信息，用于评估算法性能。

表 2-2 MIT-BIH 心律失常数据库类型
Table 2-2 MIT-BIH arrhythmia database type

标签	英文名称	心跳类型
N	Normal beat	正常心跳
L	Left bundle branch block beat	左束支传导阻滞
R	Right bundle branch block beat	右束支传导阻滞
e	Atrial escape beat	房性逃逸
j	Nodal (junctional) escape beat	结性（交界性）逃逸
A	Atrial premature beat	房性早搏
a	Aberrated atrial premature beat	异常房性早搏
J	Nodal (junctional) premature beat	结性（交界性）早搏
S	Premature or ectopic supraventricular beat	室上性早搏或异位搏动
V	Premature ventricular contraction	室性早搏
E	Ventricular escape beat	室性逃逸
F	Fusion of ventricular and normal beat	心室融合心跳
!	Ventricular flutter wave	心室颤动波
P	Paced beat	起搏心跳
f	Fusion of paced and normal beat	起搏融合心跳
Q	Unclassifiable beat	未分类心跳

2.5 深度学习方法

2.5.1 卷积神经网络

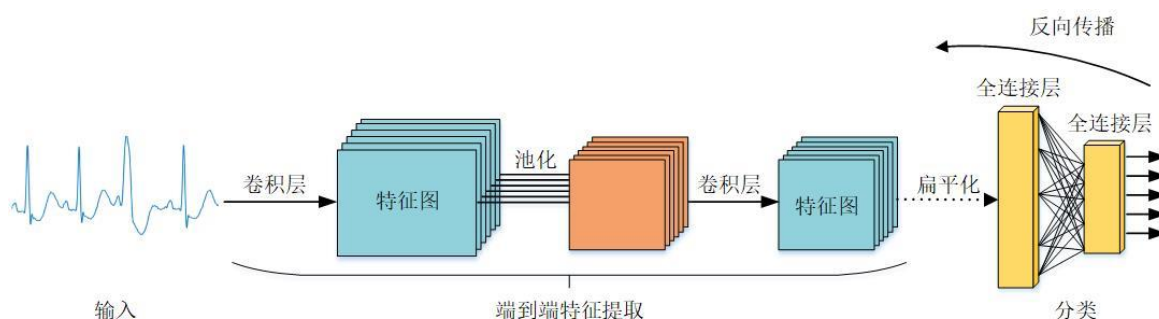


图 2-8 卷积神经网络示意图

Fig 2-8 Schematic diagram of simple convolutional neural network

卷积神经网络是受人类视觉皮层系统启发的人工神经网络之一，具有平移不变性、局部连通和权重共享等特性，相比全连接神经网络能够减少网络模型的参数量和复杂

度，使模型易于优化的同时降低过拟合的可能，是图像与信号处理、语音识别、计算机视觉和医学图像分析等众多领域常用的网络结构。卷积神经网络模型一般由卷积层、池化层以及全连接层组成，基本的卷积神经网络结构如图 2-8 所示。

卷积层：卷积层由若干卷积单元组成，在上层的特征向量和当前层的卷积核之间执行卷积运算来实现特征提取，最后通过激活函数得到下一层的特征序列，计算公式如下：

$$X_j^l = \sum_{i \in M_j} W_{ij}^l * Y_j^{l-1} + b_j^l \quad (2-6)$$

$$Y_j^l = f(X_j^l) \quad (2-7)$$

其中 l 、 j 和 i 分别表示网络中的第 l 层、第 j 个卷积核和卷积核中第 i 个权重值， Y_j^{l-1} 和 X_j^l 表示 l 层中第 j 个卷积核的输入和输出特征向量值， M 为卷积核大小， W^l 、 b^l 为 l 层的权重和偏置， $f(\cdot)$ 为激活函数。

池化层：卷积神经网络中通常将多个卷积层和池化层堆叠在一起，用来提取输入信息的高级特征。池化层又称下采样层，通过下采样操作来减少特征图大小，获得不同尺度的特征，实现降维，减少计算成本。池化操作能够去除冗余信息的同时保留有用信息，具有进一步特征提取功能。

池化层通常分为为最大值池化和平均值池化，最大值池化输出特征提取窗口中的最大值，平均值池化输出特征提取窗口中所有数值的平均值。两种池化过程如图 2-9 所示，若输入的特征图大小是 4×4 ，在经过核大小为 2×2 、步长为 2 的池化层后，输出的特征图大小变成了 2×2 。池化操作缩小了特征图的同时也保留了原始特征图中的显著信息。




图 2-9 最大值池化和平均值池化

Fig 2-9 Maximum pooling and average pooling

全连接层：全连接层是卷积神经网络中的具有若干个输出神经元的多层感知器。全连接层的作用是对高度抽象的特征进行整合和输出，可以完成回归或分类任务，其表达公式如下：

$$Y_j^l = f(W_j^l * Y_j^{l-1} + b_j^l) \quad (2-8)$$

其中 W 、 b 为权值与偏置， $f(\cdot)$ 为激活函数。

激活函数：从公式 (2-6) 可以看出卷积层的卷积运算得到的是输入与输出的线性表示，无法实现非线性拟合功能，而输入与输出之间的关系往往是复杂的、非线性的。为得到非线性映射，需要在卷积运算后引入非线性激活函数，使得数据间的线性关系变成非线性以增强模型的表达能力，常用的激活函数有 Sigmoid、Tanh、ReLU 以及

ReLU 函数变体如 Leaky ReLU、ELU 等。

Sigmoid 函数：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-9)$$

Sigmoid 函数是较为常用的非线性激活函数，函数几何图像及其导数的几何图像如图 2-10 所示。Sigmoid 函数的特点是能够将输入值变换为 (0, 1) 之间的输出值，观察该函数和其导数几何图像可知，当输入值不断增大或不断减小时，输出值的变化越小，变化趋近于零。由于神经网络需要通过反向传播来更新各个神经元上的权重值，而经过 Sigmoid 函数的微分计算会导致梯度降低，随着网络层数的增加，梯度几乎为零，即出现梯度消失现象，这会使得权重无法得到优化，模型难以收敛。




图 2-10 Sigmoid 函数及其导数几何图像

Fig 2-10 Sigmoid function and its derivative geometric image




图 2-11 Tanh 函数及其导数几何图像

Fig 2-11 Tanh function and its derivative geometric image

Tanh 函数：

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-10)$$

Tanh 函数即双曲正切函数，该函数及其导数的几何图像如图 2-11 所示。Tanh 函数输出值在 (-1, 1) 区间且以零为中心。观察其几何图像可知，该函数与 Sigmoid 函数相近，即当输入值非常大或非常小时，输出值的变化接近于零。由于其导数值不大

于 1，仍存在梯度消失问题。

ReLU 函数：

$$\text{ReLU} = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (2-11)$$

ReLU 函数几何图像及其导数的几何图像如图 2-12 所示，该函数的优点是当输入为正数时，导数值为 1，不会产生梯度消失。由于 ReLU 函数不涉及指数运算，计算速度相较于 Sigmoid 和 Tanh 函数都要快很多，然而在反向传播时，如果输入为负数，梯度完全为零。

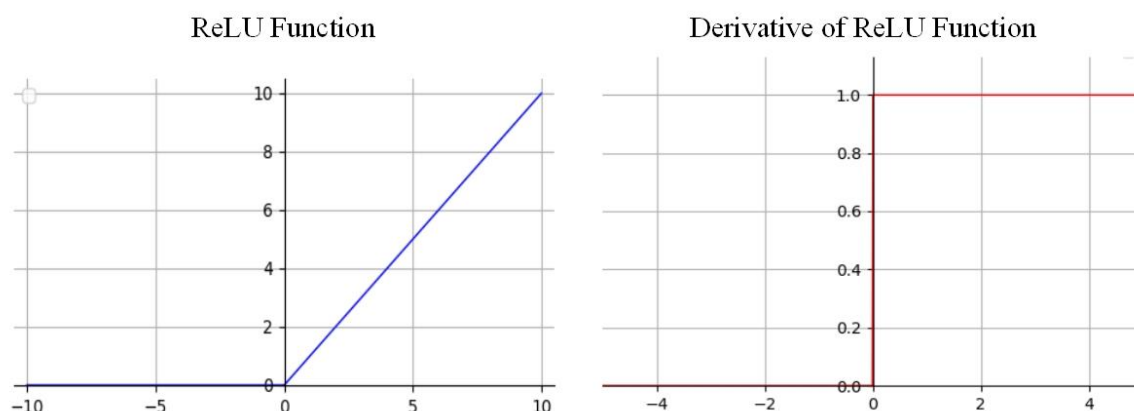


图 2-12 ReLU 函数及其导数几何图像

Fig 2-12 ReLU function and its derivative geometric image

Mish 函数^[53]是一个新的激活函数，函数表达式如下：

$$\text{Mish} = x * \tanh(\ln(1 + e^x)) \quad (2-12)$$

Mish 函数是自正则化的非单调函数，函数曲线如图 2-13 所示，从图像易知 Mish 函数具有上无界、下有界的特点，与 ReLU 函数一样能够解决梯度消失问题，但与 ReLU 不同的是 Mish 函数没有硬零边界，即该激活函数允许保留少量的负值信息，保证具有一定的正则化效应，实现更好的反向传播能力。

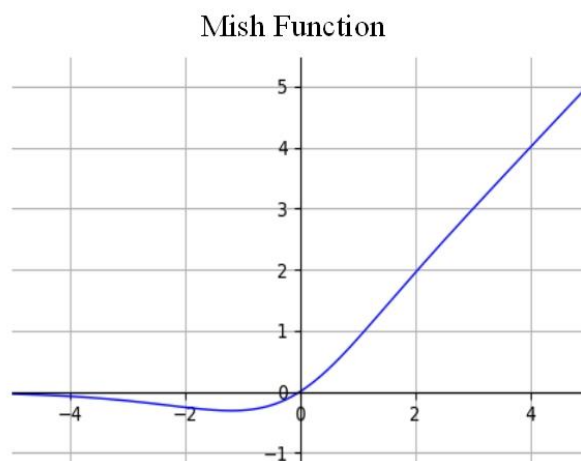


图 2-13 Mish 函数几何图像

Fig 2-13 Mish function image

2.5.2 长短期记忆网络

卷积神经网络能够作为特征提取器对输入数据进行抽象表示，但是对于时间序列信号需要考虑长期和短期的依赖关系^[25]。循环神经网络通过向前馈神经网络中添加一个存储单元能够实现短期记忆功能，目前较多地用于自然语言处理、机器翻译等领域。然而循环神经网络无法学习长期的依赖关系，在网络参数优化时会产生梯度消失或梯度爆炸的问题。长短期记忆网络（LSTM）是一种特殊的循环神经网络，LSTM 单元的结构特点和单元之间的连接允许信息在相邻的时间步中循环，通过反向传播训练模型，可以处理长期依赖关系，解决梯度消失问题，因此适用于时间序列数据的分析处理和预测。




图 2-14 LSTM 单元的内部结构

Fig 2-14 LSTM unit architecture

LSTM 单元由输入门、遗忘门和输出门组成，三个门共同控制着进出单元的信息流，其中输入门控制信息是否进入存储单元，即当输入门打开时，信息就会进入存储单元，通过关闭输入门可使存储单元状态不受无关信息的影响；输出门控制信息是否流出存储单元；遗忘门可以重置单元状态，保留有用信息，遗忘无用信息，这可避免存储单元状态信息无限量的增长，为新信息的输入留出空间，从而实现短期、长期记忆功能^[54]。LSTM 单元的内部结构如图 2-14 所示。

计算公式如下：

$$f_t = \sigma(w_f x_t + w_f h_{t-1} + b_f) \quad (2-13)$$

$$i_t = \sigma(w_i x_t + w_i h_{t-1} + b_i) \quad (2-14)$$

$$u_t = \tanh(w_u x_t + w_u h_{t-1} + b_u) \quad (2-15)$$

$$c_t = i_t \times u_t + f_t \times c_{t-1} \quad (2-16)$$

$$o_t = \sigma(w_o x_t + w_o h_{t-1} + b_o) \quad (2-17)$$

$$h_t = o_t \times \tanh(c_t) \quad (2-18)$$

其中 i_t , f_t , c_t , o_t 分别为输入门, 遗忘门, 单元状态和输出门, x_t 是输入序列, h_{t-1} 为前一个单元块的输出, c_{t-1} 为前一个 LSTM 存储块的状态值, u_t 为状态更新, w 和 b 分别表示权重和偏置, σ 为 Sigmoid 激活函数。输入门通过激活函数来创建新的记忆信息, 输出门生成当前 LSTM 单元输出信息。

2.6 本章小结

本章对心电图信号的基础知识和深度学习方法做了简要的介绍, 首先说明了心电信号的产生机理, 描述了心电信号中每个波形代表的含义; 其次根据心律失常产生的原因介绍了常见的心律失常类型, 之后介绍了国际上较为权威的四个心电数据库, 重点介绍了本文使用的 MIT-BIH 心律失常数据库; 最后介绍了深度学习算法的两种模型, 分别是卷积神经网络和长短期记忆网络。

3 基于 CNN 与 BLSTM 的心律失常分类

在提取空间特征方面卷积神经网络表现良好,而在学习时间特征方面长短期记忆网络表现突出,这两种网络结构的结合可以提取信号的本质特征^[10]。双向长短期记忆网络能够访问过去和未来的上下文信息,具有更好的特征提取和特征表示能力,结合上述网络的优点,本章提出了一种使用一维卷积神经网络(CNN)和双向长短期记忆网络(BLSTM)的心律失常分类方法,该方法不像传统方法一样需要进行人工特征提取或滤波处理过程。提出的模型首先使用卷积神经网络提取心电信号的深层形态特征,降低数据维度,然后利用双向长短期记忆网络获取特征之间的时间依赖联系,最后通过 softmax 函数实现 5 大类心电信号的分类,即根据 AAMI 标准^[55]建议分成的五种类型,包括 N 类(正常类心跳)、S 类(室上性异位心跳)、V 类(室性异位心跳)、F 类(融合心跳)和 Q 类(未能分类心跳)。

接下来,本章主要从数据预处理及表示、基于 CNN 与 BLSTM 的心律失常分类模型以及相关实验方面展开说明。

3.1 数据预处理及表示

目前的心电信号心律失常分类研究中,大多数算法的预处理工作通常包含滤波操作,也就是使用数字滤波方法或小波变换等来去除心电信号中存在的噪声,得到较为干净的心电数据。使用未经滤波处理的心电信号可以尽可能保留信号所蕴含的原始信息,增强模型的噪声鲁棒性,本章在数据预处理过程不进行降噪处理或任何预先的提取特征工作,而是直接将原始心电数据分割成统一长度的心拍,然后使用混合神经网络模型来进行心电信号心律失常的分类。

采用了公认的 MIT-BIH 心律失常数据库进行本章算法验证,该数据库的基本信息已在第二章介绍。心电信号原始数据首先通过 Matlab 中 mapminmax 函数归一化到[0,1]之间,然后根据注释文件标注的 R 峰值位置,按文献[48]方法找到 T 波集,根据 T 波将心电信号分割成单个心跳(心电节拍)的片段,并给心电片段标注相应的心律失常类型标签。为保证模型输入形状一致,将分割得到的每个片段统一到长度为 256 个采样点的数据段。把经过预处理之后的心电片段 $\mathbf{X}=[x_1, x_2, \dots, x_n]$ 作为模型的输入,其中 n 为 256, \mathbf{X} 对应的标签为 y , $y \in \{N, S, V, F, Q\}$ 。

3.2 基于 CNN 与 BLSTM 的心律失常分类模型

3.2.1 模型整体架构

所提模型是一个端到端的混合神经网络架构,即 CNN-BLSTM 架构,该架构将特征提取和分类操作融合到一个过程中。具体的,该模型由卷积神经网络

(CNN) 和双向长短期记忆网络 (BLSTM) 构成, 其中卷积神经网络模块被作为前端用于得到初始输入心电数据的非线性特征, 双向长短期记忆网络作为后端接收卷积神经网络模块提取到的抽象数据, 提取数据中的时间信息, 最后利用全连接层输出分类结果。CNN-BLSTM 模型包含四个卷积块和一个双向 LSTM 层, 其中每个卷积块包含三个卷积层, 每个卷积层后面紧跟着一个批归一化层 (BN 层) 和一个激活层, 为保留显著信息和防止网络过拟合, 在卷积块中引入了最大值池化层和丢失层。四个卷积块后是一个双向长短期记忆模块, 用于提取时间序列信息, 之后使用两个全连接层来完成信息的整合和输出分类。图 3-1 和表 3-1 分别给出了本文提出的 CNN-BLSTM 结构和对应的详细参数。




图 3-1 CNN-BLSTM 结构

Fig 3-1 Structure of CNN-BLSTM

表 3-1 CNN-BLSTM 结构的参数与细节

Table 3-1 Parameters and details of CNN-BLSTM structure

层	类型	卷积核数目/单元数	核大小, 步长	输出	参数
0	Input	-	-	256×1	0
1	Conv1D	16	8, 1	256×16	208
2-4	Conv1D Block	16	8, 1	256×16	6384
5	Max Pooling	-	2, 2	128×16	0
6	Dropout (0.1)	-	-	128×16	0
7-9	Conv1D Block	32	8, 1	128×32	20960
10	Max Pooling	-	2, 2	64×32	0
11	Dropout (0.1)	-	-	64×32	0
12-14	Conv1D Block	64	8, 1	64×64	82880
15	Max Pooling	-	2, 2	32×64	0
16	Dropout (0.1)	-	-	32×64	0
17-19	Conv1D Block	128	(4, 2, 1), 1	32×128	83840
20	Max Pooling	-	2, 2	16×128	0
21	Bi LSTM	128	-	256	263168
22	Dropout (0.2)	-	-	256	0
23	Dense	64	-	64	16448
24	Dense	5	-	5	325

3.2.2 卷积神经网络模块

卷积神经网络模块由若干个卷积层、池化层以及其他操作组成,如图 3-1 所示。多个卷积层能有效提取心电信号片段中的深度特征,加入池化层能够进一步提取高层次特征。批归一化层^[56]可以使数据分布均匀,加快模型的收敛速度;激活层可以得到非线性的变换,提升模型拟合效果,因此在每个卷积层后面添加一个批归一化层和一个激活层。

就激活函数而言,大部分研究选择的是 ReLU 函数(公式 2-11),根据其函数表达式可知,ReLU 激活函数将负输入都变成零,这表明模型处理过程中的数据如果是非正数,则会将该信息转变为零值,造成信息的丢失,因此在本章模型中的激活层使用了自正则化的 Mish 函数(公式 2-12),两个激活函数的几何图像对比如图 3-2 所示。由图 3-2 可知,相比 ReLU 激活函数,Mish 函数能够允许少量的负值存在,即信息更加完整,使得模型达到更好的性能。

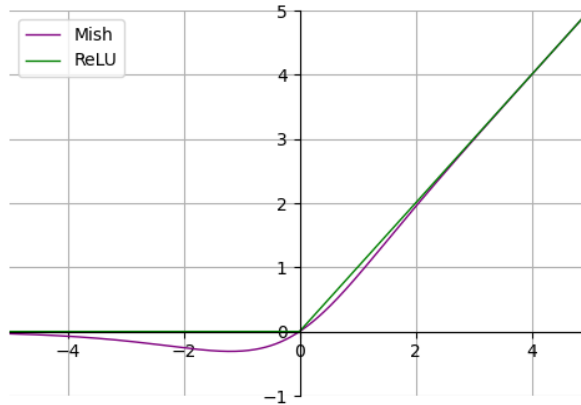


图 3-2 ReLU 函数与 Mish 函数的图像

Fig 3-2 Image of ReLU function and Mish function

为减少心电信号中的冗余信息,保留显著信息,同时降低模型的计算复杂度,在每个卷积块后使用一个最大值池化层,池化层的步长为 2。此外,为防止网络过度拟合,通过丢失层随机删除网络中的部分信息可以减少隐藏层节点间的相互作用,因此在最大值池化层后添加一个丢失层来减少过拟合现象,丢失层的丢失率为 0.1。

3.2.3 双向长短期记忆网络模块

卷积神经网络擅长处理空间或局部相关的数据,而长短期记忆网络能够捕捉时序相关的数据特征。由于心电信号是一维的时序数据,因此长短期记忆模型能够获取心电信号中时间维度上的信息。长短期记忆网络单元的输入门、输出门和遗忘门能够通过控制单元中的信息流,选择增加或删除信息,从而获取长时间段的信息之间深层联系。

双向长短期记忆(BLSTM)网络包含一个随时序正向 LSTM 和逆时序反向 LSTM 两个网络,它可以向前和向后处理两个方向的数据,因此当前单元状态可以同时访问以前和将来的信息。基于双向长短期记忆网络在处理时序数据上的优势,本文使用该网络获取卷积神经网络提取到的特征之间的长期依赖联系,双向

LSTM 网络结构如图 3-3 所示。双向 LSTM 网络的正向网络和反向网络包含相同数量的 LSTM 单元，本文模型设置其数量为 128。

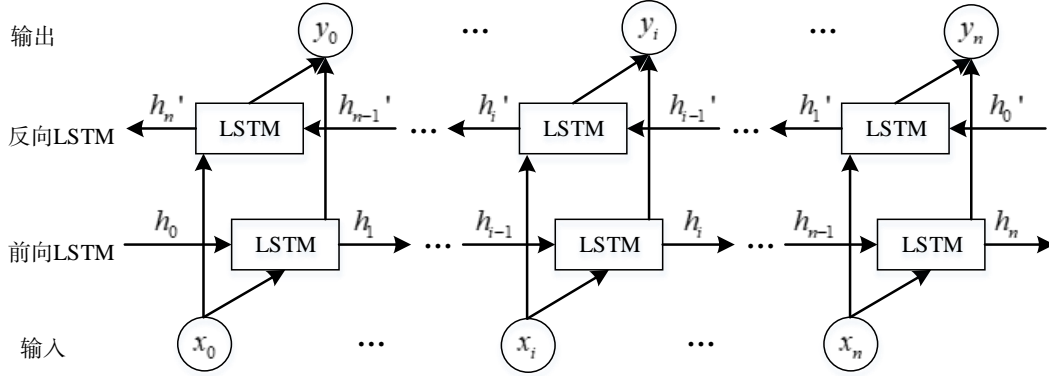


图 3-3 双向 LSTM 网络结构图

Fig 3-3 Bidirectional LSTM network architecture

在双向长短期记忆网络模块之后是一个丢失率为 0.2 的丢失层和节点数为 64 的全连接层，最后通过一个激活函数为 softmax 函数的全连接层来实现 5 大类心电信号的分类任务：

$$P(X_i) = \frac{e^{X_i}}{\sum_{j=1}^5 e^{X_j}} \quad (3-1)$$

其中 $P(X_i)$ 为预测的 X_i 属于所有可能类的概率分布。

使用交叉熵损失函数 $L_f(\theta)$ 优化模型，公式如下：

$$L_f(\theta) = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m y_{ij} \log(p_{ij}) \quad (3-2)$$

其中 n 是样本量， m 是类别数量， p_{ij} 是第 i 个样本 j 类分类器的输出， y_{ij} 是第 i 个样本 j 类的注释标签。

3.2.4 网络参数设置

网络设置训练轮数为 80，批量大小即一次输入模型的参数为 128。利用 Adam 优化函数更新权重，初始学习率为 0.001。在训练后期为缩短损失震荡幅度，加快模型收敛速度，使用衰减比率为 0.1 的学习率衰减法来自动降低学习率。

3.3 实验与结果分析

本章在深度学习框架 Keras 上进行了模型的训练和测试实验，所有实验均在一台处理器为 Intel Core i5-10300H、显卡为 NVIDIA GeForce RTX2060 的计算机上完成。

3.3.1 实验数据

实验数据来源于 MIT-BIH 心律失常数据库。根据 AAMI 标准，只有 44 条记录可以使用，因为有 4 条记录（记录 102、104、107 和 217）是心脏起搏器收集

的，其信号质量无法得到保证，不能进行可靠的处理。因此去除以上四条心电记录，将剩余 44 条第二导联的心电记录按预处理方法进行分割，并根据 AAMI 标准建议将分割后得到的心电节拍按其类型划分为 N 类（正常类心跳）、S 类（室上性异位心跳）、V 类（室性异位心跳）、F 类（融合心跳）和 Q 类（未能分类心跳）五大类，获得心电节拍总样本个数 100588，具体类别和数量见表 3-2。

表 3-2 AAMI 标准在心电信号中的详细分类
Table 3-2 Detailed classification of AAMI standards in ECG

AAMI 类别	MIT-BIH 心跳类别	数量
Normal (N)	正常心跳	89996
	房性逃逸	
	交界性逃逸	
	左束支传导阻滞	
	右束支传导阻滞	
Supraventricular ectopic beat (S)	房性早搏	2777
	异常房性早搏	
	交界性逃逸	
	室上性早搏	
Ventricular ectopic (V)	室性早搏	6999
	室性逃逸	
Fusion (F)	心室融合心跳	802
Unknown (Q)	起搏心跳	14
	起搏融合心跳	
	未分类心跳	

3.3.2 交叉验证

为得到可靠的实验结果，使用五折交叉验证方法来评估所提模型的稳定性。总样本被平均划分成五份，依次抽取其中一份用来测试，其余四份用来训练，因此会进行五次实验。每一次实验都评估模型分类的性能指标，最后计算五次实验评估指标的平均值来获得总体性能度量。

3.3.3 评估指标

为评估本章模型的有效性，使用四种指标来评估模型的性能，分别是准确率 (Acc)、灵敏度 (SE)、特异性 (SP) 和阳性预测值 (PPV)，各评估指标定义如下：

$$Acc(\%) = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (3-3)$$

$$SE(\%) = \frac{TP}{TP + FN} \times 100\% \quad (3-4)$$

$$SP(\%) = \frac{TN}{TN + FP} \times 100\% \quad (3-5)$$

$$PPV(\%) = \frac{TP}{TP + FP} \times 100\% \quad (3-6)$$

其中 TP（真阳性）表示分类正确的阳性样本数，TN（真阴性）表示分类正确的阴性样本数，FP（假阳性）表示阴性样本被错误分类为阳性样本的数量，FN（假阴性）表示阳性样本被错误分类为阴性样本的数量。

3.3.4 实验结果及分析

使用 MIT-BIH 心律失常数据集来训练和评估所提模型，经过五折交叉验证后，将各评估指标的平均值作为各心电信号类型及总体的最终评估结果，实验结果见表 3-3。由该表可知，本章模型在五大类心电信号的整体准确率、灵敏度、特异性和阳性预测值分别为 99.11%、92.33%、98.95%和 95.46%。

表 3-3 模型在测试集上分类的评估结果

Table 3-3 Evaluation results of model classified on the test set

类别	Acc (%)	SE (%)	SP (%)	PPV (%)
N	99.24	99.73	95.14	99.43
S	99.57	89.21	99.86	94.84
V	99.64	97.14	99.82	97.63
F	99.79	83.23	99.92	89.93
Q	99.99	0.00	1.00	0.00
总体	99.11	92.33	98.95	95.46




图 3-4 模型在测试集上分类的混淆矩阵

Fig 3-4 Confusion matrix of model classified on test set

图 3-4 给出了 CNN-BLSTM 模型在测试集上分类的混淆矩阵，根据混淆矩阵可知，所提出的模型能够对大多数的心电节拍正确分类。由于 F 类节拍和 Q 类节拍样本数量相对于其他三类（N 类、S 类、V 类）较少，模型不能充分学习到 F 类与 Q 类的重要特征，导致评估结果偏低。此外，S 类的灵敏度较低，原因可能是 S 类中的房性早搏类型心跳起源于窦房结以外心房的任何部位，表现为出

现形态异常的 P 波或 P 波的缺失,加上房性早搏类型心跳 QRS 波群与 N 类中的右束支传导阻滞类波形相似,使得模型无法正确区分。尽管如此,本章方法对 S 类心律失常仍实现了较好的分类性能。

3.3.5 与其他方法对比

本章模型与其他方法(采用 MIT-BIH 心律失常数据集)进行对比,如表 3-4 所示,对比方法实验结果来自对应文献。其中文献[57]使用了 db6 小波进行心电信号的去噪,通过多组对比实验得出 13 层的视觉几何群网络(mVGGNet)是最优模型,获得了 97.87%的准确率。文献[58]搭建了一个 9 层卷积神经网络模型来识别 5 类心电信号,在使用 db6 小波去噪的数据集上的分类准确率为 94.03%。Hua 等人提出了在原始心电信号中使用 R-R-R 的分割策略,该分割策略能够让网络模型更好地学习到心电信号的潜在信息,在一个平衡数据集上获得了 97%的平均准确率和平均灵敏度^[59]。本章方法在未去噪且未平衡的数据集上的准确率达到 99.11%,能够在原始心电数据中学习到重要信息,实现了较好的分类性能。

表 3-4 本文方法与其他方法整体性能比较表

Table 3-4 The overall performance comparison table of this method and other methods

文献	方法	Acc (%)	SE (%)	SP (%)	PPV (%)
本文	原始信号 + CNN-BLSTM	99.11	92.33	98.95	95.46
文献[36]	CNN+小波变换 +SVM	98.00	88.65	-	89.05
文献[37]	小波变换 + CNN	99.11	-	-	-
文献[42]	巴特沃斯滤波 + GRNN	95.00	-	-	-
文献[57]	db6 小波+ CNN	97.87	-	-	-
文献[58]	db6 小波 + CNN	94.03	96.71	91.54	97.86
文献[59]	原始信号 + CNN	97.45	97.00	-	-

表 3-5 本文方法与其他方法在 SVEB 类和 VEB 类上分类性能比较表

Table 3-5 Comparison table of classification performance between this method and other methods on SVEB and VEB

文献	SVEB			VEB		
	SE (%)	SP (%)	PPV (%)	SE (%)	SP (%)	PPV (%)
本文	89.21	99.86	94.84	97.14	99.82	97.63
文献[33]	64.60	98.60	62.10	95.00	98.10	89.50
文献[37]	87.68	99.84	93.35	98.05	99.79	97.11
文献[39]	66.90	99.80	95.70	93.00	99.80	98.20
文献[42]	85.50	99.40	92.30	88.00	98.90	92.60
文献[58]	90.59	98.63	94.30	94.22	98.84	95.30

由于 S 类(SVEB 类)和 V 类(VEB 类)的心电信号波形与 N 类信号中部分心跳的波形存在的差异非常小,许多方法在这两类上未能实现较好的分类性能,于患者而言是不利的。因此,对 SVEB 类和 VEB 类心跳的正确识别是分类器的

一项重要任务。表 3-5 给出了本章方法与其他研究对这两类心律失常的分类能力。从表中可知，在灵敏度、特异性和阳性预测值评估指标上，相比表中其他方法，本章模型在整体性能上表现更好，验证了本章方法的有效性和先进性。

3.3.6 消融实验

为验证提出的模型和 Mish 激活函数的有效性，本章进行了两组消融实验，第一组为使用 CNN-BLSTM、CNN-LSTM、CNN 以及 BLSTM 模型的消融实验；第二组为激活函数使用 Mish 和 ReLU 的消融实验。

消融实验均采用五折交叉验证策略来训练和评估模型，实验结果见表 3-6。模型的消融实验是基于卷积神经网络（CNN）、长短期记忆网络（LSTM）和双向长短期记忆网络（BLSTM）模块的有效组合展开的，其中 CNN-BLSTM 方法首先通过卷积神经网络提取原始心电信号的形态特征，之后使用双向长短期记忆网络获得特征之间的深层联系，采用 Mish 激活函数，获得了最好的分类性能。

在激活函数的消融实验中，相比 ReLU 函数，使用 Mish 激活函数实现了更高的准确率，原因在于 Mish 激活函数能够保留少量的负值数据，有利于网络学习到更加完整的信息。

表 3-6 激活函数和模型的消融实验分类性能比较表

Table 3-6 Comparison table of classification performance of activation function and model

模型	激活函数	分类性能(%)			
		Acc	SE	SP	PPV
CNN-BLSTM	Mish	99.11±0.09	92.33	98.95	95.46
	ReLU	98.98±0.11	91.40	98.80	95.30
CNN-LSTM	Mish	99.06±0.09	92.24	98.90	95.29
CNN	Mish	99.05±0.06	91.93	98.86	95.56
BLSTM	Mish	98.53±0.03	87.68	98.07	95.26

3.3.7 有无去噪对比分析

表 3-7 原始心电数据与去噪后的数据对比实验分类性能比较表

Table 3-7 Comparison table of experimental classification performance between original data and denoised data

Method	心电数据集	分类性能(%)			
		Acc	SE	SP	PPV
CNN-BLSTM	原始信号(本文)	99.11	92.33	98.95	95.46
	Db6 小波滤波	99.18	93.88	99.08	95.49
	Db8 小波滤波	99.16	93.10	99.09	94.88

为验证本章模型的噪声鲁棒性，对 MIT-BIH 心律失常数据库进行三种预处理工作得到三组实验数据，分别是未进行去噪的原始心电数据、经过 db6 小波去噪的心电数据以及经过 db8 小波去噪的心电数据。对比的三组实验数据仅存在是否经过或者经过何种小波去噪的区别，其他预处理方法以及模型训练和评估过程

完全相同，对比实验的结果见表 3-7。由该表可知，本章模型对未降噪心电数据的分类性能与小波去噪心电数据的结果相近，表明模型能够从未进行降噪处理的心电信号中提取到重要特征，验证了所提模型对噪声具有较好的抗干扰能力。

3.4 本章小结

本章提出了一种基于卷积神经网络与双向长短期记忆网络的混合网络模型，该模型可以从原始心电信号中学习到重要的形态特征及特征之间的深层联系，并按照 AAMI 标准推荐类别进行五大类心电信号分类。通过在 MIT-BIH 心律失常数据集上实验的结果表明，该组合模型能够有效提取一维心电信号的特征，实现了高准确率分类。通过心电信号是否去噪的对比实验表明，模型对噪声具有良好的鲁棒性。

4 基于改进的 HRNet-ECA 的心电信号 R 峰检测与心律失常分类

高分辨率网络（High-Resolution Network, HRNet）在特征提取过程中能够保持高分辨率表示,并通过对高到低子网生成的特征进行融合,生成可靠的高分辨率特征^[60],自提出以来已被广泛应用于关键点检测、语义分割和人脸特征点定位等领域。这些领域与本章研究内容有相似之处,因此可以将该网络用于心电信号的 R 峰检测与心律失常分类中。由于高分辨率网络是针对二维图像设计的,对于心电信号一维数据,该模型还没有进行探索。就此,本章改进了高分辨率网络使其适用于一维心电数据,并嵌入了有效的通道注意力模块（Efficient Channel Attention, ECA）^[61]来实现对一维心电信号的 R 峰检测与心律失常分类。该方案首先将正常窦性心律（Normal beat）、房性早搏（Atrial premature beat, APB）、室性早搏（Premature ventricular contraction, PVC）、左束支传导阻滞（Left bundle branch block, LBBB）和右束支传导阻滞（Right bundle branch block, RBBB）五类原始心电信号分割成 5 秒的心电片段,然后输入到改进的 HRNet 模型中进行自动学习和分类。

接下来,本章主要从高分辨率网络、本章实验数据预处理、基于改进的 HRNet 和 ECA 模型的 R 峰检测与心律失常分类方法以及相关实验方面展开说明。

4.1 HRNet 介绍

4.1.1 HRNet 整体架构

高分辨率网络（HRNet）是由 Sun 等人在 2019 年提出的^[60]。与大多数经典网络结构如 U-Net、VGGNet 类似,HRNet 由卷积层、下采样层、批归一化层和激活层组成。然而,与一般网络不同的是,HRNet 网络无需通过由低到高的操作来恢复高分辨率特征,而是并行连接高低分辨率子网,并将各子网中的特征进行融合来保持高分辨率表示,如图 4-1 所示。

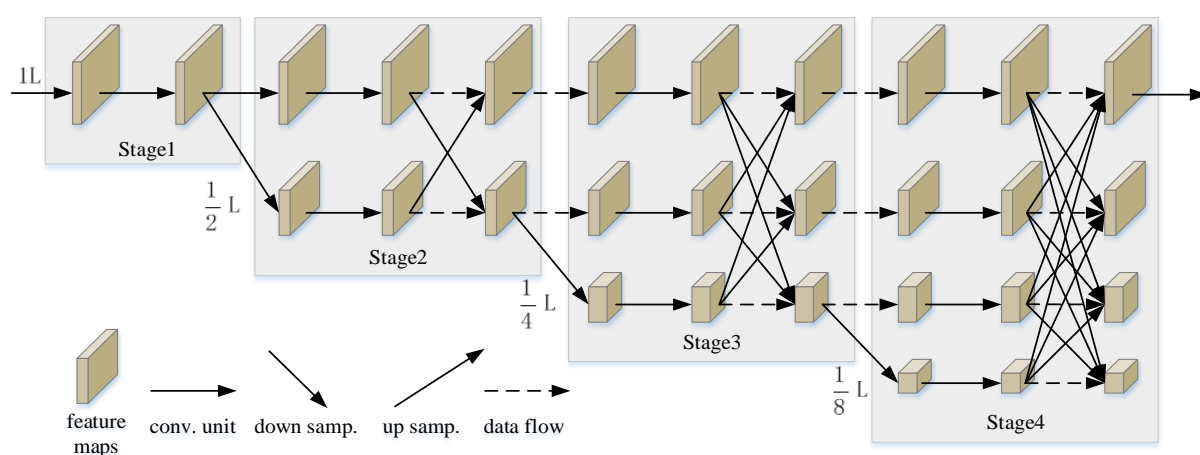


图 4-1 高分辨率网络（HRNet）的结构

Fig 4-1 The structure of High-Resolution Network

具体来说,HRNet 由四个并行的多分辨率子网组成,包括四个阶段,除第一个高分辨率子网外,其他并行子网的输入均从前面的子网特征图中采样得到。在第一阶段,

它由包含四个瓶颈残差单元的高分辨率块组成，瓶颈残差单元见图 4-2（右）所示。在第二阶段，网络结构中有两个分辨率子网，包括原来的高分辨率子网和分辨率减半的低分辨率子网，通道数（假设初始通道数为 C ）分别为 C 和 $2C$ ，该阶段的多分辨率块由四个基本残差单元组成，基本残差单元见图 4-2（左）所示。与第二阶段一样，第三阶段和第四阶段使用基本残差单元，但残差单元块数略有不同，此外通道数翻倍，分别为 $4C$ 和 $8C$ 。

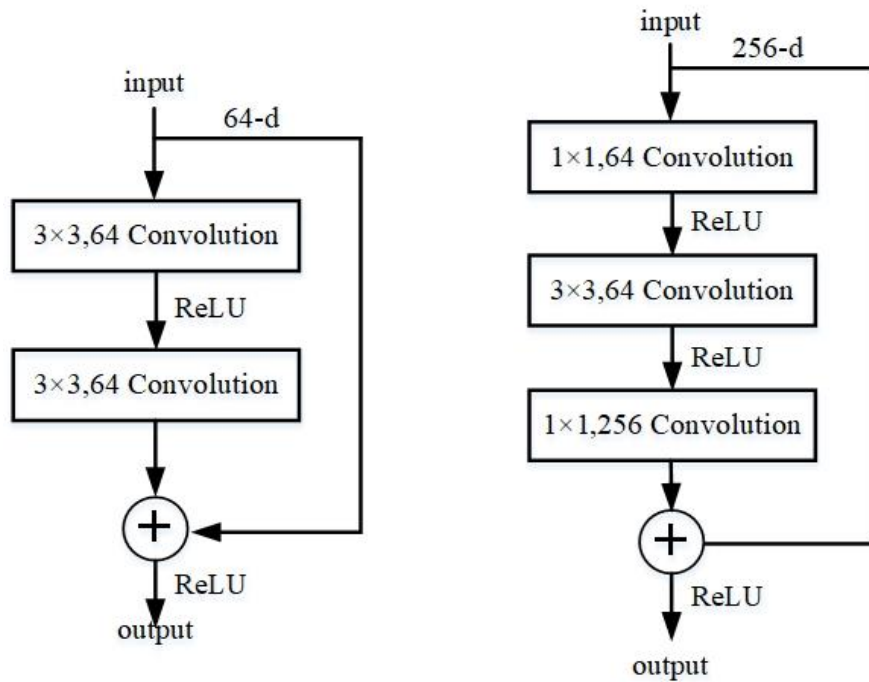


图 4-2 基本残差单元（左）和瓶颈残差单元（右）

Fig 4-2 Basic residual unit (left) and bottleneck residual unit (right)

4.1.2 特征融合

为融合子网与其他并行子网的特征信息，在同一阶段中的不同子网之间引入了特征融合单元。各子网的输出特征通过特征融合单元生成后续的多个分辨率子网的相应输入。图 4-3 为第三阶段的特征融合单元 F ，分为 $f1$, $f2$ 和 $f3$ 三个部分，用于融合高分辨率特征和低分辨率特征。

如图 4-3 所示，特征融合单元包括下采样和上采样操作，以确保处理后的特征图的分辨率与所需的特征图分辨率一致，例如，当高分辨率特征图的边长为 $1L$ ，而所需的低分辨率特征图的边长为 $1/2L$ 时，则高分辨率特征图需使用步长为 2 的卷积层进行下采样得到 $1/2L$ 边长的低分辨率特征图；当所需特征图的边长为 $1/4L$ 时，则使用两个相同的步长为 2 的卷积层进行两次下采样得到目标特征图；而当低分辨率特征图需要通过上采样操作与高分辨率特征图进行融合时，为保证上采样后特征图的宽度与上采样目标一致，首先需要使用 1×1 的卷积层来改变特征图的通道数，然后利用最近邻插值方法对特征图像进行放大得到目标分辨率特征图。




图 4-3 第三阶段特征融合单元

Fig 4-3 The feature fusion unit of the third stage

4.2 数据预处理

实验数据来自 MIT-BIH 心律失常数据库。本章利用数据集中 5 类典型的心电信号，即正常搏动（Normal）、房性早搏（APB）、室性早搏（PVC）、右束支传导阻滞（RBBB）和左束支传导阻滞（LBBB）。为保留 ECG 信号的原始信息，提升模型泛化能力，该方法直接将原始心电信号划分为 5 秒时间段的 ECG 片段，即 1800 个采样点。根据数据库的注释文件，得到 R 峰的位置和对应的心律失常类别标签。




图 4-4 用注释的 R 峰（N=Normal, L=LBBB, R=RBBB, A=APB, V=PVC）分割的 ECG 信号

Fig 4-4 ECG signal divided by annotated R peak (N = Normal, L = LBBB, R = RBBB, A = APB, V = PVC)

分割得到的每个心电信号片段可能只有一种特定的心律失常类型，也可能包含多种心律失常类型，如图 4-4 所示。如果将单个片段内的所有心电节拍限制为一种心律

失常类型，这些片段则只包含一种类型的心律失常情况。为使单个心电片段包含多种心律失常类型，对心电记录进行异质分割，如此可以分析更多的数据，使训练数据更加多样化和复杂。保存分割得到的五种典型类型的心电信号片段，以及对应的 R 峰位置和类型标签，作为网络训练和测试的数据集。

4.3 基于改进的 HRNet-ECA 的心电信号 R 峰检测与心律失常分类

4.3.1 模型整体架构

由于 HRNet 在特征提取方面的优势，本章将其引入心电信号分类中。如前所述，HRNet 网络最初是为应用于二维图像处理而开发的，而本文研究基于一维心电信号。因此，本文对 HRNet 进行了适当变更，包括设置了一个一维的多分类头：一个分类头用于检测 R 峰，另一个分类头用于实现心律失常的分类，修改后的 HRNet 架构如图 4-5 所示。取心电信号的 1800 个采样点作为网络的输入，经过四个阶段的特征学习后，通过卷积运算将通道数变为训练目标数，从而输出分类任务对应的类别。在心电信号心律失常分类任务中，训练目标设置为 5，即五种心律失常类别，根据 ECG 片段中每个 R 峰值位置的预测类型和真实标签，来评估模型对五种心律失常类型分类的准确性。在 R 峰检测任务中，心电信号标签转化为 0 与 1 的向量生成 R 峰的训练目标，根据注释文件注释的 R 峰位置的采样点设为 1，其他采样点设为 0。

该网络使用相同的卷积运算获得相同大小的输出特征图。每个卷积操作都由一个卷积层，一个批归一化层（BN 层）以及一个激活层组成。除第一阶段外，其余阶段都需要进行卷积、上采样和下采样操作。网络处理流程说明如下：第一阶段采用两个卷积层提取心电信号的简单特征，得到高分辨率的第一子网；在第二阶段，第一个高分辨率子网使用两个残差单元进一步提取特征，残差单元嵌入了有效通道注意力机制模块（ECA），嵌入 ECA 模块的残差单元如图 4-6 所示。第二个子网基于第一个高分辨率子网产生，首先采用步长为 2、卷积核数为前一阶段的 2 倍的卷积运算，得到长度减半、通道数加倍的特征向量，然后使用两个步长为 1 的相同的卷积残差单元进行卷积运算，该子网相对于第一个子网特征向量减半，因此称为低分辨率子网。后两个阶段的操作与第二阶段的操作相似。

4.3.2 改进的 HRNet 架构

改进的 HRNet 模型的第一阶段由两个卷积层组成，每个卷积层的核大小为 5×1 ，卷积核数为 16。在第二阶段，原始高分辨率子网在不改变通道数量的情况下，用含有 ECA 模块的残差单元进行两次相同的卷积运算。第二个子网基于第一个子网的输出，先对特征向量进行 32 个步长为 2 的卷积运算，得到通道数翻倍、长度减半的特征向量，然后使用两个含有 ECA 模块的相同的残差单元进行进一步的特征提取。在第二阶段的特征融合单元中，低分辨率子网需要利用 1×1 的卷积核和通道数减半的卷积运算，获得与高分辨率子网相同通道数的特征向量，然后通过上采样得到与高分辨率子网长度相同的特征向量。在下采样操作中，具有较高分辨率的特征向量采用步长为 2 的卷积和两倍通道数的卷积层来实现下采样，然后融合相同大小的特征向量。第三

和第四阶段的运算与第二阶段相似，只是特征向量减半，通道数加倍，即在四个阶段中，各个子网的卷积通道数分别为 16、32、64 和 128，对应特征向量的边长分别为 1800、900、450 和 225。

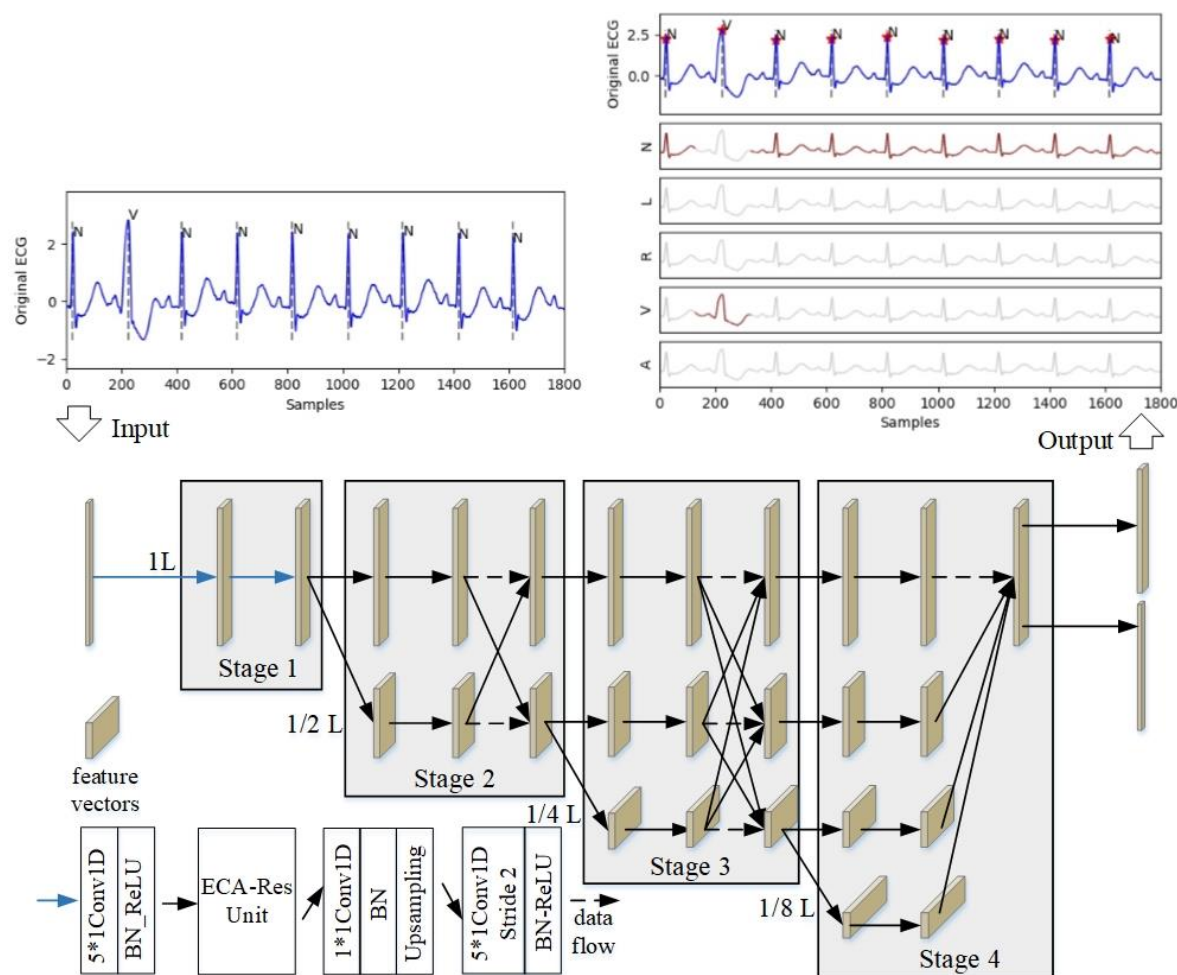


图 4-5 HRNet-ECA 的整体架构

Fig 4-5 The architecture of the HRNet-ECA

当第四阶段的特征融合之后，最后使用 1×1 的卷积层将特征映射的数量减少到对应的训练目标。R 峰检测分支的训练目标数是 1，即判断该采样点是否为 R 峰位置，通过采用 sigmoid 函数的卷积层来获得最终的 R 峰检测结果。心律失常分类的训练目标数为 5，即 5 个类别，通过采用 softmax 函数的卷积层来获得最终的心律失常分类结果。

4.3.3 ECA-Res 单元

为了获得适当的跨通道交互信息，该模型在残差单元中嵌入了一个有效通道注意力模块（ECA）。ECA 模块的目的是学习权重系数，确定不同通道的重要性，并降低模型的参数。它是对压缩和激励（Squeeze-and-Excitation, SE）模块^[62]的改进。与 SE 模块不同，ECA 模块提出了一种跨通道交互模式，当前通道特征图仅与 k 个相邻通道相互作用。具体来说，ECA 模型使用一个全局平均池和一个内核大小为 k 的快速

一维卷积来捕获信息， k 表示特征图与附近通道信息的交互范围。为了获得适当的局部通道交互信息，作者指出了 k 值与通道的映射关系^[61]（公式（4-1））。因此， k 值的大小是根据通道的数量自适应改变的，其计算过程如公式（4-2）所示。

$$C = \phi(k) = 2^{(\gamma * k - b)} \quad (4-1)$$

$$k = \varphi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}} \quad (4-2)$$

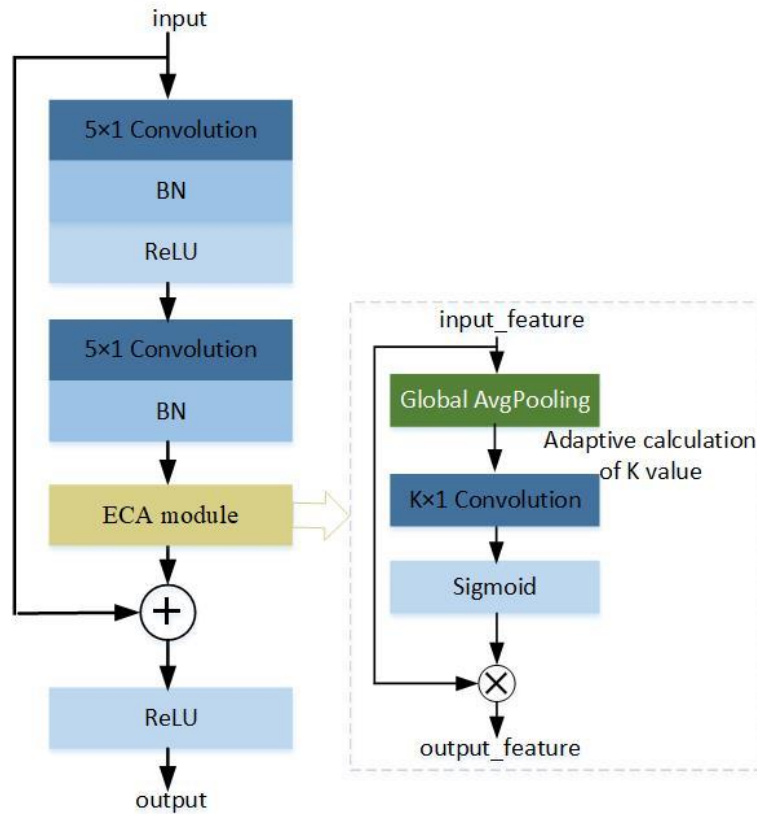


图 4-6 ECA-Res 单元
Fig 4-6 ECA-Res Unit

4.3.4 训练目标与参数设置

改进的 HRNet 模型的训练目标是对五种典型的心电信号进行 R 峰检测和心律失常分类。第一个训练目标是 R 峰检测，首先为心电信号的每个片段创建一个 1800×1 数组，根据注释文件注释的 R 峰值位置设为 1，片段的其他采样点设为 0，在训练过程中输出每个点为 R 峰位置的概率，根据真实 R 峰位置标签来判断预测的 R 峰位置是否正确；第二个训练目标是心律失常分类，根据 R 峰位置信息，设置 R 峰前 90 个采样点和 R 峰后 210 个采样点为 R 峰对应的类型值，然后根据类型转换为 1800×5 矩阵。因此，在使用训练好的模型进行测试时，可以对每个采样点进行分类。在训练和测试过程中，根据注释文件，将 ECG 片段中 R 峰位置的采样点对应的类别信息作为该片段中对应节拍的类别信息，也就是说，可以利用心电片段中所有 R 峰位置的预测类别和真实标签来判断该心电片段中有多少个心电节拍被正确识别。

对于每个训练任务，网络训练轮数为 50 轮。与文献[21][47]一样，训练模型的批

数为 20，心律失常分类任务的损失函数为多分类交叉熵损失函数，R 峰检测任务的损失函数为二进制交叉熵函数。采用 Adam 优化函数更新权值，初始学习率为 0.001。在后期，为了加快模型的收敛速度，采用衰减比为 0.1 的学习速率衰减方法，使学习速率衰减。

4.4 实验和结果分析

4.4.1 实验数据

按照数据预处理方法将心电信号分割成 5 秒的片段，表 4-1 给出了对应 R 峰标注的心电片段数，表 4-2 描述了 R 峰注释文件对应的所有心电片段的总节拍数。

表 4-1 ECG 片段数及其含有的类型

Table 4-1 Number of ECG segments and their corresponding types

ECG 片段中含有的类型	片段数量
Normal	20930
Normal, PVC	5212
Normal, APB	695
Normal, PVC, APB	102
Normal, RBBB	51
LBBB	2648
LBBB, PVC	560
LBBB, RBBB	3
LBBB, PVC, RBBB	9
RBBB	2563
RBBB, APB	771
RBBB, PVC	110
RBBB, APB, PVC	12
APB	253
PVC	51
Total	33970

表 4-2 按类型划分的 ECG 节拍总数

Table 4-2 Total ECG beats by type

ECG 节拍类型	节拍数量
Normal	161167
LBBB	19284
RBBB	17147
APB	5047
PVC	11144
Total	213789

4.4.2 交叉验证及评估指标

采用五折交叉验证方法来评估所提模型的稳定性，交叉验证策略详见 3.3.2 节。本章实验使用五种指标来评价模型的性能，分别是准确率（Acc）、灵敏度（SE）、特异性（SP）、阳性预测值（PPV）和 F1，其中准确率（Acc）定义见公式（3-3），灵敏度（SE）定义见公式（3-4），特异性（SP）定义见公式（3-5），阳性预测值（PPV）定义见公式（3-6），F1 指标定义如下：

$$F1 = \frac{2 \times TP}{2 \times TP + FP + FN} \quad (4-3)$$

其中 TP（真阳性）表示分类正确的阳性样本数，TN（真阴性）表示分类正确的阴性样本数，FP（假阳性）表示阴性样本被错误分类为阳性样本的数量，FN（假阴性）表示阳性样本被错误分类为阴性样本的数量。

4.4.3 实验结果与分析

使用 MIT-BIH 心律失常数据集来训练和评估所提模型，经过五折交叉验证后，将各评估指标的平均值作为各心电信号类型及总体的最终评估结果。表 4-3 显示了本章模型在卷积核大小为 5×1 时的心律失常分类结果。由该表可知，本章方法在五种心律失常类别上的整体准确率（Acc）、灵敏度（SE）、特异性（SP）、阳性预测值（PPV）和 F1 指标分别为 99.86%、99.37%、99.93%、99.56% 和 99.46%。

表 4-3 当卷积核大小为 5×1 时，所提模型的性能

Table 4-3 The performance of the proposed method when convolution kernel size is 5×1

类别	Acc (%)	SE (%)	SP (%)	PPV (%)	F1 (%)
N	99.89	99.96	99.70	99.90	99.93
L	99.99	99.99	99.99	99.92	99.95
R	99.97	99.80	99.99	99.88	99.84
V	99.95	99.28	99.99	99.83	99.55
A	99.91	97.80	99.96	98.92	98.36
整体	99.86	99.37	99.93	99.56	99.46

图 4-7（左）为本章模型在测试数据集上的心律失常分类混淆矩阵，由混淆矩阵可知，该模型能正确识别大部分的心电节拍。具体来说，模型基本能正确识别正常心跳、左束支传导阻滞和右束支传导阻滞三种心电信号类型。例如，总共 17147 个右束支传导阻滞心跳，模型可以正确识别 17115 个。然而，在房性早搏和室性早搏上有许多被认定为正常心跳的错误，例如 5047 个房性早搏心跳中有 111 个被错误地识别为其他类，其中 92 个被错误地识别为正常心跳。这可能是由于房性早搏与正常心跳的差异很小导致的，如房性早搏节拍与正常心跳的差异是有无 P 波，模型在分类中未检测到房性早搏节拍中 P 波的缺失而把它错误分类为正常心跳。

图 4-7（右）为本章模型在测试数据集上的 R 峰值预测的混淆矩阵，可看出有较多的真实 R 峰值未被正确识别出，这可能是在检测 R 峰值时，由于心电节拍有较宽

的 QRS 波群，在较小的 R 波和较大的 S 波中模型未能识别出 R 峰位置，或将 R 波与 S 波中间的样本预测为 R 峰位置。尽管有部分节拍的 R 峰被错检或漏检，但是模型仍实现了 99.95% 的 R 峰值准确率。




图 4-7 心律失常分类混淆矩阵（左）和 R 峰值预测的混淆矩阵（右）

Fig 4-7 Arrhythmia classification confusion matrix (left) and R peak prediction confusion matrix (right)

4.4.4 卷积核大小的选取

为确定相对合适的卷积核大小来进行心电信号特征的提取，在减少网络参数的同时使网络更有效的学习，根据网络构建经验及输入的信号长度，选择了三组不同的卷积核大小进行实验。三组实验的卷积核大小分别是 3×1 ， 5×1 和 7×1 ，表 4-4 显示了三组不同卷积核大小实验的平均准确率（Acc）、灵敏度（SE）、特异性（SP）、阳性预测值（PPV）和 F1 指标。根据表 4-4 结果可知，卷积核尺寸越大，五个性能指标值越高，表明分类性能越好。然而随着卷积核尺寸的增大，网络参数量也会随着增加，但指标提升不大。为了避免卷积核的大小过大而引起的繁琐计算，模型中的卷积核大小设为 5。

表 4-4 在不同的卷积核大小下，模型的结果对比

Table 4-4 The results of the model are compared under different convolution kernel sizes

分类任务	卷积核大小	Acc (%)	SE (%)	SP (%)	PPV (%)	F1 (%)
心律失常分类	7	99.88	99.42	99.93	99.66	99.54
	5	99.86	99.37	99.93	99.56	99.46
	3	99.69	98.29	99.82	99.17	98.73
R 峰检测	7	99.95	92.54	99.98	94.12	93.32
	5	99.95	91.69	99.98	93.64	92.65
	3	99.94	90.97	99.98	92.82	91.42

4.4.5 有无 ECA 模块的对比分析

为验证 ECA 模块的有效性，进行了无 ECA 模块的消融实验。模型中没有 ECA 模块意味着残差单元中没有 ECA 模块。没有 ECA 模块的模型在测试数据集上的分类

性能如表 4-5 所示，得到的平均灵敏度、特异性、阳性预测值、准确度和 F1 指标分别为 99.20%、99.90%、99.60%、99.83%和 99.40%，该模型 R 峰检测与心律失常分类在测试集上的混淆矩阵如图 4-8 所示。与表 4-5 中没有 ECA 模块的模型相比，表 4-3 中有 ECA 模块的模型可以获得更好的性能，五个度量指标分别提高了 0.17%、0.03%、-0.04%、0.03%和 0.06%。特别是对于“A”型，在没有 ECA 模块的情况下，提出的模型所获得的五个指标显著下降，其中，具有 ECA 模块的 5 个指标分别为 97.80%、99.96%、98.92%、99.91%和 98.36%，无 ECA 模块的分别为 97.23%、99.97%、98.61%、99.90%和 97.92%，增加 ECA 模块的模型可以提高分类性能。而在 R 峰检测任务中，有 ECA 模块的模型也获得了更好的识别性能，即减少了被漏检的 R 峰样本数。

表 4-5 无 ECA 模块的分类性能

Table 4-5 Classification performance without ECA module

类别	Acc (%)	SE (%)	SP (%)	PPV (%)	F1 (%)
N	99.86	99.95	99.56	99.86	99.90
L	99.99	99.93	99.99	99.91	99.92
R	99.97	99.77	99.99	99.89	99.83
V	99.94	99.12	99.99	99.74	99.43
A	99.90	97.23	99.97	98.61	97.92
整体	99.83	99.20	99.90	99.60	99.40




图 4-8 无 ECA 模块的心律失常分类混淆矩阵（左）和 R 峰值预测的混淆矩阵（右）

Fig 4-8 Arrhythmia classification confusion matrix (left) and R peak prediction confusion matrix (right) without ECA module

4.4.6 比较 U-Net 和 HRNet 的性能

为了评估 U-Net 模型在与 HRNet 模型相同设置下的实验性能，本章将模型的五种性能指标与 U-Net 和无 ECA 模块的模型进行了比较，对比结果如表 4-6 所示。从表中可以看出，与 U-Net 相比，HRNet 的心电节拍分类性能有了明显的提高。即使在没有 ECA 块的 HRNet 方法中，与 U-Net 模型相比，HRNet 模型在心律失常分类任务上获得的五个度量值分别增加了 0.46%、0.05%、0.16%、0.09%和 0.31%，在加入

ECA 模块后的 HRNet 模型实现了更好的分类性能。

表 4-6 HRNet 与 U-Net 分类性能比较

Table 4-6 Comparison of classification performance between HRNet and U-Net

模型	分类任务	Acc (%)	SE (%)	SP (%)	PPV (%)	F1 (%)
U-Net		99.74	98.74	99.85	99.44	99.09
HRNet	心律失常分类	99.83	99.20	99.90	99.60	99.40
HRNet+ECA		99.86	99.37	99.93	99.56	99.46
U-Net		99.94	87.97	99.98	93.53	90.66
HRNet	R 峰检测	99.95	91.42	99.98	93.75	92.57
HRNet+ECA		99.95	91.69	99.98	93.64	92.65

4.4.7 与其他方法比较

本章模型的心律失常分类性能与其他心律失常分类方法（采用 MIT-BIH 心律失常数据集中的 Normal、APB、PVC、RBBB 和 LBBB 五类心律失常数据）进行了对比，如表 4-7 所示，对比方法实验结果来源于对应文献。文献[63]将 CNN 和 LSTM 模型结合起来实现对 1000 个采样点的心电信号进行心律失常分类，在随机丢弃相同（20%）的 LSTM 循环连接和全连接层模型上实现了 98.10%的准确率。本章建立了基于改进 HRNet 的一维原始心电信号的 R 峰检测与心律失常分类模型，并在残差单元中嵌入了有效通道注意力机制模块，在 MIT-BIH 数据集上的心律失常分类准确率达到了 99.86%。这表明，改进后的模型可以从原始心电数据中学习重要信息，能够对包含多个心电节拍的心电片段进行心律失常分类。

表 4-7 不同方法在 MIT-BIH 数据集上的分类结果对比

Table 4-7 Comparison of classification results of different methods on MIT-BIH data set

作者	方法	Acc (%)	SE (%)	SP (%)	PPV (%)	F1 (%)
本文方法	Modified HRNet-ECA	99.86	99.37	99.93	99.56	99.46
Oh ^[21]	modified U-net	97.32	94.44	98.26	94.70	94.57
Pandey ^[40]	LSTM	99.37	94.89	99.14	96.73	95.77
Yildirim ^[41]	DWT & BiLSTM	99.39	-	-	-	-
Wang ^[44]	ResNet& LSTM	99.81	99.53	99.88	-	-
Huang ^[47]	MOWPT & FCResNet	98.79	95.16	-	99.39	97.23
Hua ^[59]	R-R-R & CNN	99.24	99.00	-	-	99.00
Oh ^[63]	CNN-LSTM	98.10	97.50	98.70	98.69	98.09

4.4.8 可视化分析

为了直观地展示所提模型的性能，使用训练过的模型来进行测试集中四个原始的心电图片段的 R 峰检测与心律失常分类效果，如图 4-9 所示。图 4-9 的第一行为原始心电信号波形，每个节拍的类型标签在 R 峰位置上显示，黑色虚线表示 R 峰位置的真实标签，第二行至第六行对应五种心律失常类型。在预测时，预测的 R 峰位置在第

一行用红色星型标出,预测每个采样点的心电信号类型在对应的类型行中用红色突出显示。显然,该模型能够识别 Normal、PVC、LBBB、RBBB 和 APB 样本不同类型的心电信号,同时能较为准确的检测出 R 峰,表明该模型在整个过程中具有较好的 R 峰检测和心律失常分类性能。

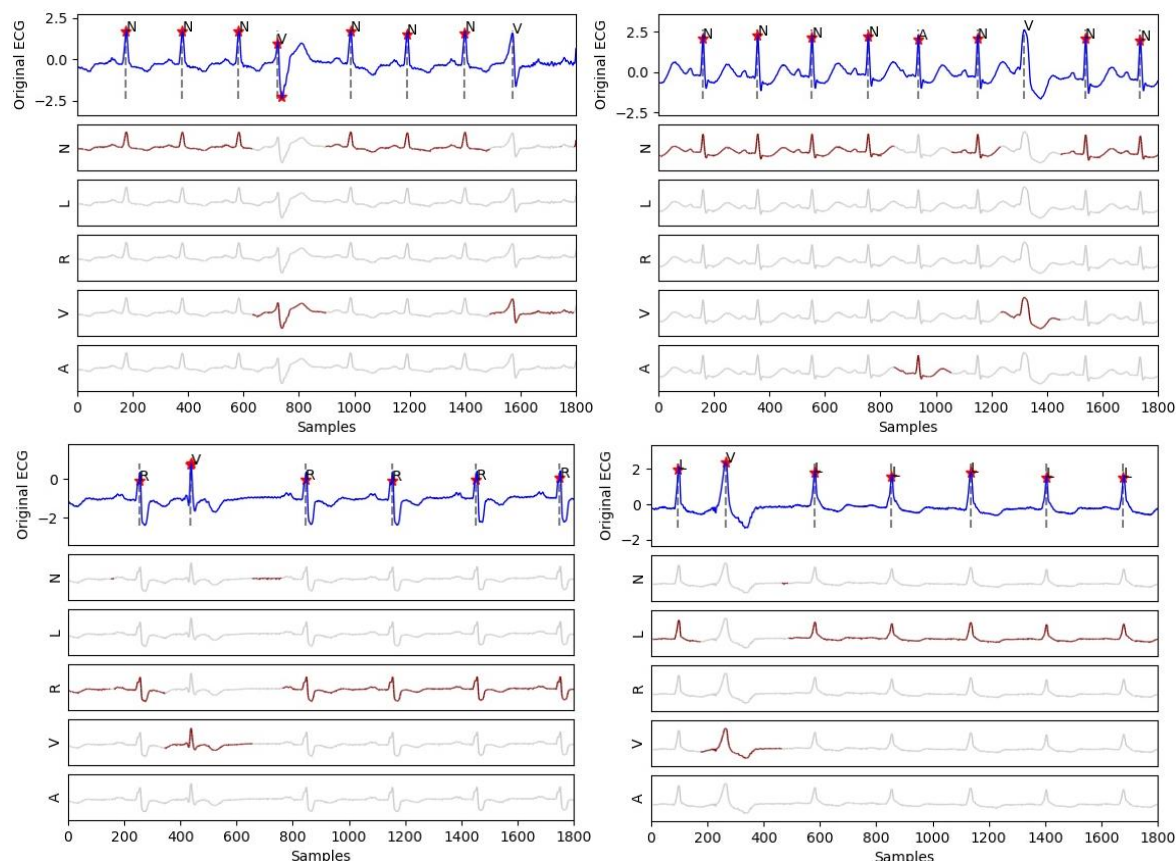


图 4-9 4 个 ECG 片段和相应的分类(第一行为原始 ECG 片段各个心跳类型的真实标签, N、L、R、V 和 A 分别表示 Normal、LBBB、RBBB、PVC 和 APB, 黑色虚线为 R 峰真实标签; 第二行到第六行表示预测每个采样点所属的类型, 红色星型表示预测的 R 峰位置)

Fig 4-9 Four ECG segments and corresponding classification (the first line is the real label of each heartbeat type of the original ECG segment, N, L, R, V and a represent Normal, LBBB, RBBB, PVC and APB respectively, and the black dotted line is the real label of the R peak; the second to sixth lines represent the type of each sampling point predicted, and the red asterisk represents the predicted R peak)

4.5 本章小结

为实现对时间长达 5 秒的心电信号片段进行逐拍检测与分类, 本章提出了一种基于改进的 HRNet 模型的 R 峰检测与心律失常分类方法。为了获得合适的跨通道交互信息, 在改进的 HRNet 模型的残差单元中嵌入了有效通道注意机制模块(ECA)。该方法首先将包含常见的五种心律失常(Normal、LBBB、RBBB、PVC 和 APB)的原始心电信号中分割成 5 秒的 ECG 片段, 然后将这些片段输入到 HRNet-ECA 模型中进行自动学习和分类, 通过在 MIT-BIH 心律失常数据库上的实验验证了所提方法的有效性。

5 总结与展望

5.1 总结

心电图是诊断心血管疾病的有力工具之一,实现心电图的自动分析能够提高疾病的诊断效率,节约时间与人力成本。近年来,基于深度学习的心律失常自动分类算法实现了比传统机器学习方法更好的检测和分类性能,克服了需要反复进行手工提取和选择特征的不足。针对现有的心律失常自动分类方法预处理时间成本高、对噪声敏感问题,构建了 CNN-BLSTM 心律失常分类模型。为对长时间的心电信号片段的逐拍分析,改进了 HRNet 模型使其适用于一维心电信号的处理,并结合有效通道注意力机制来实现心电信号的 R 峰检测和心律失常分类。本文主要研究内容如下:

(1) 由于卷积神经网络和长短期记忆网络组合的混合神经网络比单个网络模型表现效果更好,提出了一种结合卷积神经网络和双向长短期记忆模型的组合模型(CNN-BLSTM 模型)来进行心律失常的分类。在预处理阶段不进行任何的滤波操作,而是直接把原始心电信号归一化到 $[0, 1]$ 之间,然后根据注释文件的 R 峰位置找到 T 波集,之后根据 T 波集分割成单个的心电节拍,并统一到 256 个采样点。预处理得到的心电节拍输入到 CNN-BLSTM 模型中进行特征提取和分类,其中卷积神经网络能够提取心电信号的形态特征而双向长短期记忆网络可以提取心电信号中的时间序列信息,最后借助 softmax 函数完成分类任务。在公开数据库 MIT-BIH 心律失常数据库上进行相关实验,验证了该方法的有效性。此外通过对比实验表明所提模型具有良好的噪声鲁棒性。

(2) 基于高分辨率网络(HRNet)在整个特征提取过程中保持高分辨率表示和有效通道注意力机制(ECA)能够获得通道交互信息的优势,提出了基于改进的 HRNet 和有效通道注意力机制的心电信号 R 峰检测和心律失常分类算法(改进的 HRNet-ECA 模型),该算法首先将原始心电信号分割成五秒时间长即 1800 个采样点的心电片段,片段中可能包含多种心律失常类型,之后将心电信号片段输入到改进的 HRNet-ECA 模型中进行 R 峰检测和逐个节拍的分类。通过对 MIT-BIH 心律失常数据库中五种常见的心律失常类型进行实验,该算法在 R 峰检测上获得了 99.95%的准确率,在心律失常分类任务上获得了 99.86%的准确率。通过对比实验表明该模型相比于 UNet 模型更有效,同时加入的 ECA 模块可以减少心电节拍的误检率。

5.2 展望

本文提出的模型虽然在公开数据集上取得了一定的成功,但还存在以下有待进一步研究的问题:

(1) 现有的许多工作都是在一个不平衡的或未扩充的数据集上进行研究,本文亦是如此。在未来的工作中,应考虑扩充样本数少的类别的心电数据,在一个较平衡的数据集上完成实验和评估,使模型能更好地完成心律失常分类任务。

(2) 本文实验的数据均为 MIT-BIH 心律失常数据库的第二导联数据, 该导联在动态心电图记录中最常使用, 而更多导联的心电数据能使模型学习到更多信息, 更好的完成检测与分类任务。在未来应考虑利用更多导联记录的心电数据来训练与评估模型, 增强模型泛化性。

参考文献

- [1] 《中国心血管健康与疾病报告 2020》概述[J]. 中国心血管病研究. 2021, 19(07): 582-590.
- [2] 查克岚, 叶强. 心电图成像在心律失常诊治中的研究进展[J]. 心血管病学进展. 2020, 41(09): 930-933.
- [3] Zubair M, Kim J, Yoon C. An Automated ECG Beat Classification System Using Convolutional Neural Networks[C]//International Conference on IT Convergence and Security (ICITCS), 2016, 1-5.
- [4] Manisha, Dhull S K, Singh K K. ECG Beat Classifiers: A Journey from ANN To DNN[J]. Procedia Computer Science. 2020, 167: 747-759.
- [5] Lynn P A. Recursive digital filters for biological signals[J]. Medical & biological engineering. 1971, 9(1): 37-43.
- [6] Ferrara E R, Widrow B. Fetal electrocardiogram enhancement by time-sequenced adaptive filtering [J]. IEEE transactions on bio-medical engineering. 1982, 29(6): 458-460.
- [7] Yelderman M, Widrow B, Cioffi J M, et al. ECG enhancement by adaptive cancellation of electrosurgical interference[J]. IEEE transactions on bio-medical engineering. 1983, 30(7): 392-398.
- [8] Xue Q, Hu Y H, Tompkins W J. Neural-network-based adaptive matched filtering for QRS detection [J]. IEEE Transactions on Biomedical Engineering. 1992, 39(4): 317-329.
- [9] Zhang D. Wavelet Approach for ECG Baseline Wander Correction and Noise Reduction[J]. Conference proceedings: Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Conference. 2006, 2: 1212-1215.
- [10] Chen C, Hua Z, Zhang R, et al. Automated arrhythmia classification based on a combination network of CNN and LSTM[J]. Biomedical Signal Processing and Control. 2020, 57: 101819.
- [11] Sayadi O, Shamsollahi M B. Multiadaptive Bionic Wavelet Transform: Application to ECG Denoising and Baseline Wandering Reduction[J]. Eurasip Journal on Advances in Signal Processing. 2007, 2007(1): 41274.
- [12] 李肃义, 林君. 一种综合小波变换的心电信号消噪算法[J]. 仪器仪表学报. 2009, 30(4): 689-693.
- [13] Ji Y, Zhang S, Xiao W. Electrocardiogram Classification Based on Faster Regions with Convolutional Neural Network[J]. Sensors (Basel, Switzerland). 2019, 19(11):2558.
- [14] Xiong P, Wa Ng H, Liu M, et al. A stacked contractive denoising auto-encoder for ECG signal denoising[J]. 2016, 37(12): 2214-2230.
- [15] Arsene C, Hankins R, Yin H. Deep Learning Models for Denoising ECG Signals[C]// 2019 27th European Signal Processing Conference (EUSIPCO).2019:1-5
- [16] Member S, Ieee, Pan J, et al. A Real-Time QRS Detection Algorithm[J]. IEEE Transactions on Biomedical Engineering. 2007, BME-32(3): 230-236.
- [17] Li C, Zheng C, Tai C. Detection of ECG characteristic points using wavelet transforms[J]. IEEE Transactions on Biomedical Engineering. 2002, 42(1): 21-28.
- [18] Benitez D S, Gaydecki P A, Zaidi A, et al. A new QRS detection algorithm based on the Hilbert transform[J]. Computers in Cardiology. 2000, 27: 379-382
- [19] 苏嘉豪, 徐维超. 基于香农信息熵的心电 R 波检测算法[J]. 电子世界. 2017(8): 59-61.
- [20] Tarassenko L, Clifford G, Townsend N. Detection of ectopic beats in the electrocardiogram using an auto-associative neural network[J]. Neural Processing Letters. 2001, 14(1): 15-25.
- [21] Oh S L, Ng E Y, Tan R S, et al. Automated beat-wise arrhythmia diagnosis using modified U-net on extended electrocardiographic recordings with heterogeneous arrhythmia types[J]. Computers in Biology

and Medicine. 2018, 105: 92-101.

[22] Sarlija M, Jurisic F, Popovic S. A convolutional neural network based approach to QRS detection [C]// Proceedings of the 10th International Symposium on Image and Signal Processing and Analysis. 2017,121-125.

[23] Wang X, Zou Q. QRS Detection in ECG Signal Based on Residual Network [C]// 2019 IEEE 11th International Conference on Communication Software and Networks (ICCSN).2019,73-77.

[24] Bitarafan A, Amini A, Baghshah M S, et al. A Hybrid Deep Model for Automatic Arrhythmia Classification based on LSTM Recurrent Networks [C]// 2020 IEEE International Symposium on Medical Measurements and Applications (MeMeA). 2020:1-6.

[25] Murat F, Yildirim Ö, Talo M, et al. Application of deep learning techniques for heartbeats detection using ECG signals- Analysis and Review[J]. Computers in Biology and Medicine. 2020, 120:103726

[26] Minami K, Nakajima H. Real-time discrimination of ventricular tachyarrhythmia with Fourier-transform neural network[J]. IEEE transactions on bio-medical engineering. 1999, 46(2): 179-185.

[27] Turker T, Sengul D, Pawel P E A. Automated arrhythmia detection using novel hexadecimal local pattern and multilevel wavelet transform with ECG signals[J]. Knowledge-Based Systems. 2019, 186:104923.

[28] Martis R J A U R L. Application of higher order cumulant features for cardiac health diagnosis using ECG signals[J]. International Journal of Neural Systems. 2013, 23(4): 1350014.

[29] Sabut S, Sahoo S, Kanungo B, et al. Multiresolution wavelet transform based feature extraction and ECG classification to detect cardiac abnormalities[J]. Measurement. 2017, 108(108): 55-66.

[30] 王金海, 史梦颖, 张兴华. 基于 EMD 和 ApEn 特征提取的心律失常分类研究. 2016168-173.

[31] Faust O, Hagiwara Y, Hong T J, et al. Deep learning for healthcare applications based on physiological signals: A review[J]. Computer Methods & Programs in Biomedicine. 2018: S352133162.

[32] Yildirim Ö B U B. A new approach for arrhythmia classification using deep coded features and LSTM networks[J]. Computer Methods and Programs in Biomedicine. 2019, 176: 121-133.

[33] Kiranyaz S, Ince T, Gabbouj M. Real-Time Patient-Specific ECG Classification by 1-D Convolutional Neural Networks[J]. IEEE Transactions on Biomedical Engineering. 2016, 63(3): 664-675.

[34] Rajpurkar P, Hannun A Y, Haghpanahi M, et al. Cardiologist-Level Arrhythmia Detection with Convolutional Neural Networks[J]. 2017:1-9.

[35] Ullah A, Anwar S M, Bilal M, et al. Classification of Arrhythmia by Using Deep Learning with 2-D ECG Spectral Image Representation[J]. Remote Sensing. 2020, 12(10): 1685.

[36] Golrizkhatami Z, Acan A. ECG classification using three-level fusion of different feature descriptors[J]. Expert Systems with Applications. 2018, 114(DEC.): 54-64.

[37] Bouny L E, Khalil M, Adib A. ECG Heartbeat Classification Based on Multi-Scale Wavelet Convolutional Neural Networks [C]// ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2020, 3212-3216.

[38] Fernandez R, Rendel A, Ramabhadran B, et al. Using Deep Bidirectional Recurrent Neural Networks for Prosodic-Target Prediction in a Unit-Selection Text-to-Speech System [C]// Interspeech. 2015:1606-1610.

[39] Saeed, Saadatnejad, Mohammadhosein, et al. LSTM-Based ECG Classification for Continuous Monitoring on Personal Wearable Devices[J]. IEEE Journal of Biomedical & Health Informatics. 2019, 24(2):515-523.

[40] Pandey S K, Janghel R R. Automatic arrhythmia recognition from electrocardiogram signals using different feature methods with long short-term memory network model[J]. Signal Image and Video

- Processing. 2020, 14(4):1255-1263.
- [41] Yildirim Ö. A novel wavelet sequence based on deep bidirectional LSTM network model for ECG signal classification[J]. Computers in Biology and Medicine. 2018, 96: 189-202.
- [42] Li P, Wang Y, He J, et al. High-Performance Personalized Heartbeat Classification Model for Long-Term ECG Signal[J]. IEEE Transactions on Biomedical Engineering. 2017, 64(1): 78-86.
- [43] 柯丽, 王丹妮, 杜强, 等. 基于卷积长短时记忆网络的心律失常分类方法[J]. 电子与信息学报. 2020, 42(8): 1990-1998.
- [44] Wang P, Hou B, Shao S, et al. ECG Arrhythmias Detection Using Auxiliary Classifier Generative Adversarial Network and Residual Network[J]. IEEE Access. 2019, 7: 100910-100922.
- [45] Zeng W, Yuan J, Yuan C, et al. A novel technique for the detection of myocardial dysfunction using ECG signals based on hybrid signal processing and neural networks[J]. Soft Computing. 2021, 25(6): 4571-4595.
- [46] Essa E, Xie X. Multi-model Deep Learning Ensemble for ECG Heartbeat Arrhythmia Classification[C]. 2020 28th European Signal Processing Conference (EUSIPCO), 2021, 1085-1089.
- [47] Huang J S, Chen B Q, Zeng N Y, et al. Accurate classification of ECG arrhythmia using MOWPT enhanced fast compression deep learning networks[J]. Journal of Ambient Intelligence and Humanized Computing. 2020(2).
- [48] Mousavi S, Afghah F, Acharya U R. Inter- and intra- patient ECG heartbeat classification for arrhythmia detection: a sequence to sequence deep learning approach[J]. 10.48550/arXiv.1812.07421
- [49] How the Heart Works. [Online]. Available: <https://www.nhlbi.nih.gov/health-topics/how-heart-works>.
- [50] Electrical conduction system of the heart. [Online]. Available: en.wikipedia.org.
- [51] Arvanaghi R, Daneshvar S, Seyedarabi H, et al. Fusion of ECG and ABP signals based on wavelet transform for cardiac arrhythmias classification[J]. Computer Methods & Programs in Biomedicine. 2017: S350146574.
- [52] Moody G B, Mark R G. MIT-BIH arrhythmia database. [Online]. Available: <http://ecg.mit.edu/dbinfo.html>[J]. 1997, 20(3): 45-50.
- [53] Misra D. Mish: A Self Regularized Non-Monotonic Neural Activation Function[J]. 2019, 10.48550/arXiv.1908.08681.
- [54] Lyu Q, Zhu J. Revisit Long Short-Term Memory: An Optimization Perspective[J]. 2014:1-9.
- [55] AAMI-recommended practice: Testing and reporting performance results of ventricular arrhythmia detection algorithms. Arlington, V A: Association for the Advancement of Medical Instrumentation, 1987.
- [56] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. CoRR. 2015, abs/1502.03167.
- [57] Jangra M, Dhull S, Singh K K. ECG arrhythmia classification using modified visual geometry group network (mVGGNet)[J]. Journal of Intelligent & Fuzzy Systems. 2020, 38: 1-15.
- [58] Acharya U R, Oh S L, Hagiwara Y, et al. A deep convolutional neural network model to classify heartbeats[J]. Computers in Biology and Medicine. 2017, 89: 389-396.
- [59] Hua X, Han J, Zhao C, et al. A Novel Method for ECG Signal Classification via One-Dimensional Convolutional Neural Network[J]. Multimedia Systems. 2020. doi.org/10.1007/s00530-020-00713-1
- [60] Sun K, Xiao B, Liu D, et al. Deep High-Resolution Representation Learning for Human Pose Estimation[C]// 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 5686-5696.
- [61] Wang Q, Wu B, Zhu P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural

- Networks[C]// 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11531-11539.
- [62] Jie H, Li S, Gang S, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence. 2020, 42(8):2011-2023.
- [63] Oh S L, Ng E Y K, Tan R S, et al. Automated diagnosis of arrhythmia using combination of CNN and LSTM techniques with variable length heart beats[J]. Computers in Biology and Medicine. 2018: 102: 278-287.

致谢

时光荏苒，稍纵即逝。第一次进入实验室仿佛就发生在昨日，然而时钟已走过了三年。行文至此，意味着三年的研究生学习生涯就要迎来告别的时刻。此时此刻，我要感谢身边的老师、同学、朋友和家人们。

首先要感谢我的导师唐建军副教授。当我学业上遇到不解时，唐老师总是会给予我学术指导，给我提供解决方案。在平日里，唐老师也总是待人亲切，高瞻远瞩，帮我解决科研所需的硬件条件，让我能够探索新方法，完成实验和论文。唐老师治学严谨、认真负责的态度使我受益匪浅，为我以后的工作生活树立了榜样。

其次要同样感谢我的指导老师华晶副教授，华老师让我接触到了医学信号处理、深度学习领域，由此踏上了科研之路。也正是因为华老师严谨的学术态度、耐心的带领，让我在研究生学习养成了独立思考的习惯。此外，在科研路上遇到了问题或是难点时，华老师总是会耐心指导我，让我能够重拾信心继续寻找突破，使我不断进步。

还要感谢我的研究生室友周阳阳、董萍，感谢实验室的师兄郑隐馨、刘玮，师姐万颖、朱稳梦，师妹饶珏，汪婷，感谢我的研究生同学熊传镇、王振、曾武序、杨富豪、黄琼、何俞玲等，感谢我的本科班主任彭芳老师和李飞老师。特别的要感谢杰哥，在学习和生活中他总是不断鼓励和支持我，遇到问题总是耐心教导我，让我尽快摆脱沮丧，继续前行。

最后，我要感谢我的家人，一直给予我关爱和鼓励，做我坚强的后盾，让我安心完成学业。

本学位论文得到国家自然科学基金项目“基于时空相关性的多通道心电信号量化压缩感知方法研究”（编号：61861021）以及江西省教育厅科学技术研究项目“基于序列间深度学习的可穿戴设备心电信号分类研究”（编号：GJJ200426）的资助，在此一并致谢。

作者简介

李兴秀，女，汉族，江西赣州人。

现就读于江西农业大学计算机与信息工程学院，研究方向为医学信号处理和模式识别，主要研究基于深度学习的心电信号心律失常分类工作。

攻读硕士学位期间获得成果

（一）参与的科研项目

- [1] 基于时空相关性的多通道心电信号量化压缩感知方法研究. 国家自然科学基金项目. 编号: 61861021.
- [2] 基于序列间深度学习的可穿戴设备心电信号分类研究. 江西省教育厅科学技术研究项目. 编号: GJJ200426.

（二）发表的学术论文

- [1] 唐建军,李兴秀,华晶,杨富豪.基于神经网络的心电图检测分类综述[J].计算机应用与软件,2021,38(05):1-9+41.
- [2] 李兴秀,唐建军,华晶.结合 CNN 与双向 LSTM 的心律失常分类[J].计算机科学与探索,2021,15(12):2353-2361.
- [3] Hua J, Li X, Liu J, et al. A novel arrhythmia classification of electrocardiogram signal based on modified HRNet and ECA[J]. Measurement Science and Technology. 2022, 33(6): 65701.