

齐鲁工业大学
硕士学位论文研究生论文文献综述

题目：基于二维化十二导联 ECG 信号分类
与冗余性研究

学 号10431200544

姓 名李家豪

导 师庞少鹏

学科专业电子信息

研究方向智能检测技术

2021 年 10 月 15 日

基于二维化十二导联 ECG 信号分类方法

与导联冗余性研究

摘要:

心电图 (ECG) 因其简单、无创性和可靠性而主要用于心律失常的临床诊断。过去基于机器学习算法实现心律失常的自动识别已经在单导联心电图展示了较好的结果。但主观的特征提取以及心拍标签标注给医生带来了巨大的工作量。随着多个十二导联数据库的开源以及深度学习技术的出现,近些年来,许多基于深度神经网络(DNN)的模型已应用于心律失常的自动分类,并取得了巨大成功。然而受数据的限制,多数的神经网络模型以单导联作为输入数据。现如今基于十二导联的心电图已经成为临床最基础的检查项目。基于十二导联的心律失常的智能检测算法也不断涌现,其中以基于机器学习进行特征提取和分类的方法和基于深度学习的端到端的学习为主要检测算法。基于机器学习学习的算法往往涉及复杂的带有主观性的特征工程,而基于 DNN 的大多算法将十二导联时序数据作为不同通道在训练阶段独立提取十二导联心电图中每个导联的内部特征,这使得无法捕捉导联间的特征。本课题提出使用二维化的十二导联心电数据作为 DNN 的输入,利用二维卷积的方式实现正常节律和多种心律失常节律的自动识别。在此基础上,进一步研究导联之间的相关关系,从而分析导联之间的相关关系对心律失常的自动识别是如何影响的,以及探究是否存在部分导联对学习过程是无影响或存在负面影响。经过研究可能得出有潜力的辅助模型帮助医生进行心律失常分析。

关键词: 十二导联; 心电图; 深度学习; 神经网络; 心律失常

ABSTRACT:

Electrocardiogram (ECG) is mainly used for clinical diagnosis of cardiac arrhythmias due to its simplicity, non-invasiveness and reliability. In recent years, many models based on Deep Neural Networks (DNN) have been applied to the automatic classification of arrhythmia and have achieved great success. However, due to the limitation of data, most neural network models use single lead as input data. Nowadays, the 12-lead electrocardiogram has become the most basic clinical examination item. Intelligent detection algorithms based on 12-lead cardiac arrhythmia are also emerging. Among them, the method of feature extraction and classification based on machine learning and the end-to-end learning based on deep

learning are the main detection algorithms. Algorithms based on machine learning often involve complex subjective feature engineering, while most algorithms based on DNN use 12-lead time series data to extract the internal features of the 12-lead, while ignoring the features between the leads during training phase. This topic proposes to use two-dimensional 12-lead ECG data as the input of DNN, and use two-dimensional convolution to realize automatic identification of normal rhythm and a variety of arrhythmia rhythms. On this basis, further study the correlation between the leads, so as to analyze how the correlation between the leads affect the automatic recognition of arrhythmia, and explore whether there are some leads that have no effect or exist on the learning process negative impact. After research, a potential auxiliary model may be obtained to help doctors analyze arrhythmia.

Keywords: 12-lead, ECG, deep learning, neural network, cardiac arrhythmias

一、课题背景及研究意义

心血管疾病是一种常见、多发和死亡率高的慢性病，具有病情隐蔽、危险性高和突发性强等特点。心律失常是心血管疾病中最常见和重要的一种疾病，容易引起多种并发症，对人类的健康造成了极大的威胁。在临床上，心律失常的诊断主要依赖医生对于心电图的观测，这无疑加重了医生的工作负担。心电图是临床医学日常实践中的基本工具，因其简单、无创、可靠等特点，多用于心律失常的临床诊断。全世界每年获得超过 3 亿次心电图^[1]，且逐年上升，专业医生增长的速率远不能匹配心电图的产出数量，导致对病症的诊断无法及时提供。自 50 多年前引入计算机辅助解释以来，计算机辅助解释在临床心电图工作流程中变得越来越重要，在许多临床设置中作为医生解释的重要辅助手段。然而，现有的商用 ECG 解释算法仍然显示出相当高的误诊率^[2]。ECG 数据的广泛数字化和算法范例的发展相结合，可从原始数据的大规模处理中获益，这为重新检查算法 ECG 分析的标准方法提供了机会，并可能为 ECG 自动解释提供实质性改进。由于心电图的复杂性，对心电图的精确分析存在很大难度。目前专业医生对心电图的分析依靠经验人工对心电图特征进行提取分析。为客观、准确、快速地心电图自动分析，需要借助人工智能和优化算法对心电图进行自动化分析，从而提升心电图分析的效率和准确率。

现如今国家大力推行人工智能和智慧医疗。“十四五规划”中提及，坚持基本医疗卫生事业公益属性，深化医药卫生体制改革，加快优质医疗资源扩容和区域均衡布局，加快建设分级诊疗体系，加强公立医院建设和管理考核，推进国家组织药品和耗材集中采购使用改革，发展高端医疗设备。支持社会办医，推广远程

医疗。“十四五”期间将实施公立医院高质量发展工程，推进“智慧医院”建设，通过信息化手段提升医疗服务的效率、质量与安全。《“健康山东 2030”规划纲要》提出提高数字医疗设备、物联网设备、智能健康产品、中医功能状态检测与养生保健仪器设备的生产制造水平,支持研发健康医疗相关的人工智能技术、生物三维(3D)打印技术、医用机器人、健康和康复辅助器械、可穿戴设备以及相关微型传感器件,促进健康医疗智能装备产业升级,提高具有自主知识产权的医学诊疗设备、医用材料国际竞争力。加快发展康复辅助器具产业,增强自主创新能力。实施品牌提升工程,健全质量标准体系,到 2030 年,药品、医疗器械质量标准全面和国际接轨。规划了人工智能在医疗影像辅助诊断系统中的应用研究。本研究课题是将人工智能应用于基于心电图的心血管疾病识别研究中,属于国家和山东省的重点发展领域。

近些年来,基于机器学习的许多算法被提出应用于心律失常的自动诊断。传统机器学习需要人工耗费大量的时间对心电图构建特征工程。而随着深度学习的出现,耗时建立特征工程的问题得到了解决。

在过去五年中,算法的重大进步主要是由一类称为深层神经网络(DNN)的特定模型推动的。DNN 是由多个处理层组成的计算模型,每一层都能够学习与执行特定任务相关的输入数据的越来越抽象、更高级的表示。它们极大地提高了语音识别、图像识别等任务以及医疗应用的技术水平。DNN 能够识别模式并从原始输入数据中学习有用的特征,而无需进行广泛的数据预处理、特征工程或手工规则,因此特别适合解释 ECG 数据。此外,由于 DNN 性能往往随着训练数据量的增加而增加,因此这种方法能够充分利用 ECG 数据的广泛数字化。以前将 DNN 用于 ECG 解释的大部分工作都集中在 ECG 处理通道的单个方面,如降噪或特征提取,或者接近有限的诊断任务,仅检测少数心跳类型(正常、心室或室上异位、融合等)或心律诊断(最常见的是房颤或室性心动过速)。缺乏适当的数据限制了这些应用之外的许多工作。

二、国内外研究现状

1、数据库现状

目前国际公认的权威心电数据库有:麻省理工的 MIT-BIH 数据库^[31],美国心脏学会的 AHA 数据库^[32]以及欧洲的 ST-T 心电数据库^[33],这三个数据库都只记录了两个导联的心电信息。其中 MIT-BIH 心律失常数据库记录了 48 位患者的心电图记录,标签按照心拍给出,是目前应用最广泛的心律失常数据库;AHA 数据库记录了 80 条心电图记录,主要用于评价室性心律不齐探测器的检测效果;ST-T 数据库主要用于评价 ST 段和 T 波检测算法性能。这些数据库存在记录导联

数量过少,患者样本个数稀少等问题,不具备代表整体人类群体心律失常的性质。

随着研究的深入,许多十二导联数据的心电数据库开源以供研究,包括 2018 年中国生理信号挑战赛的 CPSC 心律失常数据库^[34,35]、圣彼得堡 INCART 心律失常数据库^[36,37]、Physikalisch Technische Bundesanstalt (PTB)心律失常数据库^[38]、乔治亚州心律失常数据库。其中 CPSC 心律失常数据库由两组数据分别为 6877 (男性: 3699; 女性: 3178) 条和 3453 (男性: 1843; 女性: 1610) 条的 12 导联心电图记录组成,持续时间从 6 秒到 60 秒,采样率为 500Hz; 圣彼得堡 INCART12 导联心律失常数据库包含从 32 个 Holter 记录中提取的 74 条带注释的记录,每条记录长 30 分钟,采样率为 257Hz; Physikalisch Technische Bundesanstalt (PTB)心律失常数据库是一个大型公开可用的心电图数据集。第一个 PTB 数据库包含 516 条记录 (男性: 377, 女性: 139), 采样率为 1000Hz; 乔治亚州心律失常数据库代表了美国东南部的一个独特的人口统计数据,该数据集包含 10344 (男性: 5551, 女性: 4793) 条 12 导联心电图记录,每条记录长度为 10 秒,采样率为 500Hz。这四个数据库大约包含有 27 类心律失常的记录,且标签基于记录给出,即每条 12 导联心电图记录对应一种或者多种心律失常类型。

2、研究方法

过去十多年对于心律失常自动分类的研究中,基于机器学习的算法占据大多数,这类算法通常分为特征工程和分类算法两部分。具体来说,研究人员首先利用数学方法从原始心电数据中手动提取了大量具有医学意义的心电图特征,如小波特征^[3]、P-QRS-T 复合特征^[4,5]、心率变异性统计特征^[6], RR 间期相关统计特征^[7, 10]、高阶统计特征^[8]和形态学特征^[9,10]。主成分分析^[11,12]和独立成分分析^[13,14]等数学方法实现从高维空间向低维空间提取心电图特征。经过特征工程得到的特征可输入分类算法中进行分类,常见的分类算法有支持向量机^[15,16]、自组织映射^[17]、聚类^[18]等机器学习算法用于分析人工特征,并给出预测结果。

尽管机器学习在心律失常分类方面取得了不错的表现,但仍有一些问题需要解决。例如,基于主观因素的特征工程会导致剔除一些潜在的重要特征,这可能会影响最终的分类性能。

近年来,深度神经网络以其强大的特征提取能力,极大地提升了语音识别、图像分类、疾病诊断等任务的技术水平。与机器学习方法不同,深度神经网络可以从原始输入数据中自动识别模式并学习有用的特征,而无需依赖大量的手动规则和特征工程,这使得它们特别适合解释 ECG 数据。一些研究受到启发,将深度神经网络用于基于单导联或多导联心电图的心律失常自动分类。

3、国外研究现状

针对算法的不同可分为两类，一类以建立特征工程为基础的机器学习算法，另一类以自动提取特征的深度学习神经网络算法。针对导联的不同，分为基于单导联样本（每条记录有多个心拍，标签以心拍给出）的分类算法和基于多导联样本（每条记录给出一个或多个标签）的分类算法。

Ullah 等人^[19]提出了一种基于单导联的二维卷积神经网络(CNN)模型，利用短时傅立叶变换将一维心电时间序列信号转换为二维频谱图，每个频谱图对应一个心拍以及一个标签。将 ECG 信号分为八类即正常搏动、室性早搏、起搏搏动、右束支传导阻滞搏动、左束支传导阻滞搏动、心房早搏、心室扑动波搏动、心室逸搏搏动。得到的模型在 MIT-BIH 心律失常数据库进行评估并且取得 99.11% 的平均准确率。Jun 等人^[20]提出了一种使用二维深度卷积神经网络(CNN)的 ECG 心律失常分类方法，该方法将每个心跳间期转换成二维灰度波形图像作为 CNN 分类器的输入数据，并在 MIT-BIH 心律失常数据库进行测试得到了 99.05% 的平均准确度。Hannun 等人^[21]开发了一种深度神经网络模型，实现了单导联心电数据端到端的学习，并完成 12 个心律失常类别的分类。得到的 DNN 模型在专用数据集上的敏感性超过了心脏病专家分类的平均敏感性，并且证明了端到端的深度学习方法可以从单导联心电图分类出范围广泛的不同心律失常，其诊断性能与心脏病学家相似。与单导联相比，多导联心电图包含更多有价值的信息，更有利于心律失常的自动分类。Wang 等人^[22]提出了一种基于多尺度特征提取和 12 导联心电跨尺度信息互补的方法来捕捉心电信号中的异常状态，并在 CPSC 心律失常数据库中进行了测试，得到了 82.8% 的 F_1 分数。Chen 等人^[23]提出了一种结合了卷积神经网络(CNN)、循环神经网络和注意力机制的用于心律失常分类神经网络模型，应用于 CPSC 心律失常数据库并取得了排名第一的测试结果，同时基于单导联进行实验，发现使用单导联数据产生的性能仅比使用完整 12 导联数据稍差，其中 aVR 和 V1 导联最为突出。Zhang 等人^[24]训练了一个基于十二导联 ECG 的一维 DNN 模型，所提出的模型的平均得分 $F_1=0.813$ 。该模型显示出优于从提取的专家特征中学习的四种机器学习方法的性能。此外，在单导联 ECG 上训练的深度模型产生的性能低于同时使用所有 12 个导联。在 12 个导联中，表现最好的导联是 I、aVR 和 V5。Chiou 等人^[29]应用连续小波变换（CWT）将一维 ECG 信号转换为二维光谱，用于二维 CNN 分类，并评估单个 ECG 导联对收缩性心力衰竭（HF）分类结果的贡献，设计综合评分方法以改善结果。结果表明将 12 导联心电图信号中的 V5 导联和 V6 导联进行组合，可获得质量最高的结果。此外，zhao 等人^[25]的文章表明，添加性别和年龄等临床数据作为辅助特征可以提高分类性能。

4、国内研究现状

王英龙等人^[26]提出一种基于卷积神经网络和长短期记忆网络的心电图分类方法,通过多导联心电图数据和卷积神经网络和长短期记忆网络(CNN-LSTM)组合模型实现心律失常自动分类的方法。一方面多导联心电图较单导联心电图蕴含更多信息,另一方面 CNN-LSTM 组合模型结合 CNN 和 LSTM 的优点,在学习空间数据结构和时间序列结构方面有着独特优势,利用多导联心电图数据训练 CNN-LSTM 能够提高网络的学习效率和心电图识别的精度。李潇等人^[27]提出一种基于卷积神经网络的第一导联心电图心拍分类方法,利用一维卷积神经网络。褚菲等人^[28]提出一种基于 12 导联和卷积神经网络的心电数据分类方法,利用小波变换去噪算法原始信号进行降噪;分解 12 导联心电图的周期,提取每个周期的 P-QRS-T 特征段;选取出合适的心电信号并根据设定采样点对心电信号进行数据采样;构造一维卷积神经网络,并对一维卷积神经网络进行训练,搭建 12 导联心电图心律失常分类模型。Hong 等人^[30]提出了一种用于 ECG 分类的集成分类器,首先提取心电图的统计特征、信号处理特征和医学特征,然后构建 DNN 来自动提取深层特征,同时提出了一种新的算法来寻找中心波(一名患者心电图波形中最具代表性的波形)特征。最后将专家特征、深度特征和中心波特征结合起来,训练多个梯度决策树分类器,并将这些分类器集成在一起输出预测。

以上研究部分基于单导联 ECG 数据,且多数使用 MIT-BIH 心律失常数据库进行测试,这个数据库中记录了 48 名受试者的记录,每条记录按照心拍给出标签(48 条记录约合 10 万心拍),所以在切分样本后存在多个样本对应一位病人的情况,这可能导致心律失常分类的过拟合,使得得出的测试结果偏颇。基于十二导联作为数据源的研究,往往认定,例如深度神经网络模型使用一维卷积对各导联独立进行特征学习,再将不同导联得到的特征融合,这种模式虽然能够在训练初期提取各导联的内部特征,但是无法捕获导联之间的相关关系,从而割裂了十二导联数据之间的相关性。同时,这些模型对于部分心律失常类型识别的准确度仍然有进一步提高的可能性。

近些年的部分研究涉及到使用少数几个导联完成心律失常的自动识别,并进行了对比。例如 Chen 等人^[23]开发了一种 CNN 模型来识别心律失常。仿真结果表明,仅使用单导联心电图进行自动心律失常识别的性能低于使用完整的十二导联心电图。其中以导联 aVR 和 V1 最为突出。Chiou 等人^[29]通过使用连续小波变换将每个导联转换为二维频谱,并设计了一个二维 CNN 模型来识别心力衰竭。结果表明,导联 V6 在单导联模式下实现了最高的准确性、灵敏度、特异性和 F_1 分数,而导联 V5 和 V6 的组合在多导联模式下表现最佳。Cho 等人^[39]开发了一种变分自编码器,发现基于肢体六导联利用变分自编码器诊断心肌梗死是具备可行性的。Chen 等人^[40]提出了多分支卷积和残差网络来识别心律失常。通过比较

单导联和八导联融合的认可性能,他们发现八导联融合可以提高认可性能。此外,PhysioNet 还发起了一项名为“Will Two Do? Varying Dimensions in Electrocardiography: The PhysioNet/Computing in Cardiology Challenge 2021 (PCC2021)”的基于导联信号冗余探索的竞赛^[36,37],该竞赛要求参与者构建一种算法,该算法可以分别使用十二导联、肢体六导联(I、II、III、aVR、aV和aVF)、四导联(I、II、III和V2)、三导联(I、II和V2)和二导联(I和II)诊断心律失常。

本次竞赛的一些研究具有指导意义。Philip等人^[41]基于散射循环网络(Scattering-Recurrent Networks)利用组合导联实现心律失常识别。他们发现模型的性能随着导联数量的减少而略有下降,这表明导联之间存在很强的相关性。Matteo等人^[42]使用自动化机器学习(AutoML)来对不同导联组合的ECG信号进行分类,多个模型实例的累积结果表明使用肢体六导联时性能最佳。Niels等人^[43]使用卷积循环神经网络来识别不同导联组合的心电信息异常,发现使用二导联可以获得更好的分类性能。比赛结果表明,不同导联组合在隐藏测试集中的表现差异较大。

随着算力的提高,能够实现更深层次神经网络的学习。在一定范围内神经网络的深度越深,提取的特征越抽象,特征表达能力越强。在各种神经网络结构中,CNN由于其具有局部连接和权重共享的特性,可以有效地提取局部特征。RNN常用于处理一维序列数据^[44],其变体包括长短期记忆网络LSTM^[45]、双向长短期记忆网络BiLSTM^[46]等解决了RNN长期依赖的问题。此外,ResNet^[47-50]因为克服了深度学习过程中的梯度消失和爆炸问题而成为深度学习领域最常用的框架。

三、主要研究方向

针对现如今心律失常自动识别存在的问题,提出以下可能的研究方向:

1、针对一维卷积神经网络不能够学习到导联之间关系的问题,提出二维化十二导联心电数据。建立由十二导联组成的二维平面作为神经网络的输入,利用二维卷积神经网络同时学习导联内部和导联之间的特征,提升分类性能。

2、分析不同组别导联之间的相关关系,并得出不同组别的导联对不同心律失常类别识别的影响。十二导联由标准双极导联(I、II和III)和加压单极肢体导联(aVR、aVL和aVF)以及胸导联(V1、V2、V3、V4、V5和V6)三部分组成。这三部分对心律失常的识别分别具有什么影响。

3、探究是否存在冗余导联。标准十二导联中导联II、导联aVR、导联aVL和导联aVF是由导联I和导联III的电压值计算得来。这些导联是否属于冗余数据仍有待被分析与研究。

四、预期成效及社会效益

心电图是临床最常用的检查方法之一，主要依靠心电图医师对心电波形和节律等进行分析，分析结果易受医师的主观因素影响。另一方面，各类医疗和体检等机构每天均产生大量心电图数据，但有经验的心电图医师资源却严重不足，制约了心电图的临床辅助诊断效果。同时心律失常的类型比较多，波形结构在某些心律失常类型上表现相似，因此对这些类型的心律失常的判断专业医生存在一定的误诊率。

近年来，计算机技术在人工智能领域得到了大力的发展，各种智能算法在各个领域中得到了广泛应用。将人工智能应用于心电图的信号处理、特征识别和智能诊断中是当前的大趋势。本课题旨在构建心电图多导联时序数据的二维化模型，并基于深度神经网络实现端到端的心电图心律失常的识别工作。研究成果可以提高心电图的识别准确度，提供分类决策建议，提升专业医生工作效率，推进人工智能在医疗领域中的应用，促进智能医疗技术的发展。

参考文献

- [1] Holst H, Ohlsson M, Peterson C, et al. A confident decision support system for interpreting electrocardiograms[J]. *Clinical Physiology*, 1999, 19(5): 410-418.
- [2] Shah A P, Rubin S A. Errors in the computerized electrocardiogram interpretation of cardiac rhythm[J]. *Journal of electrocardiology*, 2007, 40(5): 385-390.
- [3] Wang, J., Wang, P. and Wang, S., 2020. Automated detection of atrial fibrillation in ECG signals based on wavelet packet transform and correlation function of random process. *Biomedical Signal Processing and Control*, 55, p.101662.
- [4] Tsipouras, M.G., Fotiadis, D.I. and Sideris, D., 2005. An arrhythmia classification system based on the RR-interval signal. *Artificial intelligence in medicine*, 33(3), pp.237-250.
- [5] Haseena H H, Mathew A T, Paul J K. Fuzzy clustered probabilistic and multi layered feed forward neural networks for electrocardiogram arrhythmia classification[J]. *Journal of Medical Systems*, 2011, 35: 179-188.
- [6] Mondéjar-Guerra V, Novo J, Rouco J, et al. Heartbeat classification fusing temporal and morphological information of ECGs via ensemble of classifiers[J]. *Biomedical Signal Processing and Control*, 2019, 47: 41-48.
- [7] Afkhami R G, Azarnia G, Tinati M A. Cardiac arrhythmia classification using statistical and mixture modeling features of ECG signals[J]. *Pattern Recognition Letters*, 2016, 70: 45-51.
- [8] Martis R J, Acharya U R, Prasad H, et al. Application of higher order statistics for atrial arrhythmia classification[J]. *Biomedical signal processing and control*, 2013, 8(6): 888-900.
- [9] de Oliveira L S C, Andreão R V, Sarcinelli-Filho M. Premature ventricular beat classification using a dynamic Bayesian network[C]//2011 annual international conference of the IEEE engineering in medicine and biology society. IEEE, 2011: 4984-4987.
- [10] De Chazal P, O'Dwyer M, Reilly R B. Automatic classification of heartbeats using ECG morphology and heartbeat interval features[J]. *IEEE transactions on biomedical engineering*, 2004, 51(7): 1196-1206.
- [11] Ince T, Kiranyaz S, Gabbouj M. A generic and robust system for automated patient-specific classification of ECG signals[J]. *IEEE Transactions on Biomedical Engineering*, 2009, 56(5): 1415-1426.

- [12] Wang J S, Chiang W C, Hsu Y L, et al. ECG arrhythmia classification using a probabilistic neural network with a feature reduction method[J]. *Neurocomputing*, 2013, 116: 38-45.
- [13] Martis R J, Acharya U R, Min L C. ECG beat classification using PCA, LDA, ICA and discrete wavelet transform[J]. *Biomedical Signal Processing and Control*, 2013, 8(5): 437-448.
- [14] Martis R J, Acharya U R, Prasad H, et al. Automated detection of atrial fibrillation using Bayesian paradigm[J]. *Knowledge-Based Systems*, 2013, 54: 269-275.
- [15] Ye C, Kumar B V K V, Coimbra M T. Heartbeat classification using morphological and dynamic features of ECG signals[J]. *IEEE Transactions on Biomedical Engineering*, 2012, 59(10): 2930-2941.
- [16] Osowski S, Hoai L T, Markiewicz T. Support vector machine-based expert system for reliable heartbeat recognition[J]. *IEEE transactions on biomedical engineering*, 2004, 51(4): 582-589.
- [17] Lagerholm M, Peterson C, Braccini G, et al. Clustering ECG complexes using Hermite functions and self-organizing maps[J]. *IEEE Transactions on Biomedical Engineering*, 2000, 47(7): 838-848.
- [18] Guo G, Wang H, Bell D, et al. KNN model-based approach in classification[C]//On The Move to Meaningful Internet Systems 2003: CoopIS, DOA, and ODBASE: OTM Confederated International Conferences, CoopIS, DOA, and ODBASE 2003, Catania, Sicily, Italy, November 3-7, 2003. *Proceedings. Springer Berlin Heidelberg*, 2003: 986-996.
- [19] Ullah A, Anwar S M, Bilal M, et al. Classification of arrhythmia by using deep learning with 2-D ECG spectral image representation[J]. *Remote Sensing*, 2020, 12(10): 1685.
- [20] Jun T J, Nguyen H M, Kang D, et al. ECG arrhythmia classification using a 2-D convolutional neural network[J]. *arXiv preprint arXiv:1804.06812*, 2018.
- [21] Hannun A Y, Rajpurkar P, Haghpanahi M, et al. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network[J]. *Nature medicine*, 2019, 25(1): 65-69.
- [22] Wang R, Fan J, Li Y. Deep multi-scale fusion neural network for multi-class arrhythmia detection[J]. *IEEE journal of biomedical and health informatics*, 2020, 24(9): 2461-2472.

- [23] Chen T M, Huang C H, Shih E S C, et al. Detection and classification of cardiac arrhythmias by a challenge-best deep learning neural network model[J]. Iscience, 2020, 23(3): 100886.
- [24] Zhang D, Yang S, Yuan X, et al. Interpretable deep learning for automatic diagnosis of 12-lead electrocardiogram[J]. Iscience, 2021, 24(4): 102373.
- [25] Zhao, Z., Fang, H., Relton, S.D., Yan, R., Liu, Y., Li, Z., Qin, J. and Wong, D.C., 2020, September. Adaptive lead weighted ResNet trained with different duration signals for classifying 12-lead ECGs. In 2020 Computing in Cardiology (pp. 1-4). IEEE.
- [26] 王英龙,成曦,舒明雷,朱清,周书旺. 基于卷积神经网络和长短期记忆网络的心电图分类方法[P]. 山东省: CN110179453A,2019-08-30.
- [27] 李潇,何宇清. 一种基于卷积神经网络的第一导联心电图心拍分类方法[P]. 天津: CN107944493A,2018-04-20.
- [28] 褚菲,李佳,魏宇伦,韦昊然,杨思怡,李明. 一种基于 12 导联和卷积神经网络的心电数据分类方法[P]. 江苏省: CN111568410A,2020-08-25.
- [29] Chiou, Y.A., Syu, J.Y., Wu, S.Y., Lin, L.Y., Yi, L.T., Lin, T.T. and Lin, S.F., 2021. Electrocardiogram lead selection for intelligent screening of patients with systolic heart failure. Scientific reports, 11(1), pp.1-12.
- [30] Hong, S., Wu, M., Zhou, Y., Wang, Q., Shang, J., Li, H. and Xie, J., 2017, September. ENCASE: An ENsemble CLASsifiEr for ECG classification using expert features and deep neural networks. In 2017 Computing in cardiology (CinC) (pp. 1-4). IEEE.
- [31] Moody G B, Mark R G. The impact of the MIT-BIH arrhythmia database[J]. IEEE engineering in medicine and biology magazine, 2001, 20(3): 45-50.
- [32] Surawicz, Borys, et al. "AHA/ACCF/HRS recommendations for the standardization and interpretation of the electrocardiogram: part III: intraventricular conduction disturbances: a scientific statement from the American Heart Association Electrocardiography and Arrhythmias Committee, Council on Clinical Cardiology; the American College of Cardiology Foundation; and the Heart Rhythm Society: endorsed by the International Society for Computerized Electrocardiology." Circulation 119.10 (2009): e235-e240.
- [33] Taddei A, Distant G, Emdin M, et al. The European ST-T database: standard for evaluating systems for the analysis of ST-T changes in ambulatory electrocardiography[J]. European heart journal, 1992, 13(9): 1164-1172. Taddei

- A, Distant G, Emdin M, et al. The European ST-T database: standard for evaluating systems for the analysis of ST-T changes in ambulatory electrocardiography[J]. *European heart journal*, 1992, 13(9): 1164-1172.
- [34] Liu F, Liu C, Zhao L, et al. An open access database for evaluating the algorithms of electrocardiogram rhythm and morphology abnormality detection[J]. *Journal of Medical Imaging and Health Informatics*, 2018, 8(7): 1368-1373.
- [35] CPSC2018[EB/OL]. <http://2018.icbeb.org/Challenge.html>.
- [36] Reyna MA, Sadr N, Perez Alday EA, et al. Will Two Do? Varying Dimensions in Electrocardiography: The PhysioNet/Computing in Cardiology Challenge 2021. *Computing in Cardiology 2021*, 48: 1-4,
- [37] Reyna MA, Sadr N, Perez Alday EA, et al. Issues in the automated classification of multilead ECGs using heterogeneous labels and populations. *Physiol. Meas*, 2022.
- [38] Wagner P, Strodthoff N, Bousseljot R D, et al. PTB-XL, a large publicly available electrocardiography dataset[J]. *Scientific data*, 2020, 7(1): 154.
- [39] Cho Y, Kwon J, Kim K H, et al. Artificial intelligence algorithm for detecting myocardial infarction using six-lead electrocardiography[J]. *Scientific reports*, 2020, 10(1): 20495.
- [40] Chen B, Guo W, Li B, et al. A study of deep feature fusion based methods for classifying multi-lead ECG[J]. *arXiv preprint arXiv:1808.01721*, 2018.
- [41] Warrick P A, Lostanlen V, Eickenberg M, et al. Arrhythmia classification of reduced-lead electrocardiograms by scattering-recurrent networks[C]//2021 Computing in Cardiology (CinC). IEEE, 2021, 48: 1-4.
- [42] Bodini M, Rivolta M W, Sassi R. Classification of ECG signals with different lead systems using AutoML[C]//2021 Computing in Cardiology (CinC). IEEE, 2021, 48: 1-4.
- [43] Osnabrugge N, Rustemeyer F, Kaparakis C, et al. Multi-label classification on 12, 6, 4, 3 and 2 lead electrocardiography signals using convolutional recurrent neural networks[C]//2021 Computing in Cardiology (CinC). IEEE, 2021, 48: 1-4.
- [44] Medsker L R, Jain L C. Recurrent neural networks[J]. *Design and Applications*, 2001, 5: 64-67.

- [45] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [46] Zhou P, Shi W, Tian J, et al. Attention-based bidirectional long short-term memory networks for relation classification[C]//Proceedings of the 54th annual meeting of the association for computational linguistics (volume 2: Short papers). 2016: 207-212.
- [47] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [48] Targ S, Almeida D, Lyman K. Resnet in resnet: Generalizing residual architectures[J]. arXiv preprint arXiv:1603.08029, 2016.
- [49] Allen-Zhu Z, Li Y. What can resnet learn efficiently, going beyond kernels?[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [50] Koonce B, Koonce B. ResNet 50[J]. Convolutional Neural Networks with Swift for Tensorflow: Image Recognition and Dataset Categorization, 2021: 63-72.